

Viés Geográfico e Linguístico em LLMs para Política de Poluição do Ar: Um Benchmark de 25 Países, 14 Modelos, 4 Idiomas e 5 Tarefas

Lucas Rover^{1,*}
Eduardo Tadeu Bacalhau²
Yara de Souza Tadano¹

¹ Universidade Tecnológica Federal do Paraná (UTFPR), Brasil

² Universidade Federal do Paraná (UFPR), Brasil

* Autor correspondente: lucasrover@alunos.utfpr.edu.br

24 de junho de 2026

Resumo

Gestores ambientais públicos no Sul Global cada vez mais consultam grandes modelos de linguagem (LLMs) sobre padrões vinculantes de qualidade do ar, concentrações medidas e evidência em saúde — um domínio em que uma resposta errada pode moldar um parecer regulatório ou uma resposta de emergência. O $PM_{2.5}$ é o principal fator de risco ambiental para mortalidade prematura, e seu ônus recai desproporcionalmente sobre o Sul Global [1–4]. Se esses sistemas atendem o Sul Global de modo tão confiável quanto o Norte Global, e se o enquadramento do prompt altera a resposta, ainda não havia sido medido para um domínio de política aplicada com gabarito verificável.

Avaliamos, em benchmark, **25 países, 14 LLMs, quatro idiomas e cinco tipos de tarefa** (recuperação normativa, dado local medido, síntese de evidência em saúde, instrumentos de política e recomendação aplicada) contra gabarito oficial. Avaliamos cada modelo *tal como servido* por meio de uma stack de acesso fixa (API do fornecedor ou endpoint de inferência fixado), com um fator de persona intra-sujeito (neutro versus gestor ambiental público) e um contraste inglês/idioma-nativo intra-país. O desenho foi pré-registrado para 15 países e depois estendido post hoc para 25 (sete a mais do Norte Global, três a mais do Sul Global) para ganhar poder; todo efeito é reportado ao lado de seu valor pré-registrado de 15 países.

Três danos são robustos. Uma **diferença de camada** Norte/Sul de +6.2 pp (IC bootstrap de 95% [+3.7, +8.6], exclui zero) resolve-se, a $n = 25$, em um **gradiente de desenvolvimento** (Spearman $\rho = 0.51$ com o IDH, $p = 0.004$; Mann-Kendall $p = 0.018$; robusto a leave-one-out) que era indetectável no $n = 15$ pré-registrado ($\rho = 0.14$), fica logo abaixo do nosso limiar de tamanho de efeito pré-registrado de 0.55 e acompanha o desenvolvimento, *não* a classe de recurso linguístico (Joshi nulo). O **prompt em idioma nativo reduz a acurácia** (−2.1 pp no geral, $p = 2 \times 10^{-3}$; −7.8 pp para o hindi), de modo que o idioma local não ajuda e pode prejudicar. A **acurácia colapsa na recuperação de padrão técnico e de dado local** (T1, T2 ≈ 0.37 vs 0.64 nas demais; δ de Cliff = −0.64), um piso de limiar

regulatório; e o **modelo regional** brasileiro-português **é o pior de todos** ($\delta = -0.51$). Três correções intuitivas, portanto, falham juntas: nem uma persona de gestor local (permutação $p = 0.26$), nem o idioma local, nem um modelo regional fecham a lacuna.

Quanto ao mecanismo, o proxy de corpus pré-registrado (tamanho da Wikipédia) é nulo; um proxy de cobertura de país (sitelinks do Wikidata) correlaciona-se com a acurácia ($\rho = 0.54$, $p = 0.005$, sobrevivendo à correção de multiplicidade), mas atenua-se até a não-significância após ajuste para desenvolvimento ($p = 0.13$). Reportamos, assim, a cobertura de país como um canal *sugestivo e exploratório* — melhor que o tamanho do corpus do idioma, como esperado para uma lacuna medida em inglês — não como mecanismo estabelecido. A confiabilidade entre um painel de juízes de quatro fornecedores é forte ($\text{ICC}(2, 4) = 0.89$ da média do painel), e o gabarito está ancorado em fontes oficiais primárias para todos os 25 países; o estudo usa um juiz primário validado por painel e uma auditoria documental do gabarito, sem uma camada de padrão-ouro humano. Protocolo, prompts e código de análise serão liberados na publicação.

Palavras-chave: grandes modelos de linguagem; viés geográfico; Sul Global; justiça epistêmica; pesquisa em políticas; benchmark; PLN multilíngue

1 Introdução

Grandes modelos de linguagem (LLMs) passaram de curiosidade de pesquisa a infraestrutura operacional da administração pública em menos de cinco anos: um levantamento da OCDE sobre funções centrais de governo documenta a adoção de IA generativa ao longo da formulação de políticas e da prestação de serviços públicos, incluindo implantações que ajudam o corpo técnico da administração pública a pesquisar regulações e redigir sínteses técnicas [5]. Agências ambientais, secretarias municipais e analistas de políticas aplicadas cada vez mais redigem sínteses técnicas, traduzem normas regulatórias, localizam dados oficiais de monitoramento e caracterizam arcabouços institucionais com tal assistência. A política de poluição do ar é um domínio em que essa adoção carrega riscos diretos para a saúde pública. O material particulado fino ($\text{PM}_{2.5}$) é o principal fator de risco ambiental para mortalidade prematura no mundo [1, 2], e o ônus recai desproporcionalmente sobre o Sul Global [1]. Quando um gestor ambiental público em São Paulo, Lagos ou Jacarta consulta um LLM sobre um padrão de qualidade do ar, um prazo de atendimento ou a evidência epidemiológica por trás de uma intervenção, uma resposta imprecisa não é um erro benigno. Ela pode se propagar para um parecer regulatório, uma decisão de compra ou uma resposta de emergência durante um episódio de poluição.

A questão que este artigo aborda é se os LLMs atendem a política de poluição do ar do Sul Global de modo tão confiável quanto atendem o Norte Global, e se a forma como uma consulta é enquadrada altera a resposta. Duas vertentes recentes de evidência tornam essa questão urgente, e não hipotética.

O viés factual geográfico é real e mensurável. Moayeri et al. [6] documentou taxas de erro factual $1.5\times$ maiores para países da África Subsaariana versus países da América do Norte, em 20 modelos e 11 indicadores do Banco Mundial. Manvi et al. [7] mostrou que avaliações zero-shot de LLMs sobre temas subjetivos correlacionam-se fortemente com o nível de renda

(ρ de até 0.70 contra condições socioeconômicas). Mirza et al. [8] constatou que o GPT-4 privilegia sistematicamente afirmações sobre o Norte Global em relação ao Sul Global em tarefas de verificação factual. Esses resultados estabelecem o fenômeno, mas nenhum deles tem como alvo um único domínio aplicado de alto risco com gabarito oficial verificável, e nenhum pergunta se o viés pode ser modulado pelo enquadramento do prompt.

A assimetria linguística e de corpus é estrutural. Joshi et al. [3] mapeou uma hierarquia de seis classes de disponibilidade de recurso linguístico em PLN, mostrando que os idiomas da maioria dos países do Sul Global ocupam as classes inferiores sub-atendidas. A sub-representação no corpus de treinamento é a explicação dominante para o viés geográfico a jusante [9]. Essa assimetria não é incidental; ela reproduz padrões de longa data de infraestrutura digital e epistêmica desigual que a literatura decolonial analisou para sistemas de IA [4].

Identificamos três lacunas que o trabalho atual deixa em aberto para um domínio como a política de poluição do ar.

Lacuna 1: nenhum benchmark tem como alvo a política de poluição do ar com gabarito oficial. As avaliações existentes usam recuperação numérica do Banco Mundial (World-Bench), avaliações subjetivas (Manvi et al.), checagem factual jornalística (Global-Liar) ou conhecimento cultural cotidiano (BLEnD [10]). Nenhuma mede as tarefas de recuperação e síntese que um gestor ambiental público de fato delega a um LLM: enunciar um padrão ambiental vinculante, recuperar uma concentração oficialmente medida, resumir a evidência de carga de doença, identificar os instrumentos legais e os órgãos executores, ou recomendar uma resposta operacional. Essas tarefas ancoram-se em fontes autoritativas (conselhos ambientais nacionais, agências estaduais de monitoramento, a Organização Mundial da Saúde, as estimativas do Global Burden of Disease), o que torna a acurácia verificável de um modo que benchmarks de trivia não são.

Lacuna 2: o enquadramento por persona é inexplorado como alavanca experimental. Profissionais rotineiramente prefixam consultas com um papel (“Como secretário municipal de meio ambiente, ...”), e o condicionamento por persona ou papel é um padrão de prompt documentado em fluxos de prompting em produção [11]. Se adotar a persona de um gestor ambiental público *reduz* a lacuna de acurácia do Sul Global (ao orientar o modelo para respostas relevantes à política e conformes à regulação) ou a *amplifica* (ao convidar à fabricação confiante de especificidades regulatórias que o modelo nunca aprendeu) não foi testado em um desenho pré-especificado. Tratamos a persona como um fator experimental intra-sujeito, em vez de um confundidor não controlado.

Lacuna 3: o mecanismo de representação de corpus é asserido, não testado para este domínio. A ligação entre representação de corpus e acurácia é assumida, mas raramente medida contra confundidores e raramente separada em seus dois canais. Distinguimos o tamanho do *corpus do idioma* (quanto texto existe no idioma de um país: volume de tokens mC4 [12], tamanho do OSCAR [13], classe Joshi) da abrangência de *cobertura de país* (quão amplamente o corpus é *sobre* um país: cobertura na Wikipédia e no Wikidata), e testamos qual prediz a

acurácia em política de poluição do ar após ajuste para o Índice de Desenvolvimento Humano — uma distinção que importa porque a lacuna geográfica é medida em inglês.

Contribuições deste trabalho

Apresentamos um benchmark desenhado para essas lacunas, com hipóteses, amostragem e plano de análise pré-especificados antes da coleta de dados [14], executado em 15 países e depois estendido para 25. Ao longo do trabalho, nossa unidade de análise é o modelo *tal como servido* — uma stack de pesos do modelo, fornecedor e infraestrutura de serving alcançada por uma API ou endpoint de inferência fixados — em vez de um conjunto idealizado de pesos, porque um gestor público interage com a stack servida e qualquer lacuna medida é uma propriedade dessa stack (Seção 3). Nossas contribuições são:

1. Uma suíte de tarefas de política de poluição do ar com gabarito verificável.

Construímos cinco tipos de tarefa mapeados a atividades reais de decisão de um gestor ambiental público: recuperação de padrões ambientais vinculantes e limites de emissão (T1), recuperação de concentrações locais oficialmente medidas (T2), síntese de evidência epidemiológica de carga em saúde (T3), identificação de instrumentos de política e órgãos executores (T4) e recomendação aplicada avaliada por rubrica para um cenário operacional (T5). Cada tarefa ancora-se em fontes oficiais nacionais ou internacionais, e toda referência no gabarito é verificada contra um DOI ou URL resolvível antes de entrar no conjunto de dados.

2. Prompting por persona como fator experimental pré-especificado.

Manipulamos a persona intra-sujeito (consulta neutra vs. gestor ambiental público) e testamos, como hipótese confirmatória co-primária (H6), se a condição de persona reduz a lacuna de acurácia do Sul Global. Pré-especificamos tanto a direção de redução (hipótese de Conformidade à Norma) quanto a direção de amplificação (hipótese de Vácuo de Persona), reportando aquela que os dados sustentarem.

3. Amostragem de países triangulada teoricamente.

Selecionamos 15 países estratificados ao longo de eixos independentes: a classificação Norte/Sul da UNCTAD (operacionalizando a colonialidade [4]), a taxonomia de seis classes de recurso linguístico de Joshi et al. [3] e indicadores de desenvolvimento humano e renda, depois estendidos para 25 a fim de ganhar poder para os testes de gradiente e de mecanismo. Isso separa as contribuições geográfica, linguística e econômica do viés e mostra — como subproduto metodológico — que o gradiente de desenvolvimento é subpotente a $n = 15$, mas significativo a $n = 25$.

4. Teste mecanístico separando os dois canais de corpus.

Testamos a hipótese de representação de corpus (H4) usando proxies tanto de corpus do idioma quanto de cobertura de país, com controles de correlação parcial para o IDH. O proxy de tamanho de idioma pré-registrado é nulo; um proxy de cobertura de país é uma pista promissora, porém entrelaçada com o desenvolvimento, que reportamos como exploratória, e não como mecanismo estabelecido.

5. Sonda de modelo regional.

Incluímos um modelo aberto brasileiro-português ajustado

por instrução (Cabra-Mistral 7B v3) para testar, como hipótese confirmatória secundária (H3), se o ajuste regional estreita a lacuna do português para o Brasil em tarefas de política de poluição do ar.

6. Recursos abertos. O protocolo completo, os prompts (após validação), os documentos-fonte do gabarito, o código de análise e as figuras serão liberados na publicação sob as licenças CC-BY-4.0 e MIT.

Enquadramento teórico

Interpretamos nossos achados dentro do arcabouço da *colonialidade do saber* [4, 15] e de suas articulações de dados e infraestrutura [16, 17]. LLMs são sínteses estatísticas comprimidas de corpora produzidos sob condições de infraestrutura digital desigual e acesso desigual à publicação. Os idiomas e regiões que Joshi et al. situam nas classes sub-atendidas são justamente aqueles em que a poluição do ar mata mais pessoas [1, 3]. Quando um gestor ambiental do Sul Global consulta um modelo treinado em grande parte sobre texto do Norte Global para governar um problema local de qualidade do ar, a decisão resultante corre o risco de herdar as assimetrias do corpus. Isso posiciona nosso trabalho empírico como um teste de um elo em um ciclo de reprodução teorizado (assimetria do corpus de treinamento → assimetria de conhecimento do LLM → assimetria de decisão de política), e a manipulação de persona como um teste de se o enquadramento do prompt pode interromper esse elo.

O artigo segue assim. A Seção 2 posiciona nosso trabalho em relação à literatura. A Seção 3 apresenta o desenho pré-especificado. A Seção 4 reporta os achados empíricos. A Seção 5 os interpreta por lentes estatística e crítica e considera implicações práticas para a governança da poluição do ar. A Seção 6 encerra.

2 Trabalhos Relacionados

Organizamos o trabalho prévio em quatro vertentes: a descoberta e mensuração do viés factual geográfico, extensões multilíngues e culturais, tentativas de alinhamento e mitigação, e o uso de LLMs em contextos de decisão de política e saúde. Para cada uma, indicamos como o foco em política de poluição do ar e a manipulação de persona do presente estudo estendem a vertente.

2.1 Viés factual geográfico

Manvi et al. [7] estabeleceu que LLMs de fronteira carregam vieses sistemáticos contra regiões de condições socioeconômicas mais baixas, com correlações de Spearman de até 0.70 entre avaliações geradas pelo modelo (de atratividade, moralidade e inteligência) e a renda per capita. O espaço de desfecho (avaliações subjetivas) deixa em aberto se o mesmo viés aparece na recuperação objetiva de fatos regulatórios e epidemiológicos, que é o que a política de poluição do ar exige.

Moayeri et al. [6] introduziu o WorldBench, quantificando a recuperação factual contra indicadores do Banco Mundial em 20 LLMs e 11 indicadores e documentando erro relativo absoluto $1.5\times$ maior para a África Subsaariana versus a América do Norte. O WorldBench também foi pioneiro na detecção automática de alucinação de citação, em que modelos citam o Banco Mundial enquanto produzem estatísticas falsas. O desenho é limitado pelo espaço de indicadores

macroeconômicos; um gestor ambiental faz perguntas mais estreitas e específicas a fontes (um padrão ambiental nacional, um prazo de fase de atendimento, uma concentração medida por cidade-ano) cujo gabarito reside em conselhos ambientais e agências de monitoramento, e não em um único banco de dados agregado.

Mirza et al. [8] (Global-Liar) estendeu a questão à estabilidade temporal, mostrando que versões mais novas do GPT-4 não melhoram monotonicamente e que o privilégio de afirmações do Norte Global persiste entre versões. Sua contribuição é temporal e intra-modelo, em vez de inter-modelo, inter-idioma ou específica de domínio.

Esses estudos estabelecem que o fenômeno existe e é mensurável. Nenhum isola um único domínio aplicado com gabarito oficial verificável, e nenhum trata o enquadramento do prompt como fator manipulável.

2.2 Extensões multilíngues e culturais

Myung et al. [10] (BLEnD) introduziu pares de pergunta-resposta cobrindo 16 países e 13 idiomas em conhecimento cultural cotidiano. O achado de que LLMs têm desempenho melhor nos idiomas nativos de culturas de alto recurso, mas pior nos de baixo recurso, motiva nossa hipótese exploratória de idioma (H2) e conecta diretamente à hierarquia de recurso de Joshi et al. [3]. Ainda assim, o BLEnD mede acurácia de conhecimento cultural, não a acurácia de recuperação regulatória e de política de saúde, e sua seleção de países não é estratificada teoricamente.

Benchmarks regionais proliferaram: BRoverbs [18] para provérbios brasileiros, TiEBe [19] para eventos históricos regionais, e ALBA [20] e AMALIA [21] para português europeu. Eles documentam falhas concretas em tarefas culturalmente ancoradas, mas não abordam o uso em política aplicada, e cada um limita-se a um ou dois idiomas. O trabalho sobre construção de corpus em português [22] resalta como snapshots do Common Crawl sub-representam o conteúdo lusófono, a assimetria de corpus que nossa H4 testa.

2.3 Alinhamento e mitigação

Opuszek and Böhm [23] investigou se modelos de raciocínio reduzem o viés geográfico, constatando que o raciocínio ajuda em agregado, mas não elimina disparidades regionais. Kerche et al. [24] propôs uma tipologia baseada em lugar dos vieses de LLMs, situando o viés geográfico em um panorama sociotécnico mais amplo. Essas contribuições são conceituais e agregadas; acrescentamos um teste empírico pré-especificado e específico de domínio e introduzimos a persona como alavanca candidata de mitigação, em vez de uma propriedade fixa do modelo.

2.4 LLMs em contextos de decisão de política e saúde

Uma literatura paralela examina o uso de LLMs em cenários específicos de política. He et al. [25] avaliou recomendações de política de LLMs para a questão de pessoas em situação de rua em quatro cidades (incluindo Barcelona, Joanesburgo e South Bend), constatando uma “rigidez cega ao contexto” em que os modelos aplicam heurísticas internas estáveis mal calibradas às realidades locais e alinham-se mais de perto a especialistas do Norte Global. Seu resultado mostra que o viés importa para a política em um único domínio e um único tipo de tarefa (recomendação).

Generalizamos para um domínio regulatório e de saúde com cinco tipos de tarefa abrangendo recuperação, síntese e recomendação, e acrescentamos a manipulação de persona ausente em seu desenho.

Em saúde especificamente, Kozlakidis et al. [26] argumentam que as alucinações de LLMs carregam risco agudo em ambientes regulatórios com capacidade técnica limitada, observando que a incompatibilidade de idioma e cultura entre modelos treinados globalmente e a prática local aumenta o erro. A política de poluição do ar situa-se na interseção desse risco com a carga de mortalidade documentada pelas estimativas do Global Burden of Disease [1], o que faz da recuperação acurada de padrões e evidência em saúde uma preocupação de saúde pública, e não uma abstração de benchmark.

2.5 Persona e condicionamento por papel

O condicionamento por papel ou persona é um padrão de prompt documentado em prompting em produção [11], e um corpo crescente de trabalho relata que atribuir um papel de especialista pode deslocar as saídas do modelo em qualquer direção, dependendo da tarefa e do domínio. A evidência sistemática é desanimadora: em quatro famílias de LLMs e 2,410 perguntas factuais, adicionar personas de especialista aos prompts de sistema não melhorou a acurácia em relação a um controle sem persona, e em 162 papéis *reduziu* ligeiramente a acurácia em média [27]; uma replicação independente também constata que personas de especialista não melhoram a acurácia factual [28]. Se o condicionamento por persona ajuda ou prejudica a confiabilidade factual em domínios de alto risco e intensivos em conhecimento é, portanto, indefinido e, até onde sabemos, não testado para equidade geográfica. Tratamos, assim, a persona como fator experimental pré-especificado e testamos tanto a hipótese de Conformidade à Norma (a persona reduz a lacuna) quanto a hipótese de Vácuo de Persona (a persona a amplifica).

2.6 Posicionamento do presente trabalho

Nosso desenho difere do trabalho prévio em quatro maneiras concretas: (i) um único domínio aplicado de alto risco (política de poluição do ar) com gabarito oficial verificável, em vez de trivía numérica ou conhecimento cultural; (ii) a persona como fator experimental intra-sujeito pré-especificado, em vez de uma escolha de enquadramento não controlada; (iii) amostragem de países guiada por teoria em eixos independentes (colonialidade UNCTAD, recurso linguístico Joshi, desenvolvimento), em vez de conveniência regional; e (iv) um teste explícito do mecanismo de representação de corpus com análise de sensibilidade. Nenhum estudo prévio combina um domínio regulado de saúde pública, uma manipulação de persona e um teste de mecanismo pré-especificado.

3 Métodos

3.1 Desenho da pesquisa

Especificamos um experimento de benchmark pré-especificado, fatorial e multipaís para quantificar o viés geográfico e modulado por persona em 14 grandes modelos de linguagem em tarefas de

política de poluição do ar relevantes para a gestão ambiental pública. O desenho pré-registrado cruza 15 países (estratificados ao longo de três eixos teoricamente fundamentados), 14 LLMs abrangendo cinco camadas de acesso, um domínio guiado por teoria (política de poluição do ar), 5 tipos de tarefa e 2 condições de persona (neutra versus gestor ambiental público), com 2 replicações estocásticas por célula prompt-modelo-persona; uma extensão pós-registro (Seção 3.3) amplia a amostra para 25 países. O conjunto de estímulos cruza as cinco tarefas e as duas personas de cada país em inglês, além de uma renderização em idioma nativo intra-país para os nove países com idioma nativo-alvo, pontuado no composto $[0, 1]$. O protocolo do estudo fixa, antes da coleta de dados, as hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão e as correções de comparações múltiplas. Uma coleta restrita ao Brasil executada sob um desenho anterior de três domínios é reclassificada como piloto estendido e reportada separadamente; ela informou a calibração de prompts, mas não contribui com observações confirmatórias.

3.2 Seleção de países

Os países foram selecionados por amostragem teórica [29] triangulada em três classificações independentes. Primeiro, a **classificação Norte/Sul Global da UNCTAD** [30] operacionaliza o arcabouço da colonialidade do saber que motiva este estudo [4]. Segundo, a **taxonomia de seis classes de Joshi et al. (2020)** de representação de recurso linguístico em corpora de PLN forneceu uma dimensão de estratificação ortogonal [3]. Terceiro, os **grupos de renda do Banco Mundial (AF26)** [31] captaram a posição econômica independentemente dos dois eixos anteriores.

A amostra final de 15 países — Brasil, México, Argentina, Peru (América Latina); Nigéria, África do Sul, Quênia, Egito (África); Índia, Indonésia, Bangladesh, Filipinas (Ásia); e Estados Unidos, Alemanha, Japão (referência do Norte Global) — cobre quatro regiões do mundo, cinco classes Joshi (1 a 5) e quatro grupos de renda do Banco Mundial. Os doze países do Sul Global também variam na maturidade da governança doméstica de qualidade do ar, o que é relevante para a disponibilidade do gabarito (Seção 3.9). Países com governança estatística comprometida (por exemplo, conflito ativo) ou sem um padrão nacional de qualidade do ar publicamente recuperável foram excluídos; a Oceania e os idiomas de Classe 0 de Joshi não foram representados dadas restrições de viabilidade e são reconhecidos como limitações de escopo.

3.3 Expansão confirmatória da amostra (pós-registro)

Após a análise pré-registrada de 15 países, e *reportada aqui de modo transparente como uma extensão pós-registro, e não como parte do protocolo travado*, a amostra foi ampliada para **25 países** a fim de aumentar o poder estatístico para os testes de gradiente (H1) e de mecanismo de corpus (H4) e de multiplicar os pares de idioma intra-país disponíveis para H2. Dez países foram adicionados sob procedimentos idênticos de construção de prompt, gabarito, coleta e pontuação. Seis são referências do **Norte Global** escolhidas puramente para alargar a ponta de alto recurso do gradiente — Reino Unido, Canadá, Austrália, Coreia do Sul, França e Itália. Quatro são países de **par de idioma nativo** que adicionam contrastes em espanhol (Colômbia, Chile) e português (Portugal, Angola) para H2; destes, Portugal é também do Norte Global, enquanto

Colômbia, Chile e Angola são do Sul Global. Os dois papéis se sobrepõem, de modo que, por camada, a extensão adiciona sete países do Norte Global (as seis referências mais Portugal), elevando a célula do Norte Global de três para dez, e três do Sul Global; por idioma, eleva os pares de língua espanhola de três para cinco e os de língua portuguesa de um para três. Como esta extensão foi decidida após observar os resultados iniciais, todo efeito calculado na amostra de 25 países é reportado ao lado de sua contraparte pré-registrada de 15 países, e nenhuma conclusão pré-registrada é revista com base apenas na extensão; a expansão é tratada como uma checagem de poder e robustez, e não como um novo teste confirmatório. Angola, como Nigéria e Argentina, *não* tem padrão nacional de PM_{2.5}, fornecendo casos adicionais de ausência-de-padrão em que um modelo fiel deve recusar-se a indicar um limiar inexistente em vez de fabricá-lo.

Para multiplicar os pares de H2 sem adicionar novos idiomas, duas variantes adicionais de pergunta por (país, tarefa) também foram geradas para os cinco países originais de par nativo por meio de um modelo gerador de alta qualidade e renderizadas tanto em inglês quanto no idioma nativo; essas variantes são usadas *apenas* para o contraste pareado inglês-versus-nativo (H2), no qual qualquer imperfeição no gabarito gerado se cancela entre os dois membros de um par, e são excluídas das comparações de acurácia absoluta (H1, H3).

3.4 Covariáveis dos países

Para cada país compilamos covariáveis de desenvolvimento e de representação de corpus. O **Índice de Desenvolvimento Humano (IDH)** (Relatório de Desenvolvimento Humano da UNDP 2023–24, dados de 2022) e o **PIB per capita** indexam a posição de desenvolvimento e entram na análise de mecanismo como covariáveis de ajuste.

As exposições de representação de corpus são organizadas segundo uma distinção que a análise de mecanismo (H4) torna explícita, porque os dois canais aplicam-se a efeitos diferentes. As **medidas de corpus do idioma** quantificam quanto texto de pré-treinamento existe *em* um idioma e são o mecanismo candidato para a penalidade de idioma nativo (H2): a contagem de tokens mC4 por idioma (12, Tabela 6), o tamanho do corpus deduplicado OSCAR-2301 por idioma [13] e a classe de recurso linguístico de Joshi [3]. As **medidas de corpus de país** quantificam quanto o corpus enciclopédico é *sobre* um país, independentemente do idioma, e são o mecanismo candidato para a lacuna geográfica (H1/H4): o comprimento em bytes do artigo da Wikipédia em inglês sobre o país, o número de edições de idioma da Wikipédia com um artigo sobre ele (contagem de sitelinks do Wikidata) e o número de declarações (statements) do Wikidata sobre a entidade do país. As duas famílias não são intercambiáveis: como a lacuna geográfica é medida *em inglês* (idioma mantido constante entre países), uma lacuna Norte/Sul residual não pode ser um efeito de corpus do idioma, de modo que a H4 isola o canal de representação de país para H1 e o canal de corpus do idioma para H2. Todos os valores de covariáveis, fontes oficiais e datas de acesso são versionados no release da análise.

3.5 Seleção de modelos

Quatorze LLMs foram avaliados em cinco camadas de acesso, abrangendo cerca de duas ordens de grandeza em contagem de parâmetros e quatro geografias de dados de treinamento (Estados Unidos, China, Europa, Brasil). A **Camada A (fronteira de peso aberto, 5 modelos)**

compreendeu grandes sistemas de peso aberto acessados por endpoints de inferência gratuitos. As **Camadas B (peso aberto médio, 3 modelos)** e **C (peso aberto pequeno/regional, 2 modelos)** foram executadas localmente via Ollama sob tags de modelo fixadas; a Camada C inclui um modelo aberto brasileiro-português ajustado por instrução (Cabra-Mistral 7B v3) usado para o teste de modelo regional (H3) contra um modelo aberto treinado globalmente de escala equivalente. As **Camadas D (fechada acessível, 2 modelos)** e **E (fechada de fronteira, 1 modelo)** foram acessadas via APIs oficiais. Cada modelo foi consultado com uma string de versão ou tag fixada idêntica ao longo de toda a janela de coleta; tags e, quando disponíveis, hashes de pesos são registrados no release do protocolo para proteger contra atualizações de modelo durante a coleta. O roster completo de modelos com fornecedor, contagem de parâmetros, rota de acesso e backend de execução é fornecido na Tabela S1 do Suplementar.

Uma nota sobre a unidade de análise. Comparamos *modelos tal como servidos* por meio de uma stack de acesso fixa (API oficial do fornecedor para modelos fechados; um endpoint de inferência fixado para modelos de peso aberto), e não pesos idealizados do modelo isoladamente. A infraestrutura do provedor, a configuração de serving e a camada de API são, portanto, parte do que cada rótulo denota, e uma lacuna residual poderia, em princípio, refletir a stack em vez dos pesos. Mantemos isso constante fixando strings/tags de versão e a configuração de máximo determinismo disponível por provedor ao longo de uma janela de coleta fixa, e tratamos “modelo” ao longo do texto como abreviação dessa stack de modelo servido; desemaranhar pesos de infraestrutura é uma questão separada que não pretendemos resolver.

3.6 Domínio e taxonomia de tarefas

O domínio único é a **política de poluição do ar**, escolhido por ancorar-se em gabarito oficialmente publicado e verificável (padrões nacionais de qualidade do ar, dados de monitoramento de agências ambientais, programas federais de controle) e por mapear-se a atividades concretas de decisão de um gestor ambiental público. Cinco tipos de tarefa operacionalizam o domínio:

- **T1 — Padrão técnico.** Recuperação de padrões vinculantes de qualidade do ar, limites de emissão ou limiares regulatórios (por exemplo, o padrão anual de $PM_{2.5}$ em vigor no país).
- **T2 — Dado factual local.** Recuperação de dados de qualidade do ar oficialmente medidos para uma cidade ou região e ano especificados, conforme reportado pela agência ambiental nacional ou subnacional.
- **T3 — Síntese de evidência em saúde.** Síntese de evidência epidemiológica revisada por pares sobre a carga de saúde da poluição do ar para o país, pontuada contra uma rubrica em vez de um único valor.
- **T4 — Instrumentos de política.** Identificação de programas de política, órgãos executores e instrumentos legais de controle da poluição do ar em vigor no país.
- **T5 — Recomendação aplicada.** Recomendação aplicada avaliada por rubrica para um cenário operacional definido (por exemplo, resposta de curto prazo a um episódio de alta concentração sob inversão térmica).

T1, T2 e T4 admitem gabarito verificável e carregam o sinal primário de acurácia; T3 e T5 são tarefas de geração aberta pontuadas por rubrica. O mapeamento país-por-tarefa das classes de fonte oficial, dos critérios de equivalência e do status de verificabilidade é especificado no registro de gabarito (Seção 3.9).

3.7 Manipulação de persona

A persona é um fator intra-prompt com dois níveis. A condição **neutra** apresenta a consulta como um pedido simples de informação. A condição **public_manager_env** antepõe um quadro de papel fixo identificando o solicitante como um funcionário de gestão ambiental municipal ou regional, mantendo a pergunta substantiva idêntica entre as condições. Um único template de quadro de papel é aplicado uniformemente entre países e tarefas (traduzido quando o idioma do prompt não é o inglês), de modo que qualquer diferença entre condições seja atribuível ao quadro de persona, e não à redação da pergunta. A ordem da persona dentro de cada célula prompt-modelo é randomizada, e uma checagem de manipulação verifica se o quadro de papel é reconhecido na resposta. A redação exata, o procedimento de tradução e a codificação da checagem de manipulação são pré-especificados e reproduzidos no Material Suplementar. A persona é a base da hipótese H6, que testa se o quadro de papel reduz (ou amplifica) o gradiente de acurácia em nível de país.

3.8 Construção e validação de prompts

Os prompts foram autorados para o domínio de política de poluição do ar pela equipe de pesquisa com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrarem no conjunto confirmatório de estímulos. Um subconjunto-piloto foi primeiro validado quanto à concordância entre avaliadores usando o α de Krippendorff, com um limiar de $\alpha \geq 0.70$ exigido antes de escalar o desenho. Todos os prompts foram autorados em inglês e, para um subconjunto estratificado de países, adicionalmente em um idioma nativo relevante (matriz multilíngue esparsa; Seção S3 do Suplementar); os prompts em idioma nativo foram traduzidos e retrotraduzidos por tradutores nativos, e qualquer prompt cuja retrotradução produziu um desvio semântico foi reescrito ou excluído. Após a validação do piloto do Brasil, exigiu-se que toda afirmação factual em uma entrada de gabarito resolvesse para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido, aplicando o Protocolo de Verificação de Citações do projeto no estágio de geração do gabarito, e não apenas no estágio do manuscrito.

3.9 Gabarito e o registro de gabarito

O gabarito para as tarefas verificáveis (T1, T2, T4) foi extraído de fontes oficiais de registro: padrões nacionais de qualidade do ar e as agências que os emitem (T1), relatórios de monitoramento de agências ambientais (T2) e programas federais de política com seus órgãos executores e instrumentos legais (T4). Para T3, a referência é um conjunto curado de estudos epidemiológicos revisados por pares com DOIs resolvíveis, em vez de um único número. Como a validade do gradiente geográfico (H1) e do efeito de persona (H6) depende de o gabarito estar igualmente dis-

ponível e igualmente verificável em todos os países, construímos um registro de gabarito por país que, para cada par (país, tarefa), registra a classe de fonte oficial equivalente, a URL resolvível, o valor-ouro ou a chave da rubrica, a data de referência, o validador humano e um sinalizador de validação. O desenho do registro, os critérios de equivalência entre países e a separação explícita entre uma lacuna de conhecimento da IA e uma lacuna de disponibilidade de gabarito são documentados em `docs/ground_truth_registry_design.md` e resumidos no Material Suplementar. As entradas são versionadas por data de acesso, URL de fonte e um hash SHA-256 do documento recuperado. Onde o gabarito poderia plausivelmente ter aparecido nos dados de treinamento, um subconjunto de sensibilidade é construído a partir de documentos datados após o corte de treinamento de cada modelo. As entradas cuja fonte oficial é indisponível ou não equivalente para um país são sinalizadas e excluídas da comparação primária de acurácia para a célula (país, tarefa) afetada, de modo que gabarito ausente nunca seja pontuado como erro do modelo.

3.10 Coleta de dados

As chamadas de API e locais foram executadas à temperatura 0.3 com seeds determinísticas quando disponíveis, com 2 replicações por combinação prompt-modelo-persona para estimar a variabilidade estocástica dentro do orçamento. A coleta ocorreu dentro de uma janela fixa para minimizar confundimentos por atualização de modelo, com a tag fixada, a string de versão e o timestamp de aquisição registrados para cada chamada; como o comportamento do modelo servido pode derivar à medida que fornecedores atualizam a infraestrutura, as acurácias reportadas são estimativas point-in-time relativas a essa janela, e as datas de aquisição por provedor são liberadas com o conjunto de dados. Todas as respostas foram armazenadas junto com metadados completos da requisição (string de versão ou tag do modelo, timestamp, contagens de tokens, motivo de finalização, condição de persona) em uma camada de armazenamento versionada com checksums SHA-256. Os portões de qualidade de resposta excluíram respostas truncadas (`finish_reason` $\neq$ `stop`) e respostas em idioma divergente do solicitado; ambas foram retidas e analisadas separadamente como desfechos secundários.

A cobertura por célula não é uniforme no roster de modelos: endpoints gratuitos e com limite de taxa (por exemplo, GPT-OSS 120B via um provedor de inferência compartilhado) retornaram menos respostas admissíveis do que as APIs medidas, de modo que o N pontuado varia de cerca de 300 a 780 respostas por modelo. Reportamos o N realizado de cada modelo ao lado de sua pontuação (Tabela 1) em vez de descartar silenciosamente células sub-cobertas, e uma matriz de cobertura completa modelo $\times$ país $\times$ tarefa, com a cota e os motivos de exclusão de cada déficit, é fornecida no Material Suplementar para que nenhuma ausência fique oculta.

3.11 Medidas

A pontuação usou um protocolo de LLM-como-juiz com um único juiz primário e um painel de confiabilidade de múltiplos fornecedores. Cada resposta no conjunto confirmatório foi pontuada pelo **juiz primário** (GPT-5-mini) contra a entrada do registro de gabarito (para T1, T2, T4) ou a rubrica validada (para T3, T5), produzindo os cinco subcomponentes normalizados abaixo. Para quantificar a sensibilidade do juiz, uma **amostra de confiabilidade fixa e estratificada** (estratificada por país $\times$ tarefa $\times$ persona, com seed aleatória fixa) foi re-pontuada de modo

independente por um painel diverso de fornecedores. O painel operativo compreende quatro juízes abrangendo quatro fornecedores — GPT-5-mini (OpenAI), Claude Sonnet 4.6 (Anthropic), Gemini 2.5 Pro (Google) e DeepSeek-V3 (DeepSeek) — escolhidos por diversidade de fornecedor para que a correlação intra-fornecedor não infle a concordância aparente; um quinto juiz (Llama 3.3 70B, Meta) corrobora no subconjunto que cobriu, e um sexto candidato (Command R+, Cohere) foi tentado, mas excluído quando sua cota de provedor se esgotou durante a execução. A confiabilidade é reportada de três formas: o α de Krippendorff (um coeficiente de concordância entre avaliadores, 1 = perfeito, 0 = acaso), o ICC(2,1) de juiz único (correlação intraclassa para um avaliador, efeitos aleatórios de duas vias) e, como quantidade operativa, a **confiabilidade ICC(2,k) da média do painel**, que, pela relação de Spearman-Brown, é alta mesmo quando juízes individuais concordam apenas moderadamente. Reportamos a concordância de modo transparente, incluindo o juiz mais discordante: qualquer offset sistemático de leniência se cancela nos contrastes entre grupos que carregam todo efeito reportado (diferença de camada, penalidade de idioma, piso de tarefa), de modo que a concordância moderada de juiz único não ameaça esses contrastes. Este estudo não incluiu uma camada de padrão-ouro humano; o gabarito foi, em vez disso, ancorado em fontes oficiais primárias por meio de uma auditoria documental (Seção 3.9), e a ausência de pontuação humana independente é declarada como limitação.

O desfecho composto primário combina os cinco subcomponentes pré-especificados (ver Seção S6 do Suplementar), cada um normalizado para [0, 1]: (i) acurácia factual contra a entrada do registro (binária em T1; crédito parcial em T2–T4); (ii) completude contextual pontuada contra uma rubrica pré-validada (T3, T4, 0–5); (iii) qualidade de citação verificada por DOI e checagem de fonte oficial; (iv) ausência de alucinação, codificada binariamente (0 alucinado, 1 fiel); e (v) validade aplicada, a pontuação de rubrica para a recomendação operacional em T5. A inferência primária usa pesos iguais; duas ponderações de sensibilidade pré-especificadas (um conjunto derivado de PCA estimado no piloto estendido do BRA e um conjunto especificado pelos autores: factual 0.30, contextual 0.25, citação 0.15, alucinação 0.15, aplicada 0.15) são reportadas, e uma conclusão é tratada como robusta apenas se valer nas três. O composto é calculado por célula (país, modelo, persona) para sustentar o teste de diferença-em-diferenças de H6.

3.12 Estratégia analítica

Os três testes confirmatórios primários são pré-especificados como uma única família (F1) e corrigidos em conjunto com o procedimento de Bonferroni-Holm (uma correção familiar do tipo step-down para comparações múltiplas). Os testes confirmatórios secundários (F2) são reportados sem ajuste dentro da família, e os testes exploratórios declarados (F3) usam o FDR de Benjamini-Hochberg a $q = 0.10$ [32].

H1 (gradiente geográfico, primário). A acurácia composta média em nível de país ($n=15$) é regredida sobre o gradiente Joshi/IDH via Spearman ρ (correlação de postos), pré-especificada unicaudal com limiar $\rho \geq 0.55$ a $\alpha = 0.05$, com um teste de Mann-Kendall (um teste não paramétrico de tendência monotônica) como complemento obrigatório de não-monotonicidade e um indicador binário do Sul Global como contraste de sensibilidade.

H4 (mecanismo de representação de corpus, primário). O ρ parcial de Spearman em nível de país relaciona a representação de corpus à acurácia após ajuste para IDH e log do PIB per capita, usando contagens da Wikipédia como proxy primário ($\rho \geq 0.55$) e exigindo convergência em pelo menos duas de três operacionalizações do Common Crawl ($\rho \geq 0.40$). Uma análise de sensibilidade de E-value [33] quantifica o confundimento não medido necessário para anular a associação (limiar 2.0).

H6 (efeito de persona, primário). O efeito de persona é testado como uma diferença-em-diferenças em nível de país sobre o desfecho composto: $\Delta_{GS} = \overline{\text{persona}}_{GS} - \overline{\text{neutral}}_{GS}$ e $\Delta_{GN} = \overline{\text{persona}}_{GN} - \overline{\text{neutral}}_{GN}$, com a estatística de H6 $\Delta_{GS} - \Delta_{GN}$. H6 é sustentada (unicaudal, $\alpha = 0.05$) se a condição de persona reduzir a lacuna do Sul Global em pelo menos 0.05 no composto $[0, 1]$ (equivalentemente, 5 pontos percentuais de acurácia absoluta). A inferência usa um teste de permutação em nível de país (5,000 permutações) reportado ao lado de um teste pareado paramétrico; o teste bicaudal é reportado como checagem secundária, pois a amplificação por persona é teoricamente possível e é reportada de modo transparente se observada.

H3 (modelo regional, secundário). Um contraste unicaudal pré-especificado em um modelo linear misto generalizado compara o Cabra-Mistral 7B v3 em prompts em português brasileiro contra um modelo aberto treinado globalmente de escala equivalente, com um contraste-companheiro exploratório em outros contextos lusófonos para distinguir fechamento de lacuna de deslocamento de lacuna.

H2 e H5 (exploratórios). A interação idioma-do-prompt $\times$ país (H2) e o contraste fronteira-aberta versus fronteira-fechada (H5) são reportados descritivamente, com testes formais sob correção F3 quando aplicados.

As análises transversais de modelo misto usam Modelos Lineares Mistos Generalizados com interceptos aleatórios para país e modelo, implementados via **pymer4** [34] interfaceando com o **lme4** do R [35]: **lmer** com REML para o composto gaussiano e **glmer** com família binomial e link logit para desfechos binários. Onde uma decomposição de mediação é reportada para H4, ela usa **semopy** [36] com 5,000 replicações bootstrap. As análises de robustez, todas pré-especificadas, incluem reestimação leave-one-country-out, restrição ao subconjunto validado por padrão-ouro humano, reestimação bayesiana com prioris fracamente informativas via **pymc** [37] e uma análise separada excluindo prompts sinalizados por potencial contaminação de dados de treinamento. Uma simulação de poder de Monte Carlo (10,000 iterações sob tamanhos de efeito informados pelo piloto) confirma o poder familiar para o trio primário sob Bonferroni-Holm; o desenho de persona intra-sujeito rende uma redução mínima detectável de lacuna de aproximadamente 2–3 pontos percentuais, de modo que o limiar de 5 pontos de H6 é bem-potente. Os detalhes de poder são reportados no Material Suplementar.

3.13 Protocolo do estudo e ciência aberta

O protocolo completo — hipóteses, prompts com hashes, o registro de gabarito, o template de persona, as rubricas de pontuação, as especificações de GLMM e DiD, as correções de comparações múltiplas e os critérios de exclusão — é pré-especificado antes da coleta confirmatória de dados. O conjunto de dados analítico, após os portões de qualidade, mas antes do ajuste de modelos, é congelado e hashado para que a análise confirmatória possa ser auditada contra a

especificação travada. O protocolo completo, os prompts, as referências de gabarito, o código de análise e os dados anonimizados de resposta serão liberados na publicação sob CC-BY-4.0 (dados e prompts) e a Licença MIT (código) [38]; um Data Paper companheiro está preparado para o *Scientific Data*.

3.14 Considerações éticas

Nenhum dado pessoal de usuários finais de LLMs foi coletado. O estudo analisa saídas de modelos para questões de política publicamente relevantes; especialistas de domínio que contribuem para a validação do gabarito são reconhecidos como coautores quando atendem aos critérios do ICMJE. Os termos de serviço dos provedores de LLM foram revisados e respeitados, e as respostas são redistribuídas exclusivamente para pesquisa sob disposições de uso justo e reprodutibilidade, excluídas de qualquer aplicação comercial.

4 Resultados

Nota de amostra. Reportamos um benchmark pré-registrado de 15 países e sua extensão pós-registro para 25 países (esta última adiciona seis referências do Norte Global — Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália — e quatro países de par nativo — Colômbia, Chile, Portugal, Angola). Quatorze LLMs são pontuados em cinco tarefas, duas personas e quatro idiomas (inglês mais um idioma nativo do país — espanhol, português ou hindi — para os nove países aplicáveis, fornecendo os pares inglês/nativo intra-país que testam H2). Todo efeito calculado na amostra de 25 países é reportado ao lado de seu valor pré-registrado de 15 países; nenhuma conclusão pré-registrada é revista apenas com base na extensão. Todas as respostas são pontuadas pelo GPT-5-mini, validadas contra um painel de juízes de quatro fornecedores (Seção 4.11); o gabarito de T1 está ancorado em fontes oficiais primárias para todos os 25 países (Seção 4.9).

4.1 Amostra e julgamento

O corpus analisado compreende 9,251 respostas pontuadas por juiz no composto $[0, 1]$, das quais 7,580 são respostas a prompt em inglês nos 25 países (o restante são os pares de idioma nativo intra-país usados para H2). O juiz primário é o GPT-5-mini. Como o GPT-5-mini está ele próprio entre a camada avaliada, três juízes adicionais diversos em fornecedor re-pontuaram uma amostra fixa estratificada para quantificar a sensibilidade do juiz; a concordância é forte (confiabilidade da média do painel $\text{ICC}(2, 4) = 0.89$; Seção 4.11), o que neutraliza a sobreposição juiz-alvo para os compostos reportados.

4.2 Acurácia por modelo

A Tabela 1 ordena os 14 modelos pelo composto médio. Sistemas de fronteira (GPT-5, GPT-5-mini, DeepSeek-V3) lideram; modelos pequenos de peso aberto ficam para trás. O resultado relativo a H3 é inequívoco: o modelo regional brasileiro-português Cabra-Mistral 7B é o *pior* de todos os modelos (0.320 versus 0.543 para os demais; Mann-Whitney $p \approx 0$, δ de Cliff = -0.51 , um tamanho de efeito não paramétrico em $[-1, 1]$), contradizendo o enquadramento otimista de

H3 de que um modelo regional compra acurácia de domínio. Escala e treinamento de fronteira dominam o ajuste regional por instrução no nível de 7B.

Tabela 1: Acurácia composta confirmatória por modelo nos 25 países (juiz GPT-5-mini, $[0, 1]$). N = respostas pontuadas a prompt em inglês.

Modelo	N	Média
GPT-5	780	0.647
GPT-5-mini	777	0.626
DeepSeek-V3	500	0.625
Gemini 2.5 Flash	490	0.604
Claude Haiku 4.5	490	0.597
Qwen3 32B	498	0.546
Command R+	500	0.509
Llama 3.3 70B	474	0.506
GPT-OSS 120B	298	0.485
Phi-4 14B	500	0.485
Qwen3 14B	500	0.474
Llama 4 Scout	500	0.473
Llama 3.1 8B	777	0.424
Cabra-Mistral 7B	496	0.320

4.3 Acurácia por tarefa: o piso de recuperação factual

A dificuldade é fortemente dependente da tarefa (Tabela 2). As duas tarefas mais difíceis são **T1 (recuperação de padrão técnico, 0.367)** e **T2 (dado local medido, 0.368)** — justamente as tarefas que exigem recuperar um valor vinculante específico (um padrão nacional anual de $PM_{2.5}$; uma concentração por cidade-ano). A tarefa aberta de recomendação (T5) pontua mais alto (0.773) porque sua rubrica recompensa aconselhamento de política plausível e bem estruturado que não depende de um único fato. As duas tarefas de recuperação factual (T1, T2; média agrupada 0.367) pontuam muito abaixo das tarefas de síntese e recomendação (T3–T5, 0.638); a diferença é grande e inequívoca (Mann-Whitney $p \approx 0$, δ de Cliff = -0.64). Este é o achado mais robusto do estudo: os LLMs são mais fracos exatamente onde a gestão ambiental aplicada mais precisa deles — recuperar o limiar regulatório preciso ou o valor medido em vigor.

Tabela 2: Acurácia composta confirmatória por tipo de tarefa (25 países).

Tarefa	N	Média
T5 (recomendação aplicada)	1,508	0.773
T4 (instrumentos de política)	1,494	0.574
T3 (síntese evid. em saúde)	1,519	0.567
T2 (dado factual local)	1,530	0.368
T1 (padrão técnico)	1,529	0.367

4.4 H1 — uma diferença de camada e (a $n = 25$) um gradiente de desenvolvimento

H1 foi pré-especificada em duas partes. A **diferença de camada** vale em ambas as amostras: os dez países do Norte Global têm média 0.567 contra 0.505 dos quinze países do Sul Global, uma

diferença de **+6.2 pontos percentuais** cujo intervalo de confiança bootstrap de 95% entre países é $[+3.7, +8.6]$ pp e *exclui zero* (15 países: +6.7 pp, $[+2.8, +10.2]$). O **gradiente monotônico** comporta-se de modo diferente entre as amostras, e é aqui que a amostra estendida muda o quadro. No $n = 15$ pré-registrado, o gradiente era indetectável (Spearman $\rho(\text{acur.}, \text{IDH}) = +0.14$, $p = 0.31$; Mann-Kendall $p = 0.69$). Na amostra estendida de $n = 25$ ele torna-se significativo: $\rho(\text{acur.}, \text{IDH}) = +0.51$ ($p = 0.004$, unicaudal), com uma tendência de Mann-Kendall significativa ($S = 102$, $Z = +2.36$, $p = 0.018$). O gradiente de desenvolvimento é, portanto, real, mas estava *subpotente* a $n = 15$; as sete referências de alto IDH adicionadas (Tabela 3: Coreia do Sul, Itália, França, Canadá, Austrália, Reino Unido, Portugal, todas agrupadas perto do topo) aumentam a densidade de observações de alto desenvolvimento o suficiente para revelá-lo — sem alargar a própria amplitude do IDH (Seção 4.12).

Duas qualificações honestas delimitam este resultado. Primeiro, $\rho = 0.51$ *fica logo abaixo do nosso limiar de tamanho de efeito pré-registrado de $\rho \geq 0.55$* : o gradiente é estatisticamente significativo, mas abaixo da magnitude à qual nos pré-comprometemos para chamá-lo de gradiente forte. Segundo, o gradiente é em *desenvolvimento* (IDH), *não* em recurso linguístico: a correlação com a classe Joshi permanece nula ($\rho = -0.06$). A ordenação dos países também retém grande heterogeneidade ortogonal ao eixo — a Índia (0.631, Sul Global) ainda lidera todos os países e a Alemanha (0.535) é o país do Norte Global de menor pontuação — de modo que a desvantagem é um gradiente de desenvolvimento sobreposto a variação substancial específica de país, e não uma classificação limpa. Sob Bonferroni-Holm na família primária {H1-gradiente, H4, H6}, H1-por-IDH é o único teste que rejeita sua nula a $n = 25$ ($p = 0.004$ versus limiar 0.0167).

Tabela 3: Acurácia composta confirmatória por país, amostra de 25 países (camada: GN = Norte Global, GS = Sul Global). Ordenada pela média.

País	Camada	Média	País	Camada	Média
Índia	GS	0.631	Alemanha	GN	0.535
Coreia do Sul	GN	0.601	Chile	GS	0.528
Japão	GN	0.588	África do Sul	GS	0.522
Itália	GN	0.584	Angola	GS	0.506
Estados Unidos	GN	0.581	Bangladesh	GS	0.503
França	GN	0.564	Filipinas	GS	0.499
Canadá	GN	0.562	México	GS	0.496
Austrália	GN	0.559	Peru	GS	0.496
Reino Unido	GN	0.554	Quênia	GS	0.488
Portugal	GN	0.550	Nigéria	GS	0.465
Indonésia	GS	0.540	Egito	GS	0.465
Colômbia	GS	0.539	Argentina	GS	0.450
			Brasil	GS	0.449

4.5 H4 — representação de corpus: cobertura de país, não tamanho de idioma

O mecanismo pré-especificado para a lacuna geográfica era a representação no corpus de treinamento, com o proxy pré-registrado sendo a contagem de artigos/edições da Wikipédia. Esse proxy é **nulo** tanto a $n = 15$ quanto a $n = 25$ (Spearman $\rho = +0.08$; parcial controlando IDH

+0.04, $p = 0.87$): **a H4 como pré-registrada não é sustentada**. Exploramos então, post hoc, se um canal diferente está em ação. Como a lacuna é medida *em inglês*, uma diferença Norte/Sul residual não pode refletir quanto texto existe no idioma de um país, de modo que distinguimos o tamanho do corpus do idioma de quão amplamente o corpus é *sobre* um país. Entre três proxies de cobertura de país, o número de edições de idioma da Wikipédia com um artigo sobre o país (sitelinks do Wikidata) correlaciona-se com a acurácia no nível de ordem zero ($\rho = +0.54$, $p = 0.005$, que sobrevive à correção de Benjamini-Hochberg entre os três proxies, p ajustado = 0.016; declarações do Wikidata $\rho = +0.31$ e comprimento em bytes do artigo em inglês $\rho = +0.20$ são ambos não significativos). *Contudo*, essa associação **atenua-se até a não-significância após ajuste para o IDH** (parcial $\rho = +0.32$, $p = 0.13$), de modo que não atinge o padrão de correlação parcial que o teste de mecanismo exige. Reportamos, portanto, a abrangência de cobertura de país como um sinal *sugestivo e exploratório* — consistente com uma lacuna que aparece mesmo quando todos os países são consultados em inglês, e uma pista mais promissora que o tamanho do corpus do idioma — mas **não** como mecanismo estabelecido: o gradiente de desenvolvimento e a cobertura de país estão entrelaçados, e os dados presentes não conseguem separá-los.

Para a penalidade de idioma nativo (H2), o canal relevante é, em vez disso, o tamanho do corpus do idioma, e a direção é a prevista, embora, com apenas três idiomas nativos, seja descritiva: a penalidade por idioma cai monotonicamente com o volume de tokens mC4 [12] e o tamanho do OSCAR [13] (Spearman = -1.00 entre os três) — o hindi, o menor corpus (24B tokens mC4), carrega a maior penalidade, e o espanhol (433B) a menor.

4.6 H6 — a persona não estreita a lacuna geográfica

O fator de persona foi totalmente cruzado, de modo que H6 é testada como uma diferença-em-diferenças. O quadro de gestor ambiental público deixa a lacuna Norte/Sul essencialmente inalterada: +6.4 pp sob o quadro neutro versus +6.0 pp sob o quadro de gestor, um DiD de +0.4 pp, muito abaixo do limiar pré-especificado de 5 pp; um teste de permutação em nível de país (5,000 permutações do rótulo de camada) dá $p = 0.26$. **H6 não é sustentada** em nenhuma das amostras (DiD de 15 países +1.0 pp, $p = 0.14$): apresentar a consulta como vinda de um gestor ambiental público não estreita nem amplifica a desvantagem do Sul Global, consistente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual [27, 28]. Isso responde à questão aplicada central do estudo de forma negativa — o enquadramento do prompt não é uma correção para o viés geográfico.

4.7 H5 — aberto versus fechado-acessível

Agrupando por tipo de acesso, os modelos fechados-acessíveis têm média 0.623 ($n = 2,537$) contra 0.481 dos modelos de peso aberto ($n = 5,043$), uma vantagem fechada de +14.1 pp. Isso contraria o enquadramento otimista de H5; o braço aberto inclui modelos maiores (Llama 3.3 70B, DeepSeek-V3), de modo que a lacuna não é atribuível apenas à escala, embora o próprio DeepSeek-V3 figure em terceiro no geral. H5 é interpretada descritivamente.

4.8 H2 — o prompt em idioma nativo reduz a acurácia

Para os nove países com idioma nativo-alvo (Brasil/Portugal/Angola $\rightarrow$ português, México/Argentina/Peru/Colômbia/Índia $\rightarrow$ hindi), cada prompt é renderizado tanto em inglês quanto no idioma nativo, mantendo o conteúdo fixo, de modo que o contraste inglês/nativo é intra-país e intra-modelo. Nas células pareadas (modelo, prompt), o prompt em idioma nativo *reduz* a acurácia composta média em 2.1 pontos percentuais (Wilcoxon de postos sinalizados $p = 2 \times 10^{-3}$, $n = 762$ células). Como essas células estão agrupadas dentro de modelos e prompts, confirmamos o efeito no nível de *país*, onde a unidade é independente: agregando para um delta inglês-menos-nativo por país, todos os nove países de par nativo mostram uma penalidade (9/9 negativos, média -2.4 pp, Wilcoxon $p = 0.008$), de modo que não é um artefato de tratar células agrupadas como independentes. O efeito é modulado pelo nível de recurso do idioma nativo (Tabela 4): a penalidade do espanhol é pequena e não significativa (-1.0 pp, $p = 0.15$), a penalidade do português é agora significativa com os pares Portugal/Angola adicionados (-2.3 pp, $p = 0.033$), e a penalidade do hindi é grande (-7.8 pp, $p = 0.013$). A Índia, que pontua mais alto de todos os países em inglês, cai acentuadamente em hindi. A implicação aplicada espelha H6: a correção intuitiva — deixar um gestor local perguntar em seu próprio idioma — não ajuda e, para um idioma de menor recurso em escrita não latina, prejudica materialmente. Isso é consistente com a hierarquia de recurso linguístico [3] e com o canal de corpus do idioma de H4.

Tabela 4: H2: acurácia nativo-menos-inglês por idioma nativo (pareada dentro de país e modelo, amostra de 25 países).

Idioma nativo (classe Joshi)	Países	Δ (pp)	N pares
Espanhol (5)	MEX, ARG, PER, COL, CHL	-1.0	412
Português (4)	BRA, PRT, AGO	-2.3	284
Hindi (4)	IND	-7.8	66
Geral		-2.1	762

4.9 Proveniência do gabarito

Como a “acurácia” medida depende do gabarito, o alvo de padrão técnico (T1) para todos os 25 países foi ancorado em fontes oficiais primárias por verificação documental, e não por asserção de especialista, e é reproduzível a partir das URLs citadas. A maioria dos países tem um valor lido da regulação oficial (por exemplo, o padrão anual de $PM_{2.5}$ do Brasil de $17 \mu g/m^3$ lido verbatim do Anexo I da Resolução CONAMA 506/2024 no Diário Oficial da União; os $25 \mu g/m^3$ da Colômbia lidos da Tabla 1 da Resolución 2254/2017). Três países *não* têm padrão nacional de $PM_{2.5}$, confirmado a partir do texto oficial — a regulação NESREA da Nigéria estabelece apenas PM_{10} , a Argentina não tem valor federal vinculante e Angola não tem legislação nacional de qualidade do ar — um fato que a auditoria estabeleceu contra números secundários em circulação, porém incorretos, e no qual um modelo fiel deve recusar-se a indicar um limiar inexistente em vez de fabricá-lo. Essa proveniência é mais reproduzível do que a validação por especialista: qualquer leitor pode re-verificar cada valor a partir da fonte oficial.

4.10 Modos qualitativos de falha

Para tornar concretos os números do composto, o Quadro 1 mostra três falhas representativas extraídas verbatim dos logs de resposta (IDs de execução disponíveis no release).

Tabela 5: Quadro 1 — Modos de falha representativos (verbatim, levemente truncados).

Modo de falha	Exemplo
Fabricar um padrão inexistente (país sem norma nacional de PM _{2.5})	Para Angola (sem padrão nacional), o Gemini 2.5 Flash asseriu um padrão anual de “25 $\mu\text{g}/\text{m}^3$ ” em uma replicação e “15 $\mu\text{g}/\text{m}^3$ ” em outra; o GPT-5 asseriu “15 $\mu\text{g}/\text{m}^3$ ” para a Nigéria , que regula apenas PM ₁₀ (NESREA). Uma resposta fiel se recusaria a indicar um valor que não existe.
Errar o valor vinculante (piso de T1)	Para o Brasil (padrão anual oficial 17 $\mu\text{g}/\text{m}^3$, CONAMA 506/2024), a resposta modal dos modelos foi 15 $\mu\text{g}/\text{m}^3$ (42 respostas), com 10, 20 e 25 também comuns; o valor oficial quase nunca foi retornado.
Degradação em idioma nativo (H2)	Para a Índia (padrão anual 40 $\mu\text{g}/\text{m}^3$), o GPT-OSS 120B retornou o valor correto em inglês, mas uma resposta <i>vazia</i> à mesma pergunta em hindi.

O primeiro modo é o mais consequente para os casos sem padrão (Angola, Nigéria, Argentina): em vez de se abster, os modelos inventam um limiar regulatório plausível e discordam entre replicações e modelos sobre o valor inventado — exatamente o comportamento que um gestor público não consegue detectar sem a fonte oficial.

4.11 Confiabilidade entre juízes

Para tratar a sobreposição juiz-alvo (o GPT-5-mini está no conjunto avaliado), uma amostra de confiabilidade fixa e estratificada de 131 respostas foi re-pontuada de modo independente por um painel de juízes diverso em fornecedor: GPT-5-mini (OpenAI), Claude Sonnet 4.6 (Anthropic), Gemini 2.5 Pro (Google) e DeepSeek-V3 (DeepSeek). A confiabilidade é reportada de três formas: o α de Krippendorff = 0.667 (intervalar), o ICC(2, 1) = 0.672 de juiz único, e — a quantidade operativa — a confiabilidade da *média* do painel, ICC(2, 4) = **0.891**, que, pela relação de Spearman-Brown, é alta ainda que juízes individuais concordem apenas moderadamente. A concordância pareada é mais forte entre GPT-5-mini, Claude e DeepSeek (Pearson 0.82–0.86) e mais baixa para o Gemini, sistematicamente mais leniente (0.61–0.63); como todos os efeitos reportados são contrastes entre grupos, esse offset de leniência se cancela. Um quinto juiz (Llama 3.3 70B, Meta) corroborou no subconjunto que cobriu (Pearson pareado 0.51–0.60; ICC(2, 5) = 0.86 de cinco juízes), mas, por ser um juiz de 70B mais ruidoso, *baixou* ligeiramente o α do painel — confirmando empiricamente que quatro juízes fortes são preferíveis a cinco com um mais fraco. Um sexto candidato (Command R+) foi excluído quando sua cota de provedor se esgotou durante a execução. O estudo usa o composto único do GPT-5-mini para todos os efeitos, validado por este painel, em vez de uma pontuação média entre juízes.

4.12 Robustez do gradiente de desenvolvimento

Como o gradiente é significativo apenas na amostra estendida, testamos duas ameaças diretamente. **Extensão de amplitude.** A preocupação é que adicionar dez países — sete deles do Norte Global — fabrique o gradiente ao esticar o preditor IDH. Não fabrica: os dez países adicionados caem *dentro* da amplitude de IDH já abrangida pelos quinze originais ($[0.548, 0.950]$, da Nigéria à Alemanha), de modo que a extensão aumenta a *densidade* de observações, e não a amplitude, e a estimativa de Spearman é idêntica no conjunto restrito-à-amplitude ($\rho = 0.512$, $p = 0.009$). O gradiente fortaleceu-se de $n = 15$ para $n = 25$ não porque a amplitude do preditor se alargou, mas porque as referências de alto IDH adicionadas pontuam consistentemente bem, agudizando uma associação que a amostra menor estava subpotente para detectar. **Observações influentes.** A reestimação leave-one-country-out dá uma faixa de gradiente-IDH de $\rho \in [+0.48, +0.66]$ em todas as 25 remoções, de modo que nenhum país único o dirige; notavelmente, remover a Índia — o país do Sul Global que pontua mais alto e é o contraexemplo mais forte ao gradiente — *eleva* a correlação para $\rho = 0.66$. A Índia, portanto, não está sustentando o gradiente, mas atenuando-o, e o mesmo exercício leave-one-out deixa estáveis a diferença de camada ($[+5.8, +7.1]$ pp) e a correlação exploratória de sitelinks ($[+0.50, +0.63]$). Lemos a Índia como consistente com — e não contrária a — a explicação de cobertura de país: ela está entre os países mais extensamente documentados em fontes enciclopédicas e multilíngues, exatamente a condição sob a qual o sinal de cobertura prediz maior acurácia, razão pela qual pontua mais alto em inglês apesar de seu nível de desenvolvimento.

Robustez da métrica. O composto mistura cinco subcomponentes, então poder-se-ia temer que ele dilua ou fabrique os efeitos. Restringir ao subcomponente único mais objetivo — acurácia factual contra o valor do registro, ignorando completude, calibração e estilo — *fortalece* todo resultado principal: a diferença de camada amplia-se para +10.7 pp (versus +6.2 no composto), e o piso de recuperação factual aprofunda-se (acurácia factual de T1+T2 0.25 versus 0.71 para T3–T5). O composto é, portanto, conservador; os efeitos geográfico e de tarefa não são artefatos de misturar subcomponentes.

4.13 Síntese

A Tabela 6 mapeia cada hipótese a seu achado, ao mecanismo candidato e a um status de evidência explícito, de modo que nenhuma afirmação seja lida como mais forte do que os dados sustentam.

A expansão agudiza o resultado central enquanto deixa intactos os achados secundários. **Sustentados, com tamanhos de efeito:** uma *diferença de camada* Norte/Sul (+6.2 pp, IC bootstrap de 95% $[+3.7, +8.6]$, exclui zero) e, a $n = 25$, um *gradiente de desenvolvimento* significativo (Spearman $\rho = 0.51$ com IDH, $p = 0.004$; Mann-Kendall $p = 0.018$; rejeita sob Bonferroni-Holm) que estava subpotente no $n = 15$ pré-registrado; uma *penalidade* de idioma nativo (geral $p = 2 \times 10^{-3}$, hindi -7.8 pp, português agora significativo); um *piso* de recuperação técnica/local (T1+T2 vs demais, $\delta = -0.64$); e o modelo regional como o *pior* desempenho ($\delta = -0.51$). **Não sustentados (nulos informativos):** o gradiente *não* é de recurso linguístico (Joshi $\rho = -0.06$) e fica logo abaixo do limiar de tamanho de efeito pré-registrado de 0.55; o proxy de corpus pré-registrado (tamanho da Wikipédia) *não* é o mecanismo (parcial $\rho = 0.04$),

Tabela 6: Hipóteses, achados, mecanismos candidatos e status de evidência.

Hipótese	Achado	Mecanismo candidato	Status de evidência
H1 (diferença de camada)	+6.2 pp, IC exclui zero	desenvolvimento (camada)	Sustentado
H1 (gradiente)	$\rho = 0.51$ com IDH ($n = 25$)	desenvolvimento (IDH)	Sustentado; abaixo do 0.55 pré-registrado
H2 (idioma)	-2.1 pp; hindi -7.8	tamanho do corpus do idioma	Efeito sustentado; mecanismo descritivo ($n = 3$)
H3 (modelo regional)	$\delta = -0.51$	escala > ajuste regional	Sustentado
H4 (mec. geográfico)	sitelinks $\rho = 0.54$	cobertura de país	Exploratório (atenua com IDH)
H4 (pré-registrado)	tamanho-Wikipédia nulo	tamanho do corpus do idioma	Não sustentado
H5 (aberto/fechado)	+14.1 pp fechado	tipo de acesso / escala	Descritivo
H6 (persona)	DiD +0.4 pp	—	Não sustentado

e um proxy de cobertura de país (sitelinks $\rho = 0.54$, $p = 0.005$) é sugestivo, mas *não* robusto ao ajuste por IDH (parcial $p = 0.13$), deixando o mecanismo exploratório; e a persona *não* estreita a lacuna (permutação $p = 0.26$). A desvantagem geográfica é um gradiente de desenvolvimento real e robusto a leave-one-out, cujo mecanismo localizamos apenas *sugestivamente* na representação de país, e não no tamanho do corpus do idioma; os danos robustos dominantes são *linguísticos* (prompt em idioma nativo, pior para o hindi) e *específicos de tarefa* (recuperação factual da regulação ou do dado em vigor); e todas as três correções intuitivas — uma persona de gestor local, o idioma local e um modelo regional — falham. O gabarito está ancorado em fontes oficiais primárias para todos os 25 países, e a confiabilidade da média do painel é forte ($\text{ICC}(2, 4) = 0.89$). Isso importa para a gestão ambiental no Sul Global, onde a carga de doença é grande [1, 39] e onde justamente as tarefas mais difíceis — recuperar o padrão vinculante ou o valor medido — são as de que um gestor mais precisa [3, 4].

5 Discussão

Propusemo-nos a medir se os LLMs respondem a questões de política de poluição do ar de modo tão confiável para o Sul Global quanto para o Norte Global, se o enquadramento do prompt altera a resposta e que mecanismo dirige qualquer lacuna. O benchmark — 25 países, 14 modelos, quatro idiomas, cinco tarefas, duas personas, pontuado por um juiz validado por painel contra gabarito oficial — retorna um quadro disciplinado e em parte contraintuitivo. Uma desvantagem geográfica existe e, com poder adequado, resolve-se em um gradiente de desenvolvimento genuíno; mas seu mecanismo é a representação de país, e não o tamanho do corpus do idioma, os danos dominantes são linguísticos e específicos de tarefa, e toda correção intuitiva falha. Organizamos a discussão em torno do gradiente e seu mecanismo, dos danos robustos, das três correções fracassadas, dos riscos de saúde pública, das limitações que delimitam as afirmações e do que se

segue para a prática.

5.1 A lacuna geográfica é um gradiente de desenvolvimento — visível só com poder

No $n = 15$ pré-registrado, a *diferença de camada* Norte/Sul era real (+6.7 pp, IC exclui zero), mas o *gradiente* era indetectável (Spearman vs IDH $\rho = 0.14$, $p = 0.31$). Estendendo a amostra para 25 países — adicionando sete referências de alto IDH do Norte Global que adensam a ponta de alto desenvolvimento da amostra (sem alargar sua amplitude; Seção 4.12) — o gradiente resolve-se em significância ($\rho = 0.51$ com IDH, $p = 0.004$; Mann-Kendall $p = 0.018$), o único teste da família primária que rejeita sua nula sob Bonferroni-Holm. Somos deliberadamente transparentes de que esta é uma extensão pós-registro e de que $\rho = 0.51$ fica logo abaixo do limiar de tamanho de efeito pré-especificado de 0.55: a afirmação honesta é que o gradiente é significativo, porém de magnitude moderada, e que estava subpotente, não ausente, no desenho registrado. Isso é, por si só, uma lição metodológica para a área — gradientes de viés geográfico entre um punhado de países são fáceis de perder a n pequeno, e o nulo a $n = 15$ teria sido a conclusão errada.

Crucialmente, o gradiente é em *desenvolvimento* (IDH), não em classe de recurso linguístico (Joshi $\rho = -0.06$), e coexiste com grande heterogeneidade específica de país: a Índia lidera todos os 25 países apesar de ser do Sul Global, e a Alemanha é o país do Norte Global de menor pontuação. A desvantagem é um gradiente de desenvolvimento sobreposto a substancial idiosincrasia, e não uma classificação limpa, razão pela qual o contraste de camada e o gradiente são descrições complementares, e não redundantes.

5.2 Um mecanismo sugestivo: cobertura de país acima do tamanho do corpus do idioma

Nosso teste de mecanismo pré-registrado falha: o proxy de tamanho da Wikipédia é nulo (parcial $\rho = 0.04$), de modo que a H4 como registrada não é sustentada. Explorando mais, encontramos uma pista mais promissora. Como a lacuna é medida *em inglês*, com o idioma da consulta mantido constante, uma diferença Norte/Sul residual não pode ser um efeito de quanto texto existe no idioma de um país; e o candidato que *de fato* acompanha a acurácia é quão amplamente o corpus representa o país — os sitelinks do Wikidata correlacionam-se a $\rho = 0.54$ ($p = 0.005$, sobrevivendo à correção de multiplicidade entre três proxies de cobertura). Somos deliberadamente cautelosos sobre este resultado: a associação *atenua-se até a não-significância após ajuste para o desenvolvimento* (parcial $\rho = 0.32$, $p = 0.13$), de modo que cobertura de país e IDH estão entrelaçados e o desenho presente não consegue estabelecer que a cobertura *cause* a lacuna. Oferecemos, portanto, o contraste cobertura-de-país-acima-de-tamanho-de-idioma como um *refinamento sugestivo e testável* da intuição de “menos dados para regiões sub-representadas” — que o caso da Índia ilustra (sua altíssima cobertura enciclopédica multilíngue acompanha sua pontuação máxima em inglês) e que a análise leave-one-out mostra não ser dirigida por nenhum país único — em vez de como mecanismo estabelecido. Se replicar sob um desenho que consiga separar cobertura de desenvolvimento, isso reenquadraria a mitigação para quão abrangentemente um país é descrito em fontes amplamente espelhadas, e não para o tamanho do corpus

810 web de seu idioma.

811 5.3 Os danos robustos são linguísticos e específicos de tarefa

812 Dois achados são grandes, significativos e estáveis em ambas as amostras. Primeiro, o **piso de**
813 **recuperação factual**: as duas tarefas que exigem um valor vinculante específico — o padrão
814 nacional (T1) e uma concentração medida por cidade-ano (T2) — pontuam em torno de 0.37,
815 muito abaixo de síntese e recomendação (0.64; $\delta = -0.64$). O piso recai justamente sobre
816 os valores vinculantes em que um gestor mais precisa confiar. Segundo, a **penalidade de**
817 **idioma nativo**: perguntar no idioma local reduz a acurácia (-2.1 pp no geral, $p = 0.002$),
818 desprezivelmente para o espanhol de alto recurso, mas materialmente para o hindi (-7.8 pp). A
819 penalidade acompanha o tamanho do corpus do idioma entre os três idiomas nativos, o mecanismo
820 que a hierarquia de recurso prediz [3, 12]. Juntos, esses achados dizem que o risco prático é
821 concentrado, não difuso: um gestor recuperando um limiar regulatório, especialmente em um
822 idioma de menor recurso, está na pior célula do desenho.

823 5.4 Três correções intuitivas, todas falhando

824 A contribuição aplicada é em grande parte negativa. A **persona de gestor local** não estreita
825 a lacuna (DiD $+0.4$ pp, permutação $p = 0.26$); apresentar a consulta como vinda de um gestor
826 ambiental público não muda nada, consistente com a evidência de que personas de especialista
827 não melhoram a acurácia factual [27, 28]. O **idioma local** não ajuda e pode prejudicar (H2).
828 O **modelo regional** — o brasileiro-português Cabra-Mistral 7B — é o *pior* desempenho dos
829 14 ($\delta = -0.51$), de modo que recorrer a um pequeno modelo ajustado localmente abre mão da
830 escala e do treinamento de fronteira que de fato carregam a acurácia de domínio. Profissionais
831 rotineiramente implantam as três como correções; nenhuma sobrevive ao contato com os dados.
832 A mensagem honesta para as agências ambientais do Sul Global é que nenhuma das soluções
833 baratas em nível de prompt ou de modelo substitui a verificação do valor vinculante contra a
834 fonte oficial.

835 5.5 Por que o domínio importa

836 Os riscos não são abstrações de benchmark. O material particulado fino está entre os principais
837 fatores de risco ambiental para mortalidade prematura, e o ônus recai desproporcionalmente sobre
838 o Sul Global; o Global Burden of Disease atribui da ordem de cinquenta mil mortes por ano só
839 no Brasil à exposição ao $PM_{2.5}$ [1], e a exposição de curto prazo continua a dirigir mortalidade
840 mensurável em cidades brasileiras [39]. Quando um gestor delega uma consulta normativa ou
841 uma recomendação de episódio a um LLM, uma resposta imprecisa pode se propagar para um
842 parecer regulatório ou uma resposta de emergência. O alinhamento é a parte preocupante: as
843 regiões nas classes inferiores da hierarquia de recurso [3] e com cobertura enciclopédica mais
844 rala são também onde a poluição do ar mais mata, de modo que o modelo é menos confiável
845 exatamente onde as consequências são maiores. Lemos todo o padrão dentro do arcabouço da
846 colonialidade do saber [4]: os LLMs são sínteses comprimidas de corpora produzidos sob acesso
847 digital e de publicação desigual, e o gradiente de desenvolvimento, o mecanismo de cobertura de

país e a penalidade de idioma são três elos mensuráveis da assimetria de corpus à assimetria de conhecimento.

5.6 Limitações

Juiz primário único. Todos os efeitos usam o composto do GPT-5-mini. Tratamos a sobreposição juiz-alvo com um painel de quatro fornecedores em uma amostra fixa (média do painel $ICC(2, 4) = 0.89$), mas não fazemos média dos juízes para a pontuação primária, e a concordância de juiz individual é apenas moderada ($\alpha = 0.67$); um quinto juiz mais leniente baixou o α , ressaltando a sensibilidade residual do juiz. Como todos os efeitos reportados são contrastes entre grupos, o offset de leniência de um juiz se cancela, o que é o que torna o composto de juiz único defensável aqui.

Sem camada de padrão-ouro humano. O gabarito está ancorado em fontes oficiais primárias por auditoria documental, e não por pontuação humana independente. Isso é altamente reproduzível (cada valor re-verificável a partir de uma URL citada), mas não captura o julgamento de especialista nas tarefas pontuadas por rubrica (T3, T5). Duas características mitigam parcialmente a preocupação de que as pontuações reflitam o juiz em vez das respostas: o painel de juízes de quatro fornecedores ($ICC(2, 4) = 0.89$) e o fato de que restringir à acurácia factual objetiva fortalece, em vez de enfraquecer, os efeitos (Seção 4.12), de modo que as lacunas principais não são artefato de um composto permissivo. Uma validação cega por especialista humano de uma amostra estratificada de respostas, pontuada contra a mesma rubrica com a concordância humano-juiz reportada, permanece o próximo passo natural e é diferida ao painel de coautores.

Expansão pós-registro. O resultado de 25 países é uma extensão decidida após a análise registrada; reportamo-lo ao lado dos valores de $n = 15$ e o tratamos como uma checagem de poder e robustez, mas uma replicação confirmatória a $n = 25$ fortaleceria a afirmação do gradiente, que atualmente fica logo abaixo do limiar de tamanho de efeito pré-especificado.

Covariáveis grosseiras e três idiomas nativos. Os proxies de corpus são públicos e reproduzíveis, porém grosseiros; o mecanismo de corpus do idioma para H2 repousa em apenas três idiomas nativos e é reportado descritivamente; e os idiomas nativos da Oceania e de Classe 0 de Joshi permanecem fora de escopo.

Domínio único. Todos os efeitos vêm de um único domínio aplicado (política de poluição do ar) e de uma única família de proxies de corpus (Wikimedia). O gradiente de desenvolvimento e o sinal de cobertura de país podem não transferir para outros domínios de política com padrões de documentação diferentes, e confinamos a linguagem mecanística e de “alavanca tratável” a este domínio, em vez de ao viés geográfico de LLMs em geral; a replicação entre domínios é o próximo passo natural.

A stack do modelo servido como unidade de análise. Cada modelo é avaliado tal como servido por meio de uma stack de acesso fixa (API do fornecedor ou endpoint de inferência fixado), de modo que a infraestrutura do provedor, a configuração de serving e a camada de API são parte do que cada rótulo denota. Mantemos a stack constante dentro da janela de coleta, mas uma lacuna geográfica residual poderia, em princípio, refletir a stack em vez dos pesos; desemaranhar pesos de infraestrutura — como um desenho controlado de quase-isolamento poderia — está além do escopo deste estudo, e reportamos a lacuna como propriedade da stack servida que um

gestor público de fato consulta, e não de pesos idealizados.

5.7 Implicações

Para as agências ambientais do Sul Global, a orientação operacional é concreta: tratar as saídas de LLM sobre padrões vinculantes e dados medidos como rascunhos a serem checados contra o diário oficial, não presumir que uma consulta em idioma local ou um pequeno modelo ajustado regionalmente melhore a acurácia, e não confiar no enquadramento por papel para fechar a lacuna. Para os desenvolvedores de modelos, o resultado de cobertura de país aponta para uma alavanca tratável — abrangência de representação enciclopédica — distinta do volume bruto de corpus do idioma. Para a comunidade de mensuração, a reversão de $n = 15$ para $n = 25$ é uma advertência de que gradientes de viés geográfico são facilmente subpotentes. Esses são os elos que o estudo se propôs a sondar, e os dados transformam cada um de uma preocupação plausível em um efeito medido com gabarito ancorado em fonte oficial.

6 Conclusão

Os grandes modelos de linguagem estão se tornando infraestrutura operacional para a política de poluição do ar, um domínio em que uma resposta imprecisa sobre um padrão vinculante, uma concentração medida ou uma resposta operacional carrega riscos diretos de saúde pública no Sul Global, onde a carga de mortalidade por $PM_{2.5}$ é mais pesada [1, 39]. Medimos o viés geográfico e modulado por persona nesse domínio com um benchmark de 25 países, 14 modelos e quatro idiomas, pontuado por um juiz validado por painel contra gabarito ancorado em fontes oficiais primárias para cada país.

A desvantagem geográfica é real e, dado poder adequado, resolve-se em um gradiente de desenvolvimento significativo (Spearman $\rho = 0.51$ com IDH a $n = 25$, tendo sido indetectável no $n = 15$ pré-registrado, robusto a leave-one-out, mas abaixo do nosso limiar de tamanho de efeito pré-registrado), ao lado de uma diferença de camada Norte/Sul estável de +6.2 pp. O mecanismo é mais difícil de fixar: o proxy de corpus pré-registrado é nulo, e um proxy de cobertura de país correlaciona-se com a acurácia ($\rho = 0.54$), mas não sobrevive ao ajuste para desenvolvimento, de modo que reportamos a representação de país — e não o tamanho do corpus do idioma — como uma pista *sugestiva* coerente com uma lacuna medida em inglês, e não como mecanismo estabelecido. Os danos dominantes são linguísticos (o prompt em idioma nativo reduz a acurácia, pior para o hindi) e específicos de tarefa (um piso acentuado de recuperação factual em padrões e dados medidos, $\delta = -0.64$). E as três correções intuitivas todas falham: uma persona de gestor local não estreita a lacuna ($p = 0.26$), o idioma local não ajuda e pode prejudicar, e o modelo regional brasileiro-português é o pior de todos os sistemas ($\delta = -0.51$).

A mensagem honesta para as agências ambientais do Sul Global é, portanto, concreta e em grande parte cautelar: as saídas de LLM sobre padrões vinculantes e dados medidos devem ser tratadas como rascunhos checados contra o diário oficial, e nenhuma das soluções baratas em nível de prompt ou de modelo — enquadramento por papel, o idioma local, um pequeno modelo ajustado regionalmente — substitui essa verificação. Para os desenvolvedores de modelos, o resultado de cobertura de país identifica uma alavanca tratável distinta do volume bruto de corpus.

Lemos o padrão dentro do arcabouço da colonialidade do saber [4]: as regiões sub-atendidas nos corpora de treinamento [3] são as mesmas em que a poluição do ar mais mata, e este estudo transforma dois desses elos — um gradiente de desenvolvimento e uma penalidade de idioma — de preocupações plausíveis em efeitos medidos, enquanto localiza um terceiro (cobertura de país) apenas sugestivamente. Reportamos também uma advertência metodológica: a reversão de $n = 15$ para $n = 25$ mostra que gradientes de viés geográfico são facilmente subpotentes, e sinalizamos a expansão como uma extensão pós-registro cujo gradiente fica logo abaixo do nosso limiar de tamanho de efeito pré-especificado. Protocolo, prompts, registro de gabarito ancorado em fontes oficiais, código de análise e dados anonimizados de resposta são liberados abertamente.

Disponibilidade de dados e código

O protocolo completo, os prompts e o código de análise serão liberados na publicação em github.com/Roverlucas/artigo-vies-analise-regional sob as licenças MIT (código) e CC-BY-4.0 (dados/prompts/documentação), juntamente com o registro de gabarito e as respostas anonimizadas dos LLMs. O pipeline de análise é reproduzível de ponta a ponta via `python code/run_all.py`.

Protocolo do estudo

O plano de análise estatística foi pré-especificado para o desenho confirmatório de 15 países. As análises confirmatórias seguem essas especificações; a extensão pós-registro para 25 países e as análises exploratórias (notavelmente o proxy de cobertura de país de H4) são rotuladas explicitamente e reportadas ao lado de suas contrapartes pré-registradas de 15 países. O protocolo completo, os prompts, o registro de gabarito e o código de análise serão liberados na publicação.

Agradecimentos

Este trabalho foi apoiado por **[fontes de financiamento]**. Reconhecemos os programas de crédito de pesquisa da OpenAI, Anthropic e Google pelo apoio parcial aos custos de API.

Contribuições dos autores

Seguindo a taxonomia CRediT:

- **Lucas Rover (UTFPR):** Conceituação, Metodologia, Software, Curadoria de Dados, Análise Formal, Investigação, Visualização, Redação – Rascunho Original, Administração do Projeto.
- **Dr. Eduardo Tadeu Bacalhau (UFPR):** Validação, Supervisão, Redação – Revisão & Edição.
- **Dra. Yara de Souza Tadano (UTFPR):** Validação, Supervisão, Redação – Revisão & Edição, Obtenção de Financiamento.

Validação, supervisão e revisão final do manuscrito são compartilhadas por Dr. Eduardo Tadeu Bacalhau (UFPR) e Dra. Yara de Souza Tadano (UTFPR).

Declaração de interesses

Os autores declaram não haver interesses concorrentes.

Referências

- [1] GBD 2019 Risk Factors Collaborators. Global burden of 87 risk factors in 204 countries and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019. *The Lancet*, 396(10258):1223–1249, 2020. doi: 10.1016/S0140-6736(20)30752-2.
- [2] World Health Organization. WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Technical report, World Health Organization, Geneva, 2021. URL <https://iris.who.int/handle/10665/345329>.
- [3] Pratik Joshi, Sebastin Santy, Amar Budhiraja, Kalika Bali, and Monojit Choudhury. The state and fate of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-main.560.
- [4] Shakir Mohamed, Marie-Therese Png, and William Isaac. Decolonial AI: Decolonial theory as sociotechnical foresight in artificial intelligence. *Philosophy & Technology*, 33(4):659–684, 2020. doi: 10.1007/s13347-020-00405-8.
- [5] OECD. Governing with artificial intelligence: The state of play and way forward in core government functions. Technical report, OECD Publishing, Paris, 2024. URL https://www.oecd.org/en/publications/governing-with-artificial-intelligence_795de142-en.html.
- [6] Mazda Moayeri, Elham Tabassi, and Soheil Feizi. Worldbench: Quantifying geographic disparities in LLM factual recall. In *Proceedings of the 2024 ACM Conference on Fairness, Accountability, and Transparency*, pages 1211–1228, Rio de Janeiro, Brazil, 2024. doi: 10.1145/3630106.3658967.
- [7] Rohin Manvi, Samar Khanna, Marshall Burke, David Lobell, and Stefano Ermon. Large language models are geographically biased. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2402.02680.
- [8] Shujaat Mirza, Bruno Coelho, Yuyuan Cui, Christina Pöpper, and Damon McCoy. Global-liar: Factuality of LLMs over time and geographic regions. *arXiv preprint arXiv:2401.17839*, 2024.
- [9] Emily M. Bender, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, pages 610–623, 2021. doi: 10.1145/3442188.3445922.

- [10] Junho Myung et al. BLEnD: A benchmark for LLMs on everyday knowledge in diverse cultures and languages. *Advances in Neural Information Processing Systems*, 37:78104–78146, 2024.
- [11] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith, and Douglas C. Schmidt. A prompt pattern catalog to enhance prompt engineering with ChatGPT. *arXiv preprint arXiv:2302.11382*, 2023.
- [12] Linting Xue, Noah Constant, Adam Roberts, Mihir Kale, Rami Al-Rfou, Aditya Siddhant, Aditya Barua, and Colin Raffel. mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 483–498, 2021. doi: 10.18653/v1/2021.naacl-main.41.
- [13] Julien Abadji, Pedro Ortiz Suárez, Laurent Romary, and Benoît Sagot. Towards a cleaner document-oriented multilingual crawled corpus. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 4344–4355, 2022.
- [14] Brian A. Nosek, Charles R. Ebersole, Alexander C. DeHaven, and David T. Mellor. The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606, 2018. doi: 10.1073/pnas.1708274114.
- [15] Aníbal Quijano. Coloniality of power, eurocentrism, and Latin America. *Nepantla: Views from South*, 1(3):533–580, 2000.
- [16] Nick Couldry and Ulises A. Mejias. *The costs of connection: How data is colonizing human life and appropriating it for capitalism*. Stanford University Press, 2019.
- [17] Catherine D’Ignazio and Lauren F. Klein. *Data feminism*. MIT Press, 2020.
- [18] Unspecified Authors. BRouterbs: Measuring how much LLMs understand Portuguese proverbs. In *Journal of the Brazilian Computer Society*, 2025.
- [19] T. Almeida et al. TiEBE: Temporal and Regional event benchmark for LLMs. *arXiv preprint*, 2025.
- [20] Unspecified Authors. ALBA: A european portuguese benchmark for evaluating language and linguistic dimensions in generative LLMs. *arXiv preprint arXiv:2603.26516*, 2026.
- [21] AMALIA team. AMALIA technical report: A fully open source large language model for european portuguese. Technical report, arXiv:2603.26511, 2026.
- [22] T. Almeida, R. Nogueira, and H. Pedrini. Building high-quality datasets for Portuguese LLMs: From Common Crawl snapshots to industrial-grade corpora. *Journal of the Brazilian Computer Society*, 31(1):1247–1263, 2025.
- [23] M. Opuszkó and P. Böhm. New york, new york – unraveling bias in large language models: Investigating differences between standard and reasoning-based language models. In *AI Revolution: Research, Ethics and Society*, pages 92–106. Springer, 2026.

- [24] F. Kerche, M. Zook, and M. Graham. The silicon gaze: A typology of biases and inequality in LLMs through the lens of place. *Platforms & Society*, 2026. doi: 10.1177/29768624251408919.
- [25] Jiao He et al. What would an LLM do? evaluating policymaking capabilities of large language models. *arXiv preprint arXiv:2509.03827*, 2025.
- [26] Z. Kozlakidis, T. Wootton, and M. T. Mayrhofer. Through the looking glass: ethical considerations regarding LLM-induced hallucinations to medical questions. *Frontiers in Digital Health*, 8:1736616, 2026.
- [27] Mingqian Zheng, Jiaxin Pei, Lajanugen Logeswaran, Moontae Lee, and David Jurgens. When “a helpful assistant” is not really helpful: Personas in system prompts do not improve performances of large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15126–15154, 2024. doi: 10.18653/v1/2024.findings-emnlp.888.
- [28] Lennart Meincke, Basir Savir, Ina Shapiro, Dan Shapiro, Lilach Mollick, and Ethan R. Mollick. Prompting science report 4 — playing pretend: Expert personas don’t improve factual accuracy. SSRN Working Paper, 2025. SSRN id 5879722.
- [29] Michael Quinn Patton. *Qualitative research and evaluation methods*. SAGE Publications, 4th edition, 2015.
- [30] UNCTAD. UNCTAD statistical classifications — june 2024 update. Technical report, UN Trade and Development, 2024. URL <https://unctadstat.unctad.org/EN/Classifications.html>.
- [31] World Bank Group. World Bank Country and Lending Groups — FY26 Classification. Technical report, The World Bank, 2025. URL <https://datahelpdesk.worldbank.org/knowledgebase/articles/906519>.
- [32] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995. doi: 10.1111/j.2517-6161.1995.tb02031.x.
- [33] Tyler J. VanderWeele and Peng Ding. Sensitivity analysis in observational research: introducing the E-value. *Annals of Internal Medicine*, 167(4):268–274, 2017. doi: 10.7326/M16-2607.
- [34] Eshin Jolly. *pymr4: Connecting R and Python for linear mixed modeling*, 2018.
- [35] Douglas Bates, Martin Mächler, Ben Bolker, and Steve Walker. Fitting linear mixed-effects models using lme4. *Journal of Statistical Software*, 67(1):1–48, 2015. doi: 10.18637/jss.v067.i01.
- [36] Anna A. Igolkina and Georgy Meshcheryakov. semopy: A python package for structural equation modeling. *Structural Equation Modeling*, 27(6):952–963, 2020.

- 1069 [37] Oriol Abril-Pla, V. Andreani, C. Carroll, Lan Dong, C. J. Fongesbeck, M. Kochurov, Ravin
1070 Kumar, J. Lao, C. C. Luhmann, O. A. Martin, et al. PyMC: A modern and comprehensive
1071 probabilistic programming framework in Python. *PeerJ Computer Science*, 9:e1516, 2023.
- 1072 [38] Lucas Rover, Eduardo Tadeu Bacalhau, and Yara Tadano. Geographic bias in LLMs: Ben-
1073 chmark dataset and code, 2026. To be deposited on publication.
- 1074 [39] Weeberb J. Requia, Ana Maria Vicedo-Cabrera, Heresh Amini, and Joel D. Schwartz. Short-
1075 term air pollution exposure and mortality in Brazil: Investigating the susceptible population
1076 groups. *Environmental Pollution*, 340:122797, 2024. doi: 10.1016/j.envpol.2023.122797.