

De quem é a regulação que o modelo conhece?
Confiabilidade da informação regulatória que os LLMs
recordam para a gestão ambiental pública em 25 países

Lucas Rover^{1,*}
Vitor de Melo Dominski²
Anibal Tavares de Azevedo³
Eduardo Tadeu Bacalhau⁴
Yara de Souza Tadano¹

¹ Universidade Tecnológica Federal do Paraná (UTFPR), Brasil

² Faculdade Descomplica, Brasil

³ Universidade Estadual de Campinas (Unicamp), Brasil

⁴ Universidade Federal do Paraná (UFPR), Brasil

* Autor correspondente: lucasrover@alunos.utfpr.edu.br

ORCID: L.R. 0000-0001-6641-9224 · V.M.D. 0009-0001-0209-9089 · A.T.A. 0000-0003-1678-7795 · E.T.B. 0000-0002-39

21 de setembro de 2026

Resumo

Um gestor ambiental municipal pergunta a um modelo de linguagem qual é o padrão vinculante de PM_{2,5} em seu país, e nada na resposta diz se ela corresponde ao registro oficial. Propomos um protocolo para essa conferência e relatamos o que ele encontra. As respostas são pontuadas contra registros oficiais, por código sempre que a resposta correta é um valor publicado e por um painel de juízes de três fornecedores nos demais casos, em 25 países, 14 configurações de acesso e quatro idiomas (8.244 células pontuadas). As três mitigações que um órgão consegue implantar sem construir nada falham. Perguntar no idioma do próprio país reduz a acurácia em 5.0 pontos percentuais (modelo misto com intercepto aleatório por país, $p = 6 \times 10^{-7}$) e torna o modelo 9.4 pontos menos propenso a devolver um valor conferível contra o registro; declarar o papel oficial não muda nada ($p = 0.29$); e um modelo de 7B com ajuste regional fica em último entre os catorze. A acurácia é mais baixa na tarefa com consequência administrativa, recordar o valor vinculante (0.39 contra 0.61 para síntese e recomendação). Uma lacuna Norte/Sul de +5.0 pp persiste (permutação por país, $p = 0.019$), é maior nos desfechos que nenhum juiz toca e se concentra nas tarefas cuja resposta é um fato nacional; no padrão nacional a razão de chances é 0.44, com intervalo por país de [0.18, 1.05]. Um mecanismo de cobertura de corpus não se estabelece quando a inferência é feita no nível do país. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada.

1 Introdução

Os grandes modelos de linguagem tornaram-se infraestrutura de trabalho da administração pública em poucos anos. Um levantamento da OCDE sobre funções centrais de governo documenta a adoção de IA generativa em formulação de políticas e prestação de serviços, incluindo assistentes que ajudam assessores do serviço público a recuperar informação e as fontes por trás dela (OECD, 2025). A política de poluição do ar é um domínio em que isso tem consequência direta para a saúde pública. O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura no mundo (GBD 2019 Risk Factors Collaborators, 2020; World Health Organization, 2021), e a carga recai de forma desproporcional sobre o Sul Global. Quando um gestor ambiental pergunta a um modelo sobre um padrão de qualidade do ar, um prazo de atendimento ou a evidência por trás de uma intervenção, uma resposta imprecisa pode se propagar para um parecer regulatório, uma decisão de compra ou uma resposta de emergência durante um episódio de poluição.

Este artigo pergunta se os modelos respondem a essas questões com a mesma confiabilidade para países do Sul Global e do Norte Global, e se a forma de enquadrar a consulta muda a resposta. As duas premissas têm apoio. O viés factual geográfico é mensurável: as taxas de erro são $1,5\times$ maiores para países da África Subsaariana do que para a América do Norte em 20 modelos (Moayeri et al., 2024), as avaliações dos modelos sobre temas subjetivos acompanham condições socioeconômicas até $\rho = 0,70$ (Manvi et al., 2024), e os modelos privilegiam sistematicamente afirmações sobre o Norte Global (Mirza et al., 2024). A assimetria linguística por trás disso é estrutural: os idiomas da maioria dos países do Sul Global ocupam as classes mal servidas da hierarquia de recursos (Joshi et al., 2020), e grandes corpora derivados da Internet “super-representam pontos de vista hegemônicos e codificam vieses potencialmente danosos a populações marginalizadas” (Bender et al., 2021). A produção decolonial lê essa assimetria como uma infraestrutura epistêmica desigual reproduzida pelos sistemas de IA (Mohamed et al., 2020).

Três lacunas organizam o estudo. Nenhum benchmark visa informação regulatória com gabarito oficial: as avaliações existentes usam recordação de indicadores do Banco Mundial, avaliações subjetivas, checagem jornalística ou conhecimento cultural cotidiano, e nenhuma mede as tarefas que um gestor delega, como enunciar um padrão vinculante, recuperar uma concentração medida oficialmente, resumir a evidência de carga de doença, identificar instrumentos legais e órgãos executores ou recomendar uma resposta operacional. O enquadramento por persona não foi examinado como alavanca experimental, embora os praticantes prefixem um papel rotineiramente e os fornecedores o recomendem (Seção 2); se ele reduz a lacuna, ao direcionar para respostas conformes à regulação, ou a amplia, ao convidar à fabricação confiante, não foi testado em desenho pré-especificado. E o mecanismo de representação no corpus costuma ser afirmado em vez de medido contra confundidores, e raramente é separado em seus dois canais, o tamanho do corpus do idioma (Xue et al., 2021; Abadji et al., 2022) e a amplitude da cobertura do país, distinção que importa aqui porque a lacuna geográfica é medida em inglês.

Objetivos e escopo

O estudo tem três objetivos delimitados. O primeiro é estabelecer um protocolo de auditoria de informação regulatória. Seu objeto é a concordância entre a resposta de um modelo e o valor publicado no registro oficial, para tarefas que um órgão ambiental delega; ele não mede capacidade geral do modelo, qualidade de raciocínio ou utilidade para outros fins. O protocolo é a contribuição que se transfere, e o domínio é onde o demonstramos. O segundo é testar as mitigações disponíveis a uma administração. Um órgão público diante de respostas ruins sobre o próprio país pode declarar o papel oficial no prompt, perguntar no idioma nacional ou rodar um modelo aberto com ajuste regional, e testamos as três como fatores de desenho. O modelo regional que pudemos rodar é um ajuste comunitário de uma base de 7B em português brasileiro, do tipo que um órgão consegue baixar; o achado diz respeito a essa classe, e o protocolo liberado permite testar qualquer outro candidato. Não testamos recuperação aumentada, ajuste fino ou verificação com humano no circuito, que exigem capacidade que a maioria dos órgãos da nossa amostra do Sul Global não tem. Todas as consultas são respondidas a partir da memória paramétrica do modelo, sem busca na web nem recuperação de documentos, e por isso o título fala em informação recordada, e não recuperada. O terceiro objetivo é localizar onde a confiabilidade difere e, até onde o desenho permite, por quê; testamos a explicação por representação no corpus e não reivindicamos identificação causal.

Ao longo do texto, a unidade de análise é o modelo tal como servido, isto é, pesos, fornecedor e infraestrutura de serviço alcançados por um endpoint fixado, porque o gestor público interage com essa configuração e qualquer lacuna medida é propriedade dela. Hipóteses, amostragem e plano de análise foram fixados antes da coleta (Nosek et al., 2018) para 15 países e depois estendidos a 25; o plano nunca foi depositado publicamente, portanto não reivindicamos pré-registro, e o estudo é relatado como exploratório do início ao fim.

Contribuições deste trabalho

1. *Um protocolo de auditoria para informação regulatória.* A pergunta que uma administração enfrenta é se o valor que o modelo devolve corresponde ao registro oficial. Construímos cinco tipos de tarefa a partir do trabalho cotidiano de um órgão ambiental (Tabela 1), cada um atrelado a uma fonte oficial, de modo que a correção é adjudicável em vez de uma questão de impressão de especialista, e o protocolo se transfere a qualquer domínio regulado em que a resposta correta é publicada.
2. *As três correções de localização a que os órgãos recorrem, testadas em vez de presumidas.* Enquadramento por persona, prompt em idioma nativo e modelo com ajuste regional são, cada um, uma decisão de compra ou de fluxo de trabalho. Nenhum funciona, e perguntar no idioma do próprio país reduz a acurácia em 5.0 pontos percentuais, de forma mais acentuada para o idioma de corpus mais escasso.
3. *Um desenho que separa quem é mal servido de por quê, e relata onde não consegue.* Os países são estratificados pela divisão desenvolvido/em desenvolvimento da UNCTAD, pela taxonomia de recursos linguísticos de Joshi e pelo desenvolvimento, de modo que explicações geográficas, linguísticas e econômicas possam ser distinguidas. Entre países, cobertura

e desenvolvimento são colineares; dentro dos países, o contraste por tarefa que sugere um efeito de cobertura no nível da resposta não sobrevive à inferência no nível do país, e relatamos o mecanismo como não estabelecido. Documentamos também que o proxy de corpus pré-especificado atribui a Wikipédia inglesa a todo país da amostra com inglês como língua oficial, de modo que ele acompanha a história colonial e não o tamanho do corpus.

4. *Gabarito adjudicado por código, e o que isso muda.* Reconstruir duas chaves de tarefa a partir de registros oficiais e mover a comparação de faixa para código reduziu o gradiente de desenvolvimento de $\rho = 0,51$ para $\rho = 0.36$ e mais que dobrou a penalidade do idioma nativo nas mesmas respostas; mover a terceira tarefa com valor de registro de um juiz para código removeu um confundimento entre juiz e tier. Nesta literatura, a chave de gabarito, e não o tamanho da amostra, é a restrição que vincula.
5. *Recursos abertos.* Protocolo, prompts, registros de gabarito com suas fontes oficiais, código de análise e o registro de desvios são liberados sob CC-BY-4.0 e MIT, com pipeline de reprodução em um comando.

2 Trabalhos Relacionados

A literatura prévia corre por quatro fios: a medição do viés factual geográfico, extensões multilíngues e culturais, tentativas de mitigação, e o uso de LLMs em contextos de decisão de política e saúde.

2.1 Viés factual geográfico e extensões multilíngues

[Manvi et al. \(2024\)](#) estabeleceram que LLMs de fronteira carregam vieses sistemáticos contra regiões de condições socioeconômicas mais baixas, com correlações de até 0,70 entre avaliações geradas pelo modelo e um proxy dessas condições; o espaço de desfecho são avaliações subjetivas, o que deixa em aberto se o mesmo viés aparece na recordação objetiva de fatos regulatórios. [Moayeri et al. \(2024\)](#) quantificaram a recordação factual contra indicadores do Banco Mundial em 20 LLMs, documentando erro relativo absoluto $1,5\times$ maior para a África Subsaariana do que para a América do Norte; o desenho é limitado pelo espaço de indicadores macroeconômicos, enquanto um gestor ambiental faz perguntas mais estreitas e específicas de fonte, cujo gabarito vive em conselhos ambientais e agências de monitoramento. [Mirza et al. \(2024\)](#) mostraram que versões mais novas do GPT-4 não melhoram monotonicamente e que o privilégio de afirmações sobre o Norte Global persiste.

A literatura de sondagem multilíngue estabeleceu cedo que o que um modelo recorda depende do idioma da consulta. [Jiang et al. \(2020\)](#) sondaram fatos em formato cloze em 23 idiomas e encontraram acurácia abaixo de 15% mesmo em inglês e espanhol e abaixo de 5% em marathi e iorubá, com metade dos fatos corretamente recordados em um único idioma; [Kassner et al. \(2021\)](#) traduziram os mesmos benchmarks para 53 idiomas e encontraram o mBERT abaixo de 60% do seu desempenho em inglês em 32 deles, um viés para entidades do idioma da consulta e nenhuma relação clara entre o tamanho da Wikipédia de um idioma e sua recordação. Esses resultados dizem respeito a codificadores mascarados de 2020; a pergunta que levantam, se a

recordação em um idioma acompanha o corpus desse idioma, é a que H2 e H4 fazem a modelos generativos. [Myung et al. \(2024\)](#) cobriram 16 países e 13 idiomas em conhecimento cultural cotidiano, constatando que os LLMs têm melhor desempenho nos idiomas nativos de culturas de alto recurso e pior nos de baixo recurso, o achado que motiva H2 e se conecta à hierarquia de recursos de [Joshi et al. \(2020\)](#). Benchmarks regionais proliferaram: BRoverbs ([Almeida et al., 2025b](#)), TiEBE ([Almeida et al., 2025c](#)), ALBA ([Vieira et al., 2026](#)) e AMALIA ([Simplicio et al., 2026](#)) documentam falhas concretas em tarefas culturalmente situadas, mas não tratam do uso aplicado em política pública. O trabalho de construção de corpora em português é explícito em que o esforço se concentrou no inglês: [Almeida et al. \(2025a\)](#) montam um corpus de 120 bilhões de tokens em português porque pipelines específicos por idioma são necessários para alcançar qualidade industrial. Essa assimetria na quantidade de texto por idioma é o que H4 testa.

Esses estudos estabelecem que o fenômeno existe e é mensurável. Nenhum isola um único domínio aplicado com gabarito oficial verificável, e nenhum trata o enquadramento do prompt como fator manipulável.

2.2 Mitigação, persona e condicionamento por papel

[Opuszko and Böhm \(2026\)](#) constataram que o raciocínio ajuda no agregado, mas não elimina as disparidades regionais, e [Kerche et al. \(2026\)](#) propuseram uma tipologia baseada em lugar que situa o viés geográfico num panorama sociotécnico mais amplo. Ambos são conceituais e agregados.

O condicionamento por papel é o que os fornecedores instruem os próprios usuários a fazer. A Anthropic documenta a definição de papel no prompt de sistema ([Anthropic, 2026](#)), o guia da OpenAI abre a estrutura de mensagem recomendada com um bloco de identidade ([OpenAI, 2026](#)), a documentação do Gemini, da Google, pede que definições de papel, que ela chama de persona, sejam colocadas na instrução de sistema ([Google, 2026](#)), o exemplo padrão da xAI inicia toda conversa com um prompt de sistema que atribui um papel ([xAI, 2026](#)), e o padrão está catalogado na literatura de prompting ([White et al., 2023](#)). A evidência sistemática sobre se isso ajuda é negativa: em quatro famílias de LLM e 2.410 perguntas factuais, personas de especialista não melhoraram a acurácia em relação a um controle sem persona e a reduziram ligeiramente em 162 papéis ([Zheng et al., 2024](#)). Um estudo independente com seis modelos em questões de múltipla escolha de nível de pós-graduação chega à mesma conclusão: casar uma persona de especialista com o tipo de problema não teve efeito significativo no desempenho ([Basil et al., 2025](#)). Se o condicionamento por persona ajuda ou prejudica a confiabilidade factual em domínios de alto risco é, portanto, questão em aberto e, até onde sabemos, não testada para equidade geográfica. Tratamos a persona como fator experimental pré-especificado e testamos tanto a hipótese de conformidade à norma (a persona reduz a lacuna) quanto a hipótese do vácuo de persona (a persona a amplia).

2.3 LLMs em política, saúde e na administração

[Le Coz et al. \(2025\)](#) avaliaram recomendações de política de LLMs para a situação de rua em quatro cidades (Barcelona, Joanesburgo, South Bend e Macau) e leram o padrão como “uma rigidez cega ao contexto e um viés potencial baseado no discurso online publicado sobre a si-

183 tuação de rua nas regiões do mundo com dados super-representados nos LLMs”, em contraste
184 com especialistas que ajustaram as decisões a realidades codificadas localmente. Trata-se de um
185 domínio e um tipo de tarefa, que generalizamos para cinco tipos de tarefa cobrindo recordação,
186 síntese e recomendação. O precedente mais próximo num domínio regulado é [Dahl et al. \(2024\)](#),
187 que fizeram a quatro modelos públicos perguntas verificáveis sobre casos federais dos Estados
188 Unidos e encontraram taxas de alucinação entre 58% e 88%, mais altas para as cortes inferiores
189 e as jurisdições menos proeminentes, e mais altas de novo para os casos mais antigos e os mais
190 recentes, de modo que o conhecimento dos modelos fica atrás da doutrina em vigor; nosso piso
191 de recordação e a análise da escada na Seção 4.9 são a contraparte ambiental desses dois gradi-
192 entes. Na saúde, [Kozlakidis et al. \(2026\)](#) argumentam que alucinações carregam risco agudo em
193 ambientes regulatórios com capacidade técnica limitada, onde o descompasso de idioma e cultura
194 aumenta o erro, um risco que encontra a carga de mortalidade documentada pelas estimativas
195 do Global Burden of Disease ([GBD 2019 Risk Factors Collaborators, 2020](#)).

196 A questão da implantação já não é hipotética. [Kim \(2026\)](#) estima efeitos de produtividade
197 burocrática da IA generativa de forma quase-experimental, e [Robinson \(2026\)](#) documenta que
198 escolher qual modelo um órgão roda é hoje uma decisão explícita de compra entre opções de pesos
199 abertos e hospedadas pelo fornecedor. Nossos achados no nível do modelo falam a essa decisão:
200 os modelos de pesos abertos, como grupo, ficam +12.8 pontos abaixo dos fechados no composto,
201 ainda que um modelo de pesos abertos (DeepSeek-V3) lidere a lista, e o modelo português com
202 ajuste regional seja o mais fraco dos catorze. Dois outros fios enquadram por que uma resposta
203 errada importa administrativamente. [Choroszewicz \(2026\)](#) mostra que ferramentas de apoio com
204 IA generativa posicionam os profissionais da linha de frente como “zonas de deformação moral”,
205 absorvendo a responsabilidade por falhas originadas a montante, e [Cordella and Gualdi \(2024\)](#), ao
206 analisar a primeira medida vinculante que um regulador impôs a um serviço de IA generativa (a
207 intervenção italiana sobre o ChatGPT), argumentam que arcabouços tecnologicamente neutros
208 ignoram o que é específico desses sistemas e que os reguladores precisam engajar diretamente
209 seu funcionamento técnico. Sobre a recepção, [Aoki et al. \(2024\)](#) testam se o tipo de explicação
210 muda a acurácia, a justiça e a confiabilidade percebidas entre os afetados.

211 Nada disso estabelece se a resposta subjacente está correta, nem se a correção se distribui
212 de forma uniforme entre os Estados que dependem dela. Confiabilidade percebida e acurácia
213 medida são grandezas diferentes, e um sistema pode ser bem explicado, bem governado, bem
214 recebido e errado. Essa é a lacuna que este estudo enfrenta, num domínio em que a resposta
215 correta está publicada num registro oficial e pode ser conferida.

216 2.4 Posicionamento do presente trabalho

217 O desenho difere do trabalho prévio em quatro aspectos: um único domínio aplicado de alto
218 risco com gabarito oficial verificável, em vez de trivialidades numéricas ou conhecimento cultu-
219 ral; persona como fator intra-sujeito pré-especificado, em vez de escolha de enquadramento não
220 controlada; amostragem de países orientada por teoria em eixos independentes (a divisão de-
221 desenvolvido/em desenvolvimento da UNCTAD, recursos linguísticos de Joshi, desenvolvimento),
222 em vez de conveniência regional; e um teste explícito do mecanismo de representação no corpus
223 com análise de sensibilidade. Nenhum estudo anterior combina um domínio regulado de saúde

pública, uma manipulação de persona e um teste de mecanismo pré-especificado.

3 Métodos

3.1 Desenho da pesquisa

O estudo é um experimento de benchmark pré-especificado, fatorial e multipaíses que quantifica o viés geográfico e o viés modulado por persona em 14 grandes modelos de linguagem em tarefas de política de poluição do ar. O desenho pré-especificado cruza 15 países (estratificados em três eixos com fundamento teórico), 14 LLMs em cinco tiers de acesso, um domínio, cinco tipos de tarefa e duas condições de persona, com duas replicações estocásticas por célula; uma extensão post hoc (Seção 3.3) amplia a amostra para 25 países. O conjunto de estímulos cruza as cinco tarefas e as duas personas de cada país em inglês, mais uma versão em idioma nativo, dentro do país, para os nove países com idioma nativo alvo, pontuada no composto $[0, 1]$. O protocolo fixou, antes da coleta, as hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão e as correções para comparações múltiplas. Uma coleta apenas do Brasil executada sob um desenho anterior de três domínios é reclassificada como piloto estendido e relatada à parte; ela informou a calibração dos prompts e não contribui com observações para a análise principal.

3.2 Seleção de países

Os países foram selecionados por amostragem teórica (Patton, 2015) triangulada em três classificações independentes: a distinção Norte/Sul Global, operacionalizada pela classificação de economias desenvolvidas/em desenvolvimento da UNCTAD (UNCTAD, 2024), que carrega o arcabouço da colonialidade do saber que motiva o estudo (Mohamed et al., 2020); a taxonomia de seis classes de representação de recursos linguísticos de Joshi et al. (Joshi et al., 2020); e os grupos de renda do Banco Mundial (World Bank Group, 2025).

A amostra pré-especificada de 15 (Brasil, México, Argentina, Peru; Nigéria, África do Sul, Quênia, Egito; Índia, Indonésia, Bangladesh, Filipinas; e Estados Unidos, Alemanha e Japão como referências do Norte Global) cobre quatro regiões do mundo e quatro grupos de renda. O eixo de recursos linguísticos revelou-se muito menos diferenciado do que o pretendido: os idiomas oficiais dominantes caem em apenas três classes de Joshi, doze dos quinze partilhando a Classe 5, e estender a 25 não ajuda, pois dezoito são Classe 5. Isso é uma propriedade do mundo e não do nosso sorteio, porque os idiomas oficiais da maioria dos Estados são eles próprios de alto recurso, mas deixa o eixo linguístico com variância insuficiente para ser separado dos demais, e tratamos os resultados de Joshi de acordo (Seção 4.6). Países com governança estatística comprometida ou sem padrão nacional recuperável publicamente foram excluídos dos quinze pré-especificados; a Oceania entrou apenas com a extensão (Austrália), e idiomas da Classe 0 de Joshi não estão representados, o que anotamos como limitação de escopo.

3.3 Expansão da amostra após a análise pré-especificada

Após a análise pré-especificada de 15 países, e relatada aqui como extensão post hoc e não como parte do protocolo fechado, a amostra foi ampliada para 25 países sob procedimentos idênticos,

para elevar o poder dos testes de gradiente e de mecanismo e multiplicar os pares de idioma dentro do país disponíveis para H2. O manuscrito relata a amostra de 25 países do início ao fim; a família primária recomputada apenas sobre os 15 pré-especificados está tabulada no material suplementar, para que o leitor veja o que o protocolo fechado teria concluído. Como a extensão seguiu à observação dos resultados iniciais, nenhuma conclusão pré-especificada é revisada apenas com base na extensão, e a expansão é tratada como verificação de poder e robustez, não como teste novo. Angola, como a Nigéria e a Argentina, não tem padrão nacional de PM_{2,5} ambiente, acrescentando casos sem padrão em que um modelo fiel precisa declinar de enunciar um limiar inexistente. As dez adições e seus papéis estão detalhados no material suplementar. Duas variantes extras de pergunta por (país, tarefa) foram geradas para os pares de H2 no momento do desenho, mas nunca foram coletadas nem pontuadas; a análise de H2 usa a única versão em idioma nativo de cada prompt em inglês.

3.4 Covariáveis de país

O Índice de Desenvolvimento Humano (PNUD 2023–24) e o PIB per capita indexam a posição de desenvolvimento e entram na análise de mecanismo como covariáveis de ajuste. As exposições de representação no corpus se dividem ao longo de uma distinção que a análise de mecanismo torna explícita, porque os dois canais se aplicam a efeitos diferentes. As medidas de corpus do idioma quantificam quanto texto de pré-treinamento existe em um idioma e são o mecanismo candidato para a penalidade do idioma nativo: contagem de tokens do mC4 (Xue et al., 2021, Tabela 6), tamanho do corpus OSCAR-2301 (corpus introduzido por Abadji et al., 2022; valores por idioma lidos da ficha do conjunto OSCAR-2301, cujos totais diferem da versão 22.01 descrita naquele artigo) e a classe de Joshi (Joshi et al., 2020). As medidas de corpus do país quantificam quanto o corpus enciclopédico fala sobre um país, independentemente do idioma, e são o mecanismo candidato para a lacuna geográfica: o tamanho do artigo da Wikipédia inglesa, o número de edições da Wikipédia com artigo sobre o país e o número de declarações do Wikidata sobre a entidade do país.

As duas famílias não são intercambiáveis. Como a lacuna geográfica é medida em inglês, com o idioma mantido constante entre países, uma lacuna Norte/Sul residual não pode ser efeito de corpus do idioma. Wikipédia e Wikidata nunca são gabarito aqui; são a variável explicativa. Aquilo contra o que uma resposta é pontuada é sempre um registro oficial (Seção 3.9). Se tivéssemos pontuado contra uma enciclopédia, o estudo mediria concordância com uma enciclopédia, que não é a pergunta que uma administração pública enfrenta.

3.5 Seleção de modelos

Catorze LLMs foram avaliados em cinco tiers de acesso, cobrindo cerca de duas ordens de grandeza em número de parâmetros e quatro geografias de dados de treinamento (Estados Unidos, China, Europa, Brasil): fronteira de pesos abertos (5), pesos abertos intermediários (3) e pesos abertos pequenos ou regionais (2), fechados acessíveis (3) e fechado de fronteira (1). Três dos modelos de pesos abertos foram servidos localmente (Ollama, tags fixadas: Phi-4 14B, Qwen3 14B, Cabra-Mistral 7B); os outros sete modelos de pesos abertos foram servidos por endpoints hospedados (tier gratuito da Groq para cinco, as APIs da DeepSeek e da Cohere para dois), e os

quatro modelos fechados pelas APIs dos seus fornecedores. O tier pequeno inclui um modelo com ajuste de instrução em português brasileiro (Cabra-Mistral 7B v3, um ajuste fino do Mistral-7B-Instruct-v0.3), testado contra um modelo aberto de treinamento global e escala pareada para H3. Cada modelo foi consultado com uma tag fixada idêntica ao longo de toda a janela de coleta. A lista completa está na Tabela Suplementar S1.

Comparamos modelos tal como servidos por uma configuração de acesso fixa, e não pesos idealizados. Infraestrutura do provedor, configuração de serviço e camada de API fazem parte do que cada rótulo denota, e uma lacuna residual poderia em princípio refletir a pilha em vez dos pesos; mantemos isso constante fixando tags de versão e uma configuração de amostragem fixa por provedor ao longo de uma janela fixa (Seção 3.10).

3.6 Domínio e taxonomia de tarefas

O domínio único é a política de poluição do ar, escolhido porque se ancora em gabarito oficialmente publicado e verificável e se mapeia a atividades concretas de decisão de um gestor ambiental público. Cada uma das cinco tarefas corresponde a uma pergunta que um gestor tem de responder no curso do trabalho ordinário, e cada uma foi redigida de modo que uma resposta errada carregasse consequência administrativa. A Tabela 1 as traz com o prompt tal como foi emitido aos modelos, usando o Brasil como instância trabalhada, ao lado da decisão que cada uma representa.

Tabela 1: As cinco tarefas, o prompt como emitido e a decisão que cada uma representa. Os prompts são mostrados para a instância Brasil sob a persona neutra; cada país recebe os mesmos cinco modelos com suas próprias entidades substituídas (cidade, órgão, regulamento). Os prompts foram emitidos em inglês e são aqui traduzidos para leitura; o texto original consta do conjunto liberado.

Tarefa	Prompt emitido, em tradução (Brasil)	Decisão que representa
T1 Padrão técnico	“Qual é o padrão nacional vigente de média anual de qualidade do ar para PM _{2,5} no Brasil? Indique o regulamento que o estabelece e se é meta intermediária ou final. Limite-se a 1–3 frases.”	Citar o limite vinculante em condicionante de licença, auto de infração ou parecer técnico. O valor errado vicia o ato.
T2 Dado factual local	“Segundo a agência ambiental nacional ou subnacional, qual foi a concentração média anual de PM _{2,5} em São Paulo, Brasil, no ano mais recente reportado? Forneça o valor em $\mu\text{g}/\text{m}^3$, a estação ou rede de referência e a fonte.”	Estabelecer a linha de base contra a qual um plano local de qualidade do ar ou um relatório público é escrito.
T3 Síntese de evidência em saúde	“Resuma a evidência epidemiológica sobre mortalidade atribuível à exposição ambiental a PM _{2,5} no Brasil na última década. Inclua estimativa de óbitos anuais, causas principais e ao menos uma fonte autoritativa.”	Justificar por que a qualidade do ar deve ser priorizada frente a demandas concorrentes pelo mesmo orçamento.
T4 Instrumentos de política	“Liste os principais programas nacionais ou instrumentos legais de monitoramento e controle da poluição do ar ambiente no Brasil, com o órgão executor de cada um.”	Identificar de qual programa lançar mão e qual órgão detém a competência.
T5 Recomendação aplicada	“Uma região metropolitana do Brasil enfrenta episódio previsto com PM _{2,5} projetado para exceder $75 \mu\text{g}/\text{m}^3$ em 24 horas. Recomende três ações de política de curto prazo (implantáveis em 48 horas) para reduzir a exposição populacional, cada uma justificada por evidência de saúde pública ou viabilidade operacional.”	Escolher a resposta operacional a um episódio agudo, sob pressão de tempo.

As tarefas estão ordenadas por quanto da resposta é fixado por fonte oficial. T1, T2 e T4 admitem gabarito verificável e carregam o sinal primário de acurácia; T3 e T5 são tarefas de

geração aberta pontuadas por rubrica, em que respostas competentes legitimamente diferem. A ordenação permite perguntar se os modelos falham de maneira uniforme ou especificamente onde é preciso recordar um valor nacional publicado, que é a pergunta sobre a qual os resultados se apoiam. O mapeamento de país por tarefa das classes de fonte oficial e do estatuto de verificabilidade está no registro de gabarito (Seção 3.9), e o conjunto completo de prompts dos 25 países é liberado com os dados.

3.7 Manipulação de persona

A persona é um fator intra-prompt com dois níveis, e a manipulação segue a prática que os próprios fornecedores documentam e recomendam (Seção 2). A condição neutra apresenta a consulta como pedido simples de informação; a condição `public_manager_env` antepõe um enquadramento de papel fixo que identifica o solicitante como servidor de gestão ambiental municipal ou regional, mantendo idêntica a pergunta substantiva. Para a T1 do Brasil, o enquadramento é a frase única “*I am the municipal environmental management official of São Paulo, Brazil, and I need to brief decision-makers.*” Um único modelo de frase é aplicado uniformemente a países e tarefas, traduzido onde o idioma do prompt não é o inglês, de modo que qualquer diferença entre condições seja atribuível ao enquadramento e não à redação da pergunta. A ordem das personas dentro de cada célula prompt-modelo é aleatorizada, e uma checagem de manipulação verifica se o enquadramento é reconhecido na resposta. Redação exata, procedimento de tradução e codificação da checagem de manipulação estão no material suplementar.

Um detalhe de implementação importa para a leitura do resultado. Toda requisição neste estudo é enviada como um único turno de usuário, sem prompt de sistema, de modo que o enquadramento de papel é prefixado à mensagem do usuário em vez de instalado como instrução de sistema. Três dos quatro guias de fornecedor colocam o papel no prompt de sistema; o da Google afirma que ele cabe na instrução de sistema ou “no início do prompt do usuário” (Google, 2026), que é o canal que testamos. A escolha é deliberada: a via do prompt de sistema exige acesso à API e um desenvolvedor para configurá-la, enquanto os servidores públicos cujas decisões motivam este estudo chegam a esses modelos pela interface de chat do consumidor, em que o único canal disponível é a mensagem que digitam. Testamos, portanto, o enquadramento de papel tal como o setor o pratica, e a Seção 5.7 declara o que permanece sem teste. A persona é a base de H6.

3.8 Construção e validação dos prompts

Os prompts foram redigidos para o domínio pela equipe de pesquisa com supervisão de domínio e validados contra o registro de gabarito antes de entrar no conjunto principal de estímulos, com toda afirmação factual de uma entrada do registro obrigada a resolver para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido. O plano de análise previa um piloto de 50 prompts pontuado por dois avaliadores humanos independentes ($\alpha \geq 0,70$) antes de escalar o desenho. Esse piloto não foi executado, e não existe α no nível de avaliador para este estudo; a confiabilidade da rubrica é evidenciada, em vez disso, nos próprios dados principais, por um painel de três fornecedores sobre todo item que exigiu juiz (Seção 4.11), que devolve $\alpha = 0.527$. Relatamos isso como desvio do plano, e não como limiar atingido.

Todos os prompts foram redigidos em inglês e, para um subconjunto estratificado de países, adicionalmente em um idioma nativo relevante (Seção Suplementar S3). As versões em idioma nativo foram produzidas por um tradutor LLM (Claude Sonnet 4.6) instruído a preservar significado, enquadramento de persona, nomes próprios e siglas, com o gabarito factual mantido em inglês, já que o valor alvo é invariante ao idioma. Não empregamos tradutores humanos nativos, o que permanece uma limitação (Seção 5.7); auditamos as versões depois do fato, retrotraduzindo todos os 90 prompts nativos com outro modelo e fazendo dois outros modelos compararem cada um com o original em inglês (Seção 4.4). O idioma nativo é o idioma do usuário, não necessariamente o do instrumento: os padrões do Brasil, de Portugal e dos cinco países hispanófonos são publicados no idioma do prompt, enquanto as normas nacionais de qualidade do ar da Índia são publicadas em inglês, de modo que a condição em hindi pergunta num idioma que o texto oficial não usa.

3.9 Gabarito e registro de gabarito

O gabarito é um conjunto de quatro registros específicos por tarefa, liberados com os dados, e descrevemos cada um tal como foi construído, e não como foi planejado (a Tabela Suplementar S14 registra os desvios). Para T1 a chave é o valor anual de $PM_{2,5}$ em vigor durante a janela de coleta, tomado do próprio instrumento nacional (lei, decreto, regulamento ou diário oficial) e armazenado com a fonte, um trecho literal e um indicador de status. Vinte e um países têm chave numérica. Três (Angola, Argentina, Nigéria) não têm padrão nacional de $PM_{2,5}$, de modo que a resposta correta é dizer isso, e um valor enunciado é pontuado como fabricado. O Egito não tem chave, porque o texto oficial em árabe não pôde ser recuperado, e fica fora de T1 (56 células). Bangladesh é pontuado contra os $35 \mu g/m^3$ das suas Air Pollution (Control) Rules de 2022, que substituíram os 15 do diário oficial de 2005; uma versão anterior do registro carregava o valor de 2005, e a correção está registrada junto com os arquivos liberados. Onde um instrumento fixa uma escada de valores por etapas (as cinco etapas do CONAMA no Brasil, o limite de 25 da UE com 10 a partir de 2030, os 20 do Reino Unido com meta inglesa de 10 até 2040, os 9,0 dos Estados Unidos sucedendo 12,0, os 35 de Bangladesh sucedendo 15), o registro armazena a escada inteira além do valor em vigor, para que citar uma etapa vizinha possa ser separado de fabricação (Seção 4.9). O CAAQS do Canadá e o valor filipino são objetivos e não limites juridicamente vinculantes; são os únicos valores nacionais de referência que esses países publicam e são tratados como chave, o que o texto anota onde importa. O registro não guarda a data em que cada instrumento entrou em vigor, de modo que a distância entre essa data e o corte de treinamento de um modelo não pôde entrar como covariável; a análise da escada na Seção 4.9 é o substituto mais próximo disponível.

Para T2 a chave é a concentração média anual de $PM_{2,5}$ mais recente que a WHO Ambient Air Quality Database (v6.1, 2024) registra para a cidade do prompt, que compila os valores reportados por agências nacionais e subnacionais; qualquer ano reportado é aceito dentro de $\pm 20\%$, de modo que um modelo que cita um valor de agência de outro ano não é penalizado pelo ano. A janela não é neutra quanto ao tier por construção, porque as cidades do Norte Global têm séries mais longas na OMS (7.8 anos aceitos em média contra 5.6), mas a faixa de valores que ela admite é semelhante nos dois tiers (razão entre o maior e o menor valor aceito de 1.46

contra 1.43). Duas cidades não têm entrada de $PM_{2,5}$ (Luanda, Cairo) e essas células vão para o juiz. Para T3 a chave é a estimativa do Observatório Global de Saúde da OMS de óbitos atribuíveis à poluição do ar ambiente (indicador AIR_41, 2021), com o intervalo de incerteza alargado pela metade de cada lado como faixa aceita, mais a ordenação publicada das causas; o indicador cobre a poluição do ar ambiente como um todo enquanto o prompt pergunta sobre $PM_{2,5}$, e um modelo que cita outro estudo de carga (o GBD, uma coorte nacional) é pontuado pelo juiz quanto a se seu valor e suas fontes são defensáveis, e não contra o número da OMS. Para T4 o conjunto de referência é o catálogo Global Air Pollution Legislation do PNUMA para cada país, com substituições manuais onde está desatualizado. O registro guarda fonte, URL, data de acesso e status por entrada, mas não tem campo de validador humano nem hash por documento: a verificação foi documental, pelos autores, contra o texto primário. Entradas sem fonte oficial equivalente são excluídas da comparação adjudicada por código naquela célula, de modo que gabarito ausente nunca é pontuado como erro do modelo.

3.10 Coleta de dados

As chamadas foram executadas a temperatura 0,3, com duas replicações por combinação prompt-modelo-persona, dentro de uma janela fixa para minimizar confundimentos por atualização de modelo; as acurácias relatadas são, portanto, estimativas pontuais no tempo. Duas exceções são declaradas. A família GPT-5 rejeita qualquer temperatura diferente da padrão, de modo que GPT-5 e GPT-5-mini rodaram a temperatura 1,0 com esforço de raciocínio mínimo; e nenhuma semente foi enviada a provedor algum, ao contrário do que uma versão anterior afirmava, de modo que as duas réplicas a temperatura 0,3 limitam, em vez de remover, a variância intra-modelo (o material suplementar compara os efeitos-manchete com essa variância). Toda resposta foi armazenada com metadados completos da requisição (tag fixada, carimbo de tempo, contagens de tokens, motivo de término, condição de persona) sob somas de verificação SHA-256. Nenhuma resposta foi excluída pelo comprimento ou pelo idioma: respostas vazias são pontuadas como não tendo devolvido valor, e uma resposta em idioma diferente do solicitado é pontuada pelo conteúdo. Respostas vazias são mais frequentes sob prompts em idioma nativo (4.2% das respostas em inglês nas três tarefas pontuadas por código contra 11.4% em espanhol, 13.9% em português e 11.5% em hindi), o que faz parte do efeito do idioma, e não de atrito em relação a ele.

A cobertura por célula não é uniforme: endpoints gratuitos e com limite de taxa devolveram menos respostas admissíveis do que APIs pagas, de modo que o número de células pontuadas com prompt em inglês vai de 261 a 500 por modelo (777 para o modelo com mais pares em idioma nativo, quando estes são contados). Relatamos o N realizado de cada modelo ao lado da sua pontuação (Tabela 2) em vez de descartar células subcobertas, a lacuna de tier é reestimada sobre os prompts que todos os modelos responderam (Seção 4.6), e a matriz de cobertura completa, com cota e motivo de exclusão para cada déficit, está no material suplementar.

3.11 Medidas

A pontuação atribui a cada tarefa o instrumento mais confiável que ela admite.

Onde a resposta é um número em registro oficial, o código decide. Para T1, T2 e T3 o valor devolvido é extraído e comparado com o registro por um pontuador determinístico, com

salvasdas de plausibilidade que rejeitam extrações implausíveis (um ano de quatro dígitos lido como contagem de óbitos, uma população nacional lida como cifra de mortalidade, um valor de 24 horas lido como anual). O extrator normaliza dígitos devanágari, vírgulas decimais e unidades escritas por extenso, e seu comportamento nos casos que importam para a comparação entre idiomas (uma vírgula decimal, um numeral em hindi, um valor diário entre parênteses ao lado do anual) está fixado por uma suíte de testes unitários liberada com o código; uma auditoria manual estratificada das respostas de T1 em idioma nativo que ele classificou como sem valor é relatada no material suplementar, e nenhuma auditoria equivalente foi feita para T2 e T3. Comparar um valor com uma chave é exato, ao passo que um modelo de linguagem convidado a fazer a mesma aritmética a reproduz com ruído. O código resolve 99.8% das células de T1 na análise (1.614 de 1.617), 56.3% de T2 e 71.8% de T3; uma resposta de T1 sem valor extraível conta como não o tendo devolvido. Para os três países sem padrão, o código pontua se a resposta afirma que não existe padrão nacional (correto), afirma um valor (fabricado) ou declina de responder (nenhum dos dois), e a comparação de tier é relatada com e sem eles.

O veredito de código substitui um subcomponente do composto, a acurácia factual (peso 0,30); os outros quatro subcomponentes de uma célula de T1, T2 ou T3 continuam sendo os atribuídos pelo juiz que a pontuou. Para T1 esse juiz é o juiz da coleta, de modo que o composto em T1 ainda carrega o confundimento entre juiz e tier descrito abaixo em 0,70 do seu peso. Por essa razão, o desfecho primário para a comparação de tier nas tarefas com valor de registro é o próprio veredito binário de código, se a resposta devolveu o valor em vigor, e o composto é relatado como desfecho secundário (Seção 4.6).

Onde é preciso julgamento, um painel de três fornecedores decide pela média. O resíduo de T2 e T3, com toda a T4, é pontuado por Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3, escolhidos pela diversidade de fornecedores, para que a correlação intra-fornecedor não infla a concordância aparente. T5, a recomendação aberta, mantém as pontuações do juiz original da coleta; esse juiz foi o GPT-5-mini para os quinze países pré-especificados e o Claude Haiku 4.5 para os dez acrescentados na extensão, e como a extensão contém sete dos dez países do Norte Global, juiz e tier estão confundidos em qualquer efeito que ainda se apoie nessas pontuações. É por isso que o veredito factual de T1 foi movido para código: nas pontuações originais, o déficit do Sul Global em T1 era de 0.21 contra 0.38 sob o GPT-5-mini, mas de 0.37 contra 0.44 sob o Claude Haiku, uma diferença entre juízes tão grande quanto a diferença entre tiers (material suplementar). T5 não carrega efeito de tier em nenhum dos dois instrumentos. A confiabilidade é relatada como α de Krippendorff, ICC(2,1) de juiz único e, como grandeza operativa, o ICC(2,3) da média do painel, um coeficiente de efeitos aleatórios em duas vias e concordância absoluta em que as diferentes severidades dos juízes contam contra ele, computado sobre todo item que o painel pontuou, e não sobre um subconjunto de calibração. Juízes baseados em modelo de linguagem concordam com avaliadores humanos mais ou menos no nível em que humanos concordam entre si em tarefas abertas (Zheng et al., 2023), mas carregam vieses de posição, verbosidade e autofavorecimento, e os modelos reconhecem as próprias saídas o bastante para preferi-las (Zheng et al., 2023; Panickssery et al., 2024). Um membro do painel (DeepSeek-V3) é também um modelo avaliado, e testamos o autofavorecimento diretamente; os outros dois juízes pertencem a fornecedores cujos modelos estão na lista (Anthropic, Google), de modo

que uma preferência no nível do fornecedor não pode ser excluída por esse teste. Nenhuma camada humana de padrão-ouro foi coletada; o gabarito está ancorado em fontes primárias oficiais (Seção 3.9).

A unidade de análise é a célula pontuada, não a linha de log. A duplicação existe em dois níveis e cada um tem regra declarada. No nível da resposta, 21,9% das chaves (modelo, prompt, réplica) têm mais de uma resposta armazenada, porque as rodadas de coleta foram retomadas e reexecutadas; a resposta que entra na análise é a primeira armazenada na ordem dos arquivos de execução, que é a que o juiz pontuou, e os vereditos de código são computados sobre essa mesma resposta, de modo que os dois instrumentos descrevem uma única resposta. Pontuar todas as respostas armazenadas e tirar a média dos vereditos muda o veredito de código em 3.1% das células e a média em 0.0002 (material suplementar). No nível da pontuação, 951 células (11,5%) carregam mais de uma pontuação de juiz, porque o juiz foi reexecutado sobre partes do conjunto em datas diferentes; são medições repetidas do mesmo item e são colapsadas pela média, restando 8.300 células, ou 8.244 uma vez removidas as 56 células egípcias de T1 sem chave (6.573 com prompt em inglês). Tratar reexecuições como independentes inflaria o n e daria peso extra às células que por acaso foram reprocessadas. A regra foi fixada por razões metodológicas e não depende do resultado.

O composto primário combina cinco subcomponentes pré-especificados (Seção Suplementar S6), cada um normalizado para $[0, 1]$: acurácia factual contra a entrada do registro (peso 0,30), completude contextual (0,25), qualidade de citação (0,15), calibração (0,15) e ausência de alucinação (0,15). Todo efeito-manchete é recomputado sob pesos iguais e sob uma ponderação derivada de PCA, e uma conclusão conta como robusta apenas se sua direção for estável nas três. O composto é computado por célula (país, modelo, persona) para sustentar o teste de diferença-em-diferenças de H6.

3.12 Estratégia analítica

Os três testes primários são pré-especificados como uma única família (F1) e corrigidos em conjunto por Bonferroni-Holm. Os testes secundários (F2) são relatados sem ajuste dentro da família, e os testes declarados exploratórios (F3) usam FDR de Benjamini-Hochberg a $q = 0,10$ (Benjamini and Hochberg, 1995), cuja garantia vale sob dependência positiva; a correção de Benjamini-Yekutieli, válida sob dependência arbitrária, devolve as mesmas decisões nesta família, pois os testes de F3 que ela cobre têm valores de p várias ordens de grandeza abaixo do limiar.

H1 (gradiente geográfico, primária) regride a acurácia composta média por país sobre o gradiente Joshi/IDH via ρ de Spearman, pré-especificado unilateral em $\rho \geq 0,55$, com um teste de tendência de Mann-Kendall como complemento obrigatório de não monotonicidade. O contraste binário Norte/Sul Global sobre as mesmas médias por país foi pré-especificado como análise de sensibilidade de H1, e sua decomposição por tarefa (Seção 4.6) não foi pré-especificada e é exploratória. H4 (mecanismo de corpus, primária) relaciona a representação no corpus à acurácia por ρ de Spearman parcial ajustando por IDH e log do PIB per capita, com contagens da Wikipédia como proxy pré-especificado e cobertura do Wikidata como complemento exploratório. H6 (persona, primária) é uma diferença-em-diferenças no nível do país, $\Delta_{GS} - \Delta_{GN}$, sustentada

se a condição de persona reduzir a lacuna do Sul Global em ao menos 0,05 no composto, com inferência por teste de permutação no nível do país com 5.000 permutações; como o teste pré-especificado não distingue um nulo de um resultado inconclusivo, acrescentamos um teste de equivalência, dois testes unilaterais sobre a distribuição bootstrap por país da diferença-em-diferenças com margens de ± 2 e ± 5 pp. H3 (secundária) é um contraste unilateral de Mann-Whitney (δ de Cliff). H2 e H5 (exploratórias) são relatadas descritivamente sob correção F3.

Sempre que um teste nos Resultados é rodado primeiro sobre respostas, também o relatamos com o país ou o modelo como unidade, porque as respostas estão aninhadas em 25 países e 14 modelos e um valor de p no nível da resposta superestima a evidência para qualquer contraste que varie entre países. Três análises transversais corroboram a lacuna de tier: um modelo linear misto gaussiano (`statsmodels` MixedLM, REML) com interceptos aleatórios cruzados para país e modelo, ajustando por IDH centrado; uma reestimação hierárquica bayesiana (`pymc` (Abril-Pla et al., 2023), priors fracamente informativas); e E-values para robustez a confundimento não medido, computados para a diferença de médias padronizada da acurácia composta entre tiers pela aproximação $RR \approx \exp(0,91 d)$ que VanderWeele and Ding (2017) prescrevem para efeitos padronizados e cujos pressupostos ela herda. O mecanismo de corpus é sondado com um modelo de mediação exploratório (`semopy` (Igolkina and Meshcheryakov, 2020)), e a manipulação de persona com uma checagem de reconhecimento do enquadramento de papel. As análises de robustez pré-especificadas aparecem na Seção 4.12.

3.13 Protocolo do estudo e ética

O conjunto de dados analítico, após os filtros de qualidade mas antes do ajuste de modelos, é congelado e verificado por hash, de modo que a análise possa ser auditada contra a especificação fechada em vez de aceita por confiança. Os termos de liberação são declarados ao fim do artigo.

Nenhum dado pessoal de usuários finais de LLMs foi coletado; o estudo analisa saídas de modelos a perguntas de política de relevância pública. Os termos de serviço dos provedores foram revisados e respeitados, e as respostas são redistribuídas exclusivamente para pesquisa sob disposições de uso justo e reprodutibilidade, excluída qualquer aplicação comercial.

4 Resultados

Nota sobre a amostra. Os resultados são relatados sobre a amostra de 25 países. O benchmark pré-especificado cobria 15 países e foi estendido post hoc por dez (seis referências do Norte Global, Reino Unido, Canadá, Austrália, Coreia do Sul, França e Itália, e quatro países com par nativo, Colômbia, Chile, Portugal e Angola). Catorze LLMs são pontuados em cinco tarefas, duas personas e quatro idiomas (inglês mais um idioma nativo do país, espanhol, português ou hindi, para os nove países aplicáveis, o que dá os pares inglês/nativo dentro do país que testam H2). A família primária recomputada apenas sobre os 15 países pré-especificados está tabulada no material suplementar, e nenhuma conclusão pré-especificada é revisada apenas com base na extensão; onde as duas amostras divergem em uma hipótese de que o artigo depende, o texto o diz. A pontuação é adjudicada por código sempre que a resposta é um número conferível contra registro oficial, e pela média de um painel de juízes de três fornecedores nos demais casos (Seção 4.11); o gabarito de T1 está ancorado no instrumento nacional em vigor para 24 países e não tem chave para o Egito, que fica fora de T1 (Seção 4.9). Todo teste rodado primeiro sobre respostas é também relatado com o país ou o modelo como unidade.

4.1 Amostra e pontuação

O corpus analisado compreende 8.244 células pontuadas no composto $[0, 1]$, das quais 6.573 são respostas a prompts em inglês nos 25 países; o restante são os pares em idioma nativo dentro do país usados para H2. O código adjudica o veredito factual contra o registro oficial sempre que a resposta é um número publicado, resolvendo 99.8% das células de T1, 56.3% de T2 e 71.8% de T3; o resíduo, com toda a T4, é pontuado pela média de um painel de três fornecedores, e T5 mantém as pontuações do juiz da coleta. No total, 6.434 células carregam pontuação de código ou de painel.

A média do painel substitui o desenho de juiz único do protocolo original, no qual o juiz da coleta (GPT-5-mini para os quinze países pré-especificados, Claude Haiku 4.5 para os dez da extensão) estava ele próprio entre os modelos avaliados e, como a extensão contém sete dos dez países do Norte Global, estava confundido com o tier. Os juízes diferem em severidade (composto médio de 0.617 para o Gemini, 0.451 para o Claude e 0.379 para o DeepSeek), de modo que um juiz único fixa um nível arbitrário, e a confiabilidade de juiz único é $\text{ICC}(2, 1) = 0.56$ contra $\text{ICC}(2, 3) = 0.79$ da média do painel. Um membro do painel (DeepSeek-V3) é também um modelo avaliado, então checamos o autofavorecimento: ele pontua as próprias saídas de forma mais severa em relação aos outros dois juízes (-0.177) do que pontua as de qualquer outro modelo (-0.123 a -0.160).

4.2 Acurácia por modelo

A Tabela 2 ordena os 14 modelos pelo composto médio: sistemas de fronteira lideram e modelos pequenos de pesos abertos ficam atrás. Em H3, o modelo regional em português brasileiro Cabral-Mistral 7B é o mais fraco de todos (0.351 contra 0.557 para os demais; Mann-Whitney $p \approx 0$ sobre células, δ de Cliff = -0.48). O δ de Cliff é a probabilidade de uma resposta sorteada de um grupo superar uma sorteada do outro, reescalada para $[-1, +1]$, de modo que -0.48 significa que o modelo regional perde cerca de três dessas comparações para cada uma que vence. Com

o país como unidade, o Cabra fica abaixo da média dos outros treze em 25 dos 25 países, por -20.6 pp em média (Wilcoxon $p = 1 \times 10^{-5}$). O teste pré-especificado era mais estreito, o Cabra contra seu par de escala Llama 3.1 8B em prompts em português, e aponta na mesma direção com margem menor: no Brasil, o modelo regional pontua 0.258 contra 0.313 ($\delta = -0.26$, $n = 20$ células cada), e nos três países lusófonos 0.304 contra 0.362 ($\delta = -0.17$, $n = 60$ cada); pareado por prompt com as réplicas na média, o Cabra perde em 20 dos 30 prompts em português, por -5.9 pp (Wilcoxon $p = 0.002$). O ajuste de instrução regional no nível de 7B não recupera o que escala e treinamento de fronteira dão, nem mesmo no idioma e no país para os quais foi ajustado. Uma verificação de serviço relatada na Seção 4.12 confirma que o modelo foi consultado com o template de chat publicado e o compara com seu próprio modelo-base nos mesmos itens em português.

Tabela 2: Acurácia composta por modelo em 25 países (veredito factual por código onde a resposta é um valor de registro, média do painel nos demais casos; $[0, 1]$). N = respostas pontuadas a prompts em inglês.

Modelo	N	Média
DeepSeek-V3	496	0.687
GPT-5	496	0.674
Gemini 2.5 Flash	486	0.634
GPT-5-mini	495	0.626
Claude Haiku 4.5	486	0.591
Qwen3 32B	494	0.562
Command R+	496	0.530
Llama 3.3 70B	391	0.511
Llama 4 Scout	496	0.498
Qwen3 14B	496	0.485
GPT-OSS 120B	257	0.484
Phi-4 14B	496	0.477
Llama 3.1 8B	496	0.438
Cabra-Mistral 7B	492	0.351

4.3 Acurácia por tarefa: o piso de recordação

A dificuldade depende da tarefa (Tabela 3). A tarefa mais difícil é T1 (recordação do padrão técnico, 0.393), que exige devolver o padrão nacional anual de $PM_{2.5}$ em vigor. A tarefa de recomendação aberta (T5) pontua mais alto (0.769) porque sua rubrica recompensa aconselhamento de política plausível e bem estruturado que não depende de um único fato. Agrupando as duas tarefas de recordação (T1, T2; média 0.434) contra síntese e recomendação (T3–T5, 0.612), a diferença é grande sobre células (Mann-Whitney $p \approx 0$, δ de Cliff = -0.41 , cerca de duas derrotas e meia para cada vitória) e se mantém com o modelo como unidade (recordação abaixo do resto em 14 dos 14 modelos, por -17.6 pp, Wilcoxon $p = 1 \times 10^{-3}$) e com o país como unidade (25 de 25, -18.1 pp, $p = 1 \times 10^{-5}$). Os modelos são mais fracos onde a gestão ambiental aplicada mais precisa deles, em recordar o limiar regulatório em vigor.

As duas correções da pontuação são informativas aqui. T2 era originalmente pontuada contra uma chave provisória e sobe de 0.368 para 0.473 quando cada concentração devolvida é comparada com a faixa autorizada por código. T1 sempre teve chave oficial, mas era pontuada por dois juízes

de coleta de severidade diferente, e mover seu veredito factual para código a eleva de 0.367 para 0.393 mantendo-a como a tarefa mais difícil; o veredito de código também mostra o que os juízes não podiam mostrar, que mais de um terço das respostas erradas de T1 (281 de 759) cita um valor que está na escada oficial do país, um valor superado ou uma etapa futura, e não um valor fabricado (Seção 4.9). O piso é mais raso do que o relatado inicialmente e concentrado na recordação normativa.

Tabela 3: Acurácia composta por tipo de tarefa (25 países; T1 em 24, sem chave para o Egito). Em T1, T2 e T3 o subcomponente de acurácia factual é o veredito de código onde o valor devolvido é conferível contra o registro oficial, e os demais subcomponentes são pontuados por juiz; T4 é pontuada pelo painel; T5 mantém as pontuações do juiz da coleta.

Tarefa	<i>N</i>	Média
T5 (recomendação aplicada)	1.320	0.769
T3 (síntese de evid. em saúde)	1.329	0.548
T4 (instrumentos de política)	1.310	0.520
T2 (dado factual local)	1.335	0.473
T1 (padrão técnico)	1.279	0.393

4.4 H2: perguntar no idioma local reduz a acurácia

Para os nove países com idioma nativo alvo, cada prompt é apresentado em inglês e no idioma nativo com o conteúdo mantido fixo, de modo que o contraste é dentro do país e dentro do modelo. As réplicas são tiradas em média dentro de cada célula (modelo, prompt) antes do pareamento, já que parear réplica com réplica inflaria o n . Nas 839 células pareadas, o prompt em idioma nativo reduz a acurácia composta média em 5.0 pontos percentuais (Wilcoxon pareado $p = 5 \times 10^{-16}$). Esse teste trata as células como independentes, e elas estão aninhadas em nove países e catorze modelos, de modo que relatamos também a inferência que respeita o aninhamento: um modelo misto sobre as diferenças pareadas com intercepto aleatório por país dá -5.0 pp (EP 1.0, $p = 6 \times 10^{-7}$), com intercepto aleatório por modelo -4.8 pp ($p = 2 \times 10^{-9}$); com o país como unidade ($n = 9$) a penalidade é negativa em 8 de nove e tem média -5.0 ± 1.1 pp ($t = -4.6$, $p = 0.002$); com o modelo como unidade ($n = 14$) é negativa em 12 de catorze (Wilcoxon $p = 0.058$). Os três idiomas carregam penalidade significativa (Tabela 4): hindi -11.4 pp, espanhol -4.5 pp, português -4.2 pp. O hindi é o idioma de menor corpus e carrega a maior penalidade; espanhol e português, cujos corpora diferem em tamanho, carregam penalidades que não diferem. A Índia, que pontua mais alto entre os 25 países em inglês, cai mais em hindi, e parte dessa queda pode ser regressão à média, já que um país cuja pontuação em inglês é a mais alta em parte por acaso tem mais de onde cair; com um único país em hindi as duas leituras não se separam.

H2 carrega a afirmação central do estudo, e sobrevive a toda tentativa de removê-la: não é impulsionada por nenhum país isolado (deixar-um-de-fora -4.3 a -5.5 pp, todos significativos), por nenhum modelo isolado (-4.5 a -5.2 pp) nem por células extremas (5% aparado -4.5 pp, $p = 6 \times 10^{-20}$); mantém-se sob toda ponderação do composto; e aparece em toda tarefa e sob as duas condições de persona.

Duas verificações adicionais respondem às objeções que um leitor cético levanta primeiro. A primeira é que juízes baseados em modelo de linguagem poderiam penalizar a prosa não inglesa

pelo estilo e não pelo conteúdo, então testamos um desfecho binário que nenhum juiz toca: a resposta contém um valor que o extrator consegue comparar com o registro? O extrator lê numerais devanágari, vírgulas decimais e unidades por extenso, de modo que um número em hindi ou em espanhol não é penalizado pela notação (Seção 3). Prompts em inglês produzem um valor verificável 71.9% das vezes e prompts em idioma nativo 62.5%, uma diferença pareada de -9.4 pp, com a versão nativa pior em 134 dos 218 pares discordantes (teste do sinal $p = 9 \times 10^{-4}$): hindi -39.5 pp, espanhol -13.4 pp, enquanto o português, o mais bem provido dos três, não mostra tal perda ($+3.5$ pp). As respostas em português devolvem um número tão prontamente quanto as em inglês; o número está errado com mais frequência. Sobre o próprio veredito de código (nativo menos inglês, células adjudicadas por código nos dois idiomas), a penalidade do português é -9.1 pp ($n = 132$, $p = 0.019$) e a do espanhol -2.1 pontos ($n = 165$, não significativa), -5.0 pp no geral ($n = 318$, $p = 0.048$). Onde o idioma é escasso, o modelo fica menos propenso a devolver qualquer número conferível; onde o idioma é bem provido, o número que ele devolve está certo com menos frequência.

A segunda é que os prompts nativos, produzidos por um tradutor LLM, poderiam perguntar outra coisa. Testamos isso em todos os 90 prompts nativos únicos, retrotraduzindo cada um com um modelo diferente e fazendo dois outros modelos auditarem o resultado contra o original em inglês. Nos dois itens que poderiam confundir o efeito, a fidelidade é completa: nenhum prompt mudou o país e nenhum mudou a grandeza pedida (90/90 em ambos). Restringir H2 aos prompts verificados como fiéis a deixa inalterada (-4.8 pp, $p = 2 \times 10^{-8}$) contra -5.2 pp entre os divergentes, uma diferença indistinguível de zero (permutação $p = 0.80$). Separando os pares pelo instrumento que pontuou a célula nativa, a penalidade é -3.8 pp onde o código decidiu ($n = 333$, $p = 0.004$), -8.6 pp onde o painel decidiu ($n = 314$, $p = 4 \times 10^{-22}$) e -1.1 pp, não significativa, onde permanece a pontuação do juiz da coleta ($n = 192$, essencialmente T5, a recomendação aberta sem valor de registro). O subconjunto adjudicado por código é o menor dos dois porque o código só age onde existe um número, de modo que condiciona a que o modelo tenha produzido um valor nos dois idiomas e seleciona para fora o modo de falha mais severo; o subconjunto do painel carrega esse modo de falha, e é por isso que não se pode presumir que a leniência do juiz se cancele entre idiomas e por isso o desfecho sem juiz acima é o que decide a questão.

A implicação aplicada vai contra a intuição. Um gestor que suspeita que um modelo em inglês serve mal ao seu país e responde perguntando no idioma nacional torna a resposta pior, e pior pela maior margem onde o idioma é menos representado nos corpora de treinamento.

Tabela 4: H2: acurácia nativo menos inglês por idioma nativo (pareada dentro de país e modelo, réplicas em média dentro da célula, amostra de 25 países).

Idioma nativo (classe Joshi)	Países	Δ (pp)	p	N células
Espanhol (5)	MEX, ARG, PER, COL, CHL	-4.5	2×10^{-10}	457
Português (4)	BRA, PRT, AGO	-4.2	8×10^{-5}	311
Hindi (4)	IND	-11.4	4×10^{-4}	71
Geral		-5.0	5×10^{-16}	839

4.5 H6: a persona não estreita a lacuna geográfica

O fator persona foi completamente cruzado, de modo que H6 é testada como diferença-em-diferenças. O enquadramento de gestor ambiental público deixa a lacuna Norte/Sul inalterada: +4.8 pp sob o enquadramento neutro contra +5.3 pp sob o enquadramento de gestor, uma DiD de +0.5 pp, muito abaixo do limiar pré-especificado de 5 pp; um teste de permutação no nível do país (5.000 permutações do rótulo de tier) dá $p = 0.29$. O teste pré-especificado não distingue ausência de efeito de falta de poder, então acrescentamos o teste de equivalência: o intervalo bootstrap de 90% por país da DiD é $[-0.4, +1.6]$ pp, dentro tanto da margem de ± 5 pp da hipótese quanto de uma margem mais estrita de ± 2 pp, de modo que o enquadramento é equivalente a nenhum enquadramento em até 2 pp sobre a lacuna. A persona tem um efeito principal próprio, e ele é negativo: pareado por prompt e modelo, o enquadramento de gestor reduz o composto em -0.62 pp ($n = 1,654$ pares, Wilcoxon $p = 0.003$; com o país como unidade $p = 0.062$). H6 não é sustentada: apresentar a consulta como vinda de um gestor ambiental público nem estreita nem amplia a desvantagem do Sul Global, em consonância com a evidência de que personas de especialista não melhoram a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Uma checagem de manipulação constata que 50.2% das respostas na condição de persona reconhecem explicitamente o enquadramento de papel, de modo que o nulo não é artefato de o enquadramento ser ignorado.

4.6 H1: uma lacuna de tier que se sustenta, um gradiente que não

H1 foi pré-especificada em duas partes, um gradiente de desenvolvimento como teste primário e o contraste binário Norte/Sul Global como sua análise de sensibilidade, e as duas se separam com clareza.

O desfecho primário para o contraste é aquele que nenhum juiz toca. Nos desfechos adjudicados por código (toda a T1 e a parte resolvida de T2 e T3), os países do Norte Global devolvem o valor do registro 0.61 das vezes e os do Sul Global 0.46, uma lacuna de +14.7 pp com intervalo bootstrap por país de $[+5.6, +23.9]$ (permutação do rótulo de tier com o país como unidade, $p = 0.012$) e razão de chances agrupada de 0.53 $[0.48, 0.58]$. No composto, o desfecho secundário, os dez países do Norte Global têm média 0.572 contra 0.521 dos quinze do Sul Global, uma lacuna de +5.0 pontos percentuais cujo intervalo bootstrap de 95% sobre países é $[+1.6, +8.4]$ pp (permutação $p = 0.019$). A lacuna do composto é estável à retirada de qualquer país isolado (deixar-um-de-fora $[+4.4, +6.0]$ pp) e à ponderação do composto (+4.2 pp sob pesos iguais, +8.9 pp no subcomponente factual, onde se alarga). Tratar os quatro membros da União Europeia na amostra (Alemanha, França, Itália, Portugal) como uma única unidade, para que a regulação compartilhada não seja contada quatro vezes, a deixa em +5.5 pp $[+1.6, +9.3]$ ($p = 0.029$, 7 unidades do Norte contra 15). Como sete dos dez países do Norte Global entraram com a extensão, relatamos também a lacuna onde a onda não pode explicá-la: dentro da extensão apenas (sete do Norte Global contra Colômbia, Chile e Angola) ela é +5.9 pp $[+2.3, +9.6]$, e nos quinze pré-especificados (três do Norte Global contra doze) +6.1 pp $[+1.8, +10.1]$, uma estimativa pontual do mesmo tamanho numa amostra pequena demais para torná-la significativa por permutação ($p = 0.12$). A cobertura é desigual entre modelos, então restringimos também a estimativa aos 104 dos 248 prompts em inglês que todos os modelos responderam; a estimativa

pontual é a mesma (+5.1 pp) e o intervalo, sobre muito menos células, inclui zero $[-2.7, +12.8]$, $p = 0.32$).

Onde a lacuna mora. A decomposição por tarefa não foi pré-especificada e é exploratória. Reestimar o contraste em cada tarefa separadamente, com o desfecho codificado como devolver o valor do registro, mostra a desvantagem crescendo com o quanto a tarefa depende de um fato específico daquele país (Tabela 5). A tabela dá duas estimativas de cada razão de chances. O modelo binomial misto com interceptos aleatórios cruzados para país e modelo devolve uma razão de chances condicional com intervalo estreito; o bootstrap por país da razão de chances bruta, que trata o país como unidade de inferência, devolve um intervalo mais largo e é a medida honesta do que 24 países conseguem estabelecer por tarefa. No padrão nacional vinculante (T1), pontuado por código contra o instrumento em vigor, a chance bruta do Sul Global de devolver o valor do registro é 0.44 da do Norte Global (50.7% contra 31.0%), com intervalo por país de $[0.18, 1.05]$ e permutação por país $p = 0.062$; a estimativa condicional é 0.32 $[0.27, 0.39]$. Nos instrumentos de política (T4) a razão bruta é 0.50 $[0.19, 1.15]$; na síntese de evidência em saúde (T3), em que a resposta é uma estimativa internacional e não nacional, sobe para 0.76 $[0.37, 1.46]$; e na recomendação aberta (T5), a única tarefa sem valor de registro a acertar, a lacuna está ausente (1.52, $[0.22, 10.64]$). A razão de T1 mantém sua direção sob as duas objeções que sua composição convida (Seção 4.9): deixando de lado os três países do Sul Global sem padrão nacional, a estimativa condicional é 0.39 $[0.32, 0.49]$, e nos quinze pré-especificados é 0.27 $[0.21, 0.34]$. T4 é a única tarefa da tabela pontuada inteiramente pelo painel, de modo que sua razão pode carregar a ignorância do próprio juiz sobre instrumentos do Sul além da do modelo; as estimativas só de código são as livres disso. A lacuna é concentrada e não fraca: o composto a dilui ao tirar a média de tarefas em que ela está presente com uma tarefa em que não existe, e os intervalos por tarefa no nível do país são largos o bastante para que apenas o contraste agrupado só de código acima esteja estabelecido com o país como unidade.

Tabela 5: Chances do Sul Global contra o Norte Global de uma resposta factualmente correta, por tarefa (decomposição exploratória). O desfecho é acurácia factual ≥ 0.5 : o veredito de código onde a tarefa é adjudicada por código (toda a T1; a parte resolvível de T2 e T3), a pontuação do painel ou do juiz nos demais casos, de modo que para T5, que não tem valor de registro, é a nota factual do juiz. RC condicional de um modelo binomial misto com interceptos aleatórios cruzados para país e modelo; RC bruta com seu intervalo bootstrap de 95% por país e o p de permutação do rótulo de tier com o país como unidade.

Tarefa (a resposta é)	GN	GS	RC cond.	RC bruta [IC 95% país]	p
T1 padrão (valor nacional)	50.7%	30.9%	0.32	0.44 $[0.18, 1.05]$	0.062
T4 instrumentos (nacionais)	62.0%	44.7%	0.33	0.50 $[0.19, 1.15]$	0.156
T2 dado local (valor nacional)	50.7%	37.8%	0.47	0.59 $[0.34, 1.00]$	0.086
T3 síntese em saúde (internacional)	59.1%	52.3%	0.69	0.76 $[0.37, 1.46]$	0.397
T5 recomendação (sem valor de registro)	99.6%	99.7%	3.58	1.52 $[0.22, 10.64]$	0.815

Com $n = 25$, o ρ de Spearman (acurácia, IDH) = +0.36 não alcança significância convencional ($p = 0.076$; Mann-Kendall $p = 0.065$) e fica abaixo do limiar pré-especificado $\rho \geq 0.55$, que é o critério contra o qual H1 foi fixada; seu intervalo de Fisher a 95%, $[-0.04, +0.66]$, inclui tanto o zero quanto o limiar, de modo que os dados nem estabelecem o gradiente nem excluem um do tamanho com que nos comprometemos. Nos $n = 15$ pré-especificados ele está ausente ($\rho = +0.08$, $[-0.45, +0.57]$), e nenhuma reestimativa deixando um país de fora alcança 0,55

(intervalo $[+0.3, +0.5]$); sob pesos iguais é 0.35 e sob pesos de PCA 0.38. Relatamos, portanto, uma diferença de tier que conseguimos demonstrar e um gradiente de desenvolvimento que não: a desvantagem está estabelecida como diferença entre grupos, enquanto sua forma ao longo da faixa de desenvolvimento permanece em aberto. Sob Bonferroni-Holm na família primária {H1-gradiente, H4, H6}, nenhum teste rejeita seu nulo.

A ordenação dos países retém grande heterogeneidade ortogonal ao eixo (material suplementar): a Índia (0.651, Sul Global) lidera todos os países, Indonésia e África do Sul superam a maior parte do Norte Global, e Canadá e França ficam baixos. A desvantagem é uma diferença de tier sobreposta a variação substancial específica por país, e essa heterogeneidade é parte da razão de o gradiente não se resolver.

4.7 H4: a representação no corpus não se estabelece

O mecanismo pré-especificado era a representação no corpus de treinamento, aproximada pela contagem de artigos e edições da Wikipédia. Esse proxy é nulo: ρ de Spearman = +0.05 ($p = 0.82$) sem controle, e ainda nulo ao parcializar por IDH e log do PIB per capita. Um proxy post hoc de cobertura do país alcança $\rho = +0.37$ ($p = 0.070$) e se atenua após ajustar por IDH (ρ parcial = +0.19, $p = 0.37$). No nível do país nenhum dos canais se estabelece, porque com 25 países cobertura e desenvolvimento são colineares ($\rho = 0.65$ entre eles).

Mudar a unidade de variação, e o que isso pode e não pode mostrar

Cada país responde a cinco tarefas que diferem em quanto a resposta depende de um fato sobre aquele país: T1, T2 e T4 dependem; T3 (uma estimativa internacional da OMS) e T5 (uma recomendação genérica) não. Os países pontuam 0.462 no primeiro bloco e 0.658 no segundo, um déficit de especificidade de 0.196. Se o que limita o modelo é quanto o corpus fala sobre um dado país, esse déficit deveria ser menor onde a cobertura é maior, e um efeito fixo de país absorve todo efeito principal no nível do país, desenvolvimento e renda incluídos, embora não sua interação com a dependência da tarefa. No nível da resposta, a interação entre cobertura e dependência da tarefa é $\beta = +0.031$ (EP 0.005, $p = 6 \times 10^{-10}$, $n = 6,573$), e o padrão entre classificações é o que um efeito real produziria (Tabela 6): o contraste mais puro, T1 contra T5, dá o maior coeficiente, retirar T5 ou T4 o deixa intacto, e um placebo que inverte os rótulos devolve a imagem espelhada exata.

Esse valor de p no nível da resposta não é a evidência, porque a interação varia apenas entre 25 países. Com erros-padrão agrupados por país, o mesmo coeficiente tem $p = 0.099$; reduzida aos seus 25 déficits por país, a cobertura se correlaciona com o déficit a $\rho = -0.37$ ($p = 0.069$) e a $\rho = -0.16$ ($p = 0.44$) uma vez parcializado o IDH. Entrando IDH $\times$ dependência ao lado de cobertura $\times$ dependência, nenhuma das duas sobrevive com erros agrupados (cobertura $\beta = +0.013$, $p = 0.69$; IDH $\beta = +0.027$, $p = 0.35$), e dentro dos nove países anglófonos, em que o idioma da pergunta é o mesmo por construção, o coeficiente da cobertura é +0.024 com $p = 0.47$ sobre nove clusters. O proxy de corpus do idioma, ao lado da cobertura, é nulo em todos os níveis ($\beta = +0.004$, $p = 0.41$), como previsto para respostas obtidas em inglês.

O desenho dentro do país entrega, portanto, uma associação sugestiva e nenhum mecanismo estabelecido. A direção é a que a explicação por cobertura prevê, as verificações de classificação

se comportam como deveriam, e nada disso alcança significância quando o país é a unidade de inferência. Relatamos H4 como não estabelecida, e a questão cobertura-ou-desenvolvimento como aberta.

Tabela 6: Cobertura do país $\times$ dependência da tarefa, modelo no nível da resposta com efeito fixo de país. β positivo = maior cobertura, menor déficit nas tarefas dependentes do país. p do modelo misto no nível da resposta (intercepto aleatório por modelo) e, nas linhas primárias, com erros-padrão agrupados por país.

Classificação das tarefas	β	p (resposta)	p (agrupado)
T1, T2, T4 contra T3, T5 (primária)	+0.031	6×10^{-10}	0.099
T1 contra T5 (contraste mais puro)	+0.046	1×10^{-11}	
Excluindo T5 (teto em 99,7%)	+0.026	3×10^{-5}	
Excluindo T4 (a mais interpretativa)	+0.034	6×10^{-10}	
Placebo: rótulos invertidos	-0.031	6×10^{-10}	
Com IDH $\times$ dependência: cobertura	+0.013	0.057	0.69
IDH	+0.027	5×10^{-5}	0.35

A explicação por corpus é visível em H2, em que a unidade é o idioma: o hindi, o menor corpus por volume de tokens do mC4 (Xue et al., 2021) e por tamanho do OSCAR (Abadji et al., 2022), carrega a maior penalidade, enquanto espanhol e português carregam penalidades do mesmo tamanho apesar de corpora de tamanhos diferentes. Com três idiomas isso é descritivo.

4.8 H5: abertos contra fechados acessíveis

Os modelos fechados acessíveis têm média +12.8 pp acima dos de pesos abertos, contra o enquadramento otimista de H5. O braço aberto inclui modelos maiores, de modo que a lacuna não é atribuível apenas à escala, embora o DeepSeek-V3 fique em primeiro no geral. H5 é interpretada descritivamente.

4.9 Proveniência do gabarito, e o que a chave de T1 decide

Toda chave vem de um registro oficial, ancorada por verificação documental e reproduzível a partir das URLs citadas: T1 do regulamento nacional, T2 da WHO Ambient Air Quality Database v6.1, T3 do indicador AIR_41 do GHO da OMS, T4 do UNEP Global Assessment of Air Pollution Legislation. Três países não têm padrão nacional de PM_{2,5}, confirmado no texto oficial (a Nigéria regula apenas PM₁₀, a Argentina não tem valor federal vinculante, Angola não tem legislação nacional), que é onde um modelo fiel precisa declinar de enunciar um limiar inexistente. O Egito não tem valor recuperável e, portanto, não tem chave de T1. Os quatro casos são do Sul Global, de modo que a composição da chave é ela própria uma explicação candidata para a lacuna de T1. Não é: deixando de lado os três países sem padrão, a chance condicional do Sul Global em T1 é 0.39 [0.32, 0.49] da do Norte Global, contra 0.32 com eles. A chave também se moveu sob revisão, na direção Sul que o argumento da Seção 5 prevê: a entrada de Bangladesh carregava os 15 $\mu\text{g}/\text{m}^3$ do seu diário oficial de 2005 até que um leitor externo apontou as Rules de 2022, que fixam 35, e com a chave corrigida a acurácia de Bangladesh em T1 cai de 0.39 para 0.30, porque a maioria dos modelos cita o valor superado. O registro completo está no material suplementar. Wikipédia

e Wikidata aparecem apenas como variável explicativa do teste de mecanismo; nenhuma resposta é pontuada contra elas.

A chave em vigor, e a escada ao redor dela. Vários instrumentos fixam uma escada de valores, e não um só: a Resolução CONAMA 506/2024 do Brasil corre 20, 17, 15, 10, 5 $\mu\text{g}/\text{m}^3$ em cinco etapas, das quais 17 está em vigor desde janeiro de 2025; o limite europeu é 25 com 10 a partir de 2030; o valor-limite do Reino Unido é 20 com meta inglesa de 10 até 2040; os Estados Unidos passaram de 12,0 para 9,0 em 2024; Bangladesh de 15 para 35 em 2022. A chave de T1 é o valor em vigor na janela de coleta, e ela é exigente: nenhum modelo devolve 17 para o Brasil (a resposta modal é 15, a etapa seguinte), quase nenhum devolve 20 para o Reino Unido (a maioria devolve a meta de 2040 ou os 25 superados), e menos de um quarto devolve 9,0 para os Estados Unidos. Das 759 respostas erradas de T1, 281 citam um valor que está em algum ponto da escada oficial do país, uma etapa ainda não em vigor ou um valor desde então substituído, o que é confusão sobre qual valor vincula e não fabricação, e é a falha que um corte de treinamento produziria. A distinção não resgata a comparação de tier; ela a torna mais aguda. Pontuar qualquer valor da escada como correto eleva a acurácia do Norte Global em T1 de 0.51 para 0.77 e a do Sul Global apenas de 0.31 para 0.42, porque os instrumentos por etapas estão majoritariamente no Norte, e a razão de chances condicional cai para 0.14 [0.11, 0.16]. Onde o registro oferece vários números plausíveis os modelos os conhecem; onde oferece um, frequentemente não.

4.10 Modos de falha qualitativos

Três modos de falha recorrem por trás do composto, com exemplos literais no material suplementar. Os modelos fabricam padrões que não existem para os três países sem norma nacional: em 168 das 256 células de T1 pontuadas para Angola, Argentina e Nigéria a resposta afirma um valor nacional específico, em 33 afirma corretamente que nenhum existe, e em 31 declina de responder, e os valores inventados discordam entre réplicas. Eles erram o valor vinculante, respondendo 15 $\mu\text{g}/\text{m}^3$ para o Brasil onde a etapa em vigor é 17 (CONAMA 506/2024), uma confusão de etapa e não uma invenção. E degradam no idioma nativo, como quando o GPT-OSS 120B devolveu os 40 $\mu\text{g}/\text{m}^3$ corretos da Índia em inglês e uma resposta vazia em hindi.

4.11 Confiabilidade entre juízes

A confiabilidade é relatada na amostra que produz os efeitos, e não em um subconjunto de calibração. Todos os 3.190 itens que exigiram juiz foram pontuados pelos três membros do painel, dando α de Krippendorff = 0.527, ICC(2, 1) de juiz único = 0.558 e, como grandeza operativa, já que a análise usa a média do painel, ICC(2, 3) = 0.791.

O painel também isola uma regra de desenho que generaliza para além deste estudo. Onde o prompt de julgamento pedia ao modelo que comparasse uma concentração devolvida com uma faixa de tolerância expressa em palavras, isto é, que fizesse ele próprio a aritmética, a concordância entre juízes nesses itens foi $r = -0.04$. Pré-computar a faixa admissível e perguntar apenas se o valor cai dentro dela elevou a concordância nos mesmos itens para $r = +1.00$, e as 274 pontuações coletadas sob a redação ambígua foram descartadas e recoletadas. A discordância aparente entre juízes pode ser artefato do que se pede ao juiz que compute, que é a mesma lição

que [Zheng et al. \(2023\)](#) extraem quando uma resposta de referência reduz a taxa de falha de um juiz em aritmética de 70% para 15%. Aritmética pertence ao código.

4.12 Robustez

Os dois efeitos sustentados foram testados contra sete ataques e sobrevivem a todos; o gradiente de desenvolvimento fica abaixo do 0,55 pré-especificado sob cada um (seu valor mais alto, 0,48, é uma reestimativa deixando um país de fora). As saídas completas estão no material suplementar.

Nenhum país isolado, e nenhuma ponderação, carrega o resultado. A reestimação deixando um país de fora mantém a lacuna de tier do composto em $[+4.4, +6.0]$ pp e a penalidade do idioma nativo em -4.3 a -5.5 pp. Sob pesos iguais a lacuna é $+4.2$ pp e a penalidade de idioma -4.8 pp; restringir à acurácia factual contra o valor do registro as alarga para $+8.9$ e -6.1 pp e aprofunda o piso de recordação, de modo que os dois efeitos crescem onde a medição é mais objetiva. As duas réplicas de cada célula diferem em 8.5 pp em média (DP intracélula 10.1 pp), de modo que a penalidade de idioma de -5.0 pp, tirada em média sobre 839 pares, fica a cerca de dez erros-padrão do ruído que duas réplicas deixam sem resolver.

A lacuna de tier sobrevive a um teste livre de distribuição e a duas famílias de modelo. Um teste de permutação embaralha os rótulos Norte/Sul entre os 25 países dez mil vezes e conta quantas vezes o acaso sozinho produz uma lacuna deste tamanho; ele não presume nada sobre a distribuição e trata o país como unidade independente. O acaso supera a lacuna observada 1.9% das vezes ($p = 0.019$). Um modelo hierárquico bayesiano com interceptos aleatórios cruzados concorda ($\beta = -0.049$, HDI de 94% $[-0.088, -0.006]$, $P(\beta < 0) = 0.987$), enquanto um modelo misto frequentista devolve a mesma magnitude e o mesmo sinal, mas a deixa marginal ($\beta = -0.063$, $p = 0.086$), porque atribui a grande heterogeneidade entre países ao termo de erro. Dois de três testes superam o zero e os três concordam na magnitude, de modo que relatamos a lacuna como sustentada e sensível à especificação, com E-value de 1.71 na estimativa pontual e 1.31 no limite de confiança mais próximo do nulo ([VanderWeele and Ding, 2017](#)); um confundidor no nível do país de força modesta bastaria para explicá-la.

A lacuna segue a partição da UNCTAD, não as partições por IDH. Reestimada sob três partições baseadas em desenvolvimento dos mesmos 25 países, a lacuna é significativa sob a UNCTAD e não significativa sob toda divisão traçada pelo IDH (material suplementar). Isso é coerente com o gradiente nulo do IDH, já que uma divisão pelo IDH não deveria então produzir lacuna. Uma leitura é que a posição no sistema-mundo, e não a renda, é a variável operante ([Quijano, 2000](#); [Mohamed et al., 2020](#)); a leitura é post hoc, e reivindicamos a lacuna para a distinção Norte/Sul tal como convencionalmente traçada, não como afirmação geral sobre desenvolvimento.

O que o gradiente nulo exclui e o que não exclui. Simulando amostras de 25 países a correlações conhecidas, o desenho tem 77% de poder em $\rho = 0,55$, o limiar fixado de antemão, e um efeito mínimo detectável de $\rho = 0.56$. O poder diz com que frequência um gradiente verdadeiro desse tamanho teria sido detectado; ele não estreita o intervalo observado, e o intervalo relatado acima ainda inclui 0,55. Os dez países acrescentados post hoc caem dentro da faixa de IDH que os quinze originais já cobriam, de modo que a extensão eleva a densidade de observações e não a amplitude do preditor.

O modelo regional foi servido como publicado. Como H3 se apoia em um único modelo

servido localmente, verificamos a pilha de serviço depois do fato. O template do Ollama usado para o Cabra-Mistral 7B é o template de chat publicado com o tokenizador do modelo, e o modelo responde aos prompts em português em português coerente. Em seguida reservimos os 30 prompts em português, com duas réplicas, ao Cabra, à sua base declarada (Mistral-7B-Instruct-v0.3 na mesma quantização) e ao Llama 3.1 8B, e pontuamos T1–T3 com o extrator de código do estudo (material suplementar). Reservido, o Cabra devolve o valor do registro em 47% dos itens em português resolvidos por código (37% na coleta original), seu modelo-base em 50% e o Llama 3.1 8B em 43%. Com 30 itens por modelo, os três ficam a poucas respostas um do outro: o ajuste fino não supera a base de que foi treinado, a pilha de serviço não explica sua posição, e a margem do composto contra o Llama 3.1 8B vem das tarefas e dos subcomponentes julgados, não dos valores de registro.

4.13 Síntese

A Tabela 7 mapeia cada hipótese ao seu achado, ao mecanismo candidato e a um status de evidência explícito. Três efeitos são sustentados e sobrevivem a todo ataque de robustez da Seção 4.12; duas expectativas pré-especificadas não se cumprem; e o mecanismo de corpus é sugestivo dentro dos países e não estabelecido no nível do país.

Tabela 7: Hipóteses, achados, mecanismos candidatos e status de evidência. Agrupadas pelo que a evidência sustenta, não pelo número da hipótese.

Hipótese	Achado	Mecanismo
<i>Sustentadas</i>		
H2 idioma	−5.0 pp; hindi −11.4	corpus do idioma
H3 modelo regional	$\delta = -0.48$, pior de 14	escala acima de ajuste
H1 lacuna de tier	+14.7 pp só código; +5.0 pp composto	tier
<i>Não estabelecida</i>		
H4 dentro do país	$\rho = -0.37$ ($p = 0.069$) no nível do país	cobertura ou desenvolvimento
<i>Não sustentadas</i>		
H1 gradiente	$\rho = 0.36$ [−0.04, +0.66]	desenvolvimento
H4 pré-especificada	proxy de corpus do idioma nulo	corpus do idioma
H6 persona	DiD +0.5 pp, equivalente em até ± 2 pp	—
<i>Apenas descritiva</i>		
H5 aberto/fechado	+12.8 pp para fechados	tipo de acesso

Nota. O mecanismo de H2 se apoia em três idiomas nativos e é descritivo. A lacuna de tier de H1 se concentra em tarefas cuja resposta depende de um fato nacional; a decomposição por tarefa é exploratória. H4 dentro do país aponta na direção prevista e não alcança significância com o país como unidade.

5 Discussão

Propusemo-nos a medir se os LLMs respondem a perguntas de política de poluição do ar com a mesma confiabilidade para o Sul Global e para o Norte Global, se o enquadramento do prompt

muda a resposta e que mecanismo impulsiona qualquer lacuna. Em 25 países, 14 modelos, quatro idiomas, cinco tarefas e duas personas, pontuados contra gabarito oficial por código onde a resposta é um valor de registro e por um painel de três fornecedores nos demais casos, os danos que conseguimos demonstrar são práticos: os três remédios a que um órgão recorreria falham, o mais intuitivo deles torna a resposta materialmente pior, e os modelos são menos confiáveis na recordação do valor vinculante em vigor. Uma diferença de tier Norte/Sul persiste, e o mecanismo por trás dela não se estabelece no nível em que a inferência é sólida.

5.1 Três remédios intuitivos, todos falhando, e um que prejudica

O idioma local não ajuda e prejudica materialmente. Perguntar no idioma do próprio país reduz a acurácia em 5.0 pp, significativamente nos três idiomas e com o país como unidade de inferência, e a maior penalidade recai sobre o hindi, o idioma de corpus mais escasso, com a Índia, o país de maior pontuação entre os 25 em inglês, caindo mais. Essa é a direção que a hierarquia de recursos prevê (Joshi et al., 2020; Xue et al., 2021), e a medição consegue vê-la porque a unidade é o idioma e não o país; com três idiomas, e espanhol e português indistinguíveis, a ordenação é descritiva. O efeito não depende de nenhum país, modelo, tarefa, condição de persona ou instrumento de pontuação isolado, nem da qualidade da tradução, e se mantém em um desfecho que não envolve juiz algum: o modelo fica marcadamente menos propenso a produzir um número conferível, e mais propenso a não devolver nada.

A persona de gestor local não estreita a lacuna (DiD +0.5 pp, permutação $p = 0.29$, equivalente a zero em até ± 2 pp), em consonância com a evidência de que personas de especialista não melhoram a acurácia factual (Zheng et al., 2024; Basil et al., 2025), e seu efeito principal é uma pequena perda (-0.62 pp). Esse nulo pesa mais do que pesaria um nulo sobre um hábito popular, porque o enquadramento de papel é a primeira coisa que todo grande fornecedor diz aos usuários para fazer; Anthropic, OpenAI, Google e xAI convergem no mesmo conselho (Seção 2), de modo que uma administração que segue a documentação do fornecedor escreve a frase que testamos. O que essa documentação reivindica para a frase é controle sobre tom, formato e enquadramento, e nada nela diz que a técnica que molda o registro não molda também a confiabilidade factual. Nossa estimativa separa as duas. Uma checagem de manipulação confirma que metade das respostas assume explicitamente o papel, de modo que o enquadramento é recebido e muda a voz; ele não muda o que o modelo sabe. Testamo-lo digitado na mensagem e não instalado como instrução de sistema, o canal que um servidor público numa interface de chat tem (Seção 5.7).

O modelo regional é o pior dos catorze ($\delta = -0.48$), e fica atrás do seu par de escala nos prompts brasileiros em português para os quais foi ajustado (0.258 contra 0.313 do Llama 3.1 8B, em 20 células cada; -5.9 pp nos 30 prompts em português), de modo que recorrer a um modelo pequeno com ajuste local troca a escala e o treinamento de fronteira que carregam a acurácia no domínio sem comprar de volta o conhecimento local que promete. Três limites cercam isso: o teste estreito é pequeno; só nos valores de registro, reservados nos mesmos itens em português, Cabra, seu modelo-base e o Llama 3.1 8B ficam a poucas respostas um do outro (Seção 4.12), de modo que a margem do composto se apoia nas tarefas e nos subcomponentes julgados; e o modelo que pudemos rodar é um ajuste comunitário de uma base de 7B, não um modelo regional comercial de fronteira do tipo que um órgão poderia adquirir. Para esses, o achado é

uma previsão, e o protocolo liberado é o modo de testá-la.

Os praticantes implantam os três como correções; nenhum funciona, e o que um gestor mais provavelmente tenta primeiro causa dano ativo. Para órgãos ambientais do Sul Global, nenhum atalho barato no nível do prompt ou do modelo substitui a verificação do valor vinculante contra a fonte oficial.

5.2 O piso de recordação está sobre os valores que vinculam

O risco recai de forma desigual. Um gestor que redige prosa sobre política de qualidade do ar é comparativamente bem servido; um gestor que recupera o ponto de corte regulatório de que uma decisão depende está na pior célula do desenho (Seção 4.3), e pior ainda se perguntar num idioma de menor recurso. O piso não é artefato de pontuação: o veredito factual nas duas tarefas de recordação é decidido por código contra o registro, o contraste se mantém com todo modelo e todo país como unidade, e um terço das respostas erradas sobre o padrão nacional cita um valor da própria escada oficial do país e não um valor inventado. Os modelos conhecem a escada e não sabem qual degrau vincula.

5.3 Uma diferença de tier que conseguimos mostrar, e um gradiente que não

O achado geográfico é uma diferença entre grupos, não uma inclinação. Nos desfechos que nenhum juiz toca, os países do Sul Global devolvem o valor do registro +14.7 pp menos vezes do que os do Norte Global, com o país como unidade; no composto a lacuna é de +5.0 pp, do mesmo tamanho dentro da onda de extensão e nos quinze pré-especificados, e inalterada quando os quatro membros da UE contam como um. Ela é concentrada: cresce com o quanto a resposta depende de um fato específico do país e está ausente na única tarefa sem valor de registro a acertar (Seção 4.6), embora os intervalos por tarefa com o país como unidade sejam largos e essa decomposição seja exploratória. O gradiente de desenvolvimento fica abaixo do limiar pré-especificado em toda leitura, e seu intervalo, $[-0.04, +0.66]$, inclui tanto o zero quanto o limiar: 25 países nem estabelecem um gradiente nem o descartam. A ordenação dos países mostra por que os dois resultados diferem. A Índia lidera os 25 países apesar de ser do Sul Global, Canadá e França ficam baixos, de modo que a desvantagem é uma diferença de tier sobreposta a idiossincrasia específica por país que uma correlação de postos sobre 25 países não consegue atravessar.

5.4 O mecanismo, e por que não se estabelece

O teste de mecanismo pré-especificado falha, e parte da razão é um defeito no instrumento. O proxy atribui o tamanho da edição da Wikipédia no idioma oficial dominante do país, de modo que nove dos nossos 25 países recebem o valor da Wikipédia inglesa. A variável não mede quanto texto existe no idioma de um país; mede se o país tem inglês como língua oficial, o que acompanha a história colonial e não o tamanho do corpus. Relatamos isso porque afeta qualquer estudo que tenha usado ou venha a usar o mesmo proxy.

Mudar a unidade de variação deu uma associação no nível da resposta na direção prevista, com as verificações que um efeito real passaria, e ela não sobrevive à inferência com o país como

unidade: agrupado por país, o coeficiente tem $p = 0.099$, os 25 déficits por país se correlacionam com a cobertura a $\rho = -0.37$ ($p = 0.069$), e dado o IDH a associação é -0.16 . Nesses 25 países, cobertura e desenvolvimento se correlacionam a $\rho = 0.65$, e o desenho não tem alavanca que mova um sem o outro. Relatamos, portanto, a explicação por cobertura como compatível com os dados e não estabelecida por eles, e a questão cobertura-ou-desenvolvimento como aberta.

5.5 A lição metodológica: a chave importa mais que a amostra

As mesmas células pontuadas sustentam conclusões substantivas diferentes conforme o instrumento usado para pontuá-las, e o tamanho dessa diferença é a lição. Pontuar duas tarefas contra chaves provisórias e delegar a aritmética de faixa a um juiz produziu um gradiente de desenvolvimento significativo e uma penalidade de idioma pequena; reconstruir as chaves a partir de registros oficiais e mover a comparação para código reduziu o gradiente pela metade e mais que dobrou a penalidade (Seções 4.6 e 4.4). Mover o veredito factual da terceira tarefa com valor de registro de dois juízes de coleta para código mudou sua razão de chances-manchete em um terço, porque os juízes estavam divididos pela mesma linha dos tiers. A própria chave continuou se movendo sob escrutínio: a entrada do Reino Unido carregava uma meta de 2040 no lugar do limite em vigor, e a de Bangladesh carregava o valor de 2005 depois de as Rules de 2022 o terem elevado, de modo que um modelo que citava o padrão vigente correto de um país do Sul Global era pontuado como errado até que um leitor externo o apanhou. O conjunto de dados nunca mudou; apenas o instrumento. O instinto da área quando um efeito de viés geográfico se revela frágil é acrescentar países, mas o gabarito merece o escrutínio primeiro. Uma chave defeituosa não apenas acrescenta ruído; acrescenta ruído estruturado, porque os defeitos se concentram onde os textos oficiais são mais difíceis de obter ou foram revisados mais recentemente, que é onde a hipótese mora. O registro liberado carrega, por isso, um hash de conteúdo (material suplementar), para que qualquer leitor saiba contra qual versão da chave um número foi computado. A mesma lição vale para a inferência: com a resposta como unidade, H4 tinha $p = 6 \times 10^{-10}$; com o país como unidade tem $p = 0.069$, e só o segundo descreve o que 25 países conseguem mostrar.

5.6 Por que o domínio importa

O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura, e a carga recai de forma desproporcional sobre o Sul Global: a Organização Mundial da Saúde atribui 88.548 óbitos no Brasil em 2021 à poluição do ar ambiente (intervalo de incerteza 69.477 a 108.431) (World Health Organization, 2026), e a exposição de curto prazo continua a produzir mortalidade mensurável nas cidades brasileiras (Requia et al., 2024). Quando um gestor delega a um LLM uma consulta normativa ou uma recomendação para um episódio, uma resposta imprecisa pode se propagar para um parecer regulatório ou uma resposta de emergência.

Não afirmamos que o modelo é menos confiável onde as consequências são maiores, porque não medimos isso: a carga de doença não está entre nossas covariáveis de país, e a única observação no nível do país de que dispomos aponta na direção oposta, já que a Índia carrega uma das maiores cargas de mortalidade por $PM_{2.5}$ do mundo e é também o país de maior pontuação na nossa amostra. Se a confiabilidade está desalinhada da necessidade é respondível com a adição de uma covariável de mortalidade atribuível padronizada por idade, mas não por este desenho.

O arcabouço da colonialidade do saber (Mohamed et al., 2020) oferece uma interpretação do padrão que medimos, em que os LLMs são resumos comprimidos de corpora produzidos sob acesso digital e de publicação desigual e a penalidade de idioma é um elo entre assimetria de corpus e assimetria de conhecimento; os dados sustentam a penalidade e a diferença de tier, e a interpretação permanece uma interpretação.

5.7 Limitações e oportunidades futuras

Cada limite abaixo cerca este desenho, e cada um nomeia o estudo que o removeria. Nós os listamos na ordem em que os executariamos.

Sem braço de recuperação. Toda resposta vem da memória paramétrica do modelo. Um gestor que usa um assistente com busca, ou um sistema de recuperação sobre o diário oficial nacional, enfrenta outro instrumento, e a lacuna e a penalidade de idioma podem mudar sob ele. Os prompts e registros liberados permitem rodar um braço de recuperação sobre os mesmos itens, e é o primeiro estudo que acrescentariamos.

O enquadramento de papel foi testado no turno do usuário, não no prompt de sistema. O enquadramento de gestor é prefixado à mensagem em vez de instalado como instrução de sistema, onde três dos quatro guias de fornecedor o colocam; o da Google admite esse lugar ou o início do prompt do usuário, que é o que usamos. A escolha segue a população que nos interessa, servidores públicos na interface de chat, que não têm prompt de sistema a configurar, mas nosso nulo cerca o canal desse usuário, não o de um desenvolvedor. Se uma persona em instrução de sistema recupera acurácia factual onde uma digitada não recupera é um experimento de duas células sobre os mesmos itens.

Do pontuado por painel ao ancorado em padrão-ouro. Nenhum especialista humano repontuou respostas aqui. Três propriedades cercam o que isso custa: onde a resposta é um valor de registro, o veredito factual é computado por código; onde é preciso julgamento, a pontuação é a média de três fornecedores e não de um; e todo efeito relatado é um contraste entre grupos, em que a severidade sistemática de um juiz se cancela. Restringir à acurácia factual objetiva fortalece os dois efeitos-manchete, o oposto do que um juiz permissivo produziria. Dois resíduos permanecem: os quatro subcomponentes não factuais de uma célula de T1 ainda são os do juiz da coleta, razão pela qual o veredito de código e não o composto é o desfecho primário de tier, e a auditoria manual do extrator cobriu apenas T1. Uma validação cega por especialistas humanos de uma amostra estratificada, cerca de 150 respostas pontuadas por três avaliadores, que o pipeline liberado exporta diretamente, converteria um resultado ancorado em fonte oficial num resultado ancorado em padrão-ouro.

De um sinal dentro do país a um desenho causal. Dentro dos países removemos o confundimento no nível do país sem remover o confundimento tarefa-por-país, e o sinal não alcança significância no nível do país. Um desenho que varie a cobertura do país mantendo o desenvolvimento fixo, ou um estudo longitudinal que acompanhe a acurácia à medida que a pegada enciclopédica de um país cresce, trataria do primeiro problema; mais países tratariam do segundo.

De um gradiente nulo a um teste adequadamente potente. A diferença de tier está estabelecida enquanto o gradiente não está, com $n = 25$, e o intervalo do gradiente inclui o limiar. Uma replicação pré-registrada com n maior, que o conjunto de dados aberto torna barata, decidiria

se o gradiente está ausente ou subpotente.

De três idiomas nativos à matriz multilíngue completa. O resultado mais forte se apoia em três idiomas nativos, de modo que seu mecanismo é relatado descritivamente ainda que o efeito não seja; para um dos três, o hindi, o próprio instrumento oficial é publicado em inglês, de modo que a penalidade ali é uma penalidade pelo idioma do usuário e não pelo idioma do registro. A objeção da qualidade da tradução está resolvida empiricamente pelo censo de retrotradução relatado acima; o que permanece em aberto é a amplitude, e escalar para mais idiomas é a extensão de maior valor que este estudo aponta.

De um domínio a um programa multidomínio. Todos os efeitos vêm de um domínio aplicado de alto risco e de uma família de corpus (Wikimedia), e confinamos a linguagem mecanicista de acordo. A mesma suíte de tarefas e o mesmo método de registro de gabarito se transferem diretamente a outros domínios regulados e ancorados em fonte, como qualidade da água, segurança alimentar e política de vacinação.

A pilha do modelo servido como unidade de análise. Avaliamos modelos tal como servidos por configurações de acesso fixas, que é o que um gestor público consulta; uma lacuna residual poderia em princípio refletir a pilha em vez dos pesos. A verificação de serviço do modelo regional (Seção 4.12) cobre uma pilha; um desenho controlado com pesos abertos idênticos em várias pilhas separaria as duas para todas elas, o que a proveniência por chamada que liberamos permite.

5.8 O que este estudo contribui

As três correções a que os praticantes recorrem primeiro falham juntas: o idioma local prejudica, o enquadramento de persona não faz nada, e o modelo de 7B com ajuste regional é o pior dos catorze. O resultado metodológico é que, nesta literatura, a chave de gabarito, e o nível em que a inferência é feita, importam mais que o tamanho da amostra. E o desenho separa o que 25 países conseguem demonstrar do que não conseguem, relatando o segundo conjunto como aberto e não como sustentado.

6 Conclusão

Os grandes modelos de linguagem estão se tornando infraestrutura de trabalho para a política de poluição do ar, um domínio em que uma resposta imprecisa sobre um padrão vinculante, uma concentração medida ou uma resposta operacional tem consequência direta para a saúde pública no Sul Global, onde a carga de mortalidade por PM_{2,5} é mais pesada (GBD 2019 Risk Factors Collaborators, 2020; Requia et al., 2024). Medimos o viés geográfico e o viés modulado por persona nesse domínio com um benchmark de 25 países, 14 modelos e quatro idiomas (inglês mais o idioma nativo de nove países), pontuado contra gabarito ancorado em fontes primárias oficiais, por código sempre que a resposta é um valor de registro e pela média de um painel de juízes de três fornecedores nos demais casos.

Os remédios que um órgão pode tentar não funcionam, e o mais intuitivo sai pela culatra. Perguntar no idioma do próprio país reduz a acurácia em 5.0 pontos percentuais, de forma mais acentuada para o hindi, o idioma menos representado nos corpora de treinamento; uma persona

de gestor local não estreita a lacuna e é equivalente a nenhuma persona em até 2 pp; e o modelo de 7B com ajuste regional é o mais fraco dos catorze sistemas. A acurácia é também mais baixa na recordação de um valor vinculante, a tarefa que um gestor menos pode se permitir errar. Uma lacuna de tier Norte/Sul Global persiste e é estruturada: nos desfechos que nenhum juiz toca, os países do Sul Global devolvem o valor do registro +14.7 pp menos vezes, e a lacuna diminui à medida que a resposta depende menos de um fato específico do país, desaparecendo na única tarefa sem valor de registro a acertar. O gradiente de desenvolvimento não alcança significância e seu intervalo inclui tanto o zero quanto o limiar pré-especificado, de modo que relatamos uma diferença entre grupos que conseguimos demonstrar e uma forma ao longo da faixa de desenvolvimento que não conseguimos. Sobre o mecanismo, o desenho dentro do país aponta para a cobertura do país e não a estabelece quando o país é a unidade de inferência, e não reivindicamos mais do que isso.

Para os órgãos ambientais do Sul Global, a mensagem prática é de cautela. As saídas de LLMs sobre padrões vinculantes e dados medidos devem ser tratadas como rascunhos conferidos contra o diário oficial, e nenhum dos atalhos baratos no nível do prompt ou do modelo substitui essa verificação, muito menos trocar para o idioma local, que com esta evidência torna a resposta pior. A penalidade recai sobre os idiomas mal servidos nos corpora de treinamento (Joshi et al., 2020), com mais força sobre o hindi; se esses idiomas são também falados onde a carga de saúde da poluição do ar é maior não é algo que este desenho mede, e a única observação no nível do país de que dispomos (Índia) aponta na direção oposta (Seção 5).

Um resultado metodológico generaliza para além do domínio. Reconstruir duas chaves de tarefa a partir de registros oficiais e mover a comparação de faixa do juiz para o código mudou as conclusões substantivas sobre as mesmas respostas, e fazer a inferência no nível do país em vez da resposta mudou o status do teste de mecanismo. Quando um efeito nesta literatura se revela frágil, a chave de gabarito e a unidade de inferência merecem a auditoria antes da amostra, porque uma chave defeituosa acrescenta ruído estruturado que se concentra onde os dados oficiais são mais difíceis de obter, e um valor de p no nível da resposta superestima o que um punhado de países consegue mostrar.

Protocolo, prompts, registros de gabarito de fonte oficial, código de análise e dados de resposta anonimizados são liberados abertamente, com pipeline de reprodução em um comando e um gate de auditoria de método que recomputa cada número relatado a partir dos dados brutos. O estudo também fornece um modelo reutilizável para auditorias aplicadas de equidade de LLMs, com gabarito de fonte oficial, adjudicação por código sempre que a resposta é um número conferível e reprodutibilidade de ponta a ponta, nos domínios de alto risco do setor público em que esses sistemas estão sendo implantados.

Disponibilidade de dados e código

O protocolo completo, os prompts, o código de análise, os registros de gabarito e as respostas anonimizadas dos modelos serão liberados na publicação em github.com/Roverlucas/artigo-vies-analise-regional, sob licenças MIT (código) e CC-BY-4.0 (dados, prompts, documentação). A liberação inclui os registros por resposta a partir dos quais cada efeito relatado é calculado, de modo que todo número deste artigo pode ser recomputado do dado bruto em vez de aceito

1146 por confiança. O pipeline de análise roda de ponta a ponta com `python code/run_all.py`
1147 `-confirmatory`.

1148 Protocolo do estudo

1149 Hipóteses, marco amostral, definição de desfecho, limiares de decisão e correção de multiplicidade
1150 foram fixados em um plano de análise sob controle de versão antes do início da coleta confirma-
1151 tória. Esse plano não foi depositado em registro público, de modo que o leitor não pode verificar
1152 sua data de forma independente do histórico do repositório, e *não* reivindicamos pré-registro.
1153 O escopo entregue também se afastou substancialmente do desenho planejado, o que o próprio
1154 plano estabelecia como condição para o estatuto confirmatório.

1155 Relatamos o estudo, portanto, em duas camadas. A primeira declara o que foi especificado de
1156 antemão e o que aconteceu com cada item. A segunda relata o que os dados sugeriram e o plano
1157 não antecipou, rotulado como exploratório do começo ao fim, com intervalos e sem linguagem
1158 confirmatória. Os desvios em relação ao plano estão tabulados no material suplementar.

1159 Agradecimentos

1160 Esta pesquisa não recebeu financiamento específico de agências dos setores público, comercial
1161 ou sem fins lucrativos. Os custos de inferência foram pagos pelos autores; nenhum fornecedor
1162 concedeu créditos, descontos ou apoio em espécie para este estudo.

1163 Contribuições dos autores

1164 Segundo a taxonomia CRediT:

- 1165 • Lucas Rover (UTFPR): Conceituação, Metodologia, Software, Curadoria de Dados, Aná-
1166 lise Formal, Investigação, Visualização, Redação – Rascunho Original, Administração do
1167 Projeto.
- 1168 • Vitor de Melo Dominski (Faculdade Descomplica): Curadoria de Dados, Software, Análise
1169 Formal.
- 1170 • Prof. Anibal Tavares de Azevedo (Unicamp): Redação – Rascunho Original, Redação –
1171 Revisão e Edição.
- 1172 • Dr. Eduardo Tadeu Bacalhau (UFPR): Validação, Supervisão, Redação – Revisão e Edição.
- 1173 • Dra. Yara de Souza Tadano (UTFPR): Validação, Supervisão, Redação – Revisão e Edição.

1174 Declaração sobre IA generativa na redação

1175 É preciso separar dois usos distintos, porque apenas um deles é objeto desta declaração.

1176 *Como objeto e instrumento do estudo.* Modelos de linguagem são o objeto desta pesquisa
1177 e também servem como um de seus instrumentos de medida: GPT-5-mini e Claude Haiku 4.5
1178 pontuaram respostas contra o registro de gabarito como juízes da coleta; Gemini 2.5 Pro, Claude

Sonnet 4.6 e DeepSeek-V3 as repontuaram como painel de três fornecedores; e o Claude Sonnet 4.6 produziu as versões dos prompts em idioma nativo. Esses usos fazem parte do método, estão descritos na Seção 3, e são a razão de o estudo também relatar confiabilidade entre juízes e uma auditoria de retrotradução dos prompts traduzidos. Onde a resposta correta é um valor de registro oficial, o veredito é computado por código, não por modelo.

Na preparação do manuscrito. Durante a preparação deste trabalho, os autores usaram o Claude, da Anthropic (via Claude Code), para auxiliar na redação e edição do texto e na implementação do código de análise; o Codex CLI, da OpenAI, para rodar uma auditoria adversarial do manuscrito, do suplemento e do código contra suas fontes; e, por API, o Gemini 2.5 Pro, o DeepSeek-V3 e o GPT-5.2-pro como revisores independentes das afirmações e da prosa do manuscrito, cada um rodado em fornecedor diferente do que redigiu o trecho revisado. Após usar essas ferramentas, os autores revisaram e editaram o conteúdo conforme necessário e assumem responsabilidade integral pelo conteúdo da publicação. Nenhum modelo de linguagem consta como autor, e nenhum modelo contribuiu com a interpretação dos achados ou com as decisões sobre o que a evidência sustenta.

Declaração de interesses

Os autores declaram não haver conflitos de interesse.

Referências

- Abadji, J., Ortiz Suárez, P., Romary, L., and Sagot, B. (2022). Towards a cleaner document-oriented multilingual crawled corpus. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 4344–4355.
- Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fannesbeck, C. J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C. C., Martin, O. A., et al. (2023). PyMC: A modern and comprehensive probabilistic programming framework in Python. *PeerJ Computer Science*, 9:e1516.
- Almeida, T., Nogueira, R., and Pedrini, H. (2025a). Building high-quality datasets for Portuguese LLMs: From Common Crawl snapshots to industrial-grade corpora. *Journal of the Brazilian Computer Society*, 31(1):1247–1263.
- Almeida, T. S., Bonás, G. K., and Santos, J. G. A. (2025b). BRoverbs: Measuring how much LLMs understand Portuguese proverbs. *Journal of the Brazilian Computer Society*, 31:1078–1088.
- Almeida, T. S., Bonás, G. K., Santos, J. G. A., Abonizio, H., and Nogueira, R. (2025c). TiEBe: Tracking language model recall of notable worldwide events through time. *arXiv preprint arXiv:2501.07482*.
- Anthropic (2026). Prompting best practices: *Give Claude a Role*. Claude Platform Documentation, Prompt Engineering. Section “Give Claude a role”.

1214 Aoki, N., Tatsumi, T., Naruse, G., and Maeda, K. (2024). Explainable AI for government: Does
1215 the type of explanation matter to the accuracy, fairness, and trustworthiness of an algorithmic
1216 decision as perceived by those who are affected? *Government Information Quarterly*,
1217 41(4):101965.

1218 Basil, S., Shapiro, I., Shapiro, D., Mollick, E. R., Mollick, L., and Meincke, L. (2025). Prompting
1219 science report 4 — playing pretend: Expert personas don’t improve factual accuracy. SSRN
1220 Working Paper.

1221 Bender, E. M., Gebru, T., McMillan-Major, A., and Shmitchell, S. (2021). On the dangers
1222 of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM
1223 Conference on Fairness, Accountability, and Transparency*, pages 610–623.

1224 Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and
1225 powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*,
1226 57(1):289–300.

1227 Choroszewicz, M. (2026). Positioning public sector practitioners as ‘moral crumple zones’: Me-
1228 chanisms in the early use of generative AI work support tools. *Government Information
1229 Quarterly*, 43(2):102128.

1230 Cordella, A. and Gualdi, F. (2024). Regulating generative AI: The limits of technology-neutral
1231 regulatory frameworks. insights from Italy’s intervention on ChatGPT. *Government Informa-
1232 tion Quarterly*, 41(4):101982.

1233 Dahl, M., Magesh, V., Suzgun, M., and Ho, D. E. (2024). Large legal fictions: Profiling legal
1234 hallucinations in large language models. *Journal of Legal Analysis*, 16(1):64–93.

1235 GBD 2019 Risk Factors Collaborators (2020). Global burden of 87 risk factors in 204 countries
1236 and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019.
1237 *The Lancet*, 396(10258):1223–1249.

1238 Google (2026). Prompting strategies: Role definitions in system instructions. Gemini API Do-
1239 cumentation. Vendor documentation instructing developers to place role definitions (persona)
1240 in the system instruction. Accessed 2026-08-25.

1241 Igoikina, A. A. and Meshcheryakov, G. (2020). semopy: A python package for structural equation
1242 modeling. *Structural Equation Modeling*, 27(6):952–963.

1243 Jiang, Z., Anastasopoulos, A., Araki, J., Ding, H., and Neubig, G. (2020). X-FACTR: Multilin-
1244 gual factual knowledge retrieval from pretrained language models. In *Proceedings of the 2020
1245 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 5943–5959.

1246 Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate
1247 of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual
1248 Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for
1249 Computational Linguistics.

1250 Kassner, N., Dufter, P., and Schütze, H. (2021). Multilingual LAMA: Investigating knowledge in
1251 multilingual pretrained language models. In *Proceedings of the 16th Conference of the European*
1252 *Chapter of the Association for Computational Linguistics (EACL)*, pages 3250–3258.

1253 Kerche, F., Zook, M., and Graham, M. (2026). The silicon gaze: A typology of biases and
1254 inequality in LLMs through the lens of place. *Platforms & Society*.

1255 Kim, E. (2026). Generative AI in public administration: A quasi-experimental analysis of bure-
1256 aucratic productivity. *Government Information Quarterly*, 43(1):102108.

1257 Kozlakidis, Z., Wootton, T., and Mayrhofer, M. T. (2026). Through the looking glass: ethical
1258 considerations regarding LLM-induced hallucinations to medical questions. *Frontiers in Digital*
1259 *Health*, 8:1736616.

1260 Le Coz, P., Liu, J. A., Bhattacharjya, D., Curto, G., and Stinckwich, S. (2025). What would an
1261 LLM do? evaluating large language models for policymaking to alleviate homelessness. *arXiv*
1262 *preprint arXiv:2509.03827*.

1263 Manvi, R., Khanna, S., Burke, M., Lobell, D., and Ermon, S. (2024). Large language models
1264 are geographically biased. In *Proceedings of the 41st International Conference on Machine*
1265 *Learning (ICML)*. arXiv:2402.02680.

1266 Mirza, S., Coelho, B., Cui, Y., Pöpper, C., and McCoy, D. (2024). Global-liar: Factuality of
1267 LLMs over time and geographic regions. *arXiv preprint arXiv:2401.17839*.

1268 Moayeri, M., Tabassi, E., and Feizi, S. (2024). Worldbench: Quantifying geographic disparities
1269 in LLM factual recall. In *Proceedings of the 2024 ACM Conference on Fairness, Accountability,*
1270 *and Transparency*, pages 1211–1228, Rio de Janeiro, Brazil.

1271 Mohamed, S., Png, M.-T., and Isaac, W. (2020). Decolonial AI: Decolonial theory as sociotech-
1272 nical foresight in artificial intelligence. *Philosophy & Technology*, 33(4):659–684.

1273 Myung, J. et al. (2024). BLEnD: A benchmark for LLMs on everyday knowledge in diverse
1274 cultures and languages. *Advances in Neural Information Processing Systems*, 37:78104–78146.

1275 Nosek, B. A., Ebersole, C. R., DeHaven, A. C., and Mellor, D. T. (2018). The preregistration
1276 revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606.

1277 OECD (2025). Governing with artificial intelligence: The state of play and way forward in core
1278 government functions. Technical report, OECD Publishing, Paris.

1279 OpenAI (2026). Prompt engineering: Identity and message formatting. OpenAI Platform Docu-
1280 mentation. Vendor documentation recommending an “Identity” block describing the assistant’s
1281 purpose and role. Accessed 2026-08-24.

1282 Opuszek, M. and Böhm, P. (2026). New york, new york – unraveling bias in large language
1283 models: Investigating differences between standard and reasoning-based language models. In
1284 *AI Revolution: Research, Ethics and Society*, pages 92–106. Springer.

1285 Panickssery, A., Bowman, S. R., and Feng, S. (2024). LLM evaluators recognize and favor their
1286 own generations. In *Advances in Neural Information Processing Systems 37 (NeurIPS 2024)*.

1287 Patton, M. Q. (2015). *Qualitative research and evaluation methods*. SAGE Publications, 4th
1288 edition.

1289 Quijano, A. (2000). Coloniality of power, eurocentrism, and Latin America. *Nepantla: Views*
1290 *from South*, 1(3):533–580. Reprinted in Moraña, Dussel and Jáuregui (eds.), *Coloniality at*
1291 *Large*, Duke University Press, 2008, doi:10.1215/9780822388883-011.

1292 Requia, W. J., Vicedo-Cabrera, A. M., Amini, H., and Schwartz, J. D. (2024). Short-term air
1293 pollution exposure and mortality in Brazil: Investigating the susceptible population groups.
1294 *Environmental Pollution*, 340:122797.

1295 Robinson, N. (2026). Open to open-source AI? navigating AI model choice in public sector
1296 agencies. *Government Information Quarterly*, 43(2):102133.

1297 Simplício, A., Vinagre, G., Ramos, M. M., Tavares, D., Ferreira, R., et al. (2026). AMALIA
1298 technical report: A fully open source large language model for European Portuguese.

1299 UNCTAD (2024). UNCTAD statistical classifications — june 2024 update. Technical report,
1300 UN Trade and Development.

1301 VanderWeele, T. J. and Ding, P. (2017). Sensitivity analysis in observational research: introdu-
1302 cing the E-value. *Annals of Internal Medicine*, 167(4):268–274.

1303 Vieira, I., Calvo, I., Paulo, I., Furtado, J., Ferreira, R., et al. (2026). ALBA: A European
1304 Portuguese benchmark for evaluating language and linguistic dimensions in generative LLMs.
1305 *arXiv preprint arXiv:2603.26516*.

1306 White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith,
1307 J., and Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with
1308 ChatGPT. *arXiv preprint arXiv:2302.11382*.

1309 World Bank Group (2025). World Bank Country and Lending Groups — FY26 Classification.
1310 Technical report, The World Bank.

1311 World Health Organization (2021). WHO global air quality guidelines: Particulate matter
1312 (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Techni-
1313 cal report, World Health Organization, Geneva.

1314 World Health Organization (2026). Ambient air pollution attributable deaths (indicator
1315 AIR_41). Global Health Observatory. Reference year 2021, both sexes. Accessed 2026-08-
1316 19.

1317 xAI (2026). Generate text: System prompts. Grok API Documentation. Vendor documentation
1318 whose standard example initialises every conversation with a role-assigning system prompt.
1319 Accessed 2026-08-25.

- 1320 Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., and Raffel,
1321 C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings*
1322 *of the 2021 Conference of the North American Chapter of the Association for Computational*
1323 *Linguistics: Human Language Technologies (NAACL-HLT)*, pages 483–498.
- 1324 Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing,
1325 E. P., Zhang, H., Gonzalez, J. E., and Stoica, I. (2023). Judging LLM-as-a-judge with MT-
1326 bench and chatbot arena. In *Advances in Neural Information Processing Systems 36 (NeurIPS*
1327 *2023), Datasets and Benchmarks Track*.
- 1328 Zheng, M., Pei, J., Logeswaran, L., Lee, M., and Jurgens, D. (2024). When “a helpful assistant” is
1329 not really helpful: Personas in system prompts do not improve performances of large language
1330 models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages
1331 15126–15154.