

1 De quem é a regulação que o modelo conhece?
2 Confiabilidade da informação regulatória recuperada por LLMs
3 para a gestão ambiental pública em 25 países

4 Lucas Rover^{1,*}
Vitor de Melo Dominski²
Anibal Tavares de Azevedo³
Eduardo Tadeu Bacalhau⁴
Yara de Souza Tadano¹

¹ Universidade Tecnológica Federal do Paraná (UTFPR), Brasil

² Faculdade Descomplica, Brasil

³ Universidade Estadual de Campinas (Unicamp), Brasil

⁴ Universidade Federal do Paraná (UFPR), Brasil

* Autor correspondente: lucasrover@alunos.utfpr.edu.br

ORCID: L.R. 0000-0001-6641-9224 · V.M.D. 0009-0001-0209-9089 · A.T.A. 0000-0003-1678-7795 · E.T.B. 0000-0002-39

5 21 de setembro de 2026

6 **Resumo**

7 Um gestor ambiental municipal em São Paulo, Lagos ou Jacarta pergunta a um modelo
8 de linguagem qual é o padrão vinculante de PM_{2,5} em seu país. Nada na resposta diz se ela
9 corresponde ao registro oficial, e não existe método estabelecido para conferir. Contribuímos
10 com esse protocolo e relatamos o que ele encontra. Ele pontua respostas contra registros
11 oficiais, decidindo por código sempre que a resposta correta é um valor publicado e por um
12 painel de juízes de três fornecedores nos demais casos, e o aplicamos à regulação da poluição
13 do ar em 25 países, 14 configurações de acesso e quatro idiomas (8.244 células pontuadas).
14 As três mitigações que um órgão consegue implantar sem construir nada falham, e a mais
15 intuitiva piora a resposta: perguntar no idioma do próprio país *reduz* a acurácia em 5.0
16 pontos percentuais (modelo misto com intercepto aleatório por país, $p = 6 \times 10^{-7}$; oito de
17 nove países negativos) e torna o modelo 9.4 pontos menos propenso a devolver um valor
18 verificável contra o registro; declarar o papel oficial não estreita a lacuna ($p = 0.29$); e um
19 modelo de 7B com ajuste regional fica em último entre os catorze. A acurácia também
20 despenca na tarefa que carrega consequência administrativa, recuperar o valor vinculante:
21 0.39 contra 0.61 para síntese e recomendação. Uma lacuna Norte/Sul persiste (+5.0 pp,
22 permutação $p = 0.019$), é maior nos desfechos adjudicados por código, que nenhum juiz
23 toca, e se concentra onde a resposta depende de um fato nacional — no padrão nacional,
24 pontuado por código contra o instrumento em vigor, a chance do Sul Global é 0.32 da chance
25 do Norte. O escopo é delimitado: medimos concordância com a regulação publicada em um

domínio, não capacidade geral. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada.

Palavras-chave: auditoria de algoritmos; viés geográfico; viés multilíngue; governo digital; Sul Global

1 Introdução

Modelos de linguagem de grande porte passaram de curiosidade de pesquisa a infraestrutura de trabalho da administração pública em menos de cinco anos: um levantamento da OCDE sobre funções centrais de governo documenta a adoção de IA generativa na formulação de políticas e na prestação de serviços, incluindo assistentes que ajudam atendentes de serviços públicos a recuperar informação e as fontes por trás dela (OECD, 2025). A política de poluição do ar é um domínio em que isso carrega consequências diretas de saúde pública. O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura (GBD 2019 Risk Factors Collaborators, 2020; World Health Organization, 2021), e a carga recai desproporcionalmente sobre o Sul Global. Quando um gestor ambiental público em São Paulo, Lagos ou Jacarta pergunta a um LLM sobre um padrão de qualidade do ar, um prazo de atendimento ou a evidência por trás de uma intervenção, uma resposta imprecisa não é um erro benigno. Ela pode se propagar para um parecer regulatório, uma decisão de compra ou uma resposta emergencial durante um episódio de poluição.

Este artigo pergunta se os LLMs servem à política de poluição do ar do Sul Global com a mesma confiabilidade com que servem ao Norte Global, e se a forma de enquadrar a consulta muda a resposta. Ambas as premissas estão estabelecidas. O viés factual geográfico é real e mensurável: as taxas de erro são $1,5\times$ maiores para países da África Subsaariana do que para norte-americanos em 20 modelos (Moayeri et al., 2024), avaliações do modelo sobre tópicos subjetivos sensíveis acompanham condições socioeconômicas até $\rho = 0.70$ (Manvi et al., 2024), e os modelos privilegiam sistematicamente afirmações sobre o Norte Global (Mirza et al., 2024). E a assimetria linguística por trás disso é estrutural: os idiomas da maioria dos países do Sul Global ficam nas classes sub-atendidas da hierarquia de recursos (Joshi et al., 2020), e grandes corpora derivados da internet “super-representam pontos de vista hegemônicos e codificam vieses potencialmente danosos a populações marginalizadas” (Bender et al., 2021). A assimetria reproduz a infraestrutura epistêmica desigual que a literatura decolonial analisa para sistemas de IA (Mohamed et al., 2020).

Três lacunas permanecem abertas para um domínio como este, e elas organizam o estudo. Nenhum benchmark tem por alvo a informação regulatória com gabarito oficial: as avaliações existentes usam recuperação de indicadores do Banco Mundial, avaliações subjetivas, checagem jornalística ou conhecimento cultural cotidiano, e nenhuma delas mede as tarefas que um gestor de fato delega — declarar um padrão vinculante, recuperar uma concentração oficialmente medida, sintetizar a evidência de carga de saúde, identificar instrumentos legais e órgãos executores, recomendar uma resposta operacional. O enquadramento por persona não é examinado como alavanca experimental, embora profissionais rotineiramente anteponham um papel e os próprios fornecedores o recomendem (Seção 2); se ele *reduz* a lacuna, ao orientar para respostas em

conformidade com a norma, ou a *amplifica*, ao convidar à fabricação confiante, não foi testado em desenho pré-especificado. E o mecanismo de representação no corpus é afirmado em vez de medido contra confundidores, e raramente separado em seus dois canais — tamanho do *corpus da língua* (Xue et al., 2021; Abadji et al., 2022) contra a amplitude da *cobertura do país* —, distinção que importa aqui porque a lacuna geográfica é medida em inglês.

Objetivos e escopo

O estudo tem três objetivos delimitados. *Primeiro, estabelecer um protocolo de auditoria de informação regulatória*: o objeto é a concordância entre a resposta de um modelo e o valor publicado no registro oficial, para tarefas que uma agência ambiental de fato delega — não a capacidade geral do modelo, a qualidade do raciocínio ou a utilidade para qualquer outro fim. O protocolo é a contribuição que se transfere; o domínio é onde o demonstramos. *Segundo, testar as mitigações disponíveis a uma administração*: um órgão público diante de respostas ruins sobre o próprio país pode realisticamente declarar o papel oficial no prompt, perguntar no idioma nacional ou rodar um modelo aberto com ajuste regional, e testamos os três como fatores do desenho em vez de discuti-los. O modelo regional que conseguimos rodar é um fine-tune comunitário de uma base de 7B em português brasileiro, do tipo que um órgão pode baixar, não um modelo de fronteira brasileiro comercial; o achado é sobre essa classe, e o protocolo é liberado para que qualquer outro candidato passe por ele. Não testamos geração aumentada por recuperação, ajuste fino ou verificação humana no circuito, que exigem capacidade que a maior parte das agências da nossa amostra do Sul Global não tem. *Terceiro, localizar onde a confiabilidade difere e, até onde o desenho permite, por quê*: testamos a explicação de representação no corpus no nível em que a medida tem resolução, e não reivindicamos identificação causal.

Ao longo de todo o estudo, a unidade de análise é o modelo *como servido* — pesos, fornecedor e infraestrutura de serviço alcançados por um endpoint fixado —, porque é com essa pilha que o gestor público interage e qualquer lacuna medida é propriedade dela. Hipóteses, marco amostral e plano de análise foram fixados antes da coleta (Nosek et al., 2018) para 15 países e depois estendidos a 25; o plano nunca foi depositado publicamente, de modo que não reivindicamos pré-registro, e o estudo é relatado como exploratório.

Contribuições deste trabalho

1. *Um protocolo de auditoria de informação regulatória, não um benchmark de trivialidades.*

A pergunta que uma administração enfrenta não é se o modelo escreve bem sobre política, mas se o valor que ele devolve corresponde ao registro oficial. Construímos cinco tipos de tarefa a partir do trabalho cotidiano de uma agência ambiental (Tabela 1), cada uma chaveada a uma fonte oficial, de modo que a correção é adjudicável em vez de matéria de impressão de especialista. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada.

2. *As três mitigações de localização a que as agências recorrem, testadas em vez de presumidas — e todas as três falham.* Enquadramento por persona, prompt em idioma nativo e modelo com ajuste regional são, cada um, uma decisão de compra ou de fluxo de trabalho, e cada

um circula como sabedoria recebida. Nenhum funciona, e o que um gestor tem mais chance de tentar primeiro causa dano ativo: perguntar no idioma do próprio país reduz a acurácia em 5.0 pontos percentuais, de forma mais acentuada para o idioma de corpus mais escasso.

3. *Um desenho que separa quem é mal servido de por quê.* Os países são estratificados em eixos independentes — a divisão desenvolvidas/em desenvolvimento da UNCTAD (operacionalizando a colonialidade (Mohamed et al., 2020)), a taxonomia de recursos linguísticos de Joshi (Joshi et al., 2020) e desenvolvimento —, de modo que explicações geográficas, linguísticas e econômicas possam ser distinguidas em vez de confundidas. Entre países, cobertura e desenvolvimento são colineares e não podem ser separados; dentro dos países, o contraste no nível da tarefa descarta o canal do corpus da língua, mas ainda não consegue escolher entre cobertura e desenvolvimento, e dizemos isso. Registramos também que o proxy de corpus pré-especificado é defeituoso de um modo que vale conhecer para quem já o usou: ele atribui a Wikipédia inglesa a todo país da amostra que tenha o inglês como idioma oficial, indexando história colonial em vez de tamanho de corpus.
4. *Gabarito adjudicado por código, e o que isso muda.* Onde a resposta correta é um número em registro oficial, o veredito é computado contra esse registro em vez de delegado a um modelo de linguagem. Sobre as mesmas respostas, reconstruir duas chaves de tarefa a partir de registros oficiais e passar a comparação para o código reduziu o gradiente de desenvolvimento de $\rho = 0.51$ para $\rho = 0.36$ e mais que dobrou a penalidade do idioma nativo; passar a terceira tarefa com valor de registro de um juiz para o código removeu um confundimento entre juiz e tier que as pontuações julgadas carregavam. Nesta literatura, a chave de gabarito, e não o tamanho amostral, é a restrição vinculante.
5. *Recursos abertos.* Protocolo, prompts, registros de gabarito com suas fontes oficiais, código de análise e o log de desvios são liberados sob CC-BY-4.0 e MIT, com pipeline de reprodução em um comando.

2 Trabalhos Relacionados

A literatura prévia corre por quatro fios: a medição do viés factual geográfico, extensões multilíngues e culturais, tentativas de mitigação, e o uso de LLMs em contextos de decisão de política e saúde.

2.1 Viés factual geográfico e extensões multilíngues

Manvi et al. (2024) estabeleceram que LLMs de fronteira carregam vieses sistemáticos contra regiões de condições socioeconômicas mais baixas, com correlações de até 0.70 entre avaliações geradas pelo modelo e um proxy dessas condições — ainda que o espaço de desfecho sejam avaliações subjetivas, o que deixa em aberto se o mesmo viés aparece na recuperação objetiva de fatos regulatórios. Moayeri et al. (2024) quantificaram a recuperação factual contra indicadores do Banco Mundial em 20 LLMs, documentando erro relativo absoluto 1,5× maior para a África Subsaariana do que para a América do Norte; seu desenho é limitado pelo espaço de indicadores macroeconômicos, enquanto um gestor ambiental faz perguntas mais estreitas e específicas de

fonte, cujo gabarito vive em conselhos ambientais e agências de monitoramento, e não em uma única base agregada. [Mirza et al. \(2024\)](#) mostraram que versões mais novas do GPT-4 não melhoram monotonicamente e que o privilégio de afirmações sobre o Norte Global persiste.

Do lado multilíngue, [Myung et al. \(2024\)](#) cobriram 16 países e 13 idiomas em conhecimento cultural cotidiano, constatando que os LLMs têm melhor desempenho nos idiomas nativos de culturas de alto recurso e pior nos de baixo recurso — achado que motiva H2 e se conecta à hierarquia de recursos de [Joshi et al. \(2020\)](#). Benchmarks regionais proliferaram: BRoverbs ([Almeida et al., 2025b](#)), TiEBe ([Almeida et al., 2025c](#)), ALBA ([Vieira et al., 2026](#)) e AMALIA ([Simplicio et al., 2026](#)) documentam falhas concretas em tarefas culturalmente ancoradas, mas não tratam do uso aplicado em política. O trabalho sobre construção de corpus em português é explícito ao dizer que o esforço se concentrou no inglês e que montar corpora eficazes para outros idiomas segue em aberto: [Almeida et al. \(2025a\)](#) montam um corpus de 120B tokens em português justamente porque são necessários pipelines específicos do idioma para alcançar qualidade industrial. É essa assimetria de quanto texto existe por idioma que H4 testa.

Esses estudos estabelecem que o fenômeno existe e é mensurável. Nenhum isola um domínio aplicado único com gabarito oficial verificável, e nenhum trata o enquadramento do prompt como fator manipulável.

2.2 Mitigação, persona e condicionamento por papel

[Opusko and Böhm \(2026\)](#) constataram que raciocínio ajuda em agregado mas não elimina disparidades regionais, e [Kerche et al. \(2026\)](#) propuseram uma tipologia de base territorial situando o viés geográfico em um panorama sociotécnico mais amplo. Ambos são conceituais e agregados.

O condicionamento por papel não é uma prática folclórica, mas o que os fornecedores insinuam seus próprios usuários a fazer: a Anthropic documenta a definição de papel no prompt de sistema ([Anthropic, 2026](#)), o guia da OpenAI abre a estrutura de mensagem recomendada com um bloco de identidade ([OpenAI, 2026](#)), a documentação do Gemini pede que definições de papel — que ela chama de persona — fiquem na instrução de sistema ([Google, 2026](#)), o exemplo padrão da xAI inicia toda conversa com um prompt de sistema que atribui papel ([xAI, 2026](#)), e o padrão está catalogado na literatura de prompting ([White et al., 2023](#)). A evidência sistemática sobre se isso ajuda é desalentadora: em quatro famílias de LLM e 2.410 perguntas factuais, personas de especialista não melhoraram a acurácia frente a um controle sem persona e a *reduziram* ligeiramente em 162 papéis ([Zheng et al., 2024](#)). Um estudo independente com desenho diferente — seis modelos em questões de múltipla escolha de nível de pós-graduação — chega à mesma conclusão: casar a persona de especialista ao tipo do problema não teve efeito significativo sobre o desempenho ([Basil et al., 2025](#)). Se o condicionamento por persona ajuda ou prejudica a confiabilidade factual em domínios de alto risco é, portanto, questão em aberto e, até onde sabemos, não testada para equidade geográfica. Tratamos persona como fator experimental pré-especificado e testamos tanto a hipótese de Conformidade Normativa (a persona reduz a lacuna) quanto a de Vácuo de Persona (a persona a amplifica).

2.3 LLMs em política, saúde e na administração

[Le Coz et al. \(2025\)](#) avaliaram recomendações de política de LLMs para situação de rua em

quatro cidades — Barcelona, Joanesburgo, South Bend e Macau — e leem o padrão como “uma rigidez cega ao contexto e um possível viés ancorado no discurso online publicado sobre situação de rua nas regiões do mundo com dados super-representados nos LLMs”, contra especialistas que ajustaram suas decisões a realidades localmente codificadas. É um domínio e um tipo de tarefa, que generalizamos para cinco tipos abrangendo recuperação, síntese e recomendação. Em saúde, [Kozlakidis et al. \(2026\)](#) argumentam que alucinações carregam risco agudo em ambientes regulatórios com capacidade técnica limitada, onde o descompasso linguístico e cultural aumenta o erro — risco que se encontra com a carga de mortalidade documentada pelas estimativas do Global Burden of Disease ([GBD 2019 Risk Factors Collaborators, 2020](#)).

A questão da implantação já não é hipotética. [Kim \(2026\)](#) estima efeitos de produtividade burocrática da IA generativa de forma quase-experimental, e [Robinson \(2026\)](#) documenta que escolher qual modelo uma agência executa é hoje uma decisão explícita de compra entre opções de pesos abertos e hospedadas por fornecedor. Nossos dois achados no nível do modelo falam diretamente a ela: os modelos de pesos abertos, como grupo, ficam 12.9 pontos atrás dos fechados no composto, ainda que um modelo aberto (DeepSeek-V3) lidere o roster, e o modelo português com ajuste regional é o mais fraco dos catorze, de modo que as duas escolhas que uma agência poderia fazer por razões de soberania ou localidade são as duas que mais custam acurácia. Dois outros fios enquadram por que uma resposta errada importa administrativamente, e não apenas tecnicamente: [Choroszewicz \(2026\)](#) mostra que ferramentas de apoio por IA generativa posicionam profissionais de linha de frente como “zonas morais de amassamento”, absorvendo responsabilidade por falhas originadas a montante — a posição de um servidor que protocola um parecer citando um limite de emissão revogado — e [Cordella and Gualdi \(2024\)](#), analisando a primeira medida vinculante que um regulador impôs a um serviço de IA generativa — a intervenção da Itália sobre o ChatGPT —, argumentam que arcabouços neutros quanto à tecnologia não alcançam o que esses sistemas têm de específico e que reguladores precisam se envolver diretamente com o funcionamento técnico deles. A literatura sobre recepção é correspondentemente desenvolvida: [Aoki et al. \(2024\)](#) testam se o tipo de explicação muda a percepção de acurácia, justiça e confiabilidade entre os afetados.

O que nada disso estabelece é se a resposta subjacente está *correta*, e se a correção se distribui igualmente entre os Estados que dela dependem. Confiabilidade percebida e acurácia medida são quantidades diferentes, e um sistema pode ser bem explicado, bem governado, bem recebido e errado. É essa a lacuna que este estudo aborda, em um domínio em que a resposta correta é publicada em registro oficial e pode ser conferida.

2.4 Posicionamento do presente trabalho

Nosso desenho difere do trabalho prévio em quatro pontos: (i) um domínio aplicado único de alto risco com gabarito oficial verificável, em vez de trivialidades numéricas ou conhecimento cultural; (ii) persona como fator intrassujeito pré-especificado, em vez de escolha de enquadramento não controlada; (iii) amostragem de países orientada por teoria em eixos independentes (colonialidade da UNCTAD, recurso linguístico de Joshi, desenvolvimento), em vez de conveniência regional; e (iv) um teste explícito de mecanismo de representação no corpus com análise de sensibilidade. Nenhum estudo prévio combina um domínio regulado de saúde pública, uma manipulação de

224 persona e um teste de mecanismo pré-especificado.

225 3 Métodos

226 3.1 Desenho da pesquisa

227 Especificamos um experimento de benchmark pré-especificado, fatorial e multipaís, quantificando
228 viés geográfico e modulado por persona em 14 modelos de linguagem de grande porte em ta-
229 refas de política de poluição do ar. O desenho pré-especificado cruza 15 países (estratificados
230 em três eixos teoricamente fundamentados), 14 LLMs abrangendo cinco camadas de acesso, um
231 domínio, 5 tipos de tarefa e 2 condições de persona, com 2 replicações estocásticas por célula;
232 uma extensão post hoc (Seção 3.3) amplia a amostra para 25 países. O conjunto de estímulos
233 cruza as cinco tarefas e as duas personas de cada país em inglês, mais uma versão em idioma
234 nativo dentro do país para os nove países com idioma nativo alvo, pontuado no composto $[0, 1]$.
235 O protocolo fixa, antes da coleta, as hipóteses, os modelos primários, o protocolo de persona, os
236 critérios de exclusão e as correções para múltiplas comparações. Uma coleta apenas do Brasil,
237 executada sob um desenho anterior de três domínios, é reclassificada como piloto estendido e rela-
238 tada separadamente; ela informou a calibração dos prompts, mas não contribui com observações
239 confirmatórias.

240 3.2 Seleção de países

241 Os países foram selecionados por amostragem teórica (Patton, 2015) triangulada em três clas-
242 sificações independentes: a distinção Norte/Sul Global, operacionalizada pela classificação de
243 economias desenvolvidas/em desenvolvimento da UNCTAD (UNCTAD, 2024), que carrega o ar-
244 cabouço da colonialidade do saber que motiva o estudo (Mohamed et al., 2020); a taxonomia
245 de seis classes de representação de recursos linguísticos de Joshi et al. (Joshi et al., 2020); e os
246 grupos de renda do Banco Mundial (World Bank Group, 2025).

247 A amostra pré-especificada de 15 — Brasil, México, Argentina, Peru; Nigéria, África do Sul,
248 Quênia, Egito; Índia, Indonésia, Bangladesh, Filipinas; e Estados Unidos, Alemanha, Japão como
249 referências do Norte Global — cobre quatro regiões do mundo e quatro grupos de renda. O eixo de
250 recursos linguísticos revelou-se muito menos diferenciado do que se pretendia: os idiomas oficiais
251 dominantes caem em apenas três classes de Joshi, doze dos quinze compartilhando a Classe 5,
252 e estender para 25 não ajuda, já que dezoito são Classe 5. Isso é propriedade do mundo, e não
253 do nosso sorteio, porque os idiomas oficiais da maioria dos Estados são eles próprios de alto
254 recurso; mas significa que o eixo linguístico tem variância pequena demais para ser separado
255 dos demais, e tratamos os resultados de Joshi de acordo (Seção 4.6). Países com governança
256 estatística comprometida ou sem padrão nacional publicamente recuperável foram excluídos dos
257 quinze pré-especificados; a Oceania entrou apenas com a extensão (Austrália), e idiomas de
258 Classe 0 de Joshi não estão representados, o que registramos como limitação de escopo.

3.3 Ampliação da amostra após a análise pré-especificada

Após a análise pré-especificada de 15 países, e *relatado aqui como extensão post hoc e não como parte do protocolo travado*, a amostra foi ampliada para 25 países sob procedimentos idênticos, para aumentar o poder dos testes de gradiente e de mecanismo e para multiplicar os pares de idioma dentro do país disponíveis para H2. O manuscrito relata a amostra de 25 países ao longo de todo o texto; a família primária recomputada apenas sobre os 15 pré-especificados está tabulada no material suplementar, de modo que o leitor possa ver o que o protocolo travado teria concluído. Como a extensão seguiu a observação dos resultados iniciais, nenhuma conclusão pré-especificada é revisada apenas com base na extensão, e a ampliação é tratada como checagem de poder e robustez, não como novo teste confirmatório. Angola, como Nigéria e Argentina, *não* tem padrão nacional de PM_{2,5}, acrescentando casos sem padrão nos quais um modelo fiel deve se recusar a declarar um limiar inexistente. As dez adições e seus papéis estão detalhados no suplemento. Duas variantes extras de pergunta por (país, tarefa) foram geradas para os pares de H2 na fase de desenho, mas nunca foram coletadas nem pontuadas; a análise de H2 usa a única versão em idioma nativo de cada prompt em inglês.

3.4 Covariáveis de país

O Índice de Desenvolvimento Humano (PNUD 2023–24) e o PIB per capita indexam a posição de desenvolvimento e entram na análise de mecanismo como covariáveis de ajuste. As exposições de representação no corpus se dividem segundo uma distinção que a análise de mecanismo torna explícita, porque os dois canais se aplicam a efeitos diferentes. As medidas de *corpus da língua* quantificam quanto texto de pré-treinamento existe *em* um idioma e são o mecanismo candidato para a penalidade de idioma nativo: contagem de tokens do mC4 (Xue et al., 2021), tamanho do corpus OSCAR-2301 (corpus apresentado por Abadji et al., 2022; os valores por idioma vêm do dataset card do OSCAR-2301, cujos totais diferem da versão 22.01 descrita naquele artigo) e a classe de Joshi (Joshi et al., 2020). As medidas de *corpus do país* quantificam quanto o corpus enciclopédico fala *sobre* um país, independentemente do idioma, e são o mecanismo candidato para a lacuna geográfica: tamanho do artigo da Wikipédia inglesa, número de edições linguísticas com artigo sobre o país e número de declarações do Wikidata sobre a entidade do país.

As duas famílias não são intercambiáveis. Como a lacuna geográfica é medida *em inglês*, com o idioma mantido constante entre países, uma lacuna Norte/Sul residual não pode ser efeito de corpus da língua. Um ponto merece ser dito de forma direta, porque os papéis se confundem com facilidade: a Wikipédia e o Wikidata nunca são gabarito aqui, eles são a variável *explicativa*. Aquilo contra o que uma resposta é pontuada é sempre um registro oficial (Seção 3.9); tivéssemos pontuado contra uma enciclopédia, o estudo mediria concordância com uma enciclopédia, que não é a pergunta que uma administração pública enfrenta.

3.5 Seleção de modelos

Catorze LLMs foram avaliados em cinco camadas de acesso, abrangendo cerca de duas ordens de magnitude em contagem de parâmetros e quatro geografias de dados de treinamento (Estados Unidos, China, Europa, Brasil): fronteira de pesos abertos (5), pesos abertos médios (3) e

pequenos ou regionais (2), fechados acessíveis (3) e fechados de fronteira (1). Apenas três dos modelos de pesos abertos foram servidos localmente (Ollama, tags fixadas: Phi-4 14B, Qwen3 14B, Cabra-Mistral 7B); os outros sete foram servidos por endpoints hospedados (camada gratuita da Groq para cinco, APIs da DeepSeek e da Cohere para dois), e os quatro modelos fechados pelas APIs de seus fornecedores. A camada pequena inclui um modelo ajustado por instrução em português brasileiro (Cabra-Mistral 7B v3), testado contra um modelo aberto de treinamento global de escala equivalente para H3. Cada modelo foi consultado com tag fixada idêntica ao longo da janela de coleta. O roster completo está na Tabela S1 do suplemento.

Comparamos *modelos como servidos* por uma pilha de acesso fixa, e não pesos idealizados. Infraestrutura do provedor, configuração de serviço e camada de API fazem parte do que cada rótulo denota, e uma lacuna residual poderia em princípio refletir a pilha em vez dos pesos; mantemos isso constante fixando tags de versão e uma configuração de amostragem fixa por provedor ao longo de uma janela fixa (Seção 3.10).

3.6 Domínio e taxonomia de tarefas

O domínio único é a política de poluição do ar, escolhido porque se ancora em gabarito oficialmente publicado e verificável e se mapeia a atividades concretas de decisão de um gestor ambiental público. As cinco tarefas não foram escritas como um questionário genérico de conhecimento: cada uma corresponde a uma pergunta que um gestor tem de responder no curso do trabalho ordinário, e cada uma foi redigida de modo que uma resposta errada carregasse consequência administrativa, e não apenas a perda de um ponto. A Tabela 1 as traz com o prompt tal como foi emitido aos modelos, usando o Brasil como instância trabalhada, ao lado da decisão que cada uma representa.

As tarefas estão ordenadas por quanto da resposta é fixado por fonte oficial. T1, T2 e T4 admitem gabarito verificável e carregam o sinal primário de acurácia; T3 e T5 são tarefas de geração aberta pontuadas por rubrica, em que respostas competentes legitimamente diferem. É essa ordenação que torna a dimensão de tarefa informativa em vez de decorativa: ela permite perguntar se os modelos falham de maneira uniforme ou falham especificamente onde é preciso recuperar um valor nacional publicado, que é a pergunta sobre a qual os resultados se apoiam. O mapeamento de país por tarefa das classes de fonte oficial e do estatuto de verificabilidade está no registro de gabarito (Seção 3.9), e o conjunto completo de prompts dos 25 países é liberado com os dados.

3.7 Manipulação de persona

A persona é um fator dentro do prompt com dois níveis, e a manipulação não é arbitrária: atribuir um papel ao modelo é a prática que os próprios fornecedores documentam e recomendam (Seção 2). A condição neutra apresenta a consulta como pedido simples de informação; a condição `public_manager_env` antepõe um enquadramento de papel fixo identificando quem pergunta como autoridade municipal ou regional de gestão ambiental, mantendo a pergunta substantiva idêntica. Para a T1 do Brasil, o enquadramento é a frase única “*Sou o gestor ambiental municipal de São Paulo, Brasil, e preciso informar tomadores de decisão.*” Um único modelo é aplicado de forma uniforme entre países e tarefas, traduzido quando o idioma do prompt não é o inglês, de

Tabela 1: As cinco tarefas, o prompt como emitido e a decisão que cada uma representa. Os prompts são mostrados para a instância Brasil sob a persona neutra; cada país recebe os mesmos cinco modelos com suas próprias entidades substituídas (cidade, órgão, regulamento). Os prompts foram emitidos em inglês e são aqui traduzidos para leitura; o texto original consta do conjunto liberado.

Tarefa	Prompt emitido, em tradução (Brasil)	Decisão que representa
T1 Padrão técnico	“Qual é o padrão nacional vigente de média anual de qualidade do ar para PM _{2,5} no Brasil? Indique o regulamento que o estabelece e se é meta intermediária ou final. Limite-se a 1–3 frases.”	Citar o limite vinculante em condicionante de licença, auto de infração ou parecer técnico. O valor errado vicia o ato.
T2 Dado factual local	“Segundo a agência ambiental nacional ou subnacional, qual foi a concentração média anual de PM _{2,5} em São Paulo, Brasil, no ano mais recente reportado? Forneça o valor em $\mu\text{g}/\text{m}^3$, a estação ou rede de referência e a fonte.”	Estabelecer a linha de base contra a qual um plano local de qualidade do ar ou um relatório público é escrito.
T3 Síntese de evidência em saúde	“Resuma a evidência epidemiológica sobre mortalidade atribuível à exposição ambiental a PM _{2,5} no Brasil na última década. Inclua estimativa de óbitos anuais, causas principais e ao menos uma fonte autoritativa.”	Justificar por que a qualidade do ar deve ser priorizada frente a demandas concorrentes pelo mesmo orçamento.
T4 Instrumentos de política	“Liste os principais programas nacionais ou instrumentos legais de monitoramento e controle da poluição do ar ambiente no Brasil, com o órgão executor de cada um.”	Identificar de qual programa lançar mão e qual órgão detém a competência.
T5 Recomendação aplicada	“Uma região metropolitana do Brasil enfrenta episódio previsto com PM _{2,5} projetado para exceder $75 \mu\text{g}/\text{m}^3$ em 24 horas. Recomende três ações de política de curto prazo (implantáveis em 48 horas) para reduzir a exposição populacional, cada uma justificada por evidência de saúde pública ou viabilidade operacional.”	Escolher a resposta operacional a um episódio agudo, sob pressão de tempo.

modo que qualquer diferença entre condições seja atribuível ao enquadramento e não à redação da pergunta. A ordem das personas dentro de cada célula é aleatorizada, e uma checagem de manipulação verifica se o enquadramento é reconhecido na resposta. Redação exata, procedimento de tradução e codificação da checagem estão no suplemento.

Um detalhe de implementação importa para a leitura do resultado. Toda requisição neste estudo é enviada como turno único de usuário, sem prompt de sistema, de modo que o enquadramento de papel é anteposto à mensagem do usuário em vez de instalado como instrução de sistema. Três dos quatro guias o colocam ali; o do Google é explícito ao dizer que ele cabe *ou* na instrução de sistema *ou* “no princípio do prompt do usuário” (Google, 2026), que é exatamente o canal que testamos. A escolha é deliberada: a via do prompt de sistema exige acesso por API e um desenvolvedor para configurá-la, enquanto os servidores públicos cujas decisões motivam este estudo alcançam esses modelos pela interface de conversa de consumo, na qual o único canal disponível é a mensagem que digitam. Testamos, portanto, o enquadramento de papel tal como o setor de fato o executa, e a Seção 5.7 declara o que permanece não testado. A persona é a base de H6.

3.8 Construção e validação dos prompts

Os prompts foram redigidos para o domínio pela equipe de pesquisa com supervisão de domínio e validados contra o registro de gabarito antes de entrar no conjunto confirmatório de estímulos, com a exigência de que toda afirmação factual de uma entrada do registro resolvesse para uma URL de fonte oficial ou um DOI revisado por pares antes que o prompt correspondente fosse

admitido. O plano de análise previa um piloto de 50 prompts pontuado por dois avaliadores humanos independentes ($\alpha \geq 0.70$) antes de escalar o desenho. *Esse piloto não foi rodado*, e não existe α de avaliador para este estudo; a confiabilidade da rubrica é evidenciada, em vez disso, sobre os próprios dados confirmatórios, por um painel de três fornecedores sobre cada item que exigiu juiz (Seção 4.11), que devolve $\alpha = 0.527$. Relatamos isso como desvio do plano, e não como limiar atingido.

Todos os prompts foram redigidos em inglês e, para um subconjunto estratificado de países, adicionalmente em um idioma nativo relevante (Seção S3 do suplemento). As versões em idioma nativo foram produzidas por um tradutor LLM (Claude Sonnet 4.6) instruído a preservar o significado, o enquadramento de persona, nomes próprios e siglas, com o gabarito factual mantido em inglês, já que o valor-alvo é invariante ao idioma. Não empregamos tradutores humanos nativos, o que permanece uma limitação (Seção 5.7); auditamos, porém, as versões após o fato, retrotraduzindo todos os 90 prompts nativos com um modelo diferente e tendo dois outros modelos comparando cada um contra o original em inglês (Seção 4.4).

3.9 Gabarito e registro de gabarito

O gabarito é um conjunto de quatro registros específicos por tarefa, liberados com os dados, e descrevemos cada um como foi construído, não como foi planejado (a Tabela S14 do suplemento registra os desvios). Para T1 a chave é o valor anual de $PM_{2,5}$ em vigor durante a janela de coleta, tomado do próprio instrumento nacional (lei, decreto, regulamento ou diário oficial) e armazenado com a fonte, um trecho literal e uma marca de status. Vinte e um países têm chave numérica. Três (Angola, Argentina, Nigéria) não têm padrão nacional de $PM_{2,5}$, de modo que a resposta correta é dizê-lo, e um valor afirmado é pontuado como fabricado. O Egito não tem chave alguma, porque o texto oficial em árabe não pôde ser recuperado, e fica, portanto, fora de T1 (56 células). Bangladesh é pontuado contra os $35 \mu g/m^3$ de suas Air Pollution (Control) Rules 2022, que substituíram os 15 do diário oficial de 2005; uma versão anterior do registro trazia o valor de 2005, e a correção está registrada com os arquivos liberados. Onde um instrumento fixa uma escada de valores em etapas (as cinco etapas do CONAMA no Brasil, o limite europeu de 25 com 10 a partir de 2030, o limite de 20 do Reino Unido com meta inglesa de 10 até 2040, os 9,0 dos Estados Unidos que sucederam os 12,0, os 35 de Bangladesh que sucederam os 15), o registro armazena a escada inteira além do valor em vigor, para que citar uma etapa vizinha possa ser separado de fabricação (Seção 4.9). Os CAAQS do Canadá e o valor filipino são objetivos, e não limites juridicamente vinculantes; são os únicos valores nacionais de referência que esses países publicam e são tratados como chave, o que o texto anota onde importa.

Para T2 a chave é a concentração média anual de $PM_{2,5}$ mais recente que a base WHO Ambient Air Quality Database (v6.1, 2024) registra para a cidade do prompt, compilando os valores reportados por agências nacionais e subnacionais; qualquer ano reportado é aceito dentro de $\pm 20\%$, de modo que um modelo que cite um valor da agência de outro ano não é penalizado pelo ano. Duas cidades não têm entrada de $PM_{2,5}$ (Luanda, Cairo) e essas células ficam com o juiz. Para T3 a chave é a estimativa do WHO Global Health Observatory de mortes atribuíveis à poluição do ar ambiente (indicador AIR_41, 2021), com o intervalo de incerteza alargado em metade de cada lado como faixa aceita, mais a ordem publicada das causas; o indicador cobre a

poluição do ar ambiente como um todo, enquanto o prompt pergunta por PM_{2,5}, e um modelo que cite outro estudo de carga (o GBD, uma coorte nacional) é pontuado pelo juiz quanto a se sua cifra e fontes são defensáveis, não contra o número da OMS. Para T4 o conjunto de referência é o catálogo UNEP Global Air Pollution Legislation de cada país, com correções manuais onde está desatualizado. O registro anota fonte, URL, data de acesso e status por entrada, mas não tem campo de validador humano nem hash por documento: a verificação foi documental, pelos autores, contra o texto primário. Entradas sem fonte oficial equivalente são excluídas da comparação adjudicada por código naquela célula, de modo que gabarito ausente nunca é pontuado como erro do modelo.

3.10 Coleta de dados

As chamadas foram executadas a temperatura 0.3 com semente fixa onde o provedor a honra (os três modelos servidos via Ollama), com 2 replicações por combinação de prompt, modelo e persona, dentro de uma janela fixa para minimizar confundimento por atualização de modelo; as acurácias relatadas são, portanto, estimativas pontuais no tempo. Duas exceções são declaradas: a família GPT-5 rejeita qualquer temperatura diferente da padrão, de modo que GPT-5 e GPT-5-mini rodaram a temperatura 1.0; e nenhum provedor oferece configuração que torne a saída determinística, de modo que duas réplicas a 0.3 delimitam, sem remover, a variância intramodelo (o suplemento compara os efeitos principais com essa variância). Toda resposta foi armazenada com metadados completos da requisição — tag fixada, timestamp, contagem de tokens, motivo de término, condição de persona — sob checksums SHA-256. Gates de qualidade excluíram respostas truncadas e respostas em idioma divergente do da requisição, ambas retidas e analisadas separadamente.

A cobertura por célula não é uniforme: endpoints gratuitos e com limite de taxa devolveram menos respostas admissíveis do que as APIs medidas, de modo que o número de células pontuadas com prompt em inglês varia de 261 a 500 por modelo (777 para o modelo com mais pares em idioma nativo, quando estes são contados). Relatamos o N realizado de cada modelo ao lado de sua pontuação (Tabela 2) em vez de descartar silenciosamente células sub-cobertas, e a matriz completa de cobertura, com as razões de cota e exclusão de cada falta, está no suplemento.

3.11 Medidas

A pontuação atribui a cada tarefa o instrumento mais confiável que ela admite.

Onde a resposta é um número em registro oficial, o código decide. Para T1, T2 e T3, o valor devolvido é extraído e comparado com o registro por um pontuador determinístico, com guardas de plausibilidade que rejeitam extrações implausíveis — um ano de quatro dígitos lido como contagem de óbitos, uma população nacional lida como cifra de mortalidade, um valor de 24 horas lido como anual. O extrator normaliza dígitos devanágari, vírgulas decimais e unidades escritas por extenso, e seu comportamento nos casos que importam para a comparação entre idiomas (uma vírgula decimal, um numeral em hindi, um valor diário entre parênteses ao lado do anual) é fixado por uma suíte de testes unitários liberada com o código; uma auditoria manual estratificada das respostas em idioma nativo que ele classificou como sem valor está no suplemento. Comparar um valor com uma chave é exato, e um modelo de linguagem a quem

se pede a mesma aritmética só consegue reproduzi-la com ruído. O código resolve 99.8% das células de T1 na análise (1.614 de 1.617), 56.3% de T2 e 71.8% de T3; uma resposta de T1 sem valor extraível conta como não tê-lo devolvido. Para os três países sem padrão, o código pontua se a resposta afirma que não existe padrão nacional (correto), afirma um valor (fabricado) ou se recusa a responder (nem um nem outro), e a comparação primária entre tiers é reportada com e sem eles.

Onde se exige julgamento, um painel de três fornecedores decide pela média. O resíduo de T2 e T3, com toda a T4, é pontuado por Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3, escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infla a concordância aparente. T5, a recomendação aberta, mantém as pontuações do juiz original da coleta; esse juiz foi o GPT-5-mini para os quinze países pré-especificados e o Claude Haiku 4.5 para os dez acrescentados na extensão, e como a extensão contém sete dos dez países do Norte Global, juiz e tier estão confundidos em qualquer efeito que ainda repouse sobre essas pontuações. Foi por isso que T1 passou para o código: nas pontuações originais o déficit do Sul Global em T1 era 0.21 contra 0.38 sob o GPT-5-mini, mas 0.37 contra 0.44 sob o Claude Haiku, uma diferença entre juízes tão grande quanto a diferença entre tiers (suplemento). T5 não carrega efeito de tier em nenhum dos dois instrumentos. A confiabilidade é relatada como α de Krippendorff, o ICC(2,1) de juiz único e, como quantidade operativa, o ICC(2,3) da média do painel — um coeficiente de efeitos aleatórios de dois fatores e concordância absoluta, de modo que as severidades distintas dos juízes contam contra ele — computados sobre cada item que o painel pontuou em vez de sobre um subconjunto de calibração. Um membro do painel (DeepSeek-V3) é também um modelo avaliado, e testamos o autofavorecimento diretamente. Nenhuma camada humana de padrão-ouro foi coletada; o gabarito está ancorado, em vez disso, em fontes oficiais primárias (Seção 3.9).

A unidade de análise é a célula pontuada, não a linha de log. A duplicação existe em dois níveis, e cada um tem uma regra declarada. No nível da resposta, 21,9% das chaves (modelo, prompt, réplica) têm mais de uma resposta armazenada, porque as rodadas de coleta foram retomadas e reexecutadas; a resposta que entra na análise é a primeira armazenada na ordem dos arquivos de execução, que é a que o juiz pontuou, e os vereditos de código são computados sobre essa mesma resposta, para que os dois instrumentos descrevam uma única resposta. Pontuar todas as respostas armazenadas e tirar a média dos vereditos muda o veredito de código em 3,1% das células e a média em 0,0001 (suplemento). No nível do escore, 951 células (11,5%) carregam mais de um escore de juiz, porque o juiz foi reexecutado sobre partes do conjunto em datas diferentes; são medições repetidas do mesmo item, não observações independentes, e são colapsadas pela média, restando 8.300 células, ou 8.244 uma vez removidas as 56 células egípcias de T1 sem chave (6.573 com prompt em inglês). Tratar reexecuções como independentes seria pseudo-replicação: infla o n e dá peso extra às células que por acaso foram reprocessadas. A escolha é metodológica e não depende do resultado.

O composto primário combina cinco subcomponentes pré-especificados (Seção S6 do suplemento), cada um normalizado para $[0,1]$: acurácia factual contra a entrada do registro (peso 0.30), completude contextual (0.25), qualidade de citação (0.15), calibração (0.15) e ausência de alucinação (0.15). Cada efeito principal é recomputado sob pesos iguais e sob uma ponderação

derivada por ACP, e uma conclusão só conta como robusta se sua direção for estável nas três. O composto é computado por célula (país, modelo, persona) para viabilizar o teste de diferença em diferenças de H6.

3.12 Estratégia analítica

Os três testes primários são pré-especificados como uma única família (F1) e corrigidos em conjunto por Bonferroni-Holm. Os testes secundários (F2) são relatados sem ajuste dentro da família, e os declarados exploratórios (F3) usam FDR de Benjamini-Hochberg a $q = 0.10$ (Benjamini and Hochberg, 1995), cuja garantia pressupõe estatísticas de teste independentes.

H1 (gradiente geográfico, primário) regride a acurácia composta média por país sobre o gradiente Joshi/IDH via ρ de Spearman, pré-especificado unilateral em $\rho \geq 0.55$, com um teste de tendência de Mann-Kendall como complemento obrigatório de não monotonicidade. *H4 (mecanismo de corpus, primário)* relaciona representação no corpus à acurácia por ρ de Spearman parcial ajustando para IDH e log do PIB per capita, com contagens da Wikipédia como proxy pré-especificado. *H6 (persona, primário)* é uma diferença em diferenças no nível do país, sustentada se a condição de persona reduzir a lacuna do Sul Global em ao menos 0.05 no composto, com inferência por teste de permutação de 5.000 iterações. *H3 (secundária)* é um contraste unilateral de Mann-Whitney (δ de Cliff). *H2 e H5 (exploratórias)* são relatadas descritivamente sob correção F3.

Três análises transversais corroboram a lacuna de camada: um modelo linear misto gaussiano (MixedLM do `statsmodels`, REML) com interceptos aleatórios cruzados de país e modelo, ajustando para IDH centrado; uma reestimação hierárquica bayesiana (`pymc` (Abril-Pla et al., 2023)); e E-values para robustez a confundimento não medido, pela aproximação $RR \approx \exp(0.91 d)$ que VanderWeele and Ding (2017) prescrevem para efeitos padronizados e cujos pressupostos ela herda. O mecanismo de corpus é sondado com um modelo exploratório de mediação (`semopy` (Igolkina and Meshcheryakov, 2020)), e a manipulação de persona com uma checagem de reconhecimento do enquadramento. As análises de robustez pré-especificadas aparecem na Seção 4.12.

3.13 Protocolo do estudo e ética

O conjunto analítico de dados, após os gates de qualidade mas antes do ajuste dos modelos, é congelado e hashado, de modo que a análise confirmatória possa ser auditada contra a especificação travada em vez de aceita por confiança. Os termos de liberação estão declarados ao fim do artigo.

Nenhum dado pessoal de usuários finais de LLMs foi coletado; o estudo analisa saídas de modelo para perguntas de política de relevância pública. Os termos de serviço dos provedores foram revisados e respeitados, e as respostas são redistribuídas exclusivamente para pesquisa sob provisões de uso justo e reprodutibilidade, excluídas de qualquer aplicação comercial.

4 Resultados

Nota sobre a amostra. Os resultados abaixo são relatados sobre a amostra de 25 países. O benchmark pré-especificado cobria 15 países e foi estendido post hoc por dez. Catorze LLMs são pontuados em cinco tarefas, duas personas e quatro idiomas (inglês mais um idioma nativo do país — espanhol, português ou hindi — para os nove países aplicáveis, o que dá os pares inglês/nativo dentro do país que testam H2). A família primária recomputada apenas sobre os 15 países pré-especificados está tabulada no material suplementar, e nenhuma conclusão pré-especificada é revisada apenas com base na extensão; onde as duas amostras divergem em uma hipótese de que o artigo depende, dizemos isso no texto. A pontuação é adjudicada por código sempre que a resposta é um número conferível contra registro oficial, e pela média de um painel de juízes de três fornecedores nos demais casos (Seção 4.11); o gabarito de T1 está ancorado no instrumento nacional em vigor para 24 países e não tem chave para o Egito, que fica fora de T1 (Seção 4.9).

4.1 Amostra e pontuação

O corpus analisado compreende 8.244 células pontuadas no composto $[0, 1]$, das quais 6.573 são respostas a prompts em inglês nos 25 países; o restante são os pares em idioma nativo dentro do país usados para H2.

A pontuação usa o instrumento mais confiável que cada tarefa admite. Para T1, T2 e T3, em que a resposta correta é um número em registro oficial, o veredito é computado por código contra esse registro. O código resolve 99.8% das células de T1, 56.3% de T2 e 71.8% de T3; o resíduo, com toda a T4, é pontuado pela média de um painel de três fornecedores. T5 mantém as pontuações do juiz da coleta. No total, 6.434 células carregam pontuação de código ou de painel.

A média do painel substitui o desenho de juiz único do protocolo original, no qual o juiz da coleta (GPT-5-mini para os quinze países pré-especificados, Claude Haiku 4.5 para os dez da extensão) estava ele próprio entre os modelos avaliados e, como a extensão contém sete dos dez países do Norte Global, estava confundido com o tier. Duas medições justificam a mudança: os juízes diferem acentuadamente em severidade (composto médio de 0.617 para o Gemini, 0.451 para o Claude e 0.379 para o DeepSeek), de modo que um juiz único fixa um nível arbitrário, e a confiabilidade de juiz único é de apenas $ICC(2, 1) = 0.56$ contra $ICC(2, 3) = 0.79$ da média do painel. Um membro do painel (DeepSeek-V3) é também um modelo avaliado, então checamos o autofavorecimento: ele pontua as próprias saídas de forma *mais* severa em relação aos outros dois juízes (-0.177) do que pontua as de qualquer outro modelo (-0.123 a -0.160).

4.2 Acurácia por modelo

A Tabela 2 ordena os 14 modelos pelo composto médio. Sistemas de fronteira lideram e modelos pequenos de pesos abertos ficam atrás. Em H3, o modelo regional em português brasileiro Cabral-Mistral 7B é o *mais fraco* de todos (0.351 contra 0.557 para os demais; Mann-Whitney $p \approx 0$, δ de Cliff = -0.48). O δ de Cliff tem leitura direta: é a probabilidade de uma resposta sorteada de um grupo superar uma sorteada do outro, reescalada para variar de -1 a $+1$; um valor de -0.48 significa que o modelo regional perde cerca de três dessas comparações para cada uma que ganha. Essa comparação é contra o roster inteiro, que inclui sistemas de fronteira; o teste

pré-especificado era mais estreito, Cabra contra seu par de escala equivalente Llama 3.1 8B em prompts em português, e aponta na mesma direção com margem menor: no Brasil o modelo regional pontua 0.258 contra 0.313 ($\delta = -0.26$, $n = 20$ cada), e nos três países lusófonos 0.304 contra 0.362 ($\delta = -0.17$, $n = 60$ cada). O ajuste regional por instrução no patamar de 7B não recupera o que escala e treinamento de fronteira dão, mesmo no idioma e no país para os quais foi ajustado, embora com 20 células brasileiras por modelo o teste estreito seja descritivo.

Tabela 2: Acurácia composta por modelo nos 25 países (adjudicada por código onde a resposta é valor de registro, média do painel nos demais casos; $[0, 1]$). N = respostas pontuadas a prompts em inglês.

Modelo	N	Média
DeepSeek-V3	496	0.690
GPT-5	496	0.676
Gemini 2.5 Flash	486	0.636
GPT-5-mini	495	0.628
Claude Haiku 4.5	486	0.589
Qwen3 32B	494	0.560
Command R+	496	0.530
Llama 3.3 70B	391	0.514
Llama 4 Scout	496	0.500
Qwen3 14B	496	0.485
GPT-OSS 120B	257	0.479
Phi-4 14B	496	0.475
Llama 3.1 8B	496	0.437
Cabra-Mistral 7B	492	0.351

4.3 Acurácia por tarefa: o piso de recuperação

A dificuldade depende fortemente da tarefa (Tabela 3). A mais difícil por larga margem é a T1 (recuperação do padrão técnico, 0.394), que exige devolver o padrão nacional de média anual de $PM_{2,5}$ em vigor. A recomendação aberta (T5) tem a maior pontuação (0.769) porque sua rubrica premia conselho de política plausível e bem estruturado, que não depende de um fato único. Agrupando as duas tarefas de recuperação (T1, T2; média 0.434) contra síntese e recomendação (T3–T5, 0.612), a diferença é grande (Mann-Whitney $p \approx 0$, δ de Cliff = -0.41 , cerca de duas perdas e meia para cada vitória). Os LLMs são mais fracos exatamente onde a gestão ambiental aplicada mais precisa deles: recuperar o limiar regulatório em vigor.

As duas correções da pontuação são elas próprias informativas. A T2 era pontuada contra uma chave de preenchimento e sobe de 0.368 para 0.473 assim que cada concentração devolvida passa a ser comparada por código com a faixa autorizada: a correção moveu a tarefa cuja chave era defeituosa. A T1 sempre teve chave oficial, mas era pontuada por dois juízes de coleta de severidades distintas, e passá-la ao código a eleva de 0.367 para 0.394 mantendo-a como a tarefa mais difícil; o veredito de código também mostra o que os juízes não podiam: mais de um terço das respostas erradas de T1 (281 de 759) cita um valor que está na escada oficial do país — um valor superado ou uma etapa futura — e não um valor inventado (Seção 4.9). O piso é real, mais raso do que se relatou primeiro, e concentrado na recuperação normativa (T1).

Tabela 3: Acurácia composta por tipo de tarefa (25 países; T1 em 24, sem chave para o Egito). T1, T2 e T3 são adjudicadas por código onde o valor devolvido é conferível contra o registro oficial; T4 é pontuada por painel; T5 mantém as pontuações do juiz da coleta.

Tarefa	<i>N</i>	Média
T5 (recomendação aplicada)	1.320	0.769
T3 (síntese de evid. em saúde)	1.329	0.548
T4 (instrumentos de política)	1.310	0.520
T2 (dado factual local)	1.335	0.473
T1 (padrão técnico)	1.279	0.394

4.4 H2 — perguntar no idioma local reduz a acurácia

Para os nove países com idioma nativo alvo, cada prompt é renderizado em inglês e no idioma nativo, mantendo o conteúdo fixo, de modo que o contraste é dentro do país e dentro do modelo. As replicações são mediadas dentro de cada célula (modelo, prompt) antes do pareamento, já que parear replicação a replicação inflaria o n e tornaria o teste anticonservador. Nas 839 células casadas, o prompt em idioma nativo *reduz* a acurácia composta média em 5.0 pontos percentuais (Wilcoxon $p = 5 \times 10^{-16}$). Esse teste trata as células como independentes, e elas estão aninhadas em nove países e catorze modelos, de modo que reportamos também a inferência que respeita o aninhamento: um modelo misto sobre as diferenças pareadas com intercepto aleatório por país dá -5.0 pp (EP 1.0, $p = 6 \times 10^{-7}$), com intercepto aleatório por modelo -4.8 pp ($p = 3 \times 10^{-9}$); com o país como unidade ($n = 9$) a penalidade é negativa em oito de nove e tem média -5.1 ± 1.1 pp ($t = -4.6$, $p = 0.002$); com o modelo como unidade ($n = 14$) é negativa em doze de catorze (Wilcoxon $p = 0.058$). A penalidade acompanha o nível de recurso do idioma, e as três são significativas (Tabela 4): hindi -11.4 pp, espanhol -4.5 pp, português -4.2 pp. A Índia, que pontua mais alto entre os 25 em inglês, é a que mais cai em hindi.

Como H2 carrega a afirmação central do estudo, tentamos fazê-la desaparecer em vez de confirmá-la, e ela se sustentou sob todo ataque. Não é impulsionada por nenhum país (leave-one-out: -4.4 a -5.5 pp, todos significativos), por nenhum modelo (-4.5 a -5.2 pp), nem por células atípicas (5% aparados: -4.5 pp, $p = 6 \times 10^{-20}$), e sobrevive a toda ponderação do composto. Aparece em todas as tarefas e em ambas as condições de persona.

Dois ataques respondem às objeções que um leitor cético levanta primeiro. O primeiro é que juízes-modelo poderiam penalizar prosa não inglesa por estilo, e não por conteúdo; testamos então um desfecho binário que nenhum juiz toca: a resposta contém um valor que o extrator consegue comparar com o registro? O extrator lê numerais devanágari, vírgulas decimais e unidades escritas por extenso, de modo que um número em hindi ou em espanhol não é penalizado pela notação (Seção 3). Prompts em inglês devolvem valor verificável em 71.9% das vezes e em idioma nativo em 62.5%, uma diferença pareada de -9.4 pp, com a versão nativa pior em 134 dos 218 pares discordantes (teste de sinais $p = 9 \times 10^{-4}$): hindi -39.5 pp, espanhol -13.4 pp, enquanto o português, o mais bem provido dos três, não mostra tal perda ($+3.5$ pp). As respostas em português devolvem um número tão prontamente quanto as em inglês; o número é errado com mais frequência. No próprio veredito de código (nativo menos inglês, células adjudicadas por código nos dois idiomas) a penalidade do português é de -9.1 pp ($n = 132$, $p = 0.019$) e a do espanhol de -2.1 pontos ($n = 165$, não significativa), -5.0 pp no geral ($n = 318$, $p = 0.048$).

Perguntar no idioma local não apenas reduz uma nota julgada; onde o idioma é escasso, torna o modelo menos propenso a devolver um número conferível, e onde o idioma é bem provido torna o número devolvido menos vezes certo.

O segundo é que os prompts nativos, produzidos por um tradutor LLM, poderiam simplesmente perguntar outra coisa. Testamos isso em todos os 90 prompts nativos únicos — um censo, não uma amostra —, retrotraduzindo cada um com um modelo *diferente* e tendo dois outros modelos auditando o resultado contra o original em inglês. Nos dois itens que poderiam confundir o efeito, a fidelidade é completa: nenhum prompt alterou o país e nenhum alterou a quantidade solicitada (90/90 em ambos). Restringir H2 aos prompts verificados como fiéis o deixa essencialmente inalterado (-4.8 pp, $p = 2 \times 10^{-8}$) contra -5.2 pp entre os divergentes, diferença não distinguível de zero (permutação $p = 0.80$). A fidelidade da tradução não prevê o tamanho da penalidade, que é o que se espera se a tradução não a estiver causando.

Separando os pares pelo instrumento que pontuou a célula nativa, a penalidade é de -3.8 pp onde o código decidiu ($n = 333$, $p = 0.004$), -8.6 pp onde o painel decidiu ($n = 314$, $p < 10^{-21}$) e -1.1 pp, não significativa, onde permanece a pontuação do juiz da coleta ($n = 192$, essencialmente T5, a recomendação aberta sem valor de registro). O subconjunto adjudicado por código é o menor dos dois porque o código só age onde existe número, de modo que condiciona a que o modelo tenha produzido valor nos *dois* idiomas e seleciona para fora o modo de falha mais severo; o subconjunto do painel carrega esse modo de falha, e é por isso que a leniência do juiz não pode ser tida como cancelada entre idiomas e por isso o desfecho sem juiz acima é o que encerra a questão.

A implicação aplicada é o oposto da intuição. Um gestor que suspeita que um modelo em inglês serve mal seu país, e responde perguntando no idioma nacional, torna a resposta *pior* — e pior pela maior margem exatamente onde o idioma é menos representado nos corpora de treinamento.

Tabela 4: H2: acurácia nativa menos inglesa por idioma nativo (pareada dentro de país e modelo, replicações promediadas dentro da célula, amostra de 25 países).

Idioma nativo (classe Joshi)	Países	Δ (pp)	p	N células
Espanhol (5)	MEX, ARG, PER, COL, CHL	-4.5	2×10^{-10}	457
Português (4)	BRA, PRT, AGO	-4.2	8×10^{-5}	311
Hindi (4)	IND	-11.4	4×10^{-4}	71
Geral		-5.0	5×10^{-16}	839

4.5 H6 — a persona não estreita a lacuna geográfica

O fator persona foi plenamente cruzado, de modo que H6 é testado como diferença em diferenças. O enquadramento de gestor ambiental público deixa a lacuna Norte/Sul essencialmente inalterada: $+4.8$ pp sob o enquadramento neutro contra $+5.2$ pp sob o de gestor, uma DiD de $+0.5$ pp, muito abaixo do limiar pré-especificado de 5 pp; um teste de permutação no nível do país (5.000 permutações do rótulo de camada) dá $p = 0.29$. H6 não é sustentada: apresentar a consulta como vinda de um gestor ambiental público não estreita nem amplifica a desvantagem do Sul Global, coerente com a evidência de que personas de especialista não melhoram de forma confiável a

acurácia factual (Zheng et al., 2024; Basil et al., 2025). Uma checagem de manipulação encontra que 50.2% das respostas na condição de persona reconhecem explicitamente o enquadramento, de modo que o nulo não é artefato de o enquadramento ser universalmente ignorado.

4.6 H1 — uma lacuna de camada que se sustenta, um gradiente que não

A H1 foi pré-especificada em duas partes, e elas se separam com nitidez: uma se sustenta e a outra não.

A lacuna de camada se sustenta. Os dez países do Norte Global têm média de 0.572 contra 0.521 dos quinze do Sul Global, uma lacuna de +5.0 pontos percentuais cujo intervalo de confiança bootstrap de 95% entre países é [+1.6, +8.4] pp e *exclui o zero* (permutação do rótulo de camada, país como unidade, $p = 0.019$). Ela é estável à remoção de qualquer país isolado (leave-one-out [+4.4, +6.0] pp) e à ponderação do composto (+4.2 pp sob pesos iguais, +8.7 pp apenas no subcomponente factual, onde se amplia). Ela não depende dos juízes: só nos desfechos adjudicados por código (toda a T1 e a parte resolvida de T2 e T3), em que nenhum modelo pontuou nada, os países do Norte Global devolvem o valor de registro em 0.61 das vezes e os do Sul Global em 0.46, uma lacuna de +14.7 pp [+5.6, +23.9] (permutação $p = 0.012$), e a razão de chances agregada é 0.53 [0.48, 0.58]. O que quer que o painel acrescente nas tarefas julgadas, a lacuna já está lá antes de qualquer juiz ser consultado. Como sete dos dez países do Norte Global entraram com a extensão, reportamos também a lacuna onde a onda não pode explicá-la: só dentro da extensão (sete do Norte contra Colômbia, Chile e Angola) ela é de +5.9 pp [+2.4, +9.6], e nos quinze pré-especificados (três do Norte contra doze) de +6.0 pp [+1.8, +10.3], uma estimativa pontual do mesmo tamanho numa amostra pequena demais para significância por permutação ($p = 0.13$). A lacuna é propriedade dos dados, não da onda que os coletou.

Onde a lacuna vive, e por que o composto a subestima. O composto faz a média de cinco tarefas, e a lacuna não se distribui igualmente entre elas. Reestimando o mesmo contraste como modelo misto binomial em cada tarefa separadamente — desfecho codificado como devolver o valor de registro, com interceptos aleatórios cruzados de país e modelo —, a desvantagem escala com o quanto a tarefa depende de um fato específico daquele país (Tabela 5). No padrão nacional vinculante (T1), pontuado por código contra o instrumento em vigor, a chance de o Sul Global devolver o valor de registro é 0.32 da chance do Norte (50.7% contra 30.9% em taxa bruta), e nos instrumentos de política (T4) 0.33; na síntese de evidência em saúde (T3), em que a resposta é uma estimativa internacional e não nacional, a razão sobe para 0.69; e na recomendação aberta (T5), a única tarefa sem valor de registro a acertar, a lacuna desaparece inteiramente. A razão de T1 sobrevive às duas objeções que sua composição convida (Seção 4.9): deixando de lado os três países do Sul Global sem padrão nacional ela é 0.39 [0.32, 0.49], e nos quinze pré-especificados é 0.27 [0.21, 0.34]. A T4 é a única tarefa da tabela pontuada inteiramente pelo painel, de modo que sua razão pode carregar a ignorância do próprio juiz sobre os instrumentos do Sul além da do modelo; as estimativas só de código acima são as livres disso. A lacuna não é fraca — ela é *concentrada*, e o composto a dilui ao mediar tarefas em que é severa com uma tarefa em que não existe. Na pergunta que um gestor público mais leva a esses sistemas, qual é o padrão em vigor aqui, um país do Sul Global é servido a um terço das chances de um do Norte.

O gradiente monotônico não se sustenta. Em $n = 25$, o ρ de Spearman entre acurácia e IDH é

Tabela 5: Chances do Sul Global contra o Norte Global de resposta factualmente correta, por tarefa. O desfecho é acurácia factual ≥ 0.5 : o veredito de código onde a tarefa é adjudicada por código (toda a T1; a parte resolvível de T2 e T3), a nota do painel ou do juiz nos demais casos, de modo que para T5, que não tem valor de registro, é a nota factual do juiz. Modelo misto binomial, interceptos aleatórios cruzados para país e modelo.

Tarefa	A resposta é	NG	SG	RC	Intervalo 95%
T1 (padrão técnico)	um valor nacional	50.7%	30.9%	0.32	[0.27, 0.39]
T4 (instrumentos)	instrumentos nacionais	62.0%	44.7%	0.33	[0.26, 0.40]
T2 (dado medido local)	um valor nacional	50.7%	37.8%	0.47	[0.39, 0.55]
T3 (síntese de evid. saúde)	estimativa internac.	59.1%	52.3%	0.69	[0.59, 0.80]
T5 (recomendação aplicada)	nenhum valor de reg.	99.6%	99.7%	3.58	[0.84, 15.17]

de +0.36 e não alcança a significância convencional ($p = 0.076$; Mann-Kendall $p = 0.065$), ficando bem abaixo do limiar pré-especificado $\rho \geq 0.55$, que é o critério contra o qual H1 foi fixada. No $n = 15$ pré-especificado ele está essencialmente ausente ($\rho = +0.08$), e nenhuma reestimação *leave-one-country-out* alcança o limiar de 0.55 (faixa [+0.30, +0.48]); sob pesos iguais é 0.36 e sob pesos de ACP 0.38. Relatamos, portanto, uma diferença de camada que conseguimos demonstrar e um gradiente de desenvolvimento que não: a desvantagem está estabelecida como diferença entre grupos, enquanto sua forma ao longo da faixa de desenvolvimento permanece exploratória. Sob Bonferroni-Holm na família primária {H1-gradiente, H4, H6}, nenhum teste rejeita seu nulo.

A ordenação dos países retém grande heterogeneidade ortogonal aos eixos (material suplementar): a Índia (0.651, Sul Global) lidera todos os países, Indonésia e África do Sul superam a maior parte do Norte Global, e Canadá e França ficam abaixo. A desvantagem é uma diferença de camada sobreposta a variação substancial específica de cada país, e essa heterogeneidade é ela própria parte da razão de o gradiente não se resolver.

4.7 H4 — representação no corpus: cobertura do país, inseparável do desenvolvimento

O mecanismo pré-especificado era a representação no corpus de treinamento, com proxy de contagem de artigos e edições da Wikipédia. Esse proxy é nulo: ρ de Spearman = +0.05 ($p = 0.82$) sem controle, e continua nulo parcializando IDH e log do PIB per capita. Um proxy post hoc de cobertura do país alcança $\rho = +0.37$ ($p = 0.070$) e se atenua após ajuste por IDH (parcial $\rho = +0.19$, $p = 0.37$). No nível do país, nenhum dos canais fica estabelecido, porque com 25 países cobertura e desenvolvimento são colineares.

Mudar a unidade de variação resolve o que o nível do país não resolve

O obstáculo é confundimento, não ausência de sinal, e ele tem saída que não exige mais países. Cada país responde a cinco tarefas que diferem em quanto a resposta depende de um fato sobre *aquele* país: T1, T2 e T4 dependem; T3 (uma estimativa internacional da OMS) e T5 (uma recomendação genérica) não. Os países pontuam 0.462 no primeiro bloco e 0.658 no segundo, um déficit de especificidade de 0.195. Se o que limita o modelo é quanto o corpus diz sobre um dado país, esse déficit deveria ser menor onde a cobertura é maior. Estimar a interação entre

cobertura e dependência da tarefa no nível da resposta, com efeito fixo de país, dá $\beta = +0.030$ (EP 0.005, $p = 9 \times 10^{-10}$, $n = 6.573$). O efeito fixo absorve todo efeito *principal* no nível do país — desenvolvimento, renda, idioma oficial —, mas não a interação deles com a dependência da tarefa, e é aí que mora o rival: um país mais rico pode simplesmente ter mais de sua regulação on-line, alimentando tanto os dados de treinamento do modelo quanto a facilidade de construir a chave.

Quatro checagens separam o sinal de cobertura de artefato (Tabela 6). O contraste *mais puro* — T1, inteiramente nacional, contra T5, inteiramente genérica — produz o *maior* coeficiente; retirar T5 ou T4 o deixa intacto; um placebo que inverte os rótulos devolve a imagem espelhada exata; e, entrando com o proxy de corpus da língua ao lado dele, a cobertura sobrevive ($\beta = +0.030$, $p = 2 \times 10^{-9}$) e a língua não ($\beta = +0.004$, $p = 0.45$). Como toda resposta aqui foi eliciada em inglês, esse último resultado era predito e é a parte falsificável do desenho. O rival que ele não elimina é o desenvolvimento. Cobertura e IDH correlacionam a $\rho = 0.65$ entre os 25 países, e quando as duas interações entram no mesmo modelo a ordem se inverte: IDH×dependência sobrevive ($\beta = +0.027$, EP 0.007, $p = 5 \times 10^{-5}$) e cobertura×dependência não ($\beta = +0.012$, EP 0.007, $p = 0.063$). Dentro dos nove países anglófonos, onde o idioma da pergunta é o mesmo por construção, a cobertura prediz o déficit na magnitude plena ($\beta = +0.024$, $p = 0.003$); isso remove a língua como explicação, não o desenvolvimento.

A afirmação resultante é, portanto, mais estreita que “a cobertura causa a lacuna”, e mais estreita do que a escrevemos primeiro. O que o desenho dentro do país estabelece é que o déficit específico do país é menor onde o mundo registra mais sobre o país — seja esse registro medido como cobertura enciclopédica ou como desenvolvimento, que nesta amostra são duas leituras da mesma variável. Ele descarta o canal do corpus da língua; não escolhe cobertura sobre desenvolvimento, e reportamos o mecanismo como identificado apenas até esse par.

Tabela 6: Cobertura do país × dependência da tarefa, modelo misto no nível da resposta com efeito fixo de país. β positivo = maior cobertura, menor déficit nas tarefas dependentes do país.

Classificação das tarefas	β	p
T1, T2, T4 contra T3, T5 (principal)	+0.030	9×10^{-10}
T1 contra T5 (contraste mais puro)	+0.045	2×10^{-11}
Excluindo T5 (teto em 99.7%)	+0.026	3×10^{-5}
Excluindo T4 (mais interpretativa)	+0.034	1×10^{-9}
Placebo: rótulos invertidos	-0.030	9×10^{-10}
Com IDH×dependência: cobertura	+0.012	0.063
IDH	+0.027	5×10^{-5}

A explicação de corpus se mostra com mais nitidez em H2, onde a unidade é o idioma: a penalidade por idioma cai monotonicamente com o volume de tokens do mC4 (Xue et al., 2021) e o tamanho do OSCAR (Abadji et al., 2022), com o hindi, o menor corpus, carregando a maior penalidade — ainda que, com três idiomas, isso permaneça descritivo.

4.8 H5 — abertos versus fechados acessíveis

Modelos fechados acessíveis têm média +12.8 pp acima dos de pesos abertos, contra o enquadramento otimista de H5. O braço aberto inclui modelos maiores, de modo que a lacuna não é

atribuível apenas à escala, ainda que o DeepSeek-V3 lidere no geral. H5 é interpretada descritivamente.

4.9 Proveniência do gabarito, e o que a chave de T1 decide

Toda chave vem de um registro oficial, ancorada por verificação documental e reproduzível a partir das URLs citadas: T1 da regulação nacional, T2 da Base de Dados de Qualidade do Ar Ambiente da OMS v6.1, T3 do indicador AIR_41 do GHO/OMS, e T4 do Global Assessment of Air Pollution Legislation do PNUMA. Três países *não* têm padrão nacional de PM_{2,5}, confirmado no texto oficial — a Nigéria regula apenas PM₁₀, a Argentina não tem valor federal vinculante, Angola não tem legislação nacional —, e é aí que um modelo fiel deve se recusar a declarar um limiar inexistente. O Egito não tem valor recuperável e, portanto, não tem chave de T1. Todos esses quatro casos são do Sul Global, de modo que a composição da chave é ela própria uma explicação candidata para a lacuna de T1. Não é: deixando de lado os três países sem padrão, a chance do Sul Global em T1 é 0.39 [0.32,0.49] da do Norte, contra 0.32 com eles. A chave também se moveu sob revisão, na direção que o argumento da Seção 5 prevê: a entrada de Bangladesh trazia os 15 µg/m³ do diário oficial de 2005 até que um leitor externo apontasse as Rules de 2022, que fixam 35, e com a chave corrigida a acurácia de Bangladesh em T1 *cai* de 0.39 para 0.30, porque a maioria dos modelos cita o valor superado. O registro completo está no suplemento. Wikipédia e Wikidata aparecem apenas como variável explicativa do teste de mecanismo; nenhuma resposta é pontuada contra elas.

A chave em vigor, e a escada ao redor dela. Vários instrumentos fixam uma escada de valores em vez de um só: a Resolução CONAMA 506/2024 do Brasil percorre 20, 17, 15, 10, 5 µg/m³ em cinco etapas, das quais 17 está em vigor desde janeiro de 2025; o limite europeu é 25 com 10 a partir de 2030; o valor-limite do Reino Unido é 20 com uma meta inglesa de 10 até 2040; os Estados Unidos passaram de 12,0 para 9,0 em 2024; Bangladesh de 15 para 35 em 2022. A chave de T1 é o valor em vigor na janela de coleta, e ela é exigente: nenhum modelo devolve 17 para o Brasil (a resposta modal é 15, a etapa seguinte), quase nenhum devolve 20 para o Reino Unido (a maioria devolve a meta de 2040 ou o 25 superado), e menos de um quarto devolve 9,0 para os Estados Unidos. Das 759 respostas erradas de T1, 281 citam um valor que está em algum degrau da escada oficial do país — uma etapa ainda não vigente ou um valor já substituído —, o que é confusão sobre *qual* valor vincula, não fabricação, e é a falha que um corte de treinamento produziria. A distinção não salva a comparação entre tiers, ela a aguça: pontuar qualquer valor da escada como correto eleva a acurácia do Norte Global em T1 de 0.51 para 0.77 e a do Sul Global apenas de 0.31 para 0.42, porque os instrumentos escalonados estão em sua maioria no Norte, e a razão de chances cai para 0.14 [0.11,0.16]. Onde o registro oferece vários números plausíveis os modelos os conhecem; onde oferece um só, com frequência não.

4.10 Modos qualitativos de falha

Três modos de falha recorrem por trás do composto, com exemplos literais no suplemento. Os modelos *fabricam padrões inexistentes* para os três países sem norma nacional: em 168 das 256 células de T1 pontuadas para Angola, Argentina e Nigéria a resposta afirma um valor nacional específico, em 33 afirma corretamente que nenhum existe e em 31 se recusa a responder, e os

valores inventados discordam entre replicações; *erram o valor vinculante*, respondendo $15 \mu\text{g}/\text{m}^3$ para o Brasil, cuja etapa em vigor é 17 (CONAMA 506/2024), uma confusão de etapa e não uma invenção; e *degradam em idioma nativo*, como quando o GPT-OSS 120B devolveu os corretos $40 \mu\text{g}/\text{m}^3$ da Índia em inglês e resposta *vazia* em hindi.

4.11 Confiabilidade entre juízes

A confiabilidade é relatada sobre a amostra que produz os efeitos, não sobre um subconjunto de calibração. Todos os 3.190 itens que exigiram juiz foram pontuados pelos três membros do painel, dando α de Krippendorff = 0.527, ICC(2,1) de juiz único = 0.558 e — a quantidade operativa, já que a análise usa a média do painel — ICC(2,3) = 0.791.

O painel também isola uma regra de projeto que vale enunciar de forma geral. Onde o prompt de julgamento pedia ao modelo que comparasse uma concentração devolvida contra uma faixa de tolerância expressa em palavras — isto é, que fizesse ele próprio a aritmética —, a concordância entre juízes nesses itens foi de $r = -0.04$. Pré-computar a faixa admissível e perguntar apenas se o valor cai dentro dela elevou a concordância nos mesmos itens para $r = +1.00$, e as 274 pontuações coletadas sob a redação ambígua foram descartadas e recoletadas. Discordância aparente entre juízes pode ser artefato do que se pede ao juiz que compute. A aritmética pertence ao código.

4.12 Robustez

Os dois efeitos sustentados foram testados contra sete ataques e sobrevivem a todos; o gradiente de desenvolvimento fica abaixo do 0.55 pré-especificado em cada um deles (seu valor mais alto, 0.48, é uma reestimação leave-one-out), o que é o que torna seu estatuto exploratório um achado, e não uma omissão. As saídas completas estão no suplemento.

Nenhum país isolado, e nenhuma ponderação, carrega o resultado. A reestimação leave-one-country-out mantém a lacuna de camada em $[+4.4, +5.9]$ pp e a penalidade de idioma nativo entre -4.4 e -5.5 pp. Reponderar o composto não move as conclusões: sob pesos iguais a lacuna é de $+4.2$ pp e a penalidade de idioma de -4.8 pp; restringir à acurácia factual contra o valor de registro as amplia para $+8.7$ e -6.1 pp e aprofunda o piso de recuperação. Os efeitos são mais fortes onde a medida é mais objetiva. As duas réplicas de cada célula diferem em 8.5 pp em média (DP intracélula de 10.1 pp), de modo que a penalidade de idioma de -5.0 pp, mediada sobre 839 pares, fica a cerca de dez erros-padrão do ruído que duas réplicas deixam por resolver.

A lacuna de camada sobrevive a um teste livre de distribuição e a duas famílias de modelo. Um teste de permutação embaralha os rótulos Norte/Sul entre os 25 países dez mil vezes e conta com que frequência o acaso sozinho produz uma lacuna desse tamanho; ele não assume nada sobre a distribuição e trata o país, e não a resposta, como unidade independente. O acaso supera a lacuna observada em 1.9% das vezes ($p = 0.019$). Um modelo hierárquico bayesiano com interceptos aleatórios cruzados concorda ($\beta = -0.049$, HDI de 94% $[-0.088, -0.006]$, $P(\beta < 0) = 0.987$), enquanto um modelo misto frequentista devolve a mesma magnitude e sinal mas o deixa marginal ($\beta = -0.063$, $p = 0.086$), porque cobra do termo de erro a grande heterogeneidade entre países. Dois dos três testes excluem o zero e os três concordam em magnitude, de modo que relatamos a lacuna como sustentada e sensível à especificação, com E-value de 1.71 na estimativa pontual e 1.31 no limite do intervalo mais próximo do nulo (VanderWeele and Ding, 2017) — um

confundidor de país de força modesta bastaria para explicá-la, e o leitor tem o direito de pesar isso.

A lacuna acompanha a posição no sistema-mundo, não a riqueza nacional. Reestimada sob três partições baseadas em desenvolvimento dos mesmos 25 países, a lacuna é significativa sob a UNCTAD e não significativa sob toda divisão traçada pelo IDH (suplemento). Isso é coerente com o resto do artigo: o gradiente de IDH é ele próprio nulo, de modo que uma divisão por IDH não deveria produzir lacuna, e o fato de a UNCTAD separar os dados onde o IDH não separa aponta para a posição no sistema-mundo, e não a renda, como variável operante (Quijano, 2000; Mohamed et al., 2020). A leitura é post hoc, de modo que reivindicamos a lacuna para a distinção Norte/Sul tal como convencionalmente traçada, e não como afirmação geral sobre desenvolvimento.

O gradiente nulo é informativo, dentro de limites declarados. Simulando amostras de 25 países com correlações conhecidas, o desenho tem 77% de poder em $\rho = 0.55$ — o limiar fixado de antemão — e efeito mínimo detectável de $\rho = 0.56$. Um gradiente da magnitude que nos comprometemos a chamar de substancial está excluído; um fraco não está (poder de 48% em $\rho = 0.40$). Os dez países acrescentados post hoc caem *dentro* da faixa de IDH que os quinze originais já cobriam, de modo que a extensão aumenta a densidade de observações, e não a amplitude do preditor.

4.13 Síntese

A Tabela 7 mapeia cada hipótese ao seu achado, ao mecanismo candidato e a um estatuto de evidência explícito, de modo que nenhuma afirmação seja lida como mais forte do que os dados sustentam. Três efeitos são sustentados e sobrevivem a todo ataque de robustez da Seção 4.12; duas expectativas pré-especificadas não se cumprem; e o mecanismo de corpus é identificado dentro dos países apenas até o par cobertura-ou-desenvolvimento, que este desenho não consegue separar.

5 Discussão

Propusemo-nos a medir se os LLMs respondem a perguntas de política de poluição do ar com a mesma confiabilidade para o Sul Global e para o Norte Global, se o enquadramento do prompt muda a resposta, e qual mecanismo impulsiona eventual lacuna. Em 25 países, 14 modelos, quatro idiomas, cinco tarefas e duas personas, pontuados contra gabarito oficial por código onde a resposta é um valor de registro e por um painel de três fornecedores nos demais casos, os danos que conseguimos demonstrar são práticos, e não etiológicos: as três mitigações às quais uma agência recorreria falham, a mais intuitiva delas piora materialmente a resposta, e os modelos são menos confiáveis justamente na recuperação do valor vinculante em vigor. Uma diferença de camada Norte/Sul persiste, e identificamos o canal por trás dela apenas onde o desenho tem resolução para tanto.

Tabela 7: Hipóteses, achados, mecanismos candidatos e estatuto de evidência. Agrupada pelo que a evidência sustenta, não por número de hipótese.

Hipótese	Achado	Mecanismo
<i>Sustentadas</i>		
H2 idioma	−5.0 pp; hindi −11.4	corpus do idioma
H3 modelo regional	$\delta = -0.48$, pior de 14	escala sobre ajuste
H1 lacuna de camada	+5.0 pp; RC 0.32 em T1	camada
<i>Sustentada, mecanismo não separável</i>		
H4 dentro do país	$\beta = +0.030$ sozinha; +0.012 ($p = 0.063$) com IDH	cobertura ou desenvolvimento
<i>Não sustentadas</i>		
H1 gradiente	$\rho = 0.36$, abaixo de 0.55	desenvolvimento
H4 pré-especificada	proxy de corpus do idioma nulo	corpus do idioma
H6 persona	DiD +0.5 pp, $p = 0.29$	—
<i>Apenas descritiva</i>		
H5 aberto/fechado	+12.8 pp para fechados	tipo de acesso

Nota. O mecanismo de H2 repousa sobre três idiomas nativos e é descritivo. A lacuna de camada de H1 é concentrada nas tarefas cuja resposta depende de um fato nacional. H4 dentro do país descarta o canal do corpus da língua, mas não separa cobertura de desenvolvimento, e não é identificação causal.

5.1 Três mitigações intuitivas, todas falhando — e uma que prejudica

O idioma local não ajuda e prejudica materialmente. Perguntar no idioma do próprio país reduz a acurácia em 5.0 pp, de forma significativa nos três idiomas e com o país como unidade de inferência, e a penalidade escala com a escassez do corpus daquele idioma, com a Índia — país de maior pontuação entre os 25 em inglês — caindo mais em hindi. Este é o mecanismo que a hierarquia de recursos prevê (Joshi et al., 2020; Xue et al., 2021), e a medida tem resolução para vê-lo porque a unidade é o idioma e não o país. O efeito não depende de nenhum país, modelo, tarefa, condição de persona ou instrumento de pontuação em particular, nem da qualidade da tradução, e se sustenta em um desfecho que não envolve juiz algum: o modelo se torna acentuatadamente menos propenso a produzir um número conferível.

A persona de gestor local não estreita a lacuna (DiD +0.5 pp, permutação $p = 0.29$), coerente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Esse nulo pesa mais do que pesaria um nulo sobre um hábito popular, porque o enquadramento por papel é a primeira coisa que todo fornecedor relevante manda seu usuário fazer — Anthropic, OpenAI, Google e xAI convergem no mesmo conselho (Seção 2), de modo que uma administração que siga a documentação do próprio fornecedor escreverá a frase que testamos. O que essa documentação promete para a frase, lida de perto, é controle sobre tom, formato e enquadramento, e nada nela marca a fronteira: nada avisa ao leitor que a técnica que molda o registro de forma confiável não molda também a confiabilidade factual. Nossa estimativa separa as duas. Uma checagem de manipulação confirma que metade das respostas assume explicitamente o papel, de modo que o enquadramento é recebido e muda a voz; ele não muda o que o modelo sabe. Testamo-lo digitado na mensagem, e não instalado como instrução de sistema, que é o canal que um servidor público na interface de conversa efetivamente

tem e a mais estreita das duas afirmações (Seção 5.7).

O modelo regional é o *pior* desempenho entre os catorze ($\delta = -0.48$), e também fica atrás de seu par de escala equivalente nos prompts brasileiros em português para os quais foi ajustado (0.258 contra 0.313 do Llama 3.1 8B, em 20 células cada), de modo que recorrer a um modelo pequeno com ajuste local troca a escala e o treinamento de fronteira que sustentam a acurácia no domínio sem comprar de volta o conhecimento local que promete. Dois limites delimitam isso: o teste estreito é pequeno, e o modelo que conseguimos rodar é um fine-tune comunitário de uma base de 7B, não um modelo regional de fronteira comercial do tipo que um órgão de fato compraria — para esses o achado é uma predição, não um resultado, e o protocolo liberado é como testá-la.

Profissionais implantam as três como soluções; nenhuma funciona, e a que um gestor tem mais chance de tentar primeiro causa dano ativo. Para as agências ambientais do Sul Global, nenhum contorno barato no nível do prompt ou do modelo substitui verificar o valor vinculante na fonte oficial.

5.2 O piso de recuperação recai sobre os valores que vinculam

O risco recai de forma desigual. Um gestor que redige prosa sobre política de qualidade do ar é comparativamente bem servido; um gestor que recupera o limite regulatório do qual depende uma decisão está na pior célula do desenho (Seção 4.3), e pior ainda se perguntar em um idioma de menos recursos. O piso não é artefato de pontuação: as duas tarefas de recuperação são decididas por código contra o registro, e mais de um terço das respostas erradas sobre o padrão nacional cita um valor da própria escada oficial do país, e não um inventado — os modelos conhecem a escada, não o degrau que vincula.

5.3 Uma diferença de camada que podemos mostrar, e um gradiente que não

O achado geográfico é uma diferença entre grupos, não uma inclinação. A lacuna Norte/Sul no composto é modesta, tem o mesmo tamanho dentro da onda de extensão e nos quinze pré-especificados, e é concentrada: escala com o quanto a resposta depende de um fato específico do país e desaparece na única tarefa sem valor de registro a acertar (Seção 4.6). Só nos desfechos adjudicados por código, em que nenhum juiz pode ter contribuído com um déficit próprio, ela é maior do que no composto. O gradiente de desenvolvimento fica abaixo do limiar pré-especificado em toda leitura, e esse nulo é informativo porque o desenho tem 77% de poder em $\rho = 0.55$: um gradiente do tamanho com que nos comprometemos está excluído, um fraco não está. A ordenação dos países mostra por que os dois resultados diferem — a Índia lidera os 25 países apesar de ser Sul Global, Canadá e França ficam abaixo —, de modo que a desvantagem é uma diferença de camada sobreposta a uma idiosincrasia de cada país que uma correlação de postos sobre 25 países não consegue atravessar.

5.4 O mecanismo, onde o desenho tem resolução

O teste de mecanismo pré-especificado falha, e a razão é um defeito do instrumento, não ausência de sinal. O proxy atribui o tamanho da edição da Wikipédia no idioma oficial dominante do

país, de modo que nove dos nossos 25 países recebem o valor da Wikipédia *inglesa*. A variável não mede quanto texto existe no idioma de um país; mede se o país tem o inglês como idioma oficial, que é um fato de história colonial. Relatamos isso porque incide sobre qualquer estudo que tenha usado ou venha a usar o mesmo proxy.

A resolução parcial vem de mudar a unidade de variação. Dentro dos nove países anglófonos o canal linguístico não é apenas controlado, mas idêntico por construção, e a cobertura do país ainda prevê o déficit de especificidade ($\beta = +0.024$, $p = 0.003$): o que esse coeficiente mede não pode ser idioma. O que ele pode ser é desenvolvimento. Entrando junto com a cobertura, a interação IDH $\times$ dependência da tarefa toma o sinal ($\beta = +0.027$, $p = 5 \times 10^{-5}$) e a cobertura cai para $\beta = +0.012$ ($p = 0.063$), porque entre esses 25 países as duas correlacionam a $\rho = 0.65$ e o desenho não tem alavanca que mova uma sem mover a outra. O mecanismo é, portanto, identificado apenas até esse par: o déficit é menor onde há mais sobre o país em registro, e se o registro operante é a pegada enciclopédica ou o aparato mais amplo de um Estado desenvolvido, este estudo não consegue dizer.

5.5 A lição metodológica: a chave importa mais que a amostra

As mesmas células pontuadas sustentam conclusões substantivas diferentes conforme o instrumento usado para pontuá-las, e o tamanho dessa diferença é a lição. Pontuar duas tarefas contra chaves de preenchimento e delegar a aritmética de faixa a um juiz produziu um gradiente de desenvolvimento significativo e uma penalidade de idioma pequena; reconstruir as chaves a partir de registros oficiais e passar a comparação para o código reduziu o gradiente à metade e mais que dobrou a penalidade (Seções 4.6 e 4.4). Passar a terceira tarefa com valor de registro de dois juízes de coleta para o código mudou sua razão de chances-manchete em um terço, porque os juízes tinham sido divididos pela mesma linha que os tiers. E a própria chave seguiu se movendo sob escrutínio: a entrada do Reino Unido trazia uma meta para 2040 no lugar do limite em vigor, e a de Bangladesh trazia o valor de 2005 depois que as Rules de 2022 o haviam elevado, de modo que um modelo que citava o padrão vigente correto de um país do Sul Global estava sendo pontuado como errado até que um leitor externo o pegasse. O conjunto de dados nunca mudou; apenas o instrumento. O instinto do campo, quando um efeito de viés geográfico se mostra frágil, é acrescentar países, mas o gabarito merece o escrutínio primeiro: uma chave defeituosa não apenas acrescenta ruído, acrescenta ruído *estruturado*, porque os defeitos se concentram onde os textos oficiais são mais difíceis de obter ou foram revisados mais recentemente — exatamente onde vive a hipótese. O registro liberado carrega, por isso, um hash de conteúdo (material suplementar), para que qualquer leitor saiba contra qual versão da chave cada número foi computado.

5.6 Por que o domínio importa

O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura, e a carga recai desproporcionalmente sobre o Sul Global: a Organização Mundial da Saúde atribui 88.548 óbitos no Brasil em 2021 à poluição do ar ambiente (intervalo de incerteza 69.477 to 108.431) (World Health Organization, 2026), e a exposição de curto prazo segue impulsionando mortalidade mensurável em cidades brasileiras (Requia et al., 2024). Quando um gestor delega a um LLM uma consulta normativa ou uma recomendação de episódio, uma

resposta imprecisa pode se propagar para um parecer regulatório ou uma resposta emergencial.

Não afirmamos que o modelo é menos confiável onde as consequências são maiores, porque não medimos isso: a carga de doença não está entre nossas covariáveis de país, e a única observação de nível de país que temos aponta no sentido contrário, já que a Índia carrega uma das maiores cargas de mortalidade por $PM_{2,5}$ do mundo e é também o país de maior pontuação em nossa amostra. Se a confiabilidade está desalinhada da necessidade é pergunta bem posta, respondível acrescentando uma covariável de mortalidade atribuível padronizada por idade, mas não uma pergunta que este desenho responde. Interpretamos o padrão que *de fato* medimos pelo arcabouço da colonialidade do saber (Mohamed et al., 2020): os LLMs são resumos comprimidos de corpora produzidos sob acesso digital e de publicação desigual, e a penalidade de idioma é um elo mensurável entre assimetria de corpus e assimetria de conhecimento.

5.7 Limitações e oportunidades futuras

Cada limite abaixo delimita este desenho, e cada um nomeia o estudo que o removeria. Listamos na ordem em que os faríamos.

O enquadramento de papel foi testado no turno do usuário, não no prompt de sistema. O enquadramento de gestor é anteposto à mensagem em vez de instalado como instrução de sistema, onde três dos quatro guias o colocam — o do Google admite esse lugar ou o início do prompt do usuário, que foi o que usamos. A escolha acompanha a população que nos interessa — servidores públicos na interface de conversa, que não têm prompt de sistema a configurar —, mas significa que nosso nulo delimita o canal desse usuário, não o de um desenvolvedor. Se uma persona em instrução de sistema recupera acurácia factual onde uma digitada não recupera é um experimento limpo de duas células sobre os mesmos itens, e é o primeiro estudo que faríamos.

De pontuado por painel a ancorado em padrão-ouro. Nenhum especialista humano repontuou respostas aqui. Três propriedades delimitam o custo disso: onde a resposta é um valor de registro, o veredito é computado por código e nenhum juiz se envolve; onde se exige julgamento, a nota é a média de três fornecedores em vez de um; e todo efeito relatado é um contraste entre grupos, no qual a severidade sistemática de um juiz se cancela. Restringir à acurácia factual objetiva fortalece os dois efeitos principais, o oposto do que um juiz permissivo produziria. Uma validação cega por especialistas humanos de uma amostra estratificada — cerca de 150 respostas pontuadas por três avaliadores, que o pipeline liberado exporta diretamente — converteria um resultado ancorado em fonte oficial em um ancorado em padrão-ouro.

De um sinal dentro do país a um desenho causal. O canal é identificado onde o desenho tem resolução, mas não causalmente: dentro dos países removemos o confundimento no nível do país sem remover o de tarefa por país. Um desenho que varie a cobertura do país mantendo o desenvolvimento fixo, ou um estudo longitudinal acompanhando a acurácia à medida que a pegada enciclopédica de um país cresce, fecharia essa lacuna.

De um gradiente nulo a um teste com poder adequado. A diferença de camada está estabelecida enquanto o gradiente não, em $n = 25$. Uma replicação pré-registrada com n substancialmente maior — que o conjunto de dados aberto torna barata — resolveria se o gradiente é genuinamente ausente ou ainda subdimensionado.

De três idiomas nativos à matriz multilíngue completa. O resultado mais forte repousa sobre

três idiomas nativos, de modo que seu *mecanismo* é relatado descritivamente ainda que o efeito não seja. A objeção de qualidade de tradução é resolvida empiricamente, e não apenas reconhecida, pelo censo de retrotradução relatado acima. O que permanece aberto é amplitude, não validade, e escalar para mais idiomas é a extensão de maior valor que este estudo aponta.

De um domínio a um programa entre domínios. Todos os efeitos vêm de um domínio aplicado de alto risco e de uma família de corpus (Wikimedia), e confinamos a linguagem mecanicista a ele. O mesmo conjunto de tarefas e o método de registro de gabarito se transferem diretamente a outros domínios regulados e ancorados em fonte — qualidade da água, segurança de alimentos, política de vacinação.

A pilha do modelo servido como unidade de análise. Avaliamos modelos *como servidos* por pilhas de acesso fixas, que é o que um gestor público consulta; uma lacuna residual poderia, em princípio, refletir a pilha em vez dos pesos. Um desenho controlado de quase-isolamento com pesos abertos idênticos entre pilhas separaria os dois, o que a proveniência por chamada que liberamos já viabiliza.

5.8 O que este estudo contribui

Diante da evidência agora em mãos, três das contribuições listadas na Seção 1 se destacam. O resultado aplicado é decisivo e contraintuitivo: as três soluções a que os profissionais recorrem primeiro falham juntas, o idioma local prejudica ativamente, e o modelo regional é o pior desempenho entre catorze — a saída mais útil de um benchmark é muitas vezes dizer ao campo o que não funciona, com tamanhos de efeito por trás. O resultado metodológico é que, nesta literatura, a chave de gabarito, e não o tamanho amostral, é a restrição vinculante. E o desenho separa o que 25 países conseguem demonstrar do que não conseguem, relatando o segundo conjunto como aberto em vez de sustentado.

6 Conclusão

Modelos de linguagem de grande porte estão se tornando infraestrutura de trabalho para a política de poluição do ar, domínio em que uma resposta imprecisa sobre um padrão vinculante, uma concentração medida ou uma resposta operacional carrega consequências diretas de saúde pública no Sul Global, onde a carga de mortalidade por PM_{2,5} é mais pesada (GBD 2019 Risk Factors Collaborators, 2020; Requia et al., 2024). Medimos viés geográfico e modulado por persona nesse domínio com um benchmark de 25 países, 14 modelos e quatro idiomas (inglês mais o idioma nativo de nove países), pontuado contra gabarito ancorado em fontes oficiais primárias — por código sempre que a resposta é um valor de registro, e pela média de um painel de juízes de três fornecedores nos demais casos.

As mitigações que um órgão pode tentar não funcionam, e a mais intuitiva sai pela culatra. Perguntar no idioma do próprio país *reduz* a acurácia em 5.0 pontos percentuais, de forma mais acentuada onde o idioma é menos representado nos corpora de treinamento; a persona de gestor local não estreita a lacuna; e o modelo de 7B com ajuste regional é o mais fraco dos catorze sistemas. A acurácia também despenca na recuperação de um valor vinculante, a tarefa que um gestor menos pode se dar ao luxo de ter errada. Uma lacuna de camada Norte/Sul persiste e é

altamente estruturada: ao devolver o padrão nacional vinculante, a chance de resposta correta do Sul Global é 0.32 da chance do Norte, e a lacuna encolhe conforme a resposta depende menos de um fato específico do país, desaparecendo na única tarefa sem valor de registro a acertar. O gradiente monotônico de desenvolvimento não atinge significância, de modo que relatamos uma diferença entre grupos que conseguimos demonstrar e uma forma ao longo da faixa de desenvolvimento que não conseguimos. Quanto ao mecanismo, o desenho dentro dos países descarta o canal do corpus da língua para uma lacuna medida em inglês, mas não consegue separar a cobertura do país do desenvolvimento, e não reivindicamos mais do que isso.

Para as agências ambientais do Sul Global, a mensagem prática é cautelar. Saídas de LLM sobre padrões vinculantes e dados medidos devem ser tratadas como rascunhos conferidos contra o diário oficial, e nenhum contorno barato no nível do prompt ou do modelo substitui essa verificação — muito menos trocar para o idioma local, que por esta evidência piora a resposta. Interpretamos o padrão pelo arcabouço da colonialidade do saber (Mohamed et al., 2020): a penalidade recai sobre os idiomas sub-atendidos nos corpora de treinamento (Joshi et al., 2020), e recai com mais força sobre o hindi, o mais escasso dos três; se esses idiomas são também falados onde a carga de saúde da poluição do ar é maior não é algo que este desenho meça, e a única observação no nível de país de que dispomos (Índia) aponta na direção contrária (Seção 5).

Um resultado metodológico generaliza para além do domínio. Reconstruir duas chaves de gabarito a partir de registros oficiais e tirar a comparação de faixa do juiz, passando-a para o código, mudou as conclusões substantivas sobre as mesmas respostas. Quando um efeito nesta literatura se mostra frágil, a chave de gabarito merece a auditoria antes da amostra, porque uma chave defeituosa acrescenta ruído *estruturado* que se concentra exatamente onde o dado oficial é mais difícil de obter.

Protocolo, prompts, registros de gabarito com fontes oficiais, código de análise e dados de resposta anonimizados são liberados abertamente, com pipeline de reprodução em um comando e um gate de auditoria de métodos que recomputa cada número relatado a partir do dado bruto. O estudo também oferece um modelo reutilizável para auditorias aplicadas de equidade em LLMs — gabarito de fonte oficial, adjudicação por código sempre que a resposta é um número conferível, e auditabilidade de ponta a ponta — nos domínios de alto risco do setor público em que esses sistemas já estão sendo implantados.

Disponibilidade de dados e código

O protocolo completo, os prompts, o código de análise, os registros de gabarito e as respostas anonimizadas dos modelos serão liberados na publicação em github.com/Roverlucas/artigo-vies-analise-regional, sob licenças MIT (código) e CC-BY-4.0 (dados, prompts, documentação). A liberação inclui os registros por resposta a partir dos quais cada efeito relatado é calculado, de modo que todo número deste artigo pode ser recomputado do dado bruto em vez de aceitar por confiança. O pipeline de análise roda de ponta a ponta com `python code/run_all.py -confirmatory`.

Protocolo do estudo

Hipóteses, marco amostral, definição de desfecho, limiares de decisão e correção de multiplicidade foram fixados em um plano de análise sob controle de versão antes do início da coleta confirmatória. Esse plano não foi depositado em registro público, de modo que o leitor não pode verificar sua data de forma independente do histórico do repositório, e *não* reivindicamos pré-registro. O escopo entregue também se afastou substancialmente do desenho planejado, o que o próprio plano estabelecia como condição para o estatuto confirmatório.

Relatamos o estudo, portanto, em duas camadas. A primeira declara o que foi especificado de antemão e o que aconteceu com cada item. A segunda relata o que os dados sugeriram e o plano não antecipou, rotulado como exploratório do começo ao fim, com intervalos e sem linguagem confirmatória. Os desvios em relação ao plano estão tabulados no material suplementar.

Agradecimentos

Esta pesquisa não recebeu financiamento específico de agências dos setores público, comercial ou sem fins lucrativos. Os custos de inferência foram pagos pelos autores; nenhum fornecedor concedeu créditos, descontos ou apoio em espécie para este estudo.

Contribuições dos autores

Segundo a taxonomia CRediT:

- Lucas Rover (UTFPR): Conceituação, Metodologia, Software, Curadoria de Dados, Análise Formal, Investigação, Visualização, Redação – Rascunho Original, Administração do Projeto.
- Vitor de Melo Dominski (Faculdade Descomplica): Curadoria de Dados, Software, Análise Formal.
- Prof. Anibal Tavares de Azevedo (Unicamp): Redação – Rascunho Original, Redação – Revisão e Edição.
- Dr. Eduardo Tadeu Bacalhau (UFPR): Validação, Supervisão, Redação – Revisão e Edição.
- Dra. Yara de Souza Tadano (UTFPR): Validação, Supervisão, Redação – Revisão e Edição.

Declaração sobre IA generativa na redação

É preciso separar dois usos distintos, porque apenas um deles é objeto desta declaração.

Como objeto e instrumento do estudo. Modelos de linguagem são o objeto desta pesquisa e também servem como um de seus instrumentos de medida: GPT-5-mini e Claude Haiku 4.5 pontuaram respostas contra o registro de gabarito como juízes da coleta; Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3 as repontuaram como painel de três fornecedores; e o Claude Sonnet 4.6 produziu as versões dos prompts em idioma nativo. Esses usos fazem parte do método, estão descritos na Seção 3, e são a razão de o estudo também relatar confiabilidade entre juízes e

uma auditoria de retrotradução dos prompts traduzidos. Onde a resposta correta é um valor de registro oficial, o veredito é computado por código, não por modelo.

Na preparação do manuscrito. Durante a preparação deste trabalho, os autores usaram o Claude, da Anthropic (via Claude Code), para auxiliar na redação e edição do texto e na implementação do código de análise; o Codex CLI, da OpenAI, para rodar uma auditoria adversarial do manuscrito, do suplemento e do código contra suas fontes; e, por API, o Gemini 2.5 Pro, o DeepSeek-V3 e o GPT-5.2-pro como revisores independentes das afirmações e da prosa do manuscrito, cada um rodado em fornecedor diferente do que redigiu o trecho revisado. Após usar essas ferramentas, os autores revisaram e editaram o conteúdo conforme necessário e assumem responsabilidade integral pelo conteúdo da publicação. Nenhum modelo de linguagem consta como autor, e nenhum modelo contribuiu com a interpretação dos achados ou com as decisões sobre o que a evidência sustenta.

Declaração de interesses

Os autores declaram não haver conflitos de interesse.

Referências

- Abadji, J., Ortiz Suárez, P., Romary, L., and Sagot, B. (2022). Towards a cleaner document-oriented multilingual crawled corpus. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 4344–4355.
- Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C. J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C. C., Martin, O. A., et al. (2023). PyMC: A modern and comprehensive probabilistic programming framework in Python. *PeerJ Computer Science*, 9:e1516.
- Almeida, T., Nogueira, R., and Pedrini, H. (2025a). Building high-quality datasets for Portuguese LLMs: From Common Crawl snapshots to industrial-grade corpora. *Journal of the Brazilian Computer Society*, 31(1):1247–1263.
- Almeida, T. S., Bonás, G. K., and Santos, J. G. A. (2025b). BRoverbs: Measuring how much LLMs understand Portuguese proverbs. *Journal of the Brazilian Computer Society*, 31:1078–1088.
- Almeida, T. S., Bonás, G. K., Santos, J. G. A., Abonizio, H., and Nogueira, R. (2025c). TiEBE: Tracking language model recall of notable worldwide events through time. *arXiv preprint arXiv:2501.07482*.
- Anthropic (2026). Prompting best practices: *Give Claude a Role*. Claude Platform Documentation, Prompt Engineering. Section “Give Claude a role”.
- Aoki, N., Tatsumi, T., Naruse, G., and Maeda, K. (2024). Explainable AI for government: Does the type of explanation matter to the accuracy, fairness, and trustworthiness of an algorithmic decision as perceived by those who are affected? *Government Information Quarterly*, 41(4):101965.

1143 Basil, S., Shapiro, I., Shapiro, D., Mollick, E. R., Mollick, L., and Meincke, L. (2025). Prompting
1144 science report 4 — playing pretend: Expert personas don’t improve factual accuracy. SSRN
1145 Working Paper.

1146 Bender, E. M., Gebru, T., McMillan-Major, A., and Shmitchell, S. (2021). On the dangers
1147 of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM*
1148 *Conference on Fairness, Accountability, and Transparency*, pages 610–623.

1149 Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and
1150 powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*,
1151 57(1):289–300.

1152 Choroszewicz, M. (2026). Positioning public sector practitioners as ‘moral crumple zones’: Me-
1153 chanisms in the early use of generative AI work support tools. *Government Information*
1154 *Quarterly*, 43(2):102128.

1155 Cordella, A. and Gualdi, F. (2024). Regulating generative AI: The limits of technology-neutral
1156 regulatory frameworks. insights from Italy’s intervention on ChatGPT. *Government Informa-*
1157 *tion Quarterly*, 41(4):101982.

1158 GBD 2019 Risk Factors Collaborators (2020). Global burden of 87 risk factors in 204 countries
1159 and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019.
1160 *The Lancet*, 396(10258):1223–1249.

1161 Google (2026). Prompting strategies: Role definitions in system instructions. Gemini API Do-
1162 cumentation. Vendor documentation instructing developers to place role definitions (persona)
1163 in the system instruction. Accessed 2026-08-25.

1164 Igoikina, A. A. and Meshcheryakov, G. (2020). semopy: A python package for structural equation
1165 modeling. *Structural Equation Modeling*, 27(6):952–963.

1166 Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate
1167 of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual*
1168 *Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for
1169 Computational Linguistics.

1170 Kerche, F., Zook, M., and Graham, M. (2026). The silicon gaze: A typology of biases and
1171 inequality in LLMs through the lens of place. *Platforms & Society*.

1172 Kim, E. (2026). Generative AI in public administration: A quasi-experimental analysis of bure-
1173 aucratic productivity. *Government Information Quarterly*, 43(1):102108.

1174 Kozlakidis, Z., Wootton, T., and Mayrhofer, M. T. (2026). Through the looking glass: ethical
1175 considerations regarding LLM-induced hallucinations to medical questions. *Frontiers in Digital*
1176 *Health*, 8:1736616.

1177 Le Coz, P., Liu, J. A., Bhattacharjya, D., Curto, G., and Stinckwich, S. (2025). What would an
1178 LLM do? evaluating large language models for policymaking to alleviate homelessness. *arXiv*
1179 *preprint arXiv:2509.03827*.

1180 Manvi, R., Khanna, S., Burke, M., Lobell, D., and Ermon, S. (2024). Large language models
1181 are geographically biased. In *Proceedings of the 41st International Conference on Machine*
1182 *Learning (ICML)*. arXiv:2402.02680.

1183 Mirza, S., Coelho, B., Cui, Y., Pöpper, C., and McCoy, D. (2024). Global-liar: Factuality of
1184 LLMs over time and geographic regions. *arXiv preprint arXiv:2401.17839*.

1185 Moayeri, M., Tabassi, E., and Feizi, S. (2024). Worldbench: Quantifying geographic disparities
1186 in LLM factual recall. In *Proceedings of the 2024 ACM Conference on Fairness, Accountability,*
1187 *and Transparency*, pages 1211–1228, Rio de Janeiro, Brazil.

1188 Mohamed, S., Png, M.-T., and Isaac, W. (2020). Decolonial AI: Decolonial theory as sociotech-
1189 nical foresight in artificial intelligence. *Philosophy & Technology*, 33(4):659–684.

1190 Myung, J. et al. (2024). BLEnD: A benchmark for LLMs on everyday knowledge in diverse
1191 cultures and languages. *Advances in Neural Information Processing Systems*, 37:78104–78146.

1192 Nosek, B. A., Ebersole, C. R., DeHaven, A. C., and Mellor, D. T. (2018). The preregistration
1193 revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606.

1194 OECD (2025). Governing with artificial intelligence: The state of play and way forward in core
1195 government functions. Technical report, OECD Publishing, Paris.

1196 OpenAI (2026). Prompt engineering: Identity and message formatting. OpenAI Platform Docu-
1197 mentation. Vendor documentation recommending an “Identity” block describing the assistant’s
1198 purpose and role. Accessed 2026-08-24.

1199 Opuszek, M. and Böhm, P. (2026). New york, new york – unraveling bias in large language
1200 models: Investigating differences between standard and reasoning-based language models. In
1201 *AI Revolution: Research, Ethics and Society*, pages 92–106. Springer.

1202 Patton, M. Q. (2015). *Qualitative research and evaluation methods*. SAGE Publications, 4th
1203 edition.

1204 Quijano, A. (2000). Coloniality of power, eurocentrism, and Latin America. *Nepantla: Views*
1205 *from South*, 1(3):533–580. Reprinted in Moraña, Dussel and Jáuregui (eds.), *Coloniality at*
1206 *Large*, Duke University Press, 2008, doi:10.1215/9780822388883-011.

1207 Requia, W. J., Vicedo-Cabrera, A. M., Amini, H., and Schwartz, J. D. (2024). Short-term air
1208 pollution exposure and mortality in Brazil: Investigating the susceptible population groups.
1209 *Environmental Pollution*, 340:122797.

1210 Robinson, N. (2026). Open to open-source AI? navigating AI model choice in public sector
1211 agencies. *Government Information Quarterly*, 43(2):102133.

1212 Simplicio, A., Vinagre, G., Ramos, M. M., Tavares, D., Ferreira, R., et al. (2026). AMALIA
1213 technical report: A fully open source large language model for European Portuguese.

1214 UNCTAD (2024). UNCTAD statistical classifications — june 2024 update. Technical report,
1215 UN Trade and Development.

1216 VanderWeele, T. J. and Ding, P. (2017). Sensitivity analysis in observational research: introdu-
1217 cing the E-value. *Annals of Internal Medicine*, 167(4):268–274.

1218 Vieira, I., Calvo, I., Paulo, I., Furtado, J., Ferreira, R., et al. (2026). ALBA: A European
1219 Portuguese benchmark for evaluating language and linguistic dimensions in generative LLMs.
1220 *arXiv preprint arXiv:2603.26516*.

1221 White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith,
1222 J., and Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with
1223 ChatGPT. *arXiv preprint arXiv:2302.11382*.

1224 World Bank Group (2025). World Bank Country and Lending Groups — FY26 Classification.
1225 Technical report, The World Bank.

1226 World Health Organization (2021). WHO global air quality guidelines: Particulate matter
1227 (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Techni-
1228 cal report, World Health Organization, Geneva.

1229 World Health Organization (2026). Ambient air pollution attributable deaths (indicator
1230 AIR_41). Global Health Observatory. Reference year 2021, both sexes. Accessed 2026-08-
1231 19.

1232 xAI (2026). Generate text: System prompts. Grok API Documentation. Vendor documentation
1233 whose standard example initialises every conversation with a role-assigning system prompt.
1234 Accessed 2026-08-25.

1235 Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., and Raffel,
1236 C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings*
1237 *of the 2021 Conference of the North American Chapter of the Association for Computational*
1238 *Linguistics: Human Language Technologies (NAACL-HLT)*, pages 483–498.

1239 Zheng, M., Pei, J., Logeswaran, L., Lee, M., and Jurgens, D. (2024). When “a helpful assistant” is
1240 not really helpful: Personas in system prompts do not improve performances of large language
1241 models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages
1242 15126–15154.