

1 De quem é a regulação que o modelo conhece?
2 Confiabilidade da informação regulatória recuperada por LLMs
3 para a gestão ambiental pública em 25 países

4 Lucas Rover^{1,*}
Vitor de Melo Dominski²
Anibal Tavares de Azevedo³
Eduardo Tadeu Bacalhau⁴
Yara de Souza Tadano¹

¹ Universidade Tecnológica Federal do Paraná (UTFPR), Brasil

² Faculdade Descomplica, Brasil

³ Universidade Estadual de Campinas (Unicamp), Brasil

⁴ Universidade Federal do Paraná (UFPR), Brasil

* Autor correspondente: lucasrover@alunos.utfpr.edu.br

ORCID: L.R. 0000-0001-6641-9224 · V.M.D. 0009-0001-0209-9089 · A.T.A. 0000-0003-1678-7795 · E.T.B. 0000-0002-39

5 25 de agosto de 2026

6 **Resumo**

7 Administrações públicas consultam cada vez mais modelos de linguagem de grande porte
8 sobre as normas que lhes cabe aplicar, mas não existe método estabelecido para auditar
9 se essas respostas correspondem ao texto vinculante. Contribuímos com esse protocolo e
10 relatamos o que ele encontra. Ele pontua respostas contra registros oficiais, decidindo por
11 código sempre que a resposta correta é um valor publicado e por um painel de juízes de três
12 fornecedores nos demais casos, e o aplicamos à regulação da poluição do ar em 25 países, 14
13 configurações de acesso, cinco tipos de tarefa e quatro idiomas (9.251 respostas), avaliando
14 cada modelo *como servido*. As três mitigações disponíveis a um órgão público falham, e a
15 mais intuitiva causa dano: perguntar no idioma do próprio país *reduz* a acurácia em 4.8
16 pontos percentuais (Wilcoxon $p = 3 \times 10^{-15}$) e torna o modelo 17.7 pontos menos propenso
17 a devolver um valor verificável contra o registro; a persona de gestor público não estreita
18 a lacuna ($p = 0.27$); e um modelo com ajuste regional fica em último entre os catorze. A
19 acurácia também despenca justamente na recuperação do valor vinculante: 0.37, contra 0.62
20 para síntese. Uma lacuna Norte/Sul persiste (+5.1 pp, permutação $p = 0.020$), concentrada
21 onde a resposta depende de um fato nacional — no padrão nacional, a chance do Sul Global
22 é 0.22 da chance do Norte. O escopo é deliberadamente delimitado: medimos concordância
23 com a regulação publicada em um domínio, não capacidade geral do modelo, e identificamos
24 o canal de corpus apenas onde o desenho tem resolução. O protocolo se transfere a qualquer
25 domínio regulado cuja resposta correta seja publicada.

Palavras-chave: auditoria de algoritmos; viés geográfico; viés multilíngue; governo digital; Sul Global

1 Introdução

Modelos de linguagem de grande porte passaram de curiosidade de pesquisa a infraestrutura de trabalho da administração pública em menos de cinco anos: um levantamento da OCDE sobre funções centrais de governo documenta a adoção de IA generativa na formulação de políticas e na prestação de serviços, incluindo implantações que ajudam servidores a buscar normas e redigir sínteses técnicas (OECD, 2024). A política de poluição do ar é um domínio em que isso carrega consequências diretas de saúde pública. O material particulado fino é o principal fator de risco ambiental para mortalidade prematura (GBD 2019 Risk Factors Collaborators, 2020; World Health Organization, 2021), e a carga recai desproporcionalmente sobre o Sul Global. Quando um gestor ambiental público em São Paulo, Lagos ou Jacarta pergunta a um LLM sobre um padrão de qualidade do ar, um prazo de atendimento ou a evidência por trás de uma intervenção, uma resposta imprecisa não é um erro benigno. Ela pode se propagar para um parecer regulatório, uma decisão de compra ou uma resposta emergencial durante um episódio de poluição.

Este artigo pergunta se os LLMs servem à política de poluição do ar do Sul Global com a mesma confiabilidade com que servem ao Norte Global, e se a forma de enquadrar a consulta muda a resposta. Ambas as premissas estão estabelecidas. O viés factual geográfico é real e mensurável: as taxas de erro são $1,5\times$ maiores para países da África Subsaariana do que para norte-americanos em 20 modelos (Moayeri et al., 2024), avaliações zero-shot correlacionam-se com nível de renda até $\rho = 0,70$ (Manvi et al., 2024), e os modelos privilegiam sistematicamente afirmações sobre o Norte Global (Mirza et al., 2024). E a assimetria linguística por trás disso é estrutural: os idiomas da maioria dos países do Sul Global ficam nas classes sub-atendidas da hierarquia de recursos (Joshi et al., 2020), o que é a explicação dominante para o viés geográfico a jusante (Bender et al., 2021) e reproduz a infraestrutura epistêmica desigual que a literatura decolonial analisa para sistemas de IA (Mohamed et al., 2020).

Três lacunas permanecem abertas para um domínio como este, e elas organizam o estudo. Nenhum benchmark tem por alvo a informação regulatória com gabarito oficial: as avaliações existentes usam recuperação de indicadores do Banco Mundial, avaliações subjetivas, checagem jornalística ou conhecimento cultural cotidiano, e nenhuma delas mede as tarefas que um gestor de fato delega — declarar um padrão vinculante, recuperar uma concentração oficialmente medida, sintetizar a evidência de carga de saúde, identificar instrumentos legais e órgãos executores, recomendar uma resposta operacional. O enquadramento por persona não é examinado como alavanca experimental, embora profissionais rotineiramente anteponham um papel e os próprios fornecedores o recomendem (Seção 2); se ele *reduz* a lacuna, ao orientar para respostas em conformidade com a norma, ou a *amplifica*, ao convidar à fabricação confiante, não foi testado em desenho pré-especificado. E o mecanismo de representação no corpus é afirmado em vez de medido contra confundidores, e raramente separado em seus dois canais — tamanho do *corpus da língua* (Xue et al., 2021; Abadji et al., 2022) contra a amplitude da *cobertura do país* —,

distinção que importa aqui porque a lacuna geográfica é medida em inglês.

Objetivos e escopo

O estudo tem três objetivos delimitados. *Primeiro, estabelecer um protocolo de auditoria de informação regulatória*: o objeto é a concordância entre a resposta de um modelo e o valor publicado no registro oficial, para tarefas que uma agência ambiental de fato delega — não a capacidade geral do modelo, a qualidade do raciocínio ou a utilidade para qualquer outro fim. O protocolo é a contribuição que se transfere; o domínio é onde o demonstramos. *Segundo, testar as mitigações disponíveis a uma administração*: um órgão público diante de respostas ruins sobre o próprio país pode realisticamente declarar o papel oficial no prompt, perguntar no idioma nacional ou contratar um modelo com ajuste regional, e testamos os três como fatores do desenho em vez de discuti-los. Não testamos geração aumentada por recuperação, ajuste fino ou verificação humana no circuito, que exigem capacidade que a maior parte das agências da nossa amostra do Sul Global não tem. *Terceiro, localizar onde a confiabilidade difere e, até onde o desenho permite, por quê*: testamos a explicação de representação no corpus no nível em que a medida tem resolução, e não reivindicamos identificação causal.

Ao longo de todo o estudo, a unidade de análise é o modelo *como servido* — pesos, fornecedor e infraestrutura de serviço alcançados por um endpoint fixado —, porque é com essa pilha que o gestor público interage e qualquer lacuna medida é propriedade dela. Hipóteses, marco amostral e plano de análise foram fixados antes da coleta (Nosek et al., 2018) para 15 países e depois estendidos a 25; o plano nunca foi depositado publicamente, de modo que não reivindicamos pré-registro, e o estudo é relatado como exploratório.

Contribuições deste trabalho

1. *Um protocolo de auditoria de informação regulatória, não um benchmark de trivialidades.*

A pergunta que uma administração enfrenta não é se o modelo escreve bem sobre política, mas se o valor que ele devolve corresponde ao registro oficial. Construímos cinco tipos de tarefa a partir do trabalho cotidiano de uma agência ambiental (Tabela 1), cada uma chaveada a uma fonte oficial, de modo que a correção é adjudicável em vez de matéria de impressão de especialista. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada.

2. *As três mitigações de localização a que as agências recorrem, testadas em vez de presumidas — e todas as três falham.*

Enquadramento por persona, prompt em idioma nativo e modelo com ajuste regional são, cada um, uma decisão de compra ou de fluxo de trabalho, e cada um circula como sabedoria recebida. Nenhum funciona, e o que um gestor tem mais chance de tentar primeiro causa dano ativo: perguntar no idioma do próprio país reduz a acurácia em 4.8 pontos percentuais, de forma mais acentuada para o idioma de corpus mais escasso.

3. *Um desenho que separa quem é mal servido de por quê.* Os países são estratificados em eixos independentes — Norte/Sul da UNCTAD (operacionalizando a colonialidade (Mohamed et al., 2020)), a taxonomia de recursos linguísticos de Joshi (Joshi et al., 2020) e desenvolvimento —, de modo que explicações geográficas, linguísticas e econômicas pos-

105 sam ser distinguidas em vez de confundidas. Entre países, cobertura e desenvolvimento são
106 colineares e não podem ser separados; eles se separam quando a unidade de variação passa
107 a ser a tarefa dentro de um país, o que identifica a cobertura do país como canal operante.
108 Registramos também que o proxy de corpus pré-especificado é defeituoso de um modo que
109 vale conhecer para quem já o usou: ele atribui a Wikipédia inglesa a todo país da amostra
110 que tenha o inglês como idioma oficial, indexando história colonial em vez de tamanho de
111 corpus.

- 112 4. *Gabarito adjudicado por código, e o que isso muda.* Onde a resposta correta é um número
113 em registro oficial, o veredito é computado contra esse registro em vez de delegado a um
114 modelo de linguagem. Sobre as mesmas respostas, reconstruir duas chaves de tarefa a
115 partir de registros oficiais e passar a comparação para o código reduziu o gradiente de
116 desenvolvimento de $\rho = 0.51$ para $\rho = 0.37$ e mais que dobrou a penalidade do idioma
117 nativo. Nesta literatura, a chave de gabarito, e não o tamanho amostral, é a restrição
118 vinculante.
- 119 5. *Recursos abertos.* Protocolo, prompts, registros de gabarito com suas fontes oficiais, código
120 de análise e o log de desvios são liberados sob CC-BY-4.0 e MIT, com pipeline de reprodução
121 em um comando.

122 2 Trabalhos Relacionados

123 A literatura prévia corre por quatro fios: a medição do viés factual geográfico, extensões multi-
124 língues e culturais, tentativas de mitigação, e o uso de LLMs em contextos de decisão de política
125 e saúde.

126 2.1 Viés factual geográfico e extensões multilíngues

127 [Manvi et al. \(2024\)](#) estabeleceram que LLMs de fronteira carregam vieses sistemáticos contra
128 regiões de condições socioeconômicas mais baixas, com correlações de até 0.70 entre avaliações
129 geradas pelo modelo e um proxy dessas condições — ainda que o espaço de desfecho sejam
130 avaliações subjetivas, o que deixa em aberto se o mesmo viés aparece na recuperação objetiva de
131 fatos regulatórios. [Moayeri et al. \(2024\)](#) quantificaram a recuperação factual contra indicadores
132 do Banco Mundial em 20 LLMs, documentando erro relativo absoluto 1,5× maior para a África
133 Subsaariana do que para a América do Norte; seu desenho é limitado pelo espaço de indicadores
134 macroeconômicos, enquanto um gestor ambiental faz perguntas mais estreitas e específicas de
135 fonte, cujo gabarito vive em conselhos ambientais e agências de monitoramento, e não em uma
136 única base agregada. [Mirza et al. \(2024\)](#) mostraram que versões mais novas do GPT-4 não
137 melhoram monotonicamente e que o privilégio de afirmações sobre o Norte Global persiste.

138 Do lado multilíngue, [Myung et al. \(2024\)](#) cobriram 16 países e 13 idiomas em conhecimento
139 cultural cotidiano, constatando que os LLMs têm melhor desempenho nos idiomas nativos de cul-
140 turas de alto recurso e pior nos de baixo recurso — achado que motiva H2 e se conecta à hierarquia
141 de recursos de [Joshi et al. \(2020\)](#). Benchmarks regionais proliferaram: BRouterbs ([Almeida et al., 2025b](#)),
142 TiEBE ([Almeida et al., 2025c](#)), ALBA ([Vieira et al., 2026](#)) e AMALIA ([Simplicio et al.,](#)

2026) documentam falhas concretas em tarefas culturalmente ancoradas, mas não tratam do uso aplicado em política, e o trabalho sobre construção de corpus em português (Almeida et al., 2025a) evidencia como os snapshots do Common Crawl sub-representam conteúdo lusófono — a assimetria de corpus que H4 testa.

Esses estudos estabelecem que o fenômeno existe e é mensurável. Nenhum isola um domínio aplicado único com gabarito oficial verificável, e nenhum trata o enquadramento do prompt como fator manipulável.

2.2 Mitigação, persona e condicionamento por papel

Opuszko and Böhm (2026) constataram que raciocínio ajuda em agregado mas não elimina disparidades regionais, e Kerche et al. (2026) propuseram uma tipologia de base territorial situando o viés geográfico em um panorama sociotécnico mais amplo. Ambos são conceituais e agregados.

O condicionamento por papel não é uma prática folclórica, mas o que os fornecedores instruem seus próprios usuários a fazer: a Anthropic documenta a definição de papel no prompt de sistema (Anthropic, 2026), o guia da OpenAI abre a estrutura de mensagem recomendada com um bloco de identidade (OpenAI, 2026), e o padrão está catalogado na literatura de prompting (White et al., 2023). A evidência sistemática sobre se isso ajuda é desalentadora: em quatro famílias de LLM e 2.410 perguntas factuais, personas de especialista não melhoraram a acurácia frente a um controle sem persona e a *reduziram* ligeiramente em 162 papéis (Zheng et al., 2024), e uma replicação independente concorda (Basil et al., 2025). Se o condicionamento por persona ajuda ou prejudica a confiabilidade factual em domínios de alto risco é, portanto, questão em aberto e, até onde sabemos, não testada para equidade geográfica. Tratamos persona como fator experimental pré-especificado e testamos tanto a hipótese de Conformidade Normativa (a persona reduz a lacuna) quanto a de Vácuo de Persona (a persona a amplifica).

2.3 LLMs em política, saúde e na administração

Le Coz et al. (2025) avaliaram recomendações de política de LLMs para situação de rua em quatro cidades, encontrando “rigidez cega ao contexto”, em que os modelos aplicam heurísticas internas estáveis mal calibradas às realidades locais e se alinham mais ao juízo de especialistas do Norte Global — um domínio e um tipo de tarefa, que generalizamos para cinco tipos abrangendo recuperação, síntese e recomendação. Em saúde, Kozlakidis et al. (2026) argumentam que alucinações carregam risco agudo em ambientes regulatórios com capacidade técnica limitada, onde o descompasso linguístico e cultural aumenta o erro — risco que se encontra com a carga de mortalidade documentada pelas estimativas do Global Burden of Disease (GBD 2019 Risk Factors Collaborators, 2020).

A questão da implantação já não é hipotética. Kim (2026) estima efeitos de produtividade burocrática da IA generativa de forma quase-experimental, e Robinson (2026) documenta que escolher qual modelo uma agência executa é hoje uma decisão explícita de compra entre opções de pesos abertos e hospedadas por fornecedor. Nossos dois achados no nível do modelo falam diretamente a ela: os modelos de fronteira abertamente disponíveis ficam atrás dos fechados, e o modelo português com ajuste regional é o mais fraco dos catorze, de modo que as duas esco-

183 custam acurácia. Dois outros fios enquadram por que uma resposta errada importa administrati-
184 vamente, e não apenas tecnicamente: [Choroszewicz \(2026\)](#) mostra que ferramentas de apoio por
185 IA generativa posicionam profissionais de linha de frente como “zonas morais de amassamento”,
186 absorvendo responsabilidade por falhas originadas a montante — a posição de um servidor que
187 protocola um parecer citando um limite de emissão revogado — e [Cordella and Gualdi \(2024\)](#),
188 analisando a intervenção da Itália sobre o ChatGPT, argumentam que arcabouços regulatórios
189 neutros quanto à tecnologia não alcançam os danos específicos que esses sistemas produzem, o
190 que deixa a verificação no ponto de uso como o controle operante. A literatura sobre recepção
191 é correspondentemente desenvolvida: [Aoki et al. \(2024\)](#) testam se o tipo de explicação muda a
192 percepção de acurácia, justiça e confiabilidade entre os afetados.

193 O que nada disso estabelece é se a resposta subjacente está *correta*, e se a correção se distribui
194 igualmente entre os Estados que dela dependem. Confiabilidade percebida e acurácia medida
195 são quantidades diferentes, e um sistema pode ser bem explicado, bem governado, bem recebido
196 e errado. É essa a lacuna que este estudo aborda, em um domínio em que a resposta correta é
197 publicada em registro oficial e pode ser conferida.

198 2.4 Posicionamento do presente trabalho

199 Nosso desenho difere do trabalho prévio em quatro pontos: (i) um domínio aplicado único de alto
200 risco com gabarito oficial verificável, em vez de trivialidades numéricas ou conhecimento cultural;
201 (ii) persona como fator intrassujeito pré-especificado, em vez de escolha de enquadramento não
202 controlada; (iii) amostragem de países orientada por teoria em eixos independentes (colonialidade
203 da UNCTAD, recurso linguístico de Joshi, desenvolvimento), em vez de conveniência regional; e
204 (iv) um teste explícito de mecanismo de representação no corpus com análise de sensibilidade.
205 Nenhum estudo prévio combina um domínio regulado de saúde pública, uma manipulação de
206 persona e um teste de mecanismo pré-especificado.

207 3 Métodos

208 3.1 Desenho da pesquisa

209 Especificamos um experimento de benchmark pré-especificado, fatorial e multipaís, quantificando
210 viés geográfico e modulado por persona em 14 modelos de linguagem de grande porte em ta-
211 refas de política de poluição do ar. O desenho pré-especificado cruza 15 países (estratificados
212 em três eixos teoricamente fundamentados), 14 LLMs abrangendo cinco camadas de acesso, um
213 domínio, 5 tipos de tarefa e 2 condições de persona, com 2 replicações estocásticas por célula;
214 uma extensão post hoc (Seção 3.3) amplia a amostra para 25 países. O conjunto de estímulos
215 cruza as cinco tarefas e as duas personas de cada país em inglês, mais uma versão em idioma
216 nativo dentro do país para os nove países com idioma nativo alvo, pontuado no composto $[0, 1]$.
217 O protocolo fixa, antes da coleta, as hipóteses, os modelos primários, o protocolo de persona, os
218 critérios de exclusão e as correções para múltiplas comparações. Uma coleta apenas do Brasil,
219 executada sob um desenho anterior de três domínios, é reclassificada como piloto estendido e rela-
220 tada separadamente; ela informou a calibração dos prompts, mas não contribui com observações
221 confirmatórias.

3.2 Seleção de países

Os países foram selecionados por amostragem teórica (Patton, 2015) triangulada em três classificações independentes: a divisão Norte/Sul Global da UNCTAD (UNCTAD, 2024), que operacionaliza o arcabouço da colonialidade do saber que motiva o estudo (Mohamed et al., 2020); a taxonomia de seis classes de representação de recursos linguísticos de Joshi et al. (Joshi et al., 2020); e os grupos de renda do Banco Mundial (World Bank Group, 2025).

A amostra pré-especificada de 15 — Brasil, México, Argentina, Peru; Nigéria, África do Sul, Quênia, Egito; Índia, Indonésia, Bangladesh, Filipinas; e Estados Unidos, Alemanha, Japão como referências do Norte Global — cobre quatro regiões do mundo e quatro grupos de renda. O eixo de recursos linguísticos revelou-se muito menos diferenciado do que se pretendia: os idiomas oficiais dominantes caem em apenas três classes de Joshi, doze dos quinze compartilhando a Classe 5, e estender para 25 não ajuda, já que dezoito são Classe 5. Isso é propriedade do mundo, e não do nosso sorteio, porque os idiomas oficiais da maioria dos Estados são eles próprios de alto recurso; mas significa que o eixo linguístico tem variância pequena demais para ser separado dos demais, e tratamos os resultados de Joshi de acordo (Seção 4.6). Países com governança estatística comprometida ou sem padrão nacional publicamente recuperável foram excluídos; Oceania e idiomas de Classe 0 de Joshi não estão representados, o que registramos como limitação de escopo.

3.3 Ampliação da amostra após a análise pré-especificada

Após a análise pré-especificada de 15 países, e *relatado aqui como extensão post hoc e não como parte do protocolo travado*, a amostra foi ampliada para 25 países sob procedimentos idênticos, para aumentar o poder dos testes de gradiente e de mecanismo e para multiplicar os pares de idioma dentro do país disponíveis para H2. Como a extensão seguiu a observação dos resultados iniciais, todo efeito na amostra de 25 países é relatado ao lado de sua contraparte pré-especificada de 15, nenhuma conclusão pré-especificada é revisada apenas com base na extensão, e a ampliação é tratada como checagem de poder e robustez, não como novo teste confirmatório. Angola, como Nigéria e Argentina, *não* tem padrão nacional de PM_{2,5}, acrescentando casos sem padrão nos quais um modelo fiel deve se recusar a declarar um limiar inexistente. As dez adições, seus papéis e as duas variantes extras de pergunta geradas por (país, tarefa) para os pares de H2 estão detalhadas no suplemento.

3.4 Covariáveis de país

O Índice de Desenvolvimento Humano (PNUD 2023–24) e o PIB per capita indexam a posição de desenvolvimento e entram na análise de mecanismo como covariáveis de ajuste. As exposições de representação no corpus se dividem segundo uma distinção que a análise de mecanismo torna explícita, porque os dois canais se aplicam a efeitos diferentes. As medidas de *corpus da língua* quantificam quanto texto de pré-treinamento existe *em* um idioma e são o mecanismo candidato para a penalidade de idioma nativo: contagem de tokens do mC4 (Xue et al., 2021), tamanho do corpus OSCAR-2301 (Abadji et al., 2022) e a classe de Joshi (Joshi et al., 2020). As medidas de *corpus do país* quantificam quanto o corpus enciclopédico fala *sobre* um país, independentemente

do idioma, e são o mecanismo candidato para a lacuna geográfica: tamanho do artigo da Wikipédia inglesa, número de edições linguísticas com artigo sobre o país e número de declarações do Wikidata sobre a entidade do país.

As duas famílias não são intercambiáveis. Como a lacuna geográfica é medida *em inglês*, com o idioma mantido constante entre países, uma lacuna Norte/Sul residual não pode ser efeito de corpus da língua. Um ponto merece ser dito de forma direta, porque os papéis se confundem com facilidade: a Wikipédia e o Wikidata nunca são gabarito aqui, eles são a variável *explicativa*. Aquilo contra o que uma resposta é pontuada é sempre um registro oficial (Seção 3.9); tivéssemos pontuado contra uma enciclopédia, o estudo mediria concordância com uma enciclopédia, que não é a pergunta que uma administração pública enfrenta.

3.5 Seleção de modelos

Catorze LLMs foram avaliados em cinco camadas de acesso, abrangendo cerca de duas ordens de magnitude em contagem de parâmetros e quatro geografias de dados de treinamento (Estados Unidos, China, Europa, Brasil): fronteira de pesos abertos (5), pesos abertos médios (3) e pequenos ou regionais (2) executados localmente sob tags fixadas, e fechados acessíveis (2) e fechados de fronteira (1) via APIs oficiais. A camada pequena inclui um modelo ajustado por instrução em português brasileiro (Cabra-Mistral 7B v3), testado contra um modelo aberto de treinamento global de escala equivalente para H3. Cada modelo foi consultado com tag fixada idêntica ao longo da janela de coleta. O roster completo está na Tabela S1 do suplemento.

Comparamos *modelos como servidos* por uma pilha de acesso fixa, e não pesos idealizados. Infraestrutura do provedor, configuração de serviço e camada de API fazem parte do que cada rótulo denota, e uma lacuna residual poderia em princípio refletir a pilha em vez dos pesos; mantemos isso constante fixando tags de versão e a configuração de máximo determinismo disponível por provedor ao longo de uma janela fixa.

3.6 Domínio e taxonomia de tarefas

O domínio único é a política de poluição do ar, escolhido porque se ancora em gabarito oficialmente publicado e verificável e se mapeia a atividades concretas de decisão de um gestor ambiental público. As cinco tarefas não foram escritas como um questionário genérico de conhecimento: cada uma corresponde a uma pergunta que um gestor tem de responder no curso do trabalho ordinário, e cada uma foi redigida de modo que uma resposta errada carregasse consequência administrativa, e não apenas a perda de um ponto. A Tabela 1 as traz com o prompt tal como foi emitido aos modelos, usando o Brasil como instância trabalhada, ao lado da decisão que cada uma representa.

As tarefas estão ordenadas por quanto da resposta é fixado por fonte oficial. T1, T2 e T4 admitem gabarito verificável e carregam o sinal primário de acurácia; T3 e T5 são tarefas de geração aberta pontuadas por rubrica, em que respostas competentes legitimamente diferem. É essa ordenação que torna a dimensão de tarefa informativa em vez de decorativa: ela permite perguntar se os modelos falham de maneira uniforme ou falham especificamente onde é preciso recuperar um valor nacional publicado, que é a pergunta sobre a qual os resultados se apoiam. O mapeamento de país por tarefa das classes de fonte oficial e do estatuto de verificabilidade está

Tabela 1: As cinco tarefas, o prompt como emitido e a decisão que cada uma representa. Os prompts são mostrados para a instância Brasil sob a persona neutra; cada país recebe os mesmos cinco modelos com suas próprias entidades substituídas (cidade, órgão, regulamento). Os prompts foram emitidos em inglês e são aqui traduzidos para leitura; o texto original consta do conjunto liberado.

Tarefa	Prompt emitido, em tradução (Brasil)	Decisão que representa
T1 Padrão técnico	“Qual é o padrão nacional vigente de média anual de qualidade do ar para PM _{2,5} no Brasil? Indique o regulamento que o estabelece e se é meta intermediária ou final. Limite-se a 1–3 frases.”	Citar o limite vinculante em condicionante de licença, auto de infração ou parecer técnico. O valor errado vicia o ato.
T2 Dado factual local	“Segundo a agência ambiental nacional ou subnacional, qual foi a concentração média anual de PM _{2,5} em São Paulo, Brasil, no ano mais recente reportado? Forneça o valor em $\mu\text{g}/\text{m}^3$, a estação ou rede de referência e a fonte.”	Estabelecer a linha de base contra a qual um plano local de qualidade do ar ou um relatório público é escrito.
T3 Síntese de evidência em saúde	“Resuma a evidência epidemiológica sobre mortalidade atribuível à exposição ambiental a PM _{2,5} no Brasil na última década. Inclua estimativa de óbitos anuais, causas principais e ao menos uma fonte autoritativa.”	Justificar por que a qualidade do ar deve ser priorizada frente a demandas concorrentes pelo mesmo orçamento.
T4 Instrumentos de política	“Liste os principais programas nacionais ou instrumentos legais de monitoramento e controle da poluição do ar ambiente no Brasil, com o órgão executor de cada um.”	Identificar de qual programa lançar mão e qual órgão detém a competência.
T5 Recomendação aplicada	“Uma região metropolitana do Brasil enfrenta episódio previsto com PM _{2,5} projetado para exceder $75 \mu\text{g}/\text{m}^3$ em 24 horas. Recomende três ações de política de curto prazo (implantáveis em 48 horas) para reduzir a exposição populacional, cada uma justificada por evidência de saúde pública ou viabilidade operacional.”	Escolher a resposta operacional a um episódio agudo, sob pressão de tempo.

no registro de gabarito (Seção 3.9), e o conjunto completo de prompts dos 25 países é liberado com os dados.

3.7 Manipulação de persona

A persona é um fator dentro do prompt com dois níveis, e a manipulação não é arbitrária: atribuir um papel ao modelo é a prática que os próprios fornecedores documentam e recomendam (Seção 2). A condição neutra apresenta a consulta como pedido simples de informação; a condição `public_manager_env` antepõe um enquadramento de papel fixo identificando quem pergunta como autoridade municipal ou regional de gestão ambiental, mantendo a pergunta substantiva idêntica. Para a T1 do Brasil, o enquadramento é a frase única “*Sou o gestor ambiental municipal de São Paulo, Brasil, e preciso informar tomadores de decisão.*” Um único modelo é aplicado de forma uniforme entre países e tarefas, traduzido quando o idioma do prompt não é o inglês, de modo que qualquer diferença entre condições seja atribuível ao enquadramento e não à redação da pergunta. A ordem das personas dentro de cada célula é aleatorizada, e uma checagem de manipulação verifica se o enquadramento é reconhecido na resposta. Redação exata, procedimento de tradução e codificação da checagem estão no suplemento.

Um detalhe de implementação importa para a leitura do resultado. Toda requisição neste estudo é enviada como turno único de usuário, sem prompt de sistema, de modo que o enquadramento de papel é anteposto à mensagem do usuário em vez de instalado como instrução de sistema, que é onde os guias dos fornecedores o colocam. A escolha é deliberada: a via do prompt de sistema exige acesso por API e um desenvolvedor para configurá-la, enquanto os servidores

públicos cujas decisões motivam este estudo alcançam esses modelos pela interface de conversa de consumo, na qual o único canal disponível é a mensagem que digitam. Testamos, portanto, o enquadramento de papel tal como o setor de fato o executa, e a Seção 5.7 declara o que permanece não testado. A persona é a base de H6.

3.8 Construção e validação dos prompts

Os prompts foram redigidos para o domínio pela equipe de pesquisa com supervisão de domínio e validados contra o registro de gabarito antes de entrar no conjunto confirmatório de estímulos, com a exigência de que toda afirmação factual de uma entrada do registro resolvesse para uma URL de fonte oficial ou um DOI revisado por pares antes que o prompt correspondente fosse admitido. O plano de análise previa um piloto de 50 prompts pontuado por dois avaliadores humanos independentes ($\alpha \geq 0.70$) antes de escalar o desenho. *Esse piloto não foi rodado*, e não existe α de avaliador para este estudo; a confiabilidade da rubrica é evidenciada, em vez disso, sobre os próprios dados confirmatórios, por um painel de três fornecedores sobre cada item que exigiu juiz (Seção 4.11), que devolve $\alpha = 0.527$. Relatamos isso como desvio do plano, e não como limiar atingido.

Todos os prompts foram redigidos em inglês e, para um subconjunto estratificado de países, adicionalmente em um idioma nativo relevante (Seção S3 do suplemento). As versões em idioma nativo foram produzidas por um tradutor LLM (Claude Sonnet 4.6) instruído a preservar o significado, o enquadramento de persona, nomes próprios e siglas, com o gabarito factual mantido em inglês, já que o valor-alvo é invariante ao idioma. Não empregamos tradutores humanos nativos, o que permanece uma limitação (Seção 5.7); auditamos, porém, as versões após o fato, retrotraduzindo todos os 90 prompts nativos com um modelo diferente e tendo dois outros modelos comparando cada um contra o original em inglês (Seção 4.4).

3.9 Gabarito e registro de gabarito

O gabarito para as tarefas verificáveis foi extraído de fontes oficiais de registro: padrões nacionais de qualidade do ar e os órgãos que os emitem (T1), relatórios de monitoramento de agências ambientais (T2), e programas federais de política com seus órgãos executores e instrumentos legais (T4). Para T3, a referência é um conjunto curado de estudos epidemiológicos revisados por pares com DOIs resolvíveis, e não um número único.

Como a validade do gradiente geográfico depende de o gabarito estar igualmente disponível e igualmente verificável entre países, construímos um registro por país que anota, para cada par (país, tarefa), a classe de fonte oficial equivalente, a URL resolvível, o valor de referência ou a chave de rubrica, a data de referência, o validador humano e uma marca de validação. As entradas são versionadas por data de acesso, URL de fonte e um hash SHA-256 do documento recuperado. Entradas cuja fonte oficial é indisponível ou não equivalente para um país são sinalizadas e excluídas da comparação primária daquela célula, de modo que gabarito ausente nunca é pontuado como erro do modelo. O desenho do registro e os critérios de equivalência entre países estão no suplemento.

3.10 Coleta de dados

As chamadas foram executadas a temperatura 0.3 com sementes determinísticas quando disponíveis, com 2 replicações por combinação de prompt, modelo e persona, dentro de uma janela fixa para minimizar confundimento por atualização de modelo; as acurácias relatadas são, portanto, estimativas pontuais no tempo. Toda resposta foi armazenada com metadados completos da requisição — tag fixada, timestamp, contagem de tokens, motivo de término, condição de persona — sob checksums SHA-256. Gates de qualidade excluíram respostas truncadas e respostas em idioma divergente do da requisição, ambas retidas e analisadas separadamente.

A cobertura por célula não é uniforme: endpoints gratuitos e com limite de taxa devolveram menos respostas admissíveis do que as APIs medidas, de modo que o N pontuado varia de cerca de 300 a 780 por modelo. Relatamos o N realizado de cada modelo ao lado de sua pontuação (Tabela 2) em vez de descartar silenciosamente células sub-cobertas, e a matriz completa de cobertura, com as razões de cota e exclusão de cada falta, está no suplemento.

3.11 Medidas

A pontuação atribui a cada tarefa o instrumento mais confiável que ela admite.

Onde a resposta é um número em registro oficial, o código decide. Para T2 e T3, o valor devolvido é extraído e comparado com a faixa autorizada por um pontuador determinístico, com guardas de plausibilidade que rejeitam extrações implausíveis — um ano de quatro dígitos lido como contagem de óbitos, uma população nacional lida como cifra de mortalidade. Comparar um valor com uma faixa é exato, e um modelo de linguagem a quem se pede a mesma aritmética só consegue reproduzi-la com ruído. O código resolve 62.5% de T2 e 83.6% de T3.

Onde se exige julgamento, um painel de três fornecedores decide pela média. O resíduo de T2 e T3, com toda a T4, é pontuado por Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3, escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infle a concordância aparente. T1 e T5 mantêm as pontuações originais de juiz único. A confiabilidade é relatada como α de Krippendorff, o ICC(2, 1) de juiz único e, como quantidade operativa, o ICC(2, 3) da média do painel, computados sobre cada item que o painel pontuou em vez de sobre um subconjunto de calibração — uma correlação intraclassa que responde quanto uma nota se moveria se outro juiz a tivesse produzido. Um membro do painel (DeepSeek-V3) é também um modelo avaliado, e testamos o autofavorecimento diretamente. Nenhuma camada humana de padrão-ouro foi coletada; o gabarito está ancorado, em vez disso, em fontes oficiais primárias (Seção 3.9).

O composto primário combina cinco subcomponentes pré-especificados (Seção S6 do suplemento), cada um normalizado para $[0, 1]$: acurácia factual contra a entrada do registro (peso 0.30), completude contextual (0.25), qualidade de citação (0.15), calibração (0.15) e ausência de alucinação (0.15). Cada efeito principal é recomputado sob pesos iguais e sob uma ponderação derivada por ACP, e uma conclusão só conta como robusta se sua direção for estável nas três. O composto é computado por célula (país, modelo, persona) para viabilizar o teste de diferença em diferenças de H6.

3.12 Estratégia analítica

Os três testes primários são pré-especificados como uma única família (F1) e corrigidos em conjunto por Bonferroni-Holm. Os testes secundários (F2) são relatados sem ajuste dentro da família, e os declarados exploratórios (F3) usam FDR de Benjamini-Hochberg a $q = 0.10$ (Benjamini and Hochberg, 1995).

H1 (gradiente geográfico, primário) regride a acurácia composta média por país sobre o gradiente Joshi/IDH via ρ de Spearman, pré-especificado unilateral em $\rho \geq 0.55$, com um teste de tendência de Mann-Kendall como complemento obrigatório de não monotonicidade. *H4 (mecanismo de corpus, primário)* relaciona representação no corpus à acurácia por ρ de Spearman parcial ajustando para IDH e log do PIB per capita, com contagens da Wikipédia como proxy pré-especificado. *H6 (persona, primário)* é uma diferença em diferenças no nível do país, sustentada se a condição de persona reduzir a lacuna do Sul Global em ao menos 0.05 no composto, com inferência por teste de permutação de 5.000 iterações. *H3 (secundária)* é um contraste unilateral de Mann-Whitney (δ de Cliff). *H2 e H5 (exploratórias)* são relatadas descritivamente sob correção F3.

Três análises transversais corroboram a lacuna de camada: um modelo linear misto gaussiano (MixedLM do `statsmodels`, REML) com interceptos aleatórios cruzados de país e modelo, ajustando para IDH centrado; uma reestimação hierárquica bayesiana (`pymc` (Abril-Pla et al., 2023)); e E-values para robustez a confundimento não medido (VanderWeele and Ding, 2017). O mecanismo de corpus é sondado com um modelo exploratório de mediação (`semopy` (Igolkina and Meshcheryakov, 2020)), e a manipulação de persona com uma checagem de reconhecimento do enquadramento. As análises de robustez pré-especificadas aparecem na Seção 4.12.

3.13 Protocolo do estudo e ética

O conjunto analítico de dados, após os gates de qualidade mas antes do ajuste dos modelos, é congelado e hashado, de modo que a análise confirmatória possa ser auditada contra a especificação travada em vez de aceita por confiança. Os termos de liberação estão declarados ao fim do artigo.

Nenhum dado pessoal de usuários finais de LLMs foi coletado; o estudo analisa saídas de modelo para perguntas de política de relevância pública. Os termos de serviço dos provedores foram revisados e respeitados, e as respostas são redistribuídas exclusivamente para pesquisa sob provisões de uso justo e reprodutibilidade, excluídas de qualquer aplicação comercial.

4 Resultados

Nota sobre a amostra. Relatamos um benchmark *pré-especificado de 15 países* e sua *extensão post hoc para 25 países*. Catorze LLMs são pontuados em cinco tarefas, duas personas e quatro idiomas (inglês mais um idioma nativo do país — espanhol, português ou hindi — para os nove países aplicáveis, o que dá os pares inglês/nativo dentro do país que testam H2). Todo efeito computado sobre a amostra de 25 países é relatado ao lado de seu valor pré-especificado de 15 países; nenhuma conclusão pré-especificada é revisada apenas com base na extensão. A pontuação é adjudicada por código sempre que a resposta é um número conferível contra registro oficial, e pela média de um painel de juízes de três fornecedores nos demais casos (Seção 4.11).

4.1 Amostra e pontuação

O corpus analisado compreende 9.251 respostas pontuadas no composto $[0, 1]$, das quais 7.580 são respostas a prompts em inglês nos 25 países; o restante são os pares em idioma nativo dentro do país usados para H2.

A pontuação usa o instrumento mais confiável que cada tarefa admite. Para T2 e T3, em que a resposta correta é um número em registro oficial, o veredito é computado por código contra esse registro. O código resolve 62.5% de T2 e 83.6% de T3; o resíduo, com toda a T4, é pontuado pela média de um painel de três fornecedores. T1 e T5 mantêm suas pontuações originais. No total, 5.373 células carregam pontuação corrigida.

A média do painel substitui o desenho de juiz único do protocolo original, no qual o juiz (GPT-5-mini) estava ele próprio entre os modelos avaliados. Duas medições justificam a mudança: os juízes diferem acentuadamente em severidade (composto médio de 0.617 para o Gemini, 0.451 para o Claude e 0.379 para o DeepSeek), de modo que um juiz único fixa um nível arbitrário, e a confiabilidade de juiz único é de apenas $ICC(2, 1) = 0.56$ contra $ICC(2, 3) = 0.79$ da média do painel. Um membro do painel (DeepSeek-V3) é também um modelo avaliado, então checamos o autofavorecimento: ele pontua as próprias saídas de forma *mais* severa em relação aos outros dois juízes (-0.177) do que pontua as de qualquer outro modelo (-0.123 a -0.160).

4.2 Acurácia por modelo

A Tabela 2 ordena os 14 modelos pelo composto médio. Sistemas de fronteira lideram e modelos pequenos de pesos abertos ficam atrás. O resultado que incide sobre H3 é inequívoco: o modelo regional em português brasileiro Cabra-Mistral 7B é o *mais fraco* de todos (0.347 contra 0.549 para os demais; Mann-Whitney $p \approx 0$, δ de Cliff = -0.47). O δ de Cliff tem leitura direta: é a probabilidade de uma resposta sorteada de um grupo superar uma sorteada do outro, reescalada para variar de -1 a $+1$; um valor de -0.47 significa que o modelo regional perde cerca de três dessas comparações para cada uma que ganha. Isso contradiz o enquadramento otimista de H3. Escala e treinamento de fronteira dominam o ajuste regional por instrução no patamar de 7B.

4.3 Acurácia por tarefa: o piso de recuperação

A dificuldade depende fortemente da tarefa (Tabela 3). A mais difícil por larga margem é a T1 (recuperação do padrão técnico, 0.367), que exige devolver o padrão nacional de média anual de

Tabela 2: Acurácia composta por modelo nos 25 países (adjudicada por código onde a resposta é valor de registro, média do painel nos demais casos; [0, 1]). N = respostas pontuadas a prompts em inglês.

Modelo	N	Média
DeepSeek-V3	500	0.680
GPT-5	780	0.672
Gemini 2.5 Flash	490	0.624
GPT-5-mini	777	0.617
Claude Haiku 4.5	490	0.580
Qwen3 32B	498	0.553
Command R+	500	0.526
Llama 3.3 70B	474	0.507
Llama 4 Scout	500	0.492
Qwen3 14B	500	0.480
GPT-OSS 120B	298	0.479
Phi-4 14B	500	0.473
Llama 3.1 8B	777	0.437
Cabra-Mistral 7B	496	0.347

PM_{2,5} em vigor. A recomendação aberta (T5) tem a maior pontuação (0.773) porque sua rubrica premia conselho de política plausível e bem estruturado, que não depende de um fato único. Agrupando as duas tarefas de recuperação (T1, T2; média 0.417) contra síntese e recomendação (T3–T5, 0.623), a diferença é grande (Mann-Whitney $p \approx 0$, δ de Cliff = -0.47). Os LLMs são mais fracos exatamente onde a gestão ambiental aplicada mais precisa deles: recuperar o limiar regulatório em vigor.

A correção do gabarito é ela própria informativa e oferece uma checagem interna. A T1 sempre teve gabarito oficial, e sua pontuação não se move (0.367 antes e depois). A T2 era pontuada contra uma chave de preenchimento e sobe de 0.368 para 0.467 assim que cada concentração devolvida passa a ser comparada por código com a faixa autorizada. A correção moveu exatamente a tarefa cujo gabarito era defeituoso e não tocou naquela cujo gabarito era sólido, que é o comportamento esperado se a correção estiver certa.

Tabela 3: Acurácia composta por tipo de tarefa (25 países). T2 e T3 são adjudicadas por código onde o valor devolvido é conferível contra o registro oficial; T4 é pontuada por painel; T1 e T5 mantêm suas pontuações originais.

Tarefa	N	Média
T5 (recomendação aplicada)	1.508	0.773
T3 (síntese de evid. em saúde)	1.519	0.560
T4 (instrumentos de política)	1.494	0.534
T2 (dado factual local)	1.530	0.467
T1 (padrão técnico)	1.529	0.367

4.4 H2 — perguntar no idioma local reduz a acurácia

Para os nove países com idioma nativo alvo, cada prompt é renderizado em inglês e no idioma nativo, mantendo o conteúdo fixo, de modo que o contraste é dentro do país e dentro do modelo. As replicações são mediadas dentro de cada célula (modelo, prompt) antes do pareamento, já que parrear replicação a replicação inflaria o n e tornaria o teste anticonservador. Nas 839 células

casadas, o prompt em idioma nativo *reduz* a acurácia composta média em 4.8 pontos percentuais (Wilcoxon $p = 3 \times 10^{-15}$). A penalidade acompanha o nível de recurso do idioma, e as três são significativas (Tabela 4): hindi -11.1 pp, espanhol -4.4 pp, português -3.9 pp. A Índia, que pontua mais alto entre os 25 em inglês, é a que mais cai em hindi.

Como H2 carrega a afirmação central do estudo, tentamos fazê-la desaparecer em vez de confirmá-la, e ela se sustentou sob todo ataque. Não é impulsionada por nenhum país (leave-one-out: -4.2 a -5.2 pp, todos significativos), por nenhum modelo (-4.2 a -5.1 pp), nem por células atípicas (5% aparados: -4.3 pp, $p = 5 \times 10^{-19}$), e sobrevive a toda ponderação do composto. Aparece em todas as tarefas e em ambas as condições de persona.

Dois ataques respondem às objeções que um leitor cético levanta primeiro. O primeiro é que juízes-modelo poderiam penalizar prosa não inglesa por estilo, e não por conteúdo; testamos então um desfecho binário que nenhum juiz toca: a resposta contém um valor que o extrator consegue comparar com o registro? Prompts em inglês devolvem valor verificável em 66.4% das vezes e em idioma nativo em 48.7%, uma diferença pareada de -17.7 pp, com a versão nativa pior em 122 dos 182 pares discordantes (teste de sinais $p = 5 \times 10^{-6}$) e a mesma ordenação por idioma. Perguntar no idioma local não apenas reduz uma nota julgada; torna o modelo substancialmente menos propenso a devolver um número conferível.

O segundo é que os prompts nativos, produzidos por um tradutor LLM, poderiam simplesmente perguntar outra coisa. Testamos isso em todos os 90 prompts nativos únicos — um censo, não uma amostra —, retrotraduzindo cada um com um modelo *diferente* e tendo dois outros modelos auditando o resultado contra o original em inglês. Nos dois itens que poderiam confundir o efeito, a fidelidade é completa: nenhum prompt alterou o país e nenhum alterou a quantidade solicitada (90/90 em ambos). Restringir H2 aos prompts verificados como fiéis o deixa essencialmente inalterado (-4.5 pp, $p = 9 \times 10^{-8}$) contra -5.2 pp entre os divergentes, diferença não distinguível de zero (permutação $p = 0.42$). A fidelidade da tradução não prevê o tamanho da penalidade, que é o que se espera se a tradução não a estiver causando.

O efeito é mais fraco no subconjunto adjudicado por código (-2.2 pp, não significativo) por razão estrutural: o código adjudica apenas onde existe número, de modo que esse subconjunto condiciona a que o modelo tenha produzido valor nos *dois* idiomas, o que seleciona para fora o modo de falha mais severo, além de estar subdimensionado para um efeito desse tamanho.

A implicação aplicada é o oposto da intuição. Um gestor que suspeita que um modelo em inglês serve mal seu país, e responde perguntando no idioma nacional, torna a resposta *pior* — e pior pela maior margem exatamente onde o idioma é menos representado nos corpora de treinamento.

Tabela 4: H2: acurácia nativa menos inglesa por idioma nativo (pareada dentro de país e modelo, replicações promediadas dentro da célula, amostra de 25 países).

Idioma nativo (classe Joshi)	Países	Δ (pp)	p	N células
Espanhol (5)	MEX, ARG, PER, COL, CHL	-4.4	$< 10^{-4}$	457
Português (4)	BRA, PRT, AGO	-3.9	2×10^{-4}	311
Hindi (4)	IND	-11.1	5×10^{-4}	71
Geral		-4.8	3×10^{-15}	839

4.5 H6 — a persona não estreita a lacuna geográfica

O fator persona foi plenamente cruzado, de modo que H6 é testado como diferença em diferenças. O enquadramento de gestor ambiental público deixa a lacuna Norte/Sul essencialmente inalterada: +4.7 pp sob o enquadramento neutro contra +5.4 pp sob o de gestor, uma DiD de +0.6 pp, muito abaixo do limiar pré-especificado de 5 pp; um teste de permutação no nível do país (5.000 permutações do rótulo de camada) dá $p = 0.27$. H6 não é sustentada: apresentar a consulta como vinda de um gestor ambiental público não estreita nem amplifica a desvantagem do Sul Global, coerente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Uma checagem de manipulação encontra que 50.2% das respostas na condição de persona reconhecem explicitamente o enquadramento, de modo que o nulo não é artefato de o enquadramento ser universalmente ignorado.

4.6 H1 — uma lacuna de camada que se sustenta, um gradiente que não

A H1 foi pré-especificada em duas partes, e elas se separam com nitidez: uma se sustenta e a outra não.

A lacuna de camada se sustenta. Os dez países do Norte Global têm média de 0.570 contra 0.520 dos quinze do Sul Global, uma lacuna de +5.1 pontos percentuais cujo intervalo de confiança bootstrap de 95% entre países é [+1.6, +8.5] pp e *exclui o zero*. Ela é estável à remoção de qualquer país isolado (leave-one-out [+4.5, +6.0] pp) e à ponderação do composto (+4.2 pp sob pesos iguais, +8.8 pp apenas no subcomponente factual, onde se amplia).

Onde a lacuna vive, e por que o composto a subestima. O composto faz a média de cinco tarefas, e a lacuna não se distribui igualmente entre elas. Reestimando o mesmo contraste como modelo misto binomial em cada tarefa separadamente — desfecho codificado como devolver o valor de registro, com interceptos aleatórios cruzados de país e modelo —, a desvantagem escala com o quanto a tarefa depende de um fato específico daquele país (Tabela 5). No padrão nacional vinculante (T1), a chance de resposta correta do Sul Global é 0.22 da chance do Norte (52.2% contra 29.4% em taxa bruta), e nos instrumentos de política (T4), 0.33; na síntese de evidência em saúde (T3), em que a resposta é uma estimativa internacional e não nacional, a razão sobe para 0.69; e na recomendação aberta (T5), a única tarefa sem valor de registro a acertar, a lacuna desaparece inteiramente. A lacuna não é fraca — ela é *concentrada*, e o composto a dilui ao mediar tarefas em que é severa com uma tarefa em que não existe. Na pergunta que um gestor público mais leva a esses sistemas, qual é o padrão em vigor aqui, um país do Sul Global é servido a cerca de um quarto das chances de um do Norte.

Tabela 5: Chances do Sul Global contra o Norte Global de devolver o valor de registro, por tarefa. Modelo misto binomial, interceptos aleatórios cruzados para país e modelo.

Tarefa	A resposta é	NG	SG	RC	Intervalo 95%
T1 (padrão técnico)	um valor nacional	52.2%	29.4%	0.22	[0.18, 0.27]
T4 (instrumentos)	instrumentos nacionais	62.0%	44.7%	0.33	[0.26, 0.40]
T2 (dado medido local)	um valor nacional	50.7%	37.8%	0.47	[0.39, 0.55]
T3 (síntese de evid. saúde)	estimativa internac.	59.1%	52.3%	0.69	[0.59, 0.80]
T5 (recomendação aplicada)	nenhum valor de reg.	99.6%	99.7%	3.58	[0.84, 15.17]

O gradiente monotônico não se sustenta. Em $n = 25$, o ρ de Spearman entre acurácia e IDH é de $+0.37$ e não atinge significância ($p = 0.073$), e tampouco a tendência de Mann-Kendall ($p = 0.072$). No $n = 15$ pré-especificado ele está essencialmente ausente ($\rho = +0.09$), e nenhuma reestimação *leave-one-country-out* alcança o limiar pré-especificado de $\rho \geq 0.55$ (faixa $[+0.31, +0.49]$). Relatamos, portanto, uma diferença de camada que conseguimos demonstrar e um gradiente de desenvolvimento que não: a desvantagem está estabelecida como diferença entre grupos, enquanto sua forma ao longo da faixa de desenvolvimento permanece exploratória. Sob Bonferroni-Holm na família primária {H1-gradiente, H4, H6}, nenhum teste rejeita seu nulo.

A ordenação dos países retém grande heterogeneidade ortogonal aos eixos (material suplementar): a Índia (0.652, Sul Global) lidera todos os países, África do Sul e Indonésia superam a maior parte do Norte Global, e Canadá e França ficam abaixo. A desvantagem é uma diferença de camada sobreposta a variação substancial específica de cada país, e essa heterogeneidade é ela própria parte da razão de o gradiente não se resolver.

4.7 H4 — representação no corpus: cobertura do país, não tamanho da língua

O mecanismo pré-especificado era a representação no corpus de treinamento, com proxy de contagem de artigos e edições da Wikipédia. Esse proxy é nulo: ρ de Spearman = $+0.14$ ($p = 0.50$) sem controle, e continua nulo parcializando IDH e log do PIB per capita. Um proxy post hoc de cobertura do país alcança $\rho = +0.36$ ($p = 0.075$) e se atenua após ajuste por IDH (parcial $\rho = +0.18$, $p = 0.41$). No nível do país, nenhum dos canais fica estabelecido, porque com 25 países cobertura e desenvolvimento são colineares.

Mudar a unidade de variação resolve o que o nível do país não resolve

O obstáculo é confundimento, não ausência de sinal, e ele tem saída que não exige mais países. Cada país responde a cinco tarefas que diferem em quanto a resposta depende de um fato sobre *aquele* país: T1, T2 e T4 dependem; T3 (uma estimativa internacional da OMS) e T5 (uma recomendação genérica) não. Os países pontuam 0.457 no primeiro bloco e 0.663 no segundo, um déficit de especificidade de 0.206. Se o que limita o modelo é quanto o corpus diz sobre um dado país, esse déficit deveria ser menor onde a cobertura é maior — e o IDH de um país não pode explicar um déficit medido *dentro* desse mesmo país. Estimar a interação entre cobertura e dependência da tarefa no nível da resposta, com efeito fixo de país que absorve desenvolvimento, renda, idioma oficial e tudo mais que distingue países, dá $\beta = +0.026$ (EP 0.005, $p = 2 \times 10^{-8}$, $n = 7.580$).

Quatro checagens separam mecanismo de artefato (Tabela 6). O contraste *mais puro* — T1, inteiramente nacional, contra T5, inteiramente genérica — produz o *maior* coeficiente, a dose-resposta que um efeito real produz e uma associação espúria não. Retirar T5, cujo teto é 99.7%, ou T4, a mais interpretativa, o deixa intacto, e um placebo que inverte os rótulos devolve a imagem espelhada exata. Entrando com os dois canais candidatos juntos, a cobertura do país permanece forte ($\beta = +0.025$, $p = 4 \times 10^{-8}$) enquanto o proxy de corpus da língua fica marginal ($\beta = +0.010$, $p = 0.041$). Essa predição era assimétrica e, portanto, falsificável: como toda resposta aqui foi eliciada *em inglês*, o tamanho do corpus no idioma local de um país não tem

rota óbvia até quanto o modelo sabe sobre aquele país, de modo que, se o canal linguístico tivesse sobrevivido e a cobertura falhado, nossa leitura estaria errada.

A afirmação resultante é mais estreita que “a cobertura causa a lacuna”. O desenho remove por construção o confundimento no nível do país, não o de tarefa por país. O que podemos dizer é que o canal faz uma predição diferencial, que ela se sustenta, que se fortalece à medida que o contraste se aguça, e que sobrevive ao ajuste pelo canal rival.

Tabela 6: Cobertura do país $\times$ dependência da tarefa, modelo misto no nível da resposta com efeito fixo de país. β positivo = maior cobertura, menor déficit nas tarefas dependentes do país.

Classificação das tarefas	β	p
T1, T2, T4 contra T3, T5 (principal)	+0.026	2×10^{-8}
T1 contra T5 (contraste mais puro)	+0.042	3×10^{-12}
Excluindo T5 (teto em 99.7%)	+0.021	4×10^{-4}
Excluindo T4 (mais interpretativa)	+0.031	8×10^{-10}
Placebo: rótulos invertidos	-0.026	2×10^{-8}

A explicação de corpus também se mostra em H2, onde a unidade é o idioma: a penalidade por idioma cai monotonicamente com o volume de tokens do mC4 (Xue et al., 2021) e o tamanho do OSCAR (Abadji et al., 2022), com o hindi, o menor corpus, carregando a maior penalidade — ainda que, com três idiomas, isso permaneça descritivo.

4.8 H5 — abertos versus fechados acessíveis

Modelos fechados acessíveis têm média +13.3 pp acima dos de pesos abertos, contra o enquadramento otimista de H5. O braço aberto inclui modelos maiores, de modo que a lacuna não é atribuível apenas à escala, ainda que o DeepSeek-V3 lidere no geral. H5 é interpretada descritivamente.

4.9 Proveniência do gabarito

Toda chave vem de um registro oficial, ancorada por verificação documental e reproduzível a partir das URLs citadas: T1 da regulação nacional, T2 da Base de Dados de Qualidade do Ar Ambiente da OMS v6.1, T3 do indicador AIR_41 do GHQ/OMS, e T4 do Global Assessment of Air Pollution Legislation do PNUMA. Três países *não* têm padrão nacional de PM_{2,5}, confirmado no texto oficial — a Nigéria regula apenas PM₁₀, a Argentina não tem valor federal vinculante, Angola não tem legislação nacional —, e é aí que um modelo fiel deve se recusar a declarar um limiar inexistente. O registro completo está no suplemento. Wikipédia e Wikidata aparecem apenas como variável explicativa do teste de mecanismo; nenhuma resposta é pontuada contra elas.

4.10 Modos qualitativos de falha

Três modos de falha recorrem por trás do composto, com exemplos literais no suplemento. Os modelos *fabricam padrões inexistentes* para os três países sem norma nacional, inventando um limiar plausível em vez de se absterem e discordando entre replicações sobre o valor inventado; *erram o valor vinculante*, respondendo 15 $\mu\text{g}/\text{m}^3$ para o Brasil, cujo padrão é 17 (CONAMA

506/2024); e *degradam em idioma nativo*, como quando o GPT-OSS 120B devolveu os corretos
40 $\mu\text{g}/\text{m}^3$ da Índia em inglês e resposta *vazia* em hindi.

4.11 Confiabilidade entre juízes

A confiabilidade é relatada sobre a amostra que produz os efeitos, não sobre um subconjunto de calibração. Todos os 3.190 itens que exigiram juiz foram pontuados pelos três membros do painel, dando α de Krippendorff = 0.527, ICC(2,1) de juiz único = 0.558 e — a quantidade operativa, já que a análise usa a média do painel — ICC(2,3) = 0.791.

O painel também isola uma regra de projeto que vale enunciar de forma geral. Onde o prompt de julgamento pedia ao modelo que comparasse uma concentração devolvida contra uma faixa de tolerância expressa em palavras — isto é, que fizesse ele próprio a aritmética —, a concordância entre juízes nesses itens foi de $r = -0.04$. Pré-computar a faixa admissível e perguntar apenas se o valor cai dentro dela elevou a concordância nos mesmos itens para $r = +1.00$, e as 274 pontuações coletadas sob a redação ambígua foram descartadas e recoletadas. Discordância aparente entre juízes pode ser artefato do que se pede ao juiz que compute. A aritmética pertence ao código.

4.12 Robustez

Os dois efeitos sustentados foram testados contra sete ataques e sobrevivem a todos; o gradiente de desenvolvimento falha em todos na mesma direção, o que é o que torna seu estatuto exploratório um achado, e não uma omissão. As saídas completas estão no suplemento.

Nenhum país isolado, e nenhuma ponderação, carrega o resultado. A reestimação *leave-one-country-out* mantém a lacuna de camada em $[+4.5, +6.0]$ pp e a penalidade de idioma nativo entre -4.7 e -5.0 pp. Reponderar o composto não move as conclusões: sob pesos iguais a lacuna é de $+4.2$ pp e a penalidade de idioma de -4.7 pp; restringir à acurácia factual contra o valor de registro as amplia para $+8.8$ e -5.4 pp e aprofunda o piso de recuperação. Os efeitos são mais fortes onde a medida é mais objetiva.

A lacuna de camada sobrevive a um teste livre de distribuição e a duas famílias de modelo. Um teste de permutação embaralha os rótulos Norte/Sul entre os 25 países dez mil vezes e conta com que frequência o acaso sozinho produz uma lacuna desse tamanho; ele não assume nada sobre a distribuição e trata o país, e não a resposta, como unidade independente. O acaso supera a lacuna observada em 2.0% das vezes ($p = 0.020$). Um modelo hierárquico bayesiano com interceptos aleatórios cruzados concorda ($\beta = -0.052$, HDI de 94% $[-0.092, -0.016]$, $P(\beta < 0) = 0.994$), enquanto um modelo misto frequentista devolve a mesma magnitude e sinal mas o deixa marginal ($\beta = -0.066$, $p = 0.069$), porque cobra do termo de erro a grande heterogeneidade entre países. Dois dos três testes excluem o zero e os três concordam em magnitude, de modo que relatamos a lacuna como sustentada e sensível à especificação, com E-value de 1.70 na estimativa pontual e 1.31 no limite do intervalo mais próximo do nulo (VanderWeele and Ding, 2017) — um confundidor de país de força modesta bastaria para explicá-la, e o leitor tem o direito de pesar isso.

A lacuna acompanha a posição no sistema-mundo, não a riqueza nacional. Reestimada sob três partições baseadas em desenvolvimento dos mesmos 25 países, a lacuna é significativa sob a UNCTAD e não significativa sob toda divisão traçada pelo IDH (suplemento). Isso é coerente

com o resto do artigo: o gradiente de IDH é ele próprio nulo, de modo que uma divisão por IDH não deveria produzir lacuna, e o fato de a UNCTAD separar os dados onde o IDH não separa aponta para a posição no sistema-mundo, e não a renda, como variável operante (Quijano, 2000; Mohamed et al., 2020). A leitura é post hoc, de modo que reivindicamos a lacuna para a distinção Norte/Sul tal como convencionalmente traçada, e não como afirmação geral sobre desenvolvimento.

O gradiente nulo é informativo, dentro de limites declarados. Simulando amostras de 25 países com correlações conhecidas, o desenho tem 77% de poder em $\rho = 0.55$ — o limiar fixado de antemão — e efeito mínimo detectável de $\rho = 0.56$. Um gradiente da magnitude que nos comprometemos a chamar de substancial está excluído; um fraco não está (poder de 48% em $\rho = 0.40$). Os dez países acrescentados post hoc caem *dentro* da faixa de IDH que os quinze originais já cobriam, de modo que a extensão aumenta a densidade de observações, e não a amplitude do preditor.

4.13 Síntese

A Tabela 7 mapeia cada hipótese ao seu achado, ao mecanismo candidato e a um estatuto de evidência explícito, de modo que nenhuma afirmação seja lida como mais forte do que os dados sustentam. Três efeitos são sustentados e sobrevivem a todo ataque de robustez da Seção 4.12; duas expectativas pré-especificadas não se cumprem; e o mecanismo de corpus é identificado dentro dos países, onde o desenho tem resolução, e não entre eles.

Tabela 7: Hipóteses, achados, mecanismos candidatos e estatuto de evidência.

Hipótese	Achado	Mecanismo candidato	Estatuto de evidência
H2 (idioma)	−4.8 pp; hindi −11.1	tamanho do corpus da língua	Sustentada; mecanismo descritivo ($n = 3$)
H3 (modelo regional)	$\delta = -0.47$	escala > ajuste regional	Sustentada
H1 (lacuna de camada)	+5.1 pp composto; RC 0.22 em T1	camada (desenvolvimento)	Sustentada; concentrada na recuperação de fato do país
H1 (gradiente)	$\rho = 0.37, p = 0.073$	desenvolvimento (IDH)	Exploratória; não significativa
H4 (mecanismo geográfico)	dentro do país $\beta = +0.026, p = 2 \times 10^{-8}$	cobertura do país	Sustentada dentro do país; não causal
H4 (pré-especificada)	tamanho da Wikipédia nulo	tamanho do corpus da língua	Não sustentada
H5 (aberto/fechado)	+13.3 pp fechado	tipo de acesso / escala	Descritiva
H6 (per-sona)	DiD +0.6 pp	—	Não sustentada

5 Discussão

Propusemo-nos a medir se os LLMs respondem a perguntas de política de poluição do ar com a mesma confiabilidade para o Sul Global e para o Norte Global, se o enquadramento do prompt

muda a resposta, e qual mecanismo impulsiona eventual lacuna. O benchmark — 25 países, 14 modelos, quatro idiomas, cinco tarefas, duas personas, pontuado contra gabarito oficial por código onde a resposta é um valor de registro e por um painel de três fornecedores nos demais casos — devolve um quadro disciplinado e em parte contraintuitivo. Os danos que conseguimos demonstrar são práticos, e não etiológicos: as três mitigações às quais uma agência recorreria falham, a mais intuitiva delas piora materialmente a resposta, e os modelos são menos confiáveis justamente na recuperação do valor vinculante em vigor. Uma diferença de camada Norte/Sul persiste, e identificamos o canal por trás dela apenas onde o desenho tem resolução para tanto.

5.1 Três mitigações intuitivas, todas falhando — e uma que prejudica

A contribuição aplicada é em larga medida negativa, e é o resultado mais acionável.

O idioma local não ajuda e prejudica materialmente. Perguntar no idioma do próprio país reduz a acurácia em 4.8 pp, de forma significativa nos três idiomas, e a penalidade escala com a escassez do corpus daquele idioma, com a Índia — país de maior pontuação entre os 25 em inglês — caindo mais em hindi. Este é o mecanismo que a hierarquia de recursos prevê (Joshi et al., 2020; Xue et al., 2021), e a medida tem resolução para vê-lo porque a unidade é o idioma e não o país. O efeito não depende de nenhum país, modelo, tarefa, condição de persona ou instrumento de pontuação em particular, nem da qualidade da tradução, e se sustenta em um desfecho que não envolve juiz algum: o modelo se torna acentuadamente menos propenso a produzir um número conferível.

A persona de gestor local não estreita a lacuna (DiD +0.6 pp, permutação $p = 0.27$), coerente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Esse nulo pesa mais do que pesaria um nulo sobre um hábito popular, porque o enquadramento por papel é a primeira coisa que todo fornecedor relevante manda seu usuário fazer — Anthropic, OpenAI, Google e xAI convergem no mesmo conselho (Seção 2), de modo que uma administração que siga a documentação do próprio fornecedor escreverá a frase que testamos. O que essa documentação promete para a frase, lida de perto, é controle sobre tom, formato e enquadramento, e nada nela marca a fronteira: nada avisa ao leitor que a técnica que molda o registro de forma confiável não molda também a confiabilidade factual. Nossa estimativa separa as duas. Uma checagem de manipulação confirma que metade das respostas assume explicitamente o papel, de modo que o enquadramento é recebido e muda a voz; ele não muda o que o modelo sabe. Testamo-lo digitado na mensagem, e não instalado como instrução de sistema, que é o canal que um servidor público na interface de conversa efetivamente tem e a mais estreita das duas afirmações (Seção 5.7).

O modelo regional é o *pior* desempenho entre os catorze ($\delta = -0.47$), de modo que recorrer a um modelo pequeno com ajuste local troca a escala e o treinamento de fronteira que sustentam a acurácia no domínio.

Profissionais implantam as três como soluções; nenhuma funciona, e a que um gestor tem mais chance de tentar primeiro causa dano ativo. Para as agências ambientais do Sul Global, nenhum contorno barato no nível do prompt ou do modelo substitui verificar o valor vinculante na fonte oficial.

5.2 O piso de recuperação recai sobre os valores que vinculam

A acurácia despenca nas tarefas que exigem devolver um valor específico em vigor: 0.417 para recuperação normativa e de dado local, contra 0.623 para síntese e recomendação ($\delta = -0.47$), sendo mais profundo no próprio padrão nacional (T1, 0.367). O risco é concentrado. Um gestor que redige prosa sobre política de qualidade do ar é comparativamente bem servido; um gestor que recupera o limite regulatório do qual depende uma decisão está na pior célula do desenho, e pior ainda se perguntar em um idioma de menos recursos. Uma checagem interna sustenta que esse piso é genuíno, e não artefato de pontuação: corrigir o gabarito elevou a T2 — a tarefa pontuada contra uma chave de preenchimento — de 0.368 para 0.467, deixando a T1, que sempre teve gabarito oficial, em exatamente 0.367. A correção moveu a tarefa cuja chave era defeituosa e não tocou naquela cuja chave era sólida.

5.3 Uma diferença de camada que podemos mostrar, e um gradiente que não

A H1 foi pré-especificada em duas partes, e a pontuação corrigida as separa: a lacuna de camada se sustenta e o gradiente monotônico não.

Lida no composto, a lacuna parece modesta (+5.1 pp, IC bootstrap [+1.6, +8.5]). Estimada tarefa a tarefa no desfecho binário de devolver o valor de registro, não é: a lacuna escala com o quanto a resposta depende de um fato específico daquele país, de uma razão de chances de 0.22 no padrão nacional vinculante até nenhuma lacuna na recomendação aberta, a única tarefa sem valor de registro a acertar. A desvantagem é concentrada, e mediar cinco tarefas em um composto a dilui com tarefas em que ela não existe. Na pergunta que um gestor de fato leva a esses sistemas — qual é o padrão em vigor aqui —, um país do Sul Global é servido a cerca de um quarto das chances de um do Norte. Esse é o enunciado fiel do achado geográfico.

O gradiente falha em toda leitura, e o nulo é informativo em vez de vazio porque o desenho tem 77% de poder no $\rho = 0.55$ pré-especificado: um gradiente da magnitude com que nos comprometemos está excluído, ao passo que um fraco não está. A ordenação dos países mostra por que os dois resultados diferem. A Índia lidera os 25 países apesar de ser Sul Global; África do Sul e Indonésia superam a maior parte do Norte Global; Canadá e França ficam abaixo. A desvantagem é uma diferença de camada sobreposta a uma idiosincrasia substancial de cada país, e é essa idiosincrasia que uma correlação de postos sobre 25 países não tem resolução para atravessar.

5.4 O mecanismo, onde o desenho tem resolução

O teste de mecanismo pré-especificado falha, e a razão é um defeito do instrumento, não ausência de sinal. O proxy atribui o tamanho da edição da Wikipédia no idioma oficial dominante do país, de modo que nove dos nossos 25 países recebem o valor da Wikipédia *inglesa*. A variável não mede quanto texto existe no idioma de um país; mede se o país tem o inglês como idioma oficial, que é um fato de história colonial. Relatamos isso porque incide sobre qualquer estudo que tenha usado ou venha a usar o mesmo proxy.

A resolução vem de mudar a unidade de variação, e a checagem decisiva restringe-se a esses mesmos nove países anglófonos. Ali o canal linguístico não é apenas controlado, mas idêntico por

construção, e a cobertura do país ainda prevê o déficit de especificidade na magnitude da amostra completa ($\beta = +0.025$, $p = 6 \times 10^{-4}$). O que esse coeficiente mede não pode ser idioma. A afirmação para aí: a representação do país é o canal operante para uma lacuna medida em inglês, identificado em um contraste que remove por construção o confundimento no nível do país, mas não causalmente — o desenho elimina confundimento no nível do país, não no de tarefa por país.

5.5 A lição metodológica: a chave importa mais que a amostra

As mesmas 9.251 respostas sustentam conclusões substantivas diferentes conforme o instrumento usado para pontuá-las, e o tamanho dessa diferença é a lição. Pontuar duas das cinco tarefas contra gabarito de preenchimento, e delegar a um modelo de linguagem a aritmética de decidir se um número devolvido cai dentro de uma faixa autorizada, produz um gradiente de desenvolvimento de $\rho = 0.51$ ($p = 0.004$) e uma penalidade de idioma nativo de -2.1 pp. Reconstruir essas chaves a partir de registros oficiais e passar a comparação para o código transforma o gradiente em um nulo ($\rho = 0.37$), mais que dobra a penalidade de idioma para -4.8 pp e converte o espanhol de nulo em dano significativo. O conjunto de dados não mudou; apenas o instrumento de medida. O instinto do campo, quando um efeito de viés geográfico se mostra frágil, é acrescentar países, mas o gabarito merece o escrutínio primeiro: uma chave defeituosa não apenas acrescenta ruído, ela acrescenta ruído *estruturado*, porque os defeitos se concentram onde o dado oficial é mais difícil de obter — que é exatamente onde a hipótese vive.

5.6 Por que o domínio importa

O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura, e a carga recai desproporcionalmente sobre o Sul Global: a Organização Mundial da Saúde atribui 88.548 óbitos no Brasil em 2021 à poluição do ar ambiente (intervalo de incerteza 69.477 to 108.431) ([World Health Organization, 2026](#)), e a exposição de curto prazo segue impulsionando mortalidade mensurável em cidades brasileiras ([Requia et al., 2024](#)). Quando um gestor delega a um LLM uma consulta normativa ou uma recomendação de episódio, uma resposta imprecisa pode se propagar para um parecer regulatório ou uma resposta emergencial.

Não afirmamos que o modelo é menos confiável onde as consequências são maiores, porque não medimos isso: a carga de doença não está entre nossas covariáveis de país, e a única observação de nível de país que temos aponta no sentido contrário, já que a Índia carrega uma das maiores cargas de mortalidade por $PM_{2.5}$ do mundo e é também o país de maior pontuação em nossa amostra. Se a confiabilidade está desalinhada da necessidade é pergunta bem posta, respondível acrescentando uma covariável de mortalidade atribuível padronizada por idade, mas não uma pergunta que este desenho responde. Interpretamos o padrão que *de fato* medimos pelo arcabouço da colonialidade do saber ([Mohamed et al., 2020](#)): os LLMs são resumos comprimidos de corpora produzidos sob acesso digital e de publicação desigual, e a penalidade de idioma é um elo mensurável entre assimetria de corpus e assimetria de conhecimento.

5.7 Limitações e oportunidades futuras

Cada limite abaixo delimita este desenho, e cada um nomeia o estudo que o removeria. Listamos na ordem em que os faríamos.

O enquadramento de papel foi testado no turno do usuário, não no prompt de sistema. O enquadramento de gestor é anteposto à mensagem em vez de instalado como instrução de sistema, que é onde os guias dos fornecedores o colocam. A escolha acompanha a população que nos interessa — servidores públicos na interface de conversa, que não têm prompt de sistema a configurar —, mas significa que nosso nulo delimita o canal desse usuário, não o de um desenvolvedor. Se uma persona em instrução de sistema recupera acurácia factual onde uma digitada não recupera é um experimento limpo de duas células sobre os mesmos itens, e é o primeiro estudo que faríamos.

De pontuado por painel a ancorado em padrão-ouro. Nenhum especialista humano repontuou respostas aqui. Três propriedades delimitam o custo disso: onde a resposta é um valor de registro, o veredito é computado por código e nenhum juiz se envolve; onde se exige julgamento, a nota é a média de três fornecedores em vez de um; e todo efeito relatado é um contraste entre grupos, no qual a severidade sistemática de um juiz se cancela. Restringir à acurácia factual objetiva fortalece os dois efeitos principais, o oposto do que um juiz permissivo produziria. Uma validação cega por especialistas humanos de uma amostra estratificada — cerca de 150 respostas pontuadas por três avaliadores, que o pipeline liberado exporta diretamente — converteria um resultado ancorado em fonte oficial em um ancorado em padrão-ouro.

De um sinal dentro do país a um desenho causal. O canal é identificado onde o desenho tem resolução, mas não causalmente: dentro dos países removemos o confundimento no nível do país sem remover o de tarefa por país. Um desenho que varie a cobertura do país mantendo o desenvolvimento fixo, ou um estudo longitudinal acompanhando a acurácia à medida que a pegada enciclopédica de um país cresce, fecharia essa lacuna.

De um gradiente nulo a um teste com poder adequado. A diferença de camada está estabelecida enquanto o gradiente não, em $n = 25$. Uma replicação pré-registrada com n substancialmente maior — que o conjunto de dados aberto torna barata — resolveria se o gradiente é genuinamente ausente ou ainda subdimensionado.

De três idiomas nativos à matriz multilíngue completa. O resultado mais forte repousa sobre três idiomas nativos, de modo que seu mecanismo é relatado descritivamente ainda que o efeito não seja. A objeção de qualidade de tradução é resolvida empiricamente, e não apenas reconhecida, pelo censo de retrotradução relatado acima. O que permanece aberto é amplitude, não validade, e escalar para mais idiomas é a extensão de maior valor que este estudo aponta.

De um domínio a um programa entre domínios. Todos os efeitos vêm de um domínio aplicado de alto risco e de uma família de corpus (Wikimedia), e confinamos a linguagem mecanicista a ele. O mesmo conjunto de tarefas e o método de registro de gabarito se transferem diretamente a outros domínios regulados e ancorados em fonte — qualidade da água, segurança de alimentos, política de vacinação.

A pilha do modelo servido como unidade de análise. Avaliamos modelos como servidos por pilhas de acesso fixas, que é o que um gestor público consulta; uma lacuna residual poderia, em princípio, refletir a pilha em vez dos pesos. Um desenho controlado de quase-isolamento com

831 pesos abertos idênticos entre pilhas separaria os dois, o que a proveniência por chamada que
832 liberamos já viabiliza.

833 5.8 O que este estudo contribui

834 Diante da evidência agora em mãos, três das contribuições listadas na Seção 1 se destacam. O
835 resultado aplicado é decisivo e contraintuitivo: as três soluções a que os profissionais recorrem
836 primeiro falham juntas, o idioma local prejudica ativamente, e o modelo regional é o pior desem-
837 penho entre catorze — a saída mais útil de um benchmark é muitas vezes dizer ao campo o que
838 não funciona, com tamanhos de efeito por trás. O resultado metodológico é que, nesta literatura,
839 a chave de gabarito, e não o tamanho amostral, é a restrição vinculante. E o desenho separa o
840 que 25 países conseguem demonstrar do que não conseguem, relatando o segundo conjunto como
841 aberto em vez de sustentado.

842 6 Conclusão

843 Modelos de linguagem de grande porte estão se tornando infraestrutura de trabalho para a
844 política de poluição do ar, domínio em que uma resposta imprecisa sobre um padrão vinculante,
845 uma concentração medida ou uma resposta operacional carrega consequências diretas de saúde
846 pública no Sul Global, onde a carga de mortalidade por PM_{2,5} é mais pesada (GBD 2019 Risk
847 Factors Collaborators, 2020; Requia et al., 2024). Medimos viés geográfico e modulado por
848 persona nesse domínio com um benchmark de 25 países, 14 modelos e quatro idiomas, pontuado
849 contra gabarito ancorado em fontes oficiais primárias — por código sempre que a resposta é um
850 valor de registro, e pela média de um painel de juízes de três fornecedores nos demais casos.

851 As mitigações que um órgão pode tentar não funcionam, e a mais intuitiva sai pela culatra.
852 Perguntar no idioma do próprio país *reduz* a acurácia em 4.8 pontos percentuais, de forma mais
853 acentuada onde o idioma é menos representado nos corpora de treinamento; a persona de gestor
854 local não estreita a lacuna; e o modelo com ajuste regional é o mais fraco dos catorze sistemas.
855 A acurácia também despenca na recuperação de um valor vinculante, a tarefa que um gestor
856 menos pode se dar ao luxo de ter errada. Uma lacuna de camada Norte/Sul persiste e é altamente
857 estruturada: ao devolver o padrão nacional vinculante, a chance de resposta correta do Sul Global
858 é 0.22 da chance do Norte, e a lacuna encolhe conforme a resposta depende menos de um fato
859 específico do país, desaparecendo na única tarefa sem valor de registro a acertar. O gradiente
860 monotônico de desenvolvimento não atinge significância, de modo que relatamos uma diferença
861 entre grupos que conseguimos demonstrar e uma forma ao longo da faixa de desenvolvimento que
862 não conseguimos. Quanto ao mecanismo, a representação do país é o canal operante para uma
863 lacuna medida em inglês, identificado dentro dos países em vez de entre eles, e sem reivindicação
864 de identificação causal.

865 Para as agências ambientais do Sul Global, a mensagem prática é cautelar. Saídas de LLM
866 sobre padrões vinculantes e dados medidos devem ser tratadas como rascunhos conferidos contra
867 o diário oficial, e nenhum contorno barato no nível do prompt ou do modelo substitui essa
868 verificação — muito menos trocar para o idioma local, que por esta evidência piora a resposta.
869 Interpretamos o padrão pelo arcabouço da colonialidade do saber (Mohamed et al., 2020): os

idiomas sub-atendidos nos corpora de treinamento (Joshi et al., 2020) são falados onde a poluição do ar mais mata, e este estudo converte esse elo de uma preocupação plausível em um efeito medido.

Um resultado metodológico generaliza para além do domínio. Reconstruir duas chaves de gabarito a partir de registros oficiais e tirar a comparação de faixa do juiz, passando-a para o código, mudou as conclusões substantivas sobre as mesmas respostas. Quando um efeito nesta literatura se mostra frágil, a chave de gabarito merece a auditoria antes da amostra, porque uma chave defeituosa acrescenta ruído *estruturado* que se concentra exatamente onde o dado oficial é mais difícil de obter.

Protocolo, prompts, registros de gabarito com fontes oficiais, código de análise e dados de resposta anonimizados são liberados abertamente, com pipeline de reprodução em um comando e um gate de auditoria de métodos que recomputa cada número relatado a partir do dado bruto. O estudo também oferece um modelo reutilizável para auditorias aplicadas de equidade em LLMs — gabarito de fonte oficial, adjudicação por código sempre que a resposta é um número conferível, e auditabilidade de ponta a ponta — nos domínios de alto risco do setor público em que esses sistemas já estão sendo implantados.

Disponibilidade de dados e código

O protocolo completo, os prompts, o código de análise, os registros de gabarito e as respostas anonimizadas dos modelos serão liberados na publicação em github.com/Roverlucas/artigo-vies-analise-regional, sob licenças MIT (código) e CC-BY-4.0 (dados, prompts, documentação). A liberação inclui os registros por resposta a partir dos quais cada efeito relatado é calculado, de modo que todo número deste artigo pode ser recomputado do dado bruto em vez de aceito por confiança. O pipeline de análise roda de ponta a ponta com `python code/run_all.py`.

Protocolo do estudo

Hipóteses, marco amostral, definição de desfecho, limiares de decisão e correção de multiplicidade foram fixados em um plano de análise sob controle de versão antes do início da coleta confirmatória. Esse plano não foi depositado em registro público, de modo que o leitor não pode verificar sua data de forma independente do histórico do repositório, e *não* reivindicamos pré-registro. O escopo entregue também se afastou substancialmente do desenho planejado, o que o próprio plano estabelecia como condição para o estatuto confirmatório.

Relatamos o estudo, portanto, em duas camadas. A primeira declara o que foi especificado de antemão e o que aconteceu com cada item. A segunda relata o que os dados sugeriram e o plano não antecipou, rotulado como exploratório do começo ao fim, com intervalos e sem linguagem confirmatória. Os desvios em relação ao plano estão tabulados no material suplementar.

Agradecimentos

Esta pesquisa não recebeu financiamento específico de agências dos setores público, comercial ou sem fins lucrativos. Os custos de inferência foram pagos pelos autores; nenhum fornecedor

concedeu créditos, descontos ou apoio em espécie para este estudo.

Contribuições dos autores

Segundo a taxonomia CRediT:

- Lucas Rover (UTFPR): Conceituação, Metodologia, Software, Curadoria de Dados, Análise Formal, Investigação, Visualização, Redação – Rascunho Original, Administração do Projeto.
- Vitor de Melo Dominski (Faculdade Descomplica): Curadoria de Dados, Software, Análise Formal.
- Prof. Anibal Tavares de Azevedo (Unicamp): Redação – Rascunho Original, Redação – Revisão e Edição.
- Dr. Eduardo Tadeu Bacalhau (UFPR): Validação, Supervisão, Redação – Revisão e Edição.
- Dra. Yara de Souza Tadano (UTFPR): Validação, Supervisão, Redação – Revisão e Edição.

Declaração sobre IA generativa na redação

É preciso separar dois usos distintos, porque apenas um deles é objeto desta declaração.

Como objeto e instrumento do estudo. Modelos de linguagem são o objeto desta pesquisa e também servem como um de seus instrumentos de medida: GPT-5-mini, Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3 pontuaram respostas contra o registro de gabarito, e o Claude Sonnet 4.6 produziu as versões dos prompts em idioma nativo. Esses usos fazem parte do método, estão descritos na Seção 3, e são a razão de o estudo também relatar confiabilidade entre juízes e uma auditoria de retrotradução dos prompts traduzidos. Onde a resposta correta é um valor de registro oficial, o veredito é computado por código, não por modelo.

Na preparação do manuscrito. Durante a preparação deste trabalho, os autores usaram modelos de linguagem para auxiliar na redação e edição do texto e na implementação do código de análise. Após usar essas ferramentas, os autores revisaram e editaram o conteúdo conforme necessário e assumem responsabilidade integral pelo conteúdo da publicação. Nenhum modelo de linguagem consta como autor, e nenhum modelo contribuiu com a interpretação dos achados ou com as decisões sobre o que a evidência sustenta.

Declaração de interesses

Os autores declaram não haver conflitos de interesse.

Referências

- Abadji, J., Ortiz Suárez, P., Romary, L., and Sagot, B. (2022). Towards a cleaner document-oriented multilingual crawled corpus. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 4344–4355.

940 Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fannesbeck, C. J., Kochurov, M., Kumar, R.,
941 Lao, J., Luhmann, C. C., Martin, O. A., et al. (2023). PyMC: A modern and comprehensive
942 probabilistic programming framework in Python. *PeerJ Computer Science*, 9:e1516.

943 Almeida, T., Nogueira, R., and Pedrini, H. (2025a). Building high-quality datasets for Portuguese
944 LLMs: From Common Crawl snapshots to industrial-grade corpora. *Journal of the Brazilian
945 Computer Society*, 31(1):1247–1263.

946 Almeida, T. S., Bonás, G. K., and Santos, J. G. A. (2025b). BRouterbs: Measuring how much
947 LLMs understand Portuguese proverbs. *Journal of the Brazilian Computer Society*, 31:1078–
948 1088.

949 Almeida, T. S., Bonás, G. K., Santos, J. G. A., Abonizio, H., and Nogueira, R. (2025c). TiEBe:
950 Tracking language model recall of notable worldwide events through time. *arXiv preprint
951 arXiv:2501.07482*.

952 Anthropic (2026). Giving Claude a role with a system prompt. Claude Platform Documentation,
953 Prompt Engineering. Vendor documentation recommending that a role be set in the system
954 prompt. Accessed 2026-08-24.

955 Aoki, N., Tatsumi, T., Naruse, G., and Maeda, K. (2024). Explainable AI for government: Does
956 the type of explanation matter to the accuracy, fairness, and trustworthiness of an algorithmic
957 decision as perceived by those who are affected? *Government Information Quarterly*,
958 41(4):101965.

959 Basil, S., Shapiro, I., Shapiro, D., Mollick, E. R., Mollick, L., and Meincke, L. (2025). Prompting
960 science report 4 — playing pretend: Expert personas don’t improve factual accuracy. SSRN
961 Working Paper. SSRN id 5879722.

962 Bender, E. M., Gebru, T., McMillan-Major, A., and Shmitchell, S. (2021). On the dangers
963 of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM
964 Conference on Fairness, Accountability, and Transparency*, pages 610–623.

965 Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and
966 powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*,
967 57(1):289–300.

968 Choroszewicz, M. (2026). Positioning public sector practitioners as ‘moral crumple zones’: Mechanisms in the early use of generative AI work support tools. *Government Information Quarterly*, 43(2):102128.

971 Cordella, A. and Gualdi, F. (2024). Regulating generative AI: The limits of technology-neutral regulatory frameworks. insights from Italy’s intervention on ChatGPT. *Government Information Quarterly*, 41(4):101982.

974 Couldry, N. and Mejias, U. A. (2019). *The costs of connection: How data is colonizing human life and appropriating it for capitalism*. Stanford University Press.

976 D’Ignazio, C. and Klein, L. F. (2020). *Data feminism*. MIT Press.

977 GBD 2019 Risk Factors Collaborators (2020). Global burden of 87 risk factors in 204 countries
978 and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019.
979 *The Lancet*, 396(10258):1223–1249.

980 Google (2026). Prompting strategies: Role definitions in system instructions. Gemini API Do-
981 cumentation. Vendor documentation instructing developers to place role definitions (persona)
982 in the system instruction. Accessed 2026-08-25.

983 Igolkina, A. A. and Meshcheryakov, G. (2020). semopy: A python package for structural equation
984 modeling. *Structural Equation Modeling*, 27(6):952–963.

985 Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate
986 of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual*
987 *Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for
988 Computational Linguistics.

989 Kerche, F., Zook, M., and Graham, M. (2026). The silicon gaze: A typology of biases and
990 inequality in LLMs through the lens of place. *Platforms & Society*.

991 Kim, E. (2026). Generative AI in public administration: A quasi-experimental analysis of bure-
992 aucratic productivity. *Government Information Quarterly*, 43(1):102108.

993 Kozlakidis, Z., Wootton, T., and Mayrhofer, M. T. (2026). Through the looking glass: ethical
994 considerations regarding LLM-induced hallucinations to medical questions. *Frontiers in Digital*
995 *Health*, 8:1736616.

996 Le Coz, P., Liu, J. A., Bhattacharjya, D., Curto, G., and Stinckwich, S. (2025). What would an
997 LLM do? evaluating large language models for policymaking to alleviate homelessness. *arXiv*
998 *preprint arXiv:2509.03827*.

999 Manvi, R., Khanna, S., Burke, M., Lobell, D., and Ermon, S. (2024). Large language models
1000 are geographically biased. In *Proceedings of the 41st International Conference on Machine*
1001 *Learning (ICML)*. arXiv:2402.02680.

1002 Mirza, S., Coelho, B., Cui, Y., Pöpper, C., and McCoy, D. (2024). Global-liar: Factuality of
1003 LLMs over time and geographic regions. *arXiv preprint arXiv:2401.17839*.

1004 Moayeri, M., Tabassi, E., and Feizi, S. (2024). Worldbench: Quantifying geographic disparities
1005 in LLM factual recall. In *Proceedings of the 2024 ACM Conference on Fairness, Accountability,*
1006 *and Transparency*, pages 1211–1228, Rio de Janeiro, Brazil.

1007 Mohamed, S., Png, M.-T., and Isaac, W. (2020). Decolonial AI: Decolonial theory as sociotech-
1008 nical foresight in artificial intelligence. *Philosophy & Technology*, 33(4):659–684.

1009 Myung, J. et al. (2024). BLENd: A benchmark for LLMs on everyday knowledge in diverse
1010 cultures and languages. *Advances in Neural Information Processing Systems*, 37:78104–78146.

- 1011 Nosek, B. A., Ebersole, C. R., DeHaven, A. C., and Mellor, D. T. (2018). The preregistration
1012 revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606.
- 1013 OECD (2024). Governing with artificial intelligence: The state of play and way forward in core
1014 government functions. Technical report, OECD Publishing, Paris.
- 1015 OpenAI (2026). Prompt engineering: Identity and message formatting. OpenAI Platform Docu-
1016 mentation. Vendor documentation recommending an “Identity” block describing the assistant’s
1017 purpose and role. Accessed 2026-08-24.
- 1018 Opuszek, M. and Böhm, P. (2026). New york, new york – unraveling bias in large language
1019 models: Investigating differences between standard and reasoning-based language models. In
1020 *AI Revolution: Research, Ethics and Society*, pages 92–106. Springer.
- 1021 Patton, M. Q. (2015). *Qualitative research and evaluation methods*. SAGE Publications, 4th
1022 edition.
- 1023 Quijano, A. (2000). Coloniality of power, eurocentrism, and Latin America. *Nepantla: Views*
1024 *from South*, 1(3):533–580.
- 1025 Requia, W. J., Vicedo-Cabrera, A. M., Amini, H., and Schwartz, J. D. (2024). Short-term air
1026 pollution exposure and mortality in Brazil: Investigating the susceptible population groups.
1027 *Environmental Pollution*, 340:122797.
- 1028 Robinson, N. (2026). Open to open-source AI? navigating AI model choice in public sector
1029 agencies. *Government Information Quarterly*, 43(2):102133.
- 1030 Rover, L., Bacalhau, E. T., and Tadano, Y. (2026). Geographic bias in LLMs: Benchmark
1031 dataset and code. To be deposited on publication.
- 1032 Simplicio, A., Vinagre, G., Ramos, M. M., Tavares, D., Ferreira, R., et al. (2026). AMALIA
1033 technical report: A fully open source large language model for European Portuguese.
- 1034 UNCTAD (2024). UNCTAD statistical classifications — june 2024 update. Technical report,
1035 UN Trade and Development.
- 1036 VanderWeele, T. J. and Ding, P. (2017). Sensitivity analysis in observational research: introdu-
1037 cing the E-value. *Annals of Internal Medicine*, 167(4):268–274.
- 1038 Vieira, I., Calvo, I., Paulo, I., Furtado, J., Ferreira, R., et al. (2026). ALBA: A European
1039 Portuguese benchmark for evaluating language and linguistic dimensions in generative LLMs.
1040 *arXiv preprint arXiv:2603.26516*.
- 1041 White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith,
1042 J., and Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with
1043 ChatGPT. *arXiv preprint arXiv:2302.11382*.
- 1044 World Bank Group (2025). World Bank Country and Lending Groups — FY26 Classification.
1045 Technical report, The World Bank.

1046 World Health Organization (2021). WHO global air quality guidelines: Particulate matter
 1047 (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Techni-
 1048 cal report, World Health Organization, Geneva.

1049 World Health Organization (2026). Ambient air pollution attributable deaths (indicator
 1050 AIR_41). Global Health Observatory. Reference year 2021, both sexes. Accessed 2026-08-
 1051 19.

1052 xAI (2026). Generate text: System prompts. Grok API Documentation. Vendor documentation
 1053 whose standard example initialises every conversation with a role-assigning system prompt.
 1054 Accessed 2026-08-25.

1055 Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., and Raffel,
 1056 C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings*
 1057 *of the 2021 Conference of the North American Chapter of the Association for Computational*
 1058 *Linguistics: Human Language Technologies (NAACL-HLT)*, pages 483–498.

1059 Zheng, M., Pei, J., Logeswaran, L., Lee, M., and Jurgens, D. (2024). When “a helpful assistant” is
 1060 not really helpful: Personas in system prompts do not improve performances of large language
 1061 models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages
 1062 15126–15154.