

1 De quem é a regulação que o modelo conhece?
2 Confiabilidade da informação regulatória recuperada por LLMs
3 para a gestão ambiental pública em 25 países

4 Lucas Rover^{1,*}
Vitor de Melo Dominski²
Anibal Tavares de Azevedo³
Eduardo Tadeu Bacalhau⁴
Yara de Souza Tadano¹

¹ Universidade Tecnológica Federal do Paraná (UTFPR), Brasil

² Faculdade Descomplica, Brasil

³ Universidade Estadual de Campinas (Unicamp), Brasil

⁴ Universidade Federal do Paraná (UFPR), Brasil

* Autor correspondente: lucasrover@alunos.utfpr.edu.br

ORCID: L.R. 0000-0001-6641-9224 · V.M.D. 0009-0001-0209-9089 · A.T.A. 0000-0003-1678-7795 · E.T.B. 0000-0002-39

5 24 de agosto de 2026

6 **Resumo**

7 Administrações públicas consultam cada vez mais modelos de linguagem de grande porte
8 sobre as normas que lhes cabe aplicar, mas não existe método estabelecido para auditar
9 se essas respostas correspondem ao texto vinculante. Contribuímos com esse protocolo e
10 relatamos o que ele encontra.

11 O protocolo pontua respostas contra registros oficiais, decidindo por código sempre que
12 a resposta correta é um valor publicado e por um painel de juízes de três fornecedores nos
13 demais casos. Aplicamo-lo à regulação da poluição do ar em 25 países, 14 configurações de
14 acesso, cinco tipos de tarefa e quatro idiomas (9.251 respostas), avaliando cada modelo *como*
15 *servido*.

16 As três mitigações disponíveis a um órgão público falham, e a mais intuitiva causa dano.
17 Perguntar no idioma do próprio país *reduz* a acurácia em 4.8 pontos percentuais (Wilcoxon
18 $p = 3 \times 10^{-15}$) e torna o modelo 17.7 pontos menos propenso a devolver um valor verificável
19 contra o registro; a persona de gestor público não estreita a lacuna ($p = 0.27$); e um modelo
20 com ajuste regional fica em último entre os catorze. A acurácia também despenca justamente
21 na recuperação do valor vinculante: 0.37, contra 0.62 para síntese. Uma lacuna Norte/Sul
22 persiste (+5.1 pp, permutação $p = 0.020$), concentrada onde a resposta depende de um fato
23 nacional — no padrão nacional, a chance do Sul Global é 0.23 da chance do Norte.

24 O escopo é deliberadamente delimitado: medimos concordância com a regulação publi-
25 cada em um domínio, não capacidade geral do modelo, e identificamos o canal de corpus

apenas onde o desenho tem resolução. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada.

Palavras-chave: IA generativa no governo; informação regulatória; confiabilidade da informação; gestão ambiental pública; apoio algorítmico à decisão; modelos de linguagem de grande porte; Sul Global

1 Introdução

Modelos de linguagem de grande porte (LLMs) passaram de curiosidade de pesquisa a infraestrutura de trabalho da administração pública em menos de cinco anos: uma pesquisa da OCDE sobre funções centrais de governo documenta a adoção de IA generativa na formulação de políticas e na prestação de serviços públicos, incluindo usos em que servidores buscam normas e redigem sínteses técnicas (OECD, 2024). Agências ambientais, secretarias municipais e analistas de política aplicada redigem sínteses técnicas, traduzem normas regulatórias, localizam dados oficiais de monitoramento e caracterizam arranjos institucionais com esse tipo de auxílio. A política de poluição do ar é um domínio em que essa adoção carrega consequências diretas para a saúde pública. O material particulado fino (PM_{2,5}) é o principal fator de risco ambiental para mortalidade prematura no mundo (GBD 2019 Risk Factors Collaborators, 2020; World Health Organization, 2021), e a carga recai desproporcionalmente sobre o Sul Global (GBD 2019 Risk Factors Collaborators, 2020). Quando um gestor ambiental em São Paulo, Lagos ou Jacarta pergunta a um LLM sobre um padrão de qualidade do ar, um prazo de conformidade ou a evidência epidemiológica por trás de uma intervenção, uma resposta imprecisa não é erro benigno. Ela pode se propagar para uma nota técnica regulatória, uma decisão de contratação ou uma resposta emergencial durante um episódio de poluição.

Este artigo mede se os LLMs servem à política de poluição do ar do Sul Global com a mesma confiabilidade que ao Norte Global, e se o enquadramento da consulta muda a resposta. Duas linhas recentes de evidência tornam essa pergunta urgente, e não hipotética.

O viés factual geográfico é real e mensurável. Moayeri et al. (2024) documentou taxas de erro factual 1,5× maiores para países da África Subsaariana em comparação com países da América do Norte, em 20 modelos e 11 indicadores do Banco Mundial. Manvi et al. (2024) mostrou que avaliações *zero-shot* de LLMs sobre temas subjetivos se correlacionam fortemente com o nível de renda (ρ de até 0,70 contra condições socioeconômicas). Mirza et al. (2024) constatou que o GPT-4 privilegia sistematicamente afirmações sobre o Norte Global em detrimento do Sul Global em tarefas de verificação factual. Esses resultados estabelecem o fenômeno, mas nenhum deles se dirige a um único domínio aplicado de alto risco com gabarito oficial verificável, e nenhum pergunta se o viés pode ser modulado pelo enquadramento do prompt.

A assimetria linguística e de corpus é estrutural. Joshi et al. (2020) mapeou uma hierarquia de seis classes de disponibilidade de recursos linguísticos em PLN, mostrando que os idiomas da maioria dos países do Sul Global ocupam as classes menos atendidas. A sub-representação no corpus de treinamento é a explicação dominante para o viés geográfico a jusante (Bender

et al., 2021). Essa assimetria não é incidental; ela reproduz padrões duradouros de infraestrutura digital e epistêmica desigual que a literatura decolonial vem analisando para sistemas de IA (Mohamed et al., 2020).

Identificamos três lacunas que o trabalho atual deixa em aberto para um domínio como a política de poluição do ar.

Lacuna 1: nenhum benchmark tem como alvo a política de poluição do ar com gabarito oficial. As avaliações existentes usam recuperação numérica de indicadores do Banco Mundial (WorldBench), avaliações subjetivas (Manvi et al.), checagem factual jornalística (GlobalLiar) ou conhecimento cultural cotidiano (BLEnD (Myung et al., 2024)). Nenhuma mede as tarefas de recuperação e síntese que um gestor ambiental de fato delega a um LLM: declarar um padrão de qualidade do ar vinculante, recuperar uma concentração oficialmente medida, resumir a evidência de carga de doença, identificar os instrumentos legais e os órgãos executores, ou recomendar uma resposta operacional. Essas tarefas se ancoram em fontes autoritativas (conselhos ambientais nacionais, agências estaduais de monitoramento, a Organização Mundial da Saúde, as estimativas do Global Burden of Disease), o que torna a acurácia verificável de um modo que benchmarks de conhecimento geral não permitem.

Lacuna 2: o enquadramento por persona não foi examinado como alavanca experimental. Profissionais rotineiramente prefixam consultas com um papel (“Como secretário municipal de meio ambiente, ...”), e o fazem seguindo o conselho dos próprios fornecedores: a documentação da Anthropic manda dar um papel ao modelo no prompt de sistema (Anthropic, 2026) e a da OpenAI pede um bloco de identidade declarando o propósito do assistente (OpenAI, 2026), enquanto a prática está catalogada como Padrão de Persona na literatura de padrões de prompt (White et al., 2023). Se adotar a persona de um gestor ambiental público *reduz* a lacuna de acurácia do Sul Global (ao orientar o modelo para respostas relevantes à política e aderentes à norma) ou a *amplia* (ao convidar à fabricação confiante de especificidades regulatórias que o modelo nunca aprendeu) não havia sido testado em um desenho pré-especificado. Tratamos a persona como fator experimental *within-subject*, e não como um confundidor não controlado.

Lacuna 3: o mecanismo de representação no corpus é afirmado, não testado para este domínio. A ligação entre representação no corpus e acurácia é assumida, mas raramente medida contra confundidores, e raramente separada em seus dois canais. Distinguimos o *tamanho do corpus da língua* (quanto texto existe no idioma de um país: volume de tokens do mC4 (Xue et al., 2021), tamanho do OSCAR (Abadji et al., 2022), classe de Joshi) da *amplitude de cobertura do país* (quão amplamente o corpus fala sobre aquele país: cobertura na Wikipédia e no Wikidata), e testamos qual deles prediz a acurácia em política de poluição do ar após ajuste pelo Índice de Desenvolvimento Humano — uma distinção que importa porque a lacuna geográfica é medida em inglês.

Objetivos e escopo

Declaramos o escopo do estudo para que o leitor possa avaliar se a evidência se aplica à sua situação. Este estudo tem três objetivos, e cada um é delimitado.

Primeiro, estabelecer um protocolo de auditoria de informação regulatória. O objeto é a concordância entre a resposta de um modelo e o valor publicado no registro oficial, para tarefas que uma agência ambiental de fato delega. Não estamos medindo capacidade geral do modelo, qualidade de raciocínio ou utilidade para qualquer finalidade que não seja recuperar e resumir a regulação em vigor. O protocolo é a contribuição que se transfere; o domínio é onde o demonstramos.

Segundo, testar as mitigações disponíveis a uma administração. Um órgão público diante de respostas ruins sobre o próprio país pode, realisticamente, fazer três coisas sem construir nada: declarar o papel oficial no prompt, perguntar no idioma nacional, ou contratar um modelo com ajuste regional. Cada uma tem custo de contratação ou de fluxo de trabalho. Testamos as três como fatores do desenho, em vez de discuti-las. Não testamos geração aumentada por recuperação, ajuste fino ou verificação humana no circuito, que exigem capacidade técnica que a maioria das agências do nosso recorte do Sul Global não tem.

Terceiro, localizar onde a confiabilidade difere e, até onde o desenho permitir, por quê. Relatamos a distribuição da acurácia entre países, tarefas e idiomas, e testamos a explicação por representação no corpus no nível em que a medida tem resolução. Não reivindicamos identificação causal de mecanismo algum, e distinguimos ao longo de todo o texto o que o desenho demonstra do que ele não alcança.

Em todo o trabalho, nossa unidade de análise é o modelo *como servido* — uma pilha de pesos, fornecedor e infraestrutura de serviço alcançada por uma API ou endpoint de inferência fixado — e não um conjunto idealizado de pesos, porque o gestor público interage com a pilha servida e qualquer lacuna medida é propriedade dessa pilha (Seção 3). Hipóteses, amostragem e plano de análise foram fixados antes da coleta (Nosek et al., 2018) para 15 países e depois estendidos a 25; o plano nunca foi depositado publicamente, de modo que não reivindicamos pré-registro, e o estudo é relatado como exploratório do começo ao fim.

Contribuições deste trabalho

Nossas contribuições são:

1. Um protocolo de auditoria de informação regulatória, não um benchmark de conhecimento geral. A pergunta de confiabilidade que uma administração enfrenta não é se o modelo escreve bem sobre política, e sim se o valor que ele devolve corresponde ao publicado no registro oficial. Construímos cinco tipos de tarefa a partir do trabalho cotidiano de uma agência ambiental: o padrão de qualidade do ar vinculante em vigor (T1), a concentração local oficialmente medida (T2), a evidência de carga de doença que uma avaliação de impacto cita (T3), os instrumentos nacionais de política e seus órgãos executores (T4), e uma recomendação aplicada para um cenário operacional (T5). Cada chave é lida de fonte oficial, de modo que a correção é adjudicável e não matéria de impressão de especialista. O protocolo se transfere a qualquer domínio regulado cuja resposta correta seja publicada:

tributário, licenciamento, saúde pública, compras.

2. As três correções de localização às quais as agências recorrem, testadas em vez de presumidas — e as três falham. Profissionais respondem a respostas ruins sobre o próprio país com três movimentos: informar ao sistema que se é a autoridade responsável, perguntar no idioma nacional, ou adotar um modelo com ajuste regional. Cada um é uma decisão de contratação ou de fluxo de trabalho com custo, e cada um circula como sabedoria recebida. Testamos os três: persona como fator experimental *within-subject*, prompt em idioma nativo contra a linha de base em inglês dentro do país, e um modelo ajustado por instrução em português brasileiro contra um modelo global de escala equivalente. Nenhum funciona, e o que um gestor tem mais chance de tentar primeiro causa dano ativo: perguntar no idioma do próprio país reduz a acurácia em cinco pontos percentuais, de forma mais acentuada no idioma com o corpus mais escasso. Este é o achado principal do estudo e sua saída mais diretamente acionável para a prática.
3. A escolha do modelo como decisão administrativa. Se uma agência roda um modelo de pesos abertos na própria infraestrutura ou contrata um modelo hospedado por fornecedor é hoje uma questão explícita de contratação (Robinson, 2026). Avaliamos catorze configurações de acesso ao longo desse espectro e tratamos a unidade de análise como o modelo *como servido*, já que uma agência contrata uma pilha servida e não um conjunto de pesos.
4. Um desenho amostral que separa quem é mal servido de por quê. Os países são estratificados ao longo de eixos independentes: a classificação Norte/Sul da UNCTAD (que operacionaliza a colonialidade (Mohamed et al., 2020)), a taxonomia de recursos linguísticos de Joshi et al. (Joshi et al., 2020), e indicadores de desenvolvimento. Isso permite distinguir explicações geográficas, linguísticas e econômicas em vez de confundi-las, o que importa para a política pública: cada uma implica um remédio diferente e um responsável diferente.
5. Um teste de mecanismo que relata os próprios limites. Testamos a representação no corpus usando proxies tanto de corpus da língua quanto de cobertura do país, com controles por correlação parcial, e relatamos que o proxy pré-especificado é defeituoso de um modo que vale sinalizar a quem já o usou: ele atribui a Wikipédia inglesa aos nove países da amostra que têm o inglês como língua oficial, de modo que indexa história colonial e não tamanho de corpus. Entre países os canais não podem ser separados de forma alguma, porque cobertura e desenvolvimento são colineares ao longo de 25 observações. Eles se separam quando a unidade de variação muda: comparar tarefas que dependem de um fato nacional contra tarefas que não dependem, dentro do mesmo país, identifica a cobertura do país como canal operante — e isso sobrevive entre os nove países cuja língua oficial é idêntica. Separamos ao longo de todo o texto o que o desenho demonstra do que ele não alcança, e a forma do gradiente ao longo da faixa de desenvolvimento permanece na segunda categoria.
6. Gabarito adjudicado por código, e o que isso muda. Onde a resposta correta de uma tarefa é um número publicado em registro oficial, o veredito é computado contra esse registro em vez de delegado a um modelo de linguagem, porque comparar um valor com uma faixa autorizada é exato e um juiz só consegue reproduzir isso com ruído. Não se trata

de detalhe de implementação. Sobre as mesmas respostas, reconstruir as chaves de duas tarefas a partir de registros oficiais e mover a comparação para código derrubou o gradiente de desenvolvimento de $\rho = 0.51$ para $\rho = 0.37$ e mais que dobrou a penalidade do idioma nativo. Nesta literatura, a chave de gabarito, e não o tamanho da amostra, é a restrição que aperta.

7. Recursos abertos. O protocolo completo, os prompts, os registros de gabarito com suas fontes oficiais, o código de análise e o registro de desvios serão liberados sob licenças CC-BY-4.0 e MIT.

Enquadramento teórico

Interpretamos nossos achados dentro do arcabouço da *colonialidade do saber* (Quijano, 2000; Mohamed et al., 2020) e de suas articulações em dados e infraestrutura (Coudry and Mejias, 2019; D’Ignazio and Klein, 2020). LLMs são sumários estatísticos comprimidos de corpora produzidos sob condições de infraestrutura digital desigual e acesso desigual à publicação. Os idiomas e as regiões que Joshi et al. situam nas classes menos atendidas são precisamente aqueles onde a poluição do ar mata mais gente (GBD 2019 Risk Factors Collaborators, 2020; Joshi et al., 2020). Quando um gestor ambiental do Sul Global consulta um modelo treinado majoritariamente em texto do Norte Global para governar um problema local de qualidade do ar, a decisão resultante corre o risco de herdar as assimetrias do corpus. Isso posiciona nosso trabalho empírico como teste de um elo do ciclo teorizado: assimetria no corpus de treinamento, assimetria de conhecimento do LLM, assimetria na decisão de política. A manipulação de persona testa se o enquadramento do prompt interrompe esse elo.

O artigo prossegue como segue. A Seção 2 posiciona nosso trabalho em relação à literatura. A Seção 3 apresenta o desenho pré-especificado. A Seção 4 relata os achados empíricos. A Seção 5 os interpreta por lentes estatística e crítica e considera implicações práticas para a governança da poluição do ar. A Seção 6 encerra.

2 Trabalhos relacionados

Organizamos a literatura prévia em quatro fios: a descoberta e medição do viés factual geográfico, extensões multilíngues e culturais, tentativas de alinhamento e mitigação, e o uso de LLMs em contextos de decisão de política e de saúde. Para cada um, indicamos como o foco em política de poluição do ar e a manipulação de persona do presente estudo estendem o fio.

2.1 Viés factual geográfico

Manvi et al. (2024) estabeleceu que LLMs de fronteira carregam vieses sistemáticos contra regiões de condições socioeconômicas mais baixas, com correlações de Spearman de até 0,70 entre avaliações geradas pelo modelo (sobre atratividade, moralidade e inteligência) e um proxy dessas condições. O espaço de desfecho (avaliações subjetivas) deixa em aberto se o mesmo viés aparece na recuperação objetiva de fatos regulatórios e epidemiológicos, que é o que a política de poluição do ar exige.

Moayeri et al. (2024) introduziu o WorldBench, quantificando recuperação factual contra indicadores do Banco Mundial em 20 LLMs e 11 indicadores e documentando erro relativo absoluto $1,5\times$ maior para a África Subsaariana em relação à América do Norte. O WorldBench também permite detecção automática de alucinação de citação, em que modelos citam o Banco Mundial ao mesmo tempo em que produzem estatísticas falsas. O desenho é limitado pelo espaço de indicadores macroeconômicos; um gestor ambiental faz perguntas mais estreitas e específicas de fonte (um padrão nacional de qualidade do ar, um prazo de fase de conformidade, uma concentração medida em uma cidade e ano) cujo gabarito reside em conselhos ambientais e agências de monitoramento, e não em uma única base agregada.

Mirza et al. (2024) (Global-Liar) estendeu a pergunta à estabilidade temporal, mostrando que versões mais novas do GPT-4 não melhoram monotonicamente e que o privilégio a afirmações do Norte Global persiste entre versões. A contribuição é temporal e intramodelo, e não entre modelos, entre idiomas ou específica de domínio.

Esses estudos estabelecem que o fenômeno existe e é mensurável. Nenhum isola um único domínio aplicado com gabarito oficial verificável, e nenhum trata o enquadramento do prompt como fator manipulável.

2.2 Extensões multilíngues e culturais

Myung et al. (2024) (BLEnD) introduziu pares de pergunta e resposta cobrindo 16 países e 13 idiomas em conhecimento cultural cotidiano. O achado de que LLMs têm desempenho melhor nos idiomas nativos de culturas com muitos recursos e pior nos de poucos recursos motiva nossa hipótese exploratória de idioma (H2) e se conecta diretamente à hierarquia de recursos de Joshi et al. (2020). Ainda assim, o BLEnD mede acurácia de conhecimento cultural, não a acurácia da recuperação regulatória e de política de saúde, e sua seleção de países não é estratificada teoricamente.

Benchmarks regionais proliferaram: BRoverbs (Almeida et al., 2025b) para provérbios brasileiros, TiEBE (Almeida et al., 2025c) para eventos históricos regionais, e ALBA (Vieira et al., 2026) e AMALIA (Simplicio et al., 2026) para português europeu. Eles documentam falhas concretas em tarefas culturalmente ancoradas, mas não tratam do uso aplicado em política pública, e cada um se limita a um ou dois idiomas. Trabalhos sobre construção de corpus em português (Almeida et al., 2025a) sublinham como snapshots do Common Crawl sub-representam conteúdo lusófono, que é a assimetria de corpus que nossa H4 testa.

2.3 Alinhamento e mitigação

Opusko and Böhm (2026) investigou se modelos de raciocínio reduzem o viés geográfico, encontrando que o raciocínio ajuda em agregado mas não elimina as disparidades regionais. Kerche et al. (2026) propôs uma tipologia de vieses de LLM baseada em lugar, situando o viés geográfico dentro de uma paisagem sociotécnica mais ampla. Essas contribuições são conceituais e agregadas; acrescentamos um teste empírico pré-especificado e específico de domínio, e introduzimos a persona como alavanca candidata de mitigação, e não como propriedade fixa do modelo.

2.4 LLMs em contextos de decisão de política e saúde

Uma literatura paralela examina o uso de LLMs em cenários específicos de política. [Le Coz et al. \(2025\)](#) avaliou recomendações de política de LLMs para situação de rua em quatro cidades (entre elas Barcelona, Joanesburgo e South Bend), encontrando “rigidez cega ao contexto”, em que os modelos aplicam heurísticas internas estáveis mal calibradas às realidades locais e se alinham mais estreitamente a especialistas do Norte Global. O resultado mostra que o viés importa para a política em um único domínio e um único tipo de tarefa (recomendação). Generalizamos para um domínio regulatório e de saúde com cinco tipos de tarefa que abrangem recuperação, síntese e recomendação, e acrescentamos a manipulação de persona, ausente naquele desenho.

Em saúde especificamente, [Kozlakidis et al. \(2026\)](#) argumenta que alucinações de LLM carregam risco agudo em ambientes regulatórios com capacidade técnica limitada, observando que a incompatibilidade linguística e cultural entre modelos treinados globalmente e a prática local aumenta o erro. A política de poluição do ar se situa na interseção desse risco com a carga de mortalidade documentada pelas estimativas do Global Burden of Disease ([GBD 2019 Risk Factors Collaborators, 2020](#)), o que torna a recuperação acurada de padrões e evidência de saúde uma questão de saúde pública, e não uma abstração de *benchmarking*.

2.5 Persona e condicionamento por papel

O condicionamento por papel ou persona não é mera prática popular: é o que os fornecedores dos modelos instruem seus próprios usuários a fazer. A Anthropic documenta a definição de papel no prompt de sistema como forma de focar comportamento e tom ([Anthropic, 2026](#)), o guia de engenharia de prompt da OpenAI abre a estrutura de mensagem recomendada com um bloco de identidade ([OpenAI, 2026](#)), e o padrão está catalogado na literatura de *prompting* ([White et al., 2023](#)). Isso faz do resultado nulo adiante uma afirmação sobre prática recomendada pelo fornecedor, e não sobre um hábito que os profissionais inventaram. Um corpo crescente de trabalhos relata que atribuir um papel de especialista pode deslocar as saídas do modelo em qualquer direção, a depender da tarefa e do domínio. A evidência sistemática é sóbria: em quatro famílias de LLM e 2.410 perguntas factuais, acrescentar personas de especialista aos prompts de sistema não melhorou a acurácia em relação a um controle sem persona, e ao longo de 162 papéis a acurácia média foi levemente *reduzida* ([Zheng et al., 2024](#)); uma replicação independente também encontra que personas de especialista não melhoram a acurácia factual ([Basil et al., 2025](#)). Se o condicionamento por persona ajuda ou prejudica a confiabilidade factual em domínios de alto risco e intensivos em conhecimento permanece, portanto, em aberto e, até onde sabemos, não testado para equidade geográfica com gabarito oficial. Tratamos assim a persona como fator experimental pré-especificado e testamos tanto a hipótese de conformidade normativa (a persona reduz a lacuna) quanto a hipótese de vácuo de persona (a persona a amplia).

2.6 IA generativa dentro da administração

A questão da adoção não é mais hipotética. [Kim \(2026\)](#) estima efeitos de produtividade burocrática da IA generativa na administração pública de forma quase-experimental, e [Robinson \(2026\)](#) documenta que escolher qual modelo uma agência roda é hoje uma decisão explícita de

contratação, ponderada entre opções de pesos abertos e hospedadas por fornecedor. Nossos dois achados no nível do modelo falam diretamente a essa decisão: os modelos de fronteira abertamente disponíveis ficam atrás dos fechados, e o modelo em português com ajuste regional é o mais fraco dos catorze que avaliamos, de modo que as duas escolhas que uma agência poderia fazer por razões de soberania ou de localidade são justamente as que mais custam acurácia.

Dois outros fios enquadram por que uma resposta errada importa administrativamente e não apenas tecnicamente. Choroszewicz (2026) mostra que ferramentas iniciais de apoio por IA generativa posicionam profissionais de linha de frente como “zonas de amortecimento moral”, absorvendo responsabilidade por falhas originadas a montante; um servidor que protocola uma nota técnica citando um limite de emissão revogado ocupa exatamente essa posição. E Cordella and Gualdi (2024), analisando a intervenção da Itália sobre o ChatGPT, argumenta que arcabouços regulatórios neutros quanto à tecnologia não alcançam os danos específicos que esses sistemas produzem, o que deixa a verificação no ponto de uso como o controle operante. A literatura sobre como tais decisões são recebidas é correspondentemente desenvolvida: Aoki et al. (2024) testa se o tipo de explicação altera a acurácia, a justiça e a confiabilidade percebidas de uma decisão algorítmica entre os que são por ela afetados.

O que nenhum desses trabalhos estabelece é se a resposta subjacente está *correta*, e se a correção se distribui de forma homogênea entre os Estados que dela dependeriam. Confiabilidade percebida e acurácia medida são quantidades distintas, e um sistema pode ser bem explicado, bem governado, bem recebido e errado. Essa é a lacuna que este estudo endereça, usando um domínio em que a resposta correta é publicada em registro oficial e pode ser conferida.

2.7 Posicionamento do presente trabalho

Nosso desenho difere do trabalho prévio de quatro maneiras concretas: (i) um único domínio aplicado de alto risco (política de poluição do ar) com gabarito oficial verificável, em vez de conhecimento numérico geral ou cultural; (ii) a persona como fator experimental *within-subject* pré-especificado, em vez de uma escolha de enquadramento não controlada; (iii) amostragem de países orientada por teoria em eixos independentes (colonialidade da UNCTAD, recurso linguístico de Joshi, desenvolvimento), em vez de conveniência regional; e (iv) um teste explícito do mecanismo de representação no corpus com análise de sensibilidade. Nenhum estudo anterior combina um domínio regulado de saúde pública, uma manipulação de persona e um teste de mecanismo pré-especificado.

3 Métodos

3.1 Desenho da pesquisa

Especificamos um experimento de benchmark pré-especificado, fatorial e multipaís, para quantificar viés geográfico e modulado por persona em 14 modelos de linguagem de grande porte em tarefas de política de poluição do ar relevantes para a gestão ambiental pública. O desenho pré-especificado cruza 15 países (estratificados em três eixos teoricamente fundamentados), 14 LLMs abrangendo cinco camadas de acesso, um domínio orientado por teoria (política de poluição do ar), 5 tipos de tarefa e 2 condições de persona (neutra versus gestor ambiental público),

com 2 replicações estocásticas por célula de prompt, modelo e persona; uma extensão post hoc (Seção 3.3) amplia a amostra para 25 países. O conjunto de estímulos cruza as cinco tarefas e as duas personas de cada país em inglês, mais uma versão em idioma nativo dentro do país para os nove países com idioma nativo alvo, pontuado no composto $[0, 1]$. O protocolo do estudo fixa, em data anterior à coleta, as hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão e as correções para múltiplas comparações. Uma coleta apenas do Brasil, executada sob um desenho anterior de três domínios, é reclassificada como piloto estendido e relatada separadamente; ela informou a calibração dos prompts, mas não contribui com observações confirmatórias.

3.2 Seleção de países

Os países foram selecionados por amostragem teórica (Patton, 2015) triangulada em três classificações independentes. Primeiro, a classificação Norte/Sul Global da UNCTAD (UNCTAD, 2024) operacionaliza o arcabouço da colonialidade do saber que motiva este estudo (Mohamed et al., 2020). Segundo, a taxonomia de seis classes de Joshi et al. (2020) de representação de recursos linguísticos em corpora de PLN forneceu uma dimensão de estratificação ortogonal (Joshi et al., 2020). Terceiro, os grupos de renda do Banco Mundial (FY26) (World Bank Group, 2025) capturaram a posição econômica de forma independente dos dois eixos anteriores.

A amostra final de 15 países — Brasil, México, Argentina, Peru (América Latina); Nigéria, África do Sul, Quênia, Egito (África); Índia, Indonésia, Bangladesh, Filipinas (Ásia); e Estados Unidos, Alemanha, Japão (referência do Norte Global) — cobre quatro regiões do mundo e quatro grupos de renda do Banco Mundial. O eixo de recursos linguísticos é muito menos diferenciado do que o marco amostral pretendia: os idiomas oficiais dominantes desses países caem em apenas três classes de Joshi, e doze dos quinze compartilham a Classe 5. Estender para 25 países não ajuda, já que dezoito dos vinte e cinco são Classe 5. Isso é uma propriedade do mundo, e não do nosso sorteio, porque os idiomas oficiais da maioria dos Estados são eles próprios de alto recurso; mas significa que o eixo linguístico tem variância pequena demais para ser separado dos demais, e tratamos os resultados de Joshi de acordo (Seção 4.6). Os doze países do Sul Global também variam em maturidade de governança doméstica da qualidade do ar, o que é relevante para a disponibilidade de gabarito (Seção 3.9). Países com governança estatística comprometida (por exemplo, conflito ativo) ou sem padrão nacional de qualidade do ar publicamente recuperável foram excluídos; Oceania e idiomas de Classe 0 de Joshi não foram representados dadas restrições de viabilidade, e isso é reconhecido como limitação de escopo.

3.3 Ampliação da amostra após a análise pré-especificada

Após a análise pré-especificada de 15 países, e *relatado aqui de forma transparente como extensão post hoc e não como parte do protocolo travado*, a amostra foi ampliada para 25 países para aumentar o poder estatístico dos testes de gradiente (H1) e de mecanismo de corpus (H4) e para multiplicar os pares de idioma dentro do país disponíveis para H2. Dez países foram acrescentados sob procedimentos idênticos de construção de prompt, gabarito, coleta e pontuação. Seis são referências do Norte Global, escolhidas puramente para ampliar a ponta de alto recurso do gradiente — Reino Unido, Canadá, Austrália, Coreia do Sul, França e Itália. Quatro são países

de par em idioma nativo que acrescentam contrastes em espanhol (Colômbia, Chile) e português (Portugal, Angola) para H2; desses, Portugal é também Norte Global, enquanto Colômbia, Chile e Angola são Sul Global. Os dois papéis se sobrepõem, de modo que, por camada, a extensão acrescenta sete países do Norte Global (as seis referências mais Portugal), elevando a célula do Norte de três para dez, e três do Sul Global, enquanto por idioma eleva os pares em espanhol de três para cinco e os pares em português de um para três. Como essa extensão foi decidida após a observação dos resultados iniciais, todo efeito computado sobre a amostra de 25 países é relatado ao lado de sua contraparte pré-especificada de 15 países, e nenhuma conclusão pré-especificada é revisada com base apenas na extensão; a ampliação é tratada como checagem de poder e robustez, não como novo teste confirmatório. Angola, como Nigéria e Argentina, *não* tem padrão nacional de PM_{2,5}, o que fornece casos adicionais sem padrão nos quais um modelo fiel deve se recusar a declarar um limiar inexistente em vez de fabricá-lo.

Para multiplicar os pares de H2 sem acrescentar novos idiomas, duas variantes adicionais de pergunta por (país, tarefa) também foram geradas para os cinco países originais com par nativo e renderizadas em inglês e no idioma nativo; essas variantes são usadas *apenas* para o contraste pareado inglês versus nativo (H2), no qual qualquer imperfeição no gabarito gerado se cancela entre os dois membros do par, e são excluídas das comparações de acurácia absoluta (H1, H3).

3.4 Covariáveis de país

Para cada país compilamos covariáveis de desenvolvimento e de representação no corpus. O Índice de Desenvolvimento Humano (IDH) (Relatório de Desenvolvimento Humano do PNUD 2023–24, dados de 2022) e o PIB per capita indexam a posição de desenvolvimento e entram na análise de mecanismo como covariáveis de ajuste.

As exposições de representação no corpus são organizadas segundo uma distinção que a análise de mecanismo (H4) torna explícita, porque os dois canais se aplicam a efeitos diferentes. As medidas de corpus da língua quantificam quanto texto de pré-treinamento existe *em* um idioma e são o mecanismo candidato para a penalidade de idioma nativo (H2): a contagem de tokens do mC4 por idioma (Xue et al., 2021, Tabela 6), o tamanho do corpus deduplicado OSCAR-2301 por idioma (Abadji et al., 2022) e a classe de recurso linguístico de Joshi (Joshi et al., 2020). As medidas de corpus do país quantificam quanto o corpus enciclopédico fala *sobre* um país, independentemente do idioma, e são o mecanismo candidato para a lacuna geográfica (H1/H4): o tamanho em bytes do artigo da Wikipédia inglesa sobre o país, o número de edições linguísticas da Wikipédia com artigo sobre ele (contagem de sitelinks do Wikidata) e o número de declarações do Wikidata sobre a entidade do país. As duas famílias não são intercambiáveis: como a lacuna geográfica é medida *em inglês* (idioma mantido constante entre países), uma lacuna Norte/Sul residual não pode ser efeito de corpus da língua, de modo que H4 isola o canal de representação do país para H1 e o canal de corpus da língua para H2. Todos os valores de covariáveis, fontes oficiais e datas de acesso estão versionados na liberação da análise.

3.5 Seleção de modelos

Catorze LLMs foram avaliados em cinco camadas de acesso, abrangendo cerca de duas ordens de magnitude em contagem de parâmetros e quatro geografias de dados de treinamento (Es-

tados Unidos, China, Europa, Brasil). A Camada A (fronteira de pesos abertos, 5 modelos) compreendeu grandes sistemas de pesos abertos acessados por endpoints gratuitos de inferência. A Camada B (pesos abertos intermediários, 3 modelos) e a Camada C (pesos abertos pequenos ou regionais, 2 modelos) foram executadas localmente via Ollama sob tags fixadas; a Camada C inclui um modelo aberto ajustado por instrução em português brasileiro (Cabra-Mistral 7B v3) usado para o teste de modelo regional (H3) contra um modelo aberto de treinamento global com escala equivalente. A Camada D (fechados acessíveis, 2 modelos) e a Camada E (fronteira fechada, 1 modelo) foram acessadas por APIs oficiais. Cada modelo foi consultado com uma string de versão ou tag fixada e idêntica ao longo de toda a janela de coleta; tags e, quando disponíveis, hashes de pesos são registrados na liberação do protocolo para proteger contra atualizações de modelo no meio da coleta. O rol completo de modelos, com fornecedor, contagem de parâmetros, rota de acesso e backend de execução, está na Tabela S1 do material suplementar.

Uma nota sobre a unidade de análise. Comparamos *modelos como servidos* por uma pilha de acesso fixa (API oficial do fornecedor para modelos fechados; endpoint de inferência fixado para modelos de pesos abertos), e não pesos idealizados isoladamente. A infraestrutura do provedor, a configuração de serviço e a camada de API são, portanto, parte do que cada rótulo denota, e uma lacuna residual poderia, em princípio, refletir a pilha e não os pesos. Mantemos isso constante fixando strings de versão e tags e a configuração de máxima determinicidade disponível por provedor ao longo de uma janela de coleta fixa, e tratamos “modelo” ao longo do texto como abreviação dessa pilha servida; separar pesos de infraestrutura é uma questão distinta que não pretendemos resolver.

3.6 Domínio e taxonomia de tarefas

O domínio único é a política de poluição do ar, escolhido porque se ancora em gabarito oficialmente publicado e verificável (padrões nacionais de qualidade do ar, dados de monitoramento de agências ambientais, programas federais de controle) e se mapeia a atividades concretas de decisão de um gestor ambiental público. Cinco tipos de tarefa operacionalizam o domínio:

- T1 — Padrão técnico. Recuperação de padrões vinculantes de qualidade do ar, limites de emissão ou limiares regulatórios (por exemplo, o padrão de média anual de PM_{2,5} em vigor no país).
- T2 — Dado factual local. Recuperação de dados de qualidade do ar oficialmente medidos para uma cidade ou região e ano especificados, conforme reportado pela agência ambiental nacional ou subnacional.
- T3 — Síntese de evidência em saúde. Síntese de evidência epidemiológica revisada por pares sobre a carga de saúde da poluição do ar no país, pontuada contra rubrica em vez de valor único.
- T4 — Instrumentos de política. Identificação de programas de política, órgãos executores e instrumentos legais de controle da poluição do ar em vigor no país.
- T5 — Recomendação aplicada. Recomendação aplicada pontuada por rubrica para um

cenário operacional definido (por exemplo, resposta de curto prazo a um episódio de alta concentração sob inversão térmica).

T1, T2 e T4 admitem gabarito verificável e carregam o sinal primário de acurácia; T3 e T5 são tarefas de geração aberta pontuadas por rubrica. O mapeamento de país por tarefa das classes de fonte oficial, dos critérios de equivalência e do estatuto de verificabilidade está especificado no registro de gabarito (Seção 3.9).

3.7 Manipulação de persona

A persona é um fator dentro do prompt com dois níveis, e a manipulação não é arbitrária: atribuir um papel no prompt de sistema é a prática que os próprios fornecedores dos modelos documentam e recomendam. A Anthropic instrui desenvolvedores a definir um papel no prompt de sistema, afirmando que mesmo uma única frase muda o comportamento (Anthropic, 2026); o guia da OpenAI pede um bloco de “Identidade” descrevendo o propósito e o papel do assistente antes da própria tarefa (OpenAI, 2026); e a prática está catalogada como Padrão de Persona na literatura de padrões de prompt (White et al., 2023). Um órgão público que siga a documentação do próprio fornecedor chega, portanto, exatamente à manipulação que testamos. A condição neutra apresenta a consulta como pedido simples de informação. A condição `public_manager_env` antepõe um enquadramento de papel fixo identificando quem pergunta como autoridade municipal ou regional de gestão ambiental, mantendo a pergunta substantiva idêntica entre condições. Um único modelo de enquadramento de papel é aplicado de forma uniforme entre países e tarefas (traduzido quando o idioma do prompt não é o inglês), de modo que qualquer diferença entre condições seja atribuível ao enquadramento de persona e não à redação da pergunta. A ordem das personas dentro de cada célula de prompt e modelo é aleatorizada, e uma checagem de manipulação verifica se o enquadramento de papel é reconhecido na resposta. A redação exata, o procedimento de tradução e a codificação da checagem de manipulação são pré-especificados e reproduzidos no material suplementar. A persona é a base da hipótese H6, que testa se o enquadramento de papel reduz (ou amplia) o gradiente de acurácia no nível do país.

3.8 Construção e validação dos prompts

Os prompts foram elaborados para o domínio de política de poluição do ar pela equipe de pesquisa com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrar no conjunto confirmatório de estímulos. O plano de análise previa um piloto de 50 prompts pontuado por dois avaliadores humanos independentes, com α de Krippendorff ≥ 0.70 exigido antes de escalar o desenho. *Esse piloto não foi executado*, e não existe α em nível de avaliador para este estudo. A confiabilidade da rubrica é, em vez disso, evidenciada a posteriori, sobre os dados confirmatórios, por um painel de juízes de três fornecedores sobre todo item que exigiu juiz (Seção 4.11), o que retorna $\alpha = 0.527$, abaixo do limiar que o plano havia estabelecido. Relatamos isso como desvio em relação ao plano, e não como limiar atingido. Todos os prompts foram elaborados em inglês e, para um subconjunto estratificado de países, adicionalmente em um idioma nativo relevante (matriz multilíngue esparsa; Seção S3 do suplemento); as versões em idioma nativo foram produzidas por um tradutor LLM de alta qualidade

(Claude Sonnet 4.6) instruído a preservar o significado, o enquadramento de persona e nomes próprios e siglas, mantendo o gabarito factual em inglês (o valor alvo é invariante ao idioma). Não empregamos tradutores humanos nativos, o que permanece uma limitação (Seção 5). Auditamos, contudo, as versões a posteriori, retrotraduzindo todos os 90 prompts nativos com um modelo diferente e fazendo dois outros modelos compararem cada retrotradução com o original em inglês (Seção 4.4). Após a validação do piloto brasileiro, exigiu-se que toda afirmação factual em uma entrada de gabarito resolvesse para uma URL de fonte oficial ou um DOI revisado por pares antes que o prompt correspondente fosse admitido, aplicando o Protocolo de Verificação de Citações do projeto já na etapa de geração do gabarito, e não apenas na etapa de manuscrito.

3.9 Gabarito e registro de gabarito

O gabarito para as tarefas verificáveis (T1, T2, T4) foi extraído de fontes oficiais de registro: padrões nacionais de qualidade do ar e os órgãos que os editam (T1), relatórios de monitoramento de agências ambientais (T2), e programas federais de política com seus órgãos executores e instrumentos legais (T4). Para T3, a referência é um conjunto curado de estudos epidemiológicos revisados por pares com DOIs resolvíveis, e não um número único. Como a validade do gradiente geográfico (H1) e do efeito de persona (H6) depende de o gabarito estar igualmente disponível e igualmente verificável em todos os países, construímos um registro de gabarito por país que, para cada par (país, tarefa), anota a classe de fonte oficial equivalente, a URL resolvível, o valor de referência ou a chave de rubrica, a data de referência, o validador humano e uma marcação de validação. O desenho do registro, os critérios de equivalência entre países e a separação explícita entre uma lacuna de conhecimento da IA e uma lacuna de disponibilidade de gabarito estão documentados em `docs/ground_truth_registry_design.md` e resumidos no material suplementar. As entradas são versionadas por data de acesso, URL de fonte e hash SHA-256 do documento recuperado. Onde o gabarito poderia plausivelmente ter aparecido em dados de treinamento, constrói-se um subconjunto de sensibilidade a partir de documentos datados após o corte de treinamento de cada modelo. Entradas cuja fonte oficial é indisponível ou não equivalente para um país são marcadas e excluídas da comparação primária de acurácia para a célula (país, tarefa) afetada, de modo que gabarito ausente nunca seja pontuado como erro do modelo.

3.10 Coleta de dados

Chamadas de API e locais foram executadas a temperatura 0.3 com sementes determinísticas onde disponíveis, com 2 replicações por combinação de prompt, modelo e persona para estimar variabilidade estocástica dentro do orçamento. A coleta ocorreu em janela fixa para minimizar confundimentos por atualização de modelo, com a tag fixada, a string de versão e o carimbo de tempo de aquisição registrados para cada chamada; como o comportamento de um modelo servido pode derivar à medida que fornecedores atualizam infraestrutura, as acurácias relatadas são estimativas pontuais no tempo relativas a essa janela, e as datas completas de aquisição por provedor são liberadas com o conjunto de dados. Todas as respostas foram armazenadas junto com metadados completos da requisição (string ou tag de versão do modelo, carimbo de tempo, contagens de tokens, motivo de término, condição de persona) em uma camada de

armazenamento versionada com somas de verificação SHA-256. Gates de qualidade de resposta excluíram respostas truncadas (`finish_reason` $\neq$ `stop`) e respostas em idioma divergente do solicitado; ambas foram retidas e analisadas separadamente como desfechos secundários.

A cobertura por célula não é uniforme ao longo do rol de modelos: endpoints gratuitos e com limitação de taxa (por exemplo, o GPT-OSS 120B via um provedor de inferência compartilhado) retornaram menos respostas admissíveis do que as APIs medidas, de modo que o N pontuado varia de cerca de 300 a 780 respostas por modelo. Relatamos o N realizado de cada modelo ao lado de sua pontuação (Tabela 1) em vez de descartar silenciosamente células sub-cobertas, e uma matriz completa de cobertura por modelo, país e tarefa, com os motivos de cota e exclusão para cada falta, é fornecida no material suplementar para que nenhuma ausência fique escondida.

3.11 Medidas

A pontuação atribui a cada tarefa o instrumento mais confiável que ela admite, e não é o mesmo instrumento em toda parte.

Onde a resposta é um número em registro oficial, quem decide é o código. Para T2 (uma concentração medida em cidade e ano) e T3 (uma estimativa de mortalidade atribuível), o valor devolvido é extraído e comparado com a faixa autorizada do registro por um pontuador determinístico, com salvaguardas de plausibilidade que rejeitam extrações implausíveis — um ano de quatro dígitos lido como contagem de óbitos, ou uma população nacional lida como número de mortes. Comparar um valor com uma faixa é exato, e um modelo de linguagem a quem se pede a mesma aritmética só consegue reproduzi-la com ruído. O código resolve 62.5% das células de T2 e 83.6% das de T3; o restante são aquelas em que nenhum valor pôde ser extraído com confiança.

Onde é preciso julgamento, um painel de três fornecedores decide pela média. O resíduo de T2 e T3, junto com toda a T4, é pontuado por Gemini 2.5 Pro (Google), Claude Sonnet 4.6 (Anthropic) e DeepSeek-V3 (DeepSeek), escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infle a concordância aparente. A pontuação relatada é a média dos três. T1 e T5 retêm as pontuações do juiz único original (GPT-5-mini), T1 porque sempre teve gabarito oficial e T5 porque é um julgamento por rubrica sem registro contra o qual conferir.

O protocolo original usava um único juiz primário (GPT-5-mini) para todas as tarefas, o que duas medições tornam insustentável. Juízes diferem substancialmente em severidade, e a confiabilidade de juiz único é de apenas $ICC(2,1) = 0.56$ contra $ICC(2,3) = 0.79$ para a média do painel (Seção 4.11); o juiz único também estava, ele próprio, entre os modelos avaliados. A confiabilidade é relatada de três formas: o α de Krippendorff (coeficiente de concordância entre avaliadores, 1 = perfeita, 0 = acaso), o $ICC(2,1)$ de juiz único, e, como quantidade operante, a confiabilidade $ICC(2,3)$ da média do painel. Uma correlação intraclasse responde a uma pergunta prática: se outro juiz tivesse pontuado a mesma resposta, quanto a nota teria se deslocado? Valores próximos de 1 significam que a nota é propriedade da resposta; valores próximos de 0 significam que ela é propriedade de quem por acaso pontuou. Promediar vários juízes eleva esse número mesmo quando cada um deles concorda apenas moderadamente com os demais, e é por isso que a média do painel é aqui a quantidade operante e um juiz único não é. Os três valores são computados sobre todos os itens que o painel pontuou, e não sobre um subconjunto de calibração. Um membro do painel (DeepSeek-V3) é também um modelo avaliado; testamos

diretamente o autofavorecimento e relatamos o resultado. Este estudo não incluiu uma camada humana de padrão-ouro; o gabarito foi, em vez disso, ancorado em fontes oficiais primárias por auditoria documental (Seção 3.9), e a ausência de pontuação humana independente é declarada como limitação.

O desfecho composto primário combina os cinco subcomponentes pré-especificados (ver Seção S6 do suplemento), cada um normalizado para $[0, 1]$: (i) acurácia factual contra a entrada do registro (binária em T1; crédito parcial em T2–T4); (ii) completude contextual pontuada contra rubrica pré-validada (T3, T4, 0–5); (iii) qualidade de citação, pontuada contra o registro verificado por DOI e fonte oficial; (iv) ausência de alucinação, codificada de forma binária (0 alucinado, 1 fiel); e (v) validade aplicada, a nota de rubrica para a recomendação operacional em T5. O composto primário usa uma ponderação pré-especificada (factual 0.30, contextual 0.25, citação 0.15, calibração 0.15, alucinação 0.15). Como análise de sensibilidade, recomputamos cada efeito principal sob duas ponderações alternativas — pesos iguais e uma ponderação derivada por ACP (o primeiro componente principal dos cinco subcomponentes) — e tratamos uma conclusão como robusta apenas se sua direção for estável nas três (Seção 4.12). O composto é computado por célula (país, modelo, persona) para viabilizar o teste de diferença em diferenças de H6.

3.12 Estratégia analítica

Os três testes primários são pré-especificados como uma única família (F1) e corrigidos em conjunto pelo procedimento de Bonferroni-Holm. Testar várias hipóteses ao mesmo tempo eleva a chance de que uma delas pareça significativa por acaso; essa correção eleva a barra na mesma medida, de modo que um resultado que lhe sobrevive dificilmente é esse acaso. Testes secundários (F2) são relatados sem ajuste dentro da família, e testes declarados exploratórios (F3) usam FDR de Benjamini-Hochberg a $q = 0.10$ (Benjamini and Hochberg, 1995).

H1 (gradiente geográfico, primária). A acurácia composta média por país ($n = 15$) é regredida sobre o gradiente de Joshi/IDH via ρ de Spearman (correlação de postos), pré-especificada unilateral com limiar $\rho \geq 0.55$ a $\alpha = 0.05$, com um teste de Mann-Kendall (teste não paramétrico de tendência monotônica) como complemento obrigatório de não monotonicidade e uma variável indicadora de Sul Global como contraste de sensibilidade.

H4 (mecanismo de representação no corpus, primária). O ρ parcial de Spearman no nível do país relaciona representação no corpus e acurácia após ajuste por IDH e log do PIB per capita, usando contagens da Wikipédia como proxy primário pré-especificado ($\rho \geq 0.55$), complementado por proxies exploratórios de cobertura do país (sitelinks e declarações do Wikidata). A robustez dos efeitos geográficos sustentados a confundimento não medido é quantificada com E-values (VanderWeele and Ding, 2017) (Seção 4.12).

H6 (efeito de persona, primária). O efeito de persona é testado como diferença em diferenças no nível do país sobre o desfecho composto: $\Delta_{SG} = \overline{\text{personā}}_{SG} - \overline{\text{neutrā}}_{SG}$ e $\Delta_{NG} = \overline{\text{personā}}_{NG} - \overline{\text{neutrā}}_{NG}$, com estatística de H6 $\Delta_{SG} - \Delta_{NG}$. H6 é sustentada (unilateral, $\alpha = 0.05$) se a condição de persona reduzir a lacuna do Sul Global em ao menos 0.05 no composto $[0, 1]$ (equivalentemente, 5 pontos percentuais de acurácia absoluta). A inferência usa um teste de permutação no nível do país (5.000 permutações) relatado ao lado de um teste pareado paramétrico; o teste bilateral

é relatado como checagem secundária porque a amplificação por persona é teoricamente possível e é relatada de forma transparente se observada.

H3 (modelo regional, secundária). H3 é testada com contraste unilateral pré-especificado de Mann-Whitney (tamanho de efeito δ de Cliff) comparando o Cabra-Mistral 7B v3 aos demais modelos nas tarefas de política de poluição do ar.

H2 e H5 (exploratórias). A interação idioma do prompt por país (H2) e o contraste entre fronteira aberta e fronteira fechada (H5) são relatados descritivamente, com testes formais sob correção F3 onde aplicados.

Como corroboração transversal da lacuna de camada, um modelo linear misto gaussiano (o estimador MixedLM do `statsmodels`, REML) regride o composto sobre o indicador de Sul Global (ajustando por IDH centrado) com interceptos aleatórios cruzados para país e modelo, com ajustes de agrupamento único apenas por país e apenas por modelo como checagens numéricas. Análises de robustez pré-especificadas incluem reestimação *leave-one-country-out*, uma checagem de restrição de amplitude e a sensibilidade de ponderação do composto descrita acima (Seção 4.12); a robustez dos efeitos geográficos sustentados a confundimento não medido é resumida com E-values. Também reestimamos o efeito de Sul Global em um modelo hierárquico bayesiano (`pymc` (Abril-Pla et al., 2023), prioris fracamente informativas, interceptos cruzados de país e modelo), e sondamos o mecanismo de corpus com um modelo exploratório de mediação no nível do país (`semopy` (Igolkina and Meshcheryakov, 2020); IDH $\rightarrow$ cobertura do país (sitelinks) $\rightarrow$ acurácia, com intervalo de confiança bootstrap sobre o efeito indireto). A manipulação de persona é caracterizada por uma checagem de reconhecimento do enquadramento de papel no texto da resposta. Uma análise de poder *a priori* na etapa de planejamento, sob tamanhos de efeito informados pelo piloto, indicou poder familiar adequado para o trio primário sob Bonferroni-Holm e uma redução mínima detectável da lacuna de persona de alguns pontos percentuais; os detalhes de poder constam do plano de análise pré-especificado.

3.13 Protocolo do estudo e ciência aberta

O protocolo completo — hipóteses, prompts com hashes, o registro de gabarito, o modelo de persona, as rubricas de pontuação, as especificações de modelo misto e de diferença em diferenças, as correções para múltiplas comparações e os critérios de exclusão — é pré-especificado antes da coleta confirmatória. O conjunto analítico, após os gates de qualidade mas antes do ajuste dos modelos, é congelado e hashado para que a análise confirmatória possa ser auditada contra a especificação travada. O protocolo completo, os prompts, as referências de gabarito, o código de análise e os dados de resposta anonimizados serão liberados na publicação sob CC-BY-4.0 (dados e prompts) e Licença MIT (código) (Rover et al., 2026); um artigo de dados complementar está em preparação para a *Scientific Data*.

4 Resultados

Nota sobre a amostra. Relatamos um benchmark *pré-especificado de 15 países* e sua *extensão post hoc para 25 países* (esta acrescenta seis referências do Norte Global — Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália — e quatro países de par nativo — Colômbia, Chile, Portugal, Angola). Catorze LLMs são pontuados em cinco tarefas, duas personas e quatro idiomas (inglês mais um idioma nativo do país — espanhol, português ou hindi — para os nove países aplicáveis, o que dá os pares inglês/nativo dentro do país que testam H2). Todo efeito computado sobre a amostra de 25 países é relatado ao lado de seu valor pré-especificado de 15 países; nenhuma conclusão pré-especificada é revisada apenas com base na extensão. A pontuação é adjudicada por código sempre que a resposta é um número conferível contra registro oficial, e pela média de um painel de juízes de três fornecedores nos demais casos (Seção 4.11); o gabarito de T1 está ancorado em fontes oficiais primárias para todos os 25 países (Seção 4.9).

4.1 Amostra e pontuação

O corpus analisado compreende 9.251 respostas pontuadas no composto $[0, 1]$, das quais 7.580 são respostas a prompts em inglês nos 25 países (o restante são os pares em idioma nativo dentro do país usados para H2).

A pontuação é atribuída pelo instrumento mais confiável que cada tarefa admite. Para T2 e T3, em que a resposta correta é um número publicado em registro oficial, o veredito é computado por código contra esse registro: comparar um valor devolvido com uma faixa autorizada é exato, e um modelo de linguagem a quem se pede a mesma aritmética só consegue reproduzi-la com ruído. O código resolve 62.5% de T2 e 83.6% de T3; o resíduo, junto com toda a T4, é pontuado pela média de um painel de três fornecedores (Gemini 2.5 Pro, Claude Sonnet 4.6, DeepSeek-V3). T1 e T5 mantêm suas pontuações originais, T1 porque sempre teve gabarito oficial e T5 porque é julgamento por rubrica sem registro contra o qual conferir. No total, 5.373 células carregam pontuação corrigida.

A média do painel substitui o desenho de juiz único do protocolo original, no qual o juiz (GPT-5-mini) estava ele próprio entre os modelos avaliados. Duas medições justificam a mudança. Os juízes diferem acentuadamente em severidade — composto médio de 0.617 para o Gemini, 0.451 para o Claude e 0.379 para o DeepSeek —, de modo que um juiz único fixa um nível arbitrário; e a confiabilidade de juiz único é de apenas $ICC(2, 1) = 0.56$ contra $ICC(2, 3) = 0.79$ da média do painel (Seção 4.11). Um membro do painel (DeepSeek-V3) é também um modelo avaliado, então checamos diretamente o autofavorecimento: o DeepSeek pontua as próprias saídas de forma *mais* severa em relação aos outros dois juízes (-0.177) do que pontua as de qualquer outro modelo (-0.123 a -0.160), de modo que sua própria posição no ranking não é artefato de julgar a si mesmo.

4.2 Acurácia por modelo

A Tabela 1 ordena os 14 modelos pelo composto médio. Sistemas de fronteira lideram e modelos pequenos de pesos abertos ficam atrás. O resultado que incide sobre H3 é inequívoco: o modelo regional em português brasileiro Cabra-Mistral 7B é o *mais fraco* de todos (0.347 contra 0.549 para os demais; Mann-Whitney $p \approx 0$, δ de Cliff = -0.47). O δ de Cliff tem leitura direta: é a

probabilidade de uma resposta sorteada de um grupo superar uma sorteada do outro, reescalada para variar de -1 a $+1$. Um valor de -0.47 significa que o modelo regional perde cerca de três dessas comparações para cada uma que ganha. Isso contradiz o enquadramento otimista de H3, segundo o qual um modelo regional compraria acurácia de domínio. Escala e treinamento de fronteira dominam o ajuste regional por instrução no patamar de 7B.

Tabela 1: Acurácia composta por modelo nos 25 países (adjudicada por código onde a resposta é valor de registro, média do painel nos demais casos; $[0, 1]$). N = respostas pontuadas a prompts em inglês.

Modelo	N	Média
DeepSeek-V3	500	0.680
GPT-5	780	0.672
Gemini 2.5 Flash	490	0.624
GPT-5-mini	777	0.617
Claude Haiku 4.5	490	0.580
Qwen3 32B	498	0.553
Command R+	500	0.526
Llama 3.3 70B	474	0.507
Llama 4 Scout	500	0.492
Qwen3 14B	500	0.480
GPT-OSS 120B	298	0.479
Phi-4 14B	500	0.473
Llama 3.1 8B	777	0.437
Cabra-Mistral 7B	496	0.347

4.3 Acurácia por tarefa: o piso de recuperação

A dificuldade depende fortemente da tarefa (Tabela 2). A tarefa mais difícil por larga margem é a T1 (recuperação do padrão técnico, 0.367) — aquela que exige devolver o padrão nacional de média anual de $PM_{2.5}$ em vigor. A tarefa de recomendação aberta (T5) tem a maior pontuação (0.773) porque sua rubrica premia conselho de política plausível e bem estruturado, que não depende de um fato único. Agrupando as duas tarefas de recuperação (T1, T2; média 0.417) contra síntese e recomendação (T3–T5, 0.623), a diferença é grande (Mann-Whitney $p \approx 0$, δ de Cliff = -0.47 , novamente cerca de três derrotas para cada vitória). Os LLMs são mais fracos exatamente onde a gestão ambiental aplicada mais precisa deles: recuperar o limiar regulatório preciso em vigor.

A correção do gabarito é ela própria informativa aqui, e oferece uma checagem interna. A T1 sempre teve gabarito oficial, e sua pontuação não se move (0.367 antes e depois). A T2 era antes pontuada contra uma chave de preenchimento, e sobe de 0.368 para 0.467 assim que cada concentração devolvida passa a ser comparada por código com a faixa autorizada. A correção, portanto, moveu exatamente a tarefa cujo gabarito era defeituoso e não tocou naquela cujo gabarito era sólido, que é o comportamento esperado se a correção estiver certa. Isso também revisa a leitura anterior: o piso é real, mas mais raso do que se relatava, e está concentrado na recuperação normativa (T1) em vez de dividido igualmente com a recuperação de dado local (T2).

Tabela 2: Acurácia composta por tipo de tarefa (25 países). T2 e T3 são adjudicadas por código onde o valor devolvido é conferível contra o registro oficial; T4 é pontuada por painel; T1 e T5 mantêm suas pontuações originais.

Tarefa	N	Média
T5 (recomendação aplicada)	1.508	0.773
T3 (síntese de evid. em saúde)	1.519	0.560
T4 (instrumentos de política)	1.494	0.534
T2 (dado factual local)	1.530	0.467
T1 (padrão técnico)	1.529	0.367

4.4 H2 — perguntar no idioma local reduz a acurácia

O resultado mais forte do estudo é o seguinte.

Para os nove países com idioma nativo alvo (Brasil/Portugal/Angola → português; México/Argentina/Peru/Colômbia/Chile → espanhol; Índia → hindi), cada prompt é renderizado em inglês e no idioma nativo, mantendo o conteúdo fixo, de modo que o contraste inglês/nativo é dentro do país e dentro do modelo. As replicações são promediadas dentro de cada célula (modelo, prompt) antes do pareamento, porque parear replicação a replicação inflaria o n pelo número de replicações e tornaria o teste anticonservador. Nas 839 células casadas, o prompt em idioma nativo *reduz* a acurácia composta média em 4.8 pontos percentuais (Wilcoxon de postos sinalizados $p = 3 \times 10^{-15}$).

A penalidade acompanha o nível de recurso do idioma, e as três são agora significativas (Tabela 3): hindi -11.1 pp ($p = 5 \times 10^{-4}$), espanhol -4.4 pp ($p < 10^{-4}$), português -3.9 pp ($p = 2 \times 10^{-4}$). A Índia, que tem a maior pontuação entre os 25 países em inglês, é a que mais cai em hindi. O efeito sobrevive a toda ponderação alternativa do composto (-4.7 pp sob pesos iguais, -5.4 pp apenas no subcomponente factual), de modo que não é artefato de como os cinco subcomponentes são combinados.

Testamos a robustez do efeito de H2. Como H2 carrega a afirmação central do estudo, tentamos fazê-lo desaparecer em vez de confirmá-lo. Ele não é impulsionado por nenhum país em particular (*leave-one-out* sobre os nove países de par nativo: -4.2 a -5.2 pp, todos significativos), por nenhum modelo em particular (*leave-one-out* sobre catorze: -4.2 a -5.1 pp, todos significativos), nem por células extremas (aparando 5% de cada cauda: -4.3 pp, $p = 5 \times 10^{-19}$). Ele aparece em todas as tarefas, inclusive na de rubrica, e sob ambas as condições de persona. Separando por instrumento de pontuação, no entanto, ele atinge significância apenas no subconjunto pontuado pelo painel (-4.8 pp, $p = 2 \times 10^{-8}$, $n = 235$) e não nos dois menores — o juiz original (-2.5 pp, $p = 0.22$, $n = 361$) e as células adjudicadas por código (-1.7 pp, $p = 0.29$, $n = 148$). Retomamos isso adiante, porque a divisão tem causa específica e o efeito agregado que ela decompõe tem $p = 3 \times 10^{-15}$.

Também testamos um desfecho que não depende de juiz. Um leitor pode razoavelmente suspeitar de que juízes que são modelos de linguagem penalizem texto não inglês por razões de estilo, e não de conteúdo. Testamos, portanto, um desfecho binário que nenhum juiz toca: a resposta contém um valor que o extrator consegue recuperar e comparar com o registro? Em células casadas (modelo, prompt), prompts em inglês produzem valor verificável em 66.4% das vezes e prompts em idioma nativo em apenas 48.7%, uma diferença pareada de -17.7 pp; a versão

nativa é pior em 122 dos 182 pares discordantes (teste de sinais $p = 5 \times 10^{-6}$), e a ordenação por idioma é a mesma (hindi -50.0 pp, espanhol -25.5 , português $+1.2$). Perguntar no idioma local não apenas reduz uma nota julgada — torna o modelo substancialmente menos propenso a devolver um número conferível.

A possibilidade de artefato de tradução foi testada diretamente. Os prompts nativos foram produzidos por um tradutor LLM, o que levanta a única objeção que as pontuações sozinhas não respondem: talvez os modelos não respondam pior no idioma, e o prompt nativo simplesmente pergunte outra coisa. Testamos isso diretamente em todos os 90 prompts nativos únicos — um censo, não uma amostra — retrotraduzindo cada um para o inglês com um modelo *diferente* daquele que produziu a tradução, e fazendo dois outros modelos auditarem a retrotradução contra o prompt original em inglês em cinco itens concretos. As discordâncias foram resolvidas de forma conservadora: bastava um auditor apontar um item para o prompt ser marcado como divergente.

Nos dois itens que de fato poderiam confundir o efeito, a fidelidade é completa: nenhum prompt mudou o país e nenhum mudou a quantidade solicitada (90/90 em ambos). A mesma pergunta é feita em 88/90 e o enquadramento de persona é preservado em 89/90. O item que falhou com frequência (56/90) é o de detalhe acrescentado ou omitido, e suas falhas são em larga medida estilísticas — a mais comum foi uma retrotradução acrescentar uma instrução de “responda brevemente” ausente do original. Sob critério de consenso, exigindo que ambos os auditores apontem um item, 88/90 prompts são fiéis.

Restringir H2 aos prompts verificados como fiéis o deixa essencialmente inalterado: -4.5 pp ($p = 9 \times 10^{-8}$, $n = 541$ células) contra -5.2 pp entre os divergentes, uma diferença de 0.6 pp que não é ela própria distinguível de zero (permutação $p = 0.42$). A fidelidade da tradução não prediz o tamanho da penalidade, que é o que se esperaria se a tradução não a estivesse causando.

Isso também explica o único ponto em que o efeito composto é mais fraco. Entre as células adjudicadas por código, a penalidade é de -2.2 pp e não significativa; mas o código só adjudica onde existe um número, de modo que aquele subconjunto está condicionado a o modelo ter produzido um valor em *ambos* os idiomas, o que seleciona para fora o modo de falha mais severo. O subconjunto também tem poder insuficiente para um efeito desse tamanho (poder de 0.18 em 2 pp e de 0.80 em 5 pp, $n = 183$).

A implicação aplicada é direta, e é o oposto da intuição. Um gestor que suspeita que um modelo em inglês serve mal ao seu país, e responde perguntando no idioma nacional, torna a resposta *pior* — e pior por margem maior justamente onde o idioma é menos representado nos corpora de treinamento. Tomado com H6 adiante e com o resultado do modelo regional acima, os três remédios de localização falham juntos, e este prejudica ativamente. Isso é coerente com a hierarquia de recursos linguísticos (Joshi et al., 2020) e com o canal de corpus da língua de H4.

4.5 H6 — a persona não estreita a lacuna geográfica

O fator persona foi plenamente cruzado, de modo que H6 é testada como diferença em diferenças. O enquadramento de gestor ambiental público deixa a lacuna Norte/Sul essencialmente inalterada: $+4.7$ pp sob o enquadramento neutro contra $+5.4$ pp sob o de gestor, uma DiD de $+0.6$ pp, muito abaixo do limiar pré-especificado de 5 pp; um teste de permutação no nível do país (5.000

Tabela 3: H2: acurácia nativa menos inglesa por idioma nativo (pareada dentro de país e modelo, replicações promediadas dentro da célula, amostra de 25 países).

Idioma nativo (classe Joshi)	Países	Δ (pp)	p	N células
Espanhol (5)	MEX, ARG, PER, COL, CHL	-4.4	$< 10^{-4}$	457
Português (4)	BRA, PRT, AGO	-3.9	2×10^{-4}	311
Hindi (4)	IND	-11.1	5×10^{-4}	71
Geral		-4.8	3×10^{-15}	839

permutações do rótulo de camada) dá $p = 0.27$. H6 não é sustentada: apresentar a consulta como vinda de um gestor ambiental público não estreita nem amplia a desvantagem do Sul Global, coerente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Uma checagem de manipulação encontra que 50.2% das respostas na condição de persona reconhecem explicitamente o enquadramento de papel, de modo que o nulo não é artefato de o enquadramento ser universalmente ignorado.

4.6 H1 — uma lacuna de camada que se sustenta, um gradiente que não

H1 foi pré-especificada em duas partes, e agora elas se separam com clareza: uma se sustenta e a outra não.

A lacuna de camada se sustenta. Os dez países do Norte Global têm média de 0.570 contra 0.520 dos quinze países do Sul Global, uma lacuna de +5.1 pontos percentuais cujo intervalo bootstrap de 95% entre países é [+1.6, +8.5] pp e *exclui o zero*. Ela é estável à remoção de qualquer país isolado (amplitude *leave-one-out* [+4.5, +6.0] pp) e à ponderação do composto (+4.2 pp sob pesos iguais, +8.8 pp apenas no subcomponente factual, onde se amplia).

Onde a lacuna mora, e por que o composto a subestima. O composto promedia cinco tarefas, e a lacuna não se distribui igualmente entre elas. Reestimar o mesmo contraste como modelo misto binomial em cada tarefa separadamente — desfecho codificado como devolver o valor de registro, com interceptos aleatórios cruzados para país e modelo — mostra a desvantagem escalando com o quanto a tarefa depende de um fato específico daquele país (Tabela 4). No padrão nacional vinculante (T1), a chance de resposta correta do Sul Global é 0.23 da chance do Norte (52.0% contra 29.4% em taxa bruta), e nos instrumentos de política (T4), 0.34; na síntese de evidência em saúde (T3), em que a resposta é uma estimativa internacional e não nacional, a razão sobe para 0.67; e na recomendação aberta (T5), a única tarefa sem valor de registro a acertar, a lacuna desaparece por completo.

Esta é a qualificação mais importante da lacuna de camada, em qualquer direção. A lacuna não é fraca — ela é *concentrada*, e o composto a dilui ao promediar as tarefas em que ela é severa com uma tarefa em que ela não existe. Na pergunta que um gestor público mais frequentemente traz a esses sistemas, qual é o padrão em vigor aqui, um país do Sul Global é servido a aproximadamente um quarto das chances de um país do Norte.

O gradiente monotônico não se sustenta. Em $n = 25$, o ρ de Spearman entre acurácia e IDH é de +0.36 e não atinge significância ($p = 0.073$), e tampouco a tendência de Mann-Kendall ($p = 0.072$). No $n = 15$ pré-especificado ele está essencialmente ausente ($\rho = +0.08$). Nenhuma reestimação *leave-one-country-out* alcança o limiar pré-especificado de $\rho \geq 0.55$ (am-

Tabela 4: Chances do Sul Global contra o Norte Global de devolver o valor de registro, por tarefa. Modelo misto binomial, interceptos aleatórios cruzados para país e modelo.

Tarefa	A resposta é	NG	SG	RC	Intervalo 95%
T1 (padrão técnico)	um valor nacional	52.0%	29.4%	0.23	[0.19, 0.28]
T4 (instrumentos)	instrumentos nacionais	63.1%	48.5%	0.34	[0.28, 0.41]
T2 (dado medido local)	um valor nacional	50.1%	38.6%	0.51	[0.43, 0.59]
T3 (síntese de evid. saúde)	estimativa internac.	59.9%	53.5%	0.67	[0.59, 0.78]
T5 (recomendação aplicada)	nenhum valor de reg.	99.6%	99.7%	2.67	[0.80, 9.00]

plitude $[+0.31, +0.49]$, e nenhuma ponderação alternativa tampouco ($\rho = +0.31$ tanto sob pesos iguais quanto no subcomponente factual). Relatamos, portanto, uma diferença de camada que conseguimos demonstrar e um gradiente de desenvolvimento que não conseguimos: a desvantagem está estabelecida como diferença entre grupos, enquanto sua forma ao longo da faixa de desenvolvimento permanece exploratória. Sob Bonferroni-Holm na família primária $\{H1\text{-gradiente}, H4, H6\}$, nenhum teste rejeita seu nulo.

A ordenação dos países também retém grande heterogeneidade ortogonal ao eixo (Tabela 5): a Índia (0.652, Sul Global) lidera todos os países, África do Sul e Indonésia superam boa parte do Norte Global, e Canadá e França ficam abaixo. A desvantagem é uma diferença de camada sobreposta a substancial variação por país, e não um ranking limpo. Essa heterogeneidade é ela própria parte da razão de o gradiente não se resolver.

Tabela 5: Acurácia composta por país, amostra de 25 países (camada: NG = Norte Global, SG = Sul Global). Ordenada pela média.

País	Camada	Média	País	Camada	Média
Índia	SG	0.652	França	NG	0.536
Japão	NG	0.611	Bangladesh	SG	0.534
Austrália	NG	0.604	Colômbia	SG	0.530
Estados Unidos	NG	0.592	Chile	SG	0.513
Coreia do Sul	NG	0.590	Canadá	NG	0.510
Indonésia	SG	0.584	México	SG	0.507
África do Sul	SG	0.579	Quênia	SG	0.506
Itália	NG	0.577	Angola	SG	0.485
Reino Unido	NG	0.573	Nigéria	SG	0.461
Portugal	NG	0.563	Brasil	SG	0.459
Filipinas	SG	0.546	Egito	SG	0.455
Alemanha	NG	0.544	Argentina	SG	0.445
Peru	SG	0.538			

4.7 H4 — representação no corpus: cobertura do país, não tamanho do idioma

O mecanismo pré-especificado para a lacuna geográfica era a representação no corpus de treinamento, com o proxy pré-especificado sendo a contagem de artigos ou edições da Wikipédia. Esse proxy é nulo: ρ de Spearman $= +0.14$ ($p = 0.50$) sem controle, e permanece nulo ao parcializar por IDH e log do PIB per capita, que é o conjunto de ajuste que o plano especificava. Os dois conjuntos de controle dão a mesma resposta porque carregam quase a mesma informação: IDH e

log do PIB per capita se correlacionam a $\rho = 0.97$ nestes 25 países. H4 tal como pré-especificada não é sustentada.

Exploramos então, post hoc, se um canal diferente está em operação. Como a lacuna é medida *em inglês*, uma diferença Norte/Sul residual não pode refletir quanto texto existe no idioma de um país, de modo que distinguimos tamanho do corpus da língua de quão amplamente o corpus fala *sobre* um país. O melhor de três proxies de cobertura do país — o número de edições linguísticas da Wikipédia com artigo sobre o país (sitelinks do Wikidata) — se correlaciona com a acurácia a $\rho = +0.36$, que não atinge significância ($p = 0.075$), e se atenua ainda mais após ajuste por IDH (ρ parcial = $+0.18$, $p = 0.41$).

No nível do país, portanto, nenhum canal se estabelece: com 25 países não há como separar cobertura de desenvolvimento, porque os dois são colineares e a correlação parcial esgota a informação disponível.

Mudar a unidade de variação resolve o que o nível do país não resolve

O obstáculo acima é confundimento, não ausência de sinal, e tem uma saída que não exige mais países. Cada país responde a cinco tarefas, e essas tarefas diferem em um aspecto que aqui importa: quanto a resposta depende de um fato sobre *aquele* país. T1 (o padrão nacional), T2 (um valor medido localmente) e T4 (instrumentos nacionais) dependem; T3 (uma estimativa internacional da OMS) e T5 (uma recomendação genérica) não. Os países pontuam 0.457 no primeiro bloco e 0.663 no segundo, um déficit de especificidade de 0.206.

Se o que limita o modelo é quanto o corpus fala sobre um dado país, esse déficit deveria ser menor onde a cobertura é maior — e, decisivamente, o IDH de um país não pode explicar um déficit medido *dentro* desse mesmo país. Estimar a interação entre cobertura do país e dependência da tarefa no nível da resposta, com efeito fixo de país que absorve desenvolvimento, renda, idioma oficial e todo o resto que distingue países, dá $\beta = +0.026$ (EP 0.005, $p = 2 \times 10^{-8}$, $n = 7.580$): maior cobertura prediz menor déficit, na direção que o mecanismo exige.

Três checagens incidem sobre se isto é o mecanismo, e não artefato de como traçamos a linha entre tipos de tarefa (Tabela 6). O contraste *mais puro* — T1, inteiramente nacional, contra T5, inteiramente genérica — produz o *maior* coeficiente ($\beta = +0.042$, $p = 3 \times 10^{-12}$), que é a relação dose-resposta que se esperaria e não o que uma associação espúria produziria. Remover T5, cujo teto é de 99.7%, ou remover T4, a mais interpretativa das três, deixa o efeito intacto. E um placebo que simplesmente inverte os rótulos devolve a imagem espelhada exata ($\beta = -0.026$), como deve ocorrer se a quantidade for real.

Por fim, os dois canais candidatos foram inseridos juntos. Eles se correlacionam apenas fracamente entre países ($\rho = 0.21$), e sob ajuste mútuo a cobertura do país permanece forte ($\beta = +0.025$, $p = 4 \times 10^{-8}$), enquanto o proxy de corpus da língua fica marginal ($\beta = +0.010$, $p = 0.041$). A predição aqui era assimétrica e, portanto, falseável: como toda resposta desta análise foi elicitada *em inglês*, o tamanho do corpus do idioma local de um país não tem rota óbvia para quanto o modelo sabe sobre aquele país, de modo que, se o canal linguístico tivesse sobrevivido e a cobertura falhado, nossa leitura estaria errada. Não foi o caso.

Enunciamos a afirmação resultante com precisão, porque ela é mais estreita do que “a cobertura causa a lacuna”. O desenho remove o confundimento de nível país por construção, e não o

confundimento no nível de tarefa por país: se as tarefas dependentes do país fossem mais difíceis de algum modo que por acaso acompanhasse a cobertura por razão não relacionada, este teste não distinguiria. O que podemos dizer é que o canal de cobertura do país faz uma predição diferencial, que a predição se confirma, que ela se fortalece à medida que o contraste fica mais nítido, e que sobrevive quando o canal rival é ajustado. Isso é um mecanismo sustentado no nível em que este desenho tem resolução, e é o que a correlação no nível do país estava confundida demais para mostrar.

Tabela 6: Cobertura do país $\times$ dependência da tarefa, modelo misto no nível da resposta com efeito fixo de país. β positivo = maior cobertura, menor déficit nas tarefas dependentes do país.

Classificação das tarefas	β	p
T1, T2, T4 contra T3, T5 (principal)	+0.026	2×10^{-8}
T1 contra T5 (contraste mais puro)	+0.042	3×10^{-12}
Excluindo T5 (teto em 99.7%)	+0.021	4×10^{-4}
Excluindo T4 (mais interpretativa)	+0.031	8×10^{-10}
Placebo: rótulos invertidos	-0.026	2×10^{-8}

Duas características do desenho ainda delimitam o que a análise no nível do país consegue fazer, e são a razão de aquela análise falhar enquanto esta tem êxito. A variável de Joshi assume três valores nos 25 países, com dezoito compartilhando uma classe, e o proxy de corpus pré-especificado assume onze valores distintos, com nove empatados na edição inglesa. Nenhum dos dois tem resolução para separar canais entre países; o contraste dentro do país contorna ambos.

A explicação por corpus também se mostra em H2, em que a unidade é o idioma e não o país. Ali a direção é a prevista, embora com apenas três idiomas nativos permaneça descritiva: a penalidade por idioma cai monotonicamente com o volume de tokens do mC4 (Xue et al., 2021) e com o tamanho do OSCAR (Abadji et al., 2022) (Spearman = -1.00 sobre os três), com o hindi, o menor corpus (24 bilhões de tokens no mC4), carregando a maior penalidade.

4.8 H5 — aberto contra fechado-acessível

Agrupando por tipo de acesso, os modelos fechados-acessíveis ficam +13.3 pp acima dos de pesos abertos. Isso contraria o enquadramento otimista de H5; o braço aberto inclui modelos maiores (Llama 3.3 70B, DeepSeek-V3), de modo que a lacuna não é atribuível apenas à escala, embora o próprio DeepSeek-V3 agora lidere o ranking geral. H5 é interpretada descritivamente.

4.9 Proveniência do gabarito

Como a “acurácia” medida depende do gabarito, o alvo de padrão técnico (T1) para os 25 países foi ancorado em fontes oficiais primárias por verificação documental, e não por afirmação de especialista, e é reproduzível a partir das URLs citadas. A maioria dos países tem um valor lido da regulação oficial (por exemplo, o padrão anual brasileiro de $\text{PM}_{2.5}$ de $17 \mu\text{g}/\text{m}^3$, lido literalmente do Anexo I da Resolução CONAMA 506/2024 no Diário Oficial da União; os $25 \mu\text{g}/\text{m}^3$ da Colômbia, lidos da Tabela 1 da Resolución 2254/2017). Três países *não* têm padrão nacional de $\text{PM}_{2.5}$, confirmado a partir do texto oficial — a regulação NESREA da Nigéria fixa apenas PM_{10} , a Argentina não tem valor federal vinculante e Angola não tem legislação nacional de

qualidade do ar —, fato que a auditoria estabeleceu contra números secundários que circulam mas são incorretos, e no qual um modelo fiel deve se recusar a declarar um limiar inexistente em vez de fabricá-lo.

O mesmo padrão foi estendido às tarefas que antes não o tinham. T2 é adjudicada contra a WHO Ambient Air Quality Database v6.1 (23 dos 25 países têm cidade na base; Angola não tem nenhuma e o Cairo não carrega valor de $PM_{2,5}$), T3 contra o indicador AIR_41 do WHO GHO com seus intervalos de incerteza, e T4 contra o Apêndice 1 do UNEP Global Assessment of Air Pollution Legislation, cobrindo 24 dos 25 países. Essa proveniência é mais reprodutível do que validação por especialista: qualquer leitor pode reverificar cada valor na fonte oficial.

4.10 Modos qualitativos de falha

Para tornar concretos os números do composto, o Quadro 1 mostra três falhas representativas extraídas literalmente dos registros de resposta (os identificadores de execução estão disponíveis na liberação).

Tabela 7: Quadro 1 — Modos representativos de falha (literais, levemente truncados).

Modo de falha	Exemplo
Fabricar um padrão inexistente (país sem norma nacional de $PM_{2,5}$)	Para Angola (sem padrão nacional), o Gemini 2.5 Flash afirmou um padrão anual de “ $25 \mu g/m^3$ ” em uma replicação e de “ $15 \mu g/m^3$ ” em outra; o GPT-5 afirmou “ $15 \mu g/m^3$ ” para a Nigéria , que regula apenas PM_{10} (NESREA). Uma resposta fiel se recusaria a declarar um valor que não existe.
Errar o valor vinculante (piso de T1)	Para o Brasil (padrão anual oficial de $17 \mu g/m^3$, CONAMA 506/2024), a resposta modal dos modelos foi $15 \mu g/m^3$ (42 respostas), com 10, 20 e 25 também comuns; o valor oficial quase nunca foi devolvido.
Degradação em idioma nativo (H2)	Para a Índia (padrão anual de $40 \mu g/m^3$), o GPT-OSS 120B devolveu o valor correto em inglês, mas resposta <i>vazia</i> à mesma pergunta em hindi.

O primeiro modo é o mais consequente para os casos sem padrão (Angola, Nigéria, Argentina): em vez de se absterem, os modelos inventam um limiar regulatório plausível e discordam entre replicações e entre modelos sobre o valor inventado — exatamente o comportamento que um gestor público não consegue detectar sem a fonte oficial.

4.11 Confiabilidade entre juízes

A confiabilidade é relatada sobre a amostra que produz os efeitos, e não sobre um subconjunto de calibração. Todos os 3.190 itens que exigiram juiz foram pontuados pelos três membros do painel (Gemini 2.5 Pro, Claude Sonnet 4.6, DeepSeek-V3), resultando em α de Krippendorff = 0.527 (intervalar), $ICC(2, 1) = 0.558$ de juiz único e — a quantidade operante, já que a análise usa a média do painel — $ICC(2, 3) = 0.791$. A concordância de Pearson par a par é de +0.80 entre Claude e DeepSeek e de +0.65 a +0.66 entre cada um deles e o sistematicamente mais leniente Gemini.

Dois pontos merecem ênfase porque contrariam o desenho original. Primeiro, um juiz único

carregaria $ICC(2, 1) = 0.56$, que é moderado no melhor dos casos; o protocolo publicado dependia de um só, e é a média do painel que torna o composto defensável. Segundo, esses valores são menores que o $ICC(2, 4) = 0.89$ obtido na amostra de calibração de 131 itens relatada em versões anteriores. A amostra de calibração era estratificada e pequena; medida sobre 24 vezes mais itens, e sobre os mesmos itens que produzem os efeitos, a concordância é mais modesta. Relatamos a estimativa maior e menos lisonjeira porque é ela que descreve o instrumento de fato utilizado.

Durante a repontuação também identificamos, e corrigimos, um defeito de nossa própria autoria. Uma versão inicial do prompt de T2 pedia ao juiz que comparasse uma concentração devolvida com uma faixa de tolerância expressa em palavras, o que exigia que o juiz fizesse a aritmética. A concordância entre juízes nesses itens caiu para $r = -0.04$. Pré-computar a faixa admissível e perguntar apenas se o valor cai dentro dela elevou a concordância nos mesmos itens para $r = +1.00$. A discordância era artefato do nosso prompt, e não divergência genuína de julgamento, e as 274 pontuações produzidas sob a redação ambígua foram descartadas e recoletadas. Aritmética pertence ao código; ao juiz deve-se perguntar apenas o que exige julgamento.

4.12 Robustez

Observações influentes. A reestimação *leave-one-country-out* deixa a lacuna de camada em $[+4.5, +6.0]$ pp, de modo que nenhum país isolado a impulsiona. O gradiente de IDH varia em $[+0.31, +0.49]$ e nunca atinge o limiar pré-especificado de 0.55 sob nenhuma remoção, o que é parte da razão de o relatarmos como exploratório.

Robustez de métrica. O composto mistura cinco subcomponentes, e alguém poderia temer que ele dilua ou fabrique os efeitos. Ele não muda as conclusões. Sob pesos iguais, a lacuna de camada é de +4.2 pp, a penalidade de idioma nativo de -4.7 pp, o piso de recuperação $\delta = -0.44$ e o gradiente $\rho = +0.34$; restringir ao subcomponente mais objetivo — acurácia factual contra o valor de registro, ignorando completude, calibração e estilo — dá +8.8 pp, -5.4 pp, $\delta = -0.44$ e $\rho = +0.38$, com o piso de recuperação se aprofundando (acurácia factual de T1+T2 de 0.370 contra 0.657 para T3-T5). Os dois efeitos sustentados se mantêm em toda ponderação e o gradiente falha em toda ponderação, de modo que nenhuma das conclusões é artefato de como os subcomponentes são misturados.

Extensão de amplitude. Os dez países acrescentados post hoc caem dentro da faixa de IDH já coberta pelos quinze originais ($[0.548, 0.950]$, da Nigéria à Alemanha), de modo que a extensão aumenta a densidade das observações, e não a amplitude do preditor.

O que o gradiente nulo descarta e o que não descarta. Um nulo só é informativo na medida em que o desenho poderia ter enxergado o efeito. Simulando amostras de 25 países em correlações conhecidas, este desenho tem 77% de poder para detectar $\rho = 0.55$ — o limiar que pré-especificamos — e seu efeito mínimo detectável a 80% de poder é $\rho = 0.56$. O nulo, portanto, descarta um gradiente da magnitude que nos comprometemos a chamar de substancial. Ele não descarta um gradiente fraco: o poder é de 48% em $\rho = 0.40$ e de 28% em $\rho = 0.30$. A afirmação honesta é que um gradiente forte de desenvolvimento está excluído e um modesto permanece possível, o que é uma afirmação mais estreita do que “há um gradiente” ou “não há nenhum”.

A lacuna de camada depende da definição de camada. Norte e Sul Global são operacionaliza-

dos pela classificação da UNCTAD, e uma lacuna que existisse apenas sob uma taxonomia seria artefato dessa taxonomia. Reestimamo-la, portanto, sob três partições dos mesmos 25 países baseadas em desenvolvimento (Tabela 8). A lacuna é de +5.1 pp e significativa sob a UNCTAD (permutação $p = 0.020$), e é menor e não significativa sob toda partição traçada apenas por IDH.

Relatamos isso em vez de descansar sobre a partição favorável, e o vemos como coerente com o restante do artigo, e não como contradição dele. O gradiente de IDH é ele próprio nulo (Seção 4.6), de modo que uma divisão por IDH não deveria produzir lacuna; que a UNCTAD produza e o IDH não sugere que a variável operante não é riqueza nacional, e sim posição no sistema mundial, que é o que a classificação da UNCTAD codifica e o que o enquadramento da colonialidade do saber prevê (Quijano, 2000; Mohamed et al., 2020). Essa leitura é post hoc, e o leitor tem direito à alternativa: que, entre várias partições defensáveis, uma atingiu significância. Tratamos, portanto, a lacuna de camada como demonstrada *para a distinção Norte/Sul tal como convencionalmente traçada*, e não como afirmação geral sobre desenvolvimento.

Tabela 8: Lacuna de camada sob partições alternativas dos mesmos 25 países. Teste de permutação com o país como unidade, 10.000 reetiquetagens.

Partição	Lacuna (pp)	NG/SG	p
Norte/Sul da UNCTAD (usada no artigo)	+5.06	10/15	0.020
IDH abaixo da mediana da amostra (0.781)	+2.39	13/12	0.269
IDH < 0.800 (corte de “muito alto” do PNUD)	+2.92	12/13	0.182
IDH < 0.700	+1.53	20/5	0.575

Um árbitro livre de distribuição para a lacuna de camada. O bootstrap e o modelo misto discordam sobre se a lacuna supera a significância convencional. Um teste de permutação resolve a questão nos termos mais conservadores disponíveis, e o procedimento se enuncia em uma frase: embaralhar aleatoriamente os rótulos Norte/Sul entre os 25 países, vinte mil vezes, e contar com que frequência o acaso sozinho produz uma lacuna tão grande quanto a observada. Ele não assume nada sobre como os dados se distribuem e trata o país, e não a resposta individual, como unidade independente. O acaso produz uma lacuna desse tamanho em 2.0% das vezes ($p = 0.020$), de modo que rejeitamos o nulo. Damos precedência a este teste sobre o modelo misto, cujo $p = 0.069$ marginal reflete cobrar do termo de erro a heterogeneidade entre países, e não evidência contra o contraste.

Corroboração baseada em modelo, e onde ela discorda. Duas reestimções baseadas em modelo sobre a pontuação corrigida qualificam a lacuna de camada em vez de simplesmente confirmá-la, e relatamos a discordância.

Um modelo linear misto gaussiano com interceptos aleatórios cruzados para país e modelo, ajustando por IDH centrado, estima uma penalidade de Sul Global de $\beta = -0.066$ (EP 0.036) que *não* atinge significância ($p = 0.069$). Uma reestimção hierárquica bayesiana com prioris fracamente informativas concorda em magnitude e é mais decisiva quanto ao sinal: média posterior de -0.052 , HDI de 94% $[-0.091, -0.013]$, $P(\beta < 0) = 0.993$, com convergência limpa ($\hat{R} = 1.000$ em quatro cadeias).

Assim, duas das três formas de fazer a pergunta — o bootstrap no nível do país e o modelo bayesiano — colocam o intervalo longe do zero, enquanto o modelo misto frequentista o deixa marginal. As estimativas concordam em magnitude (cerca de -5 a -6 pontos percentuais) e em

1001 sinal; discordam sobre se isso é distinguível de nenhum efeito nos limiares convencionais, porque
1002 o modelo misto cobra do termo de erro a substancial heterogeneidade entre países (Tabela 5).
1003 Descrevemos, portanto, a lacuna de camada como sustentada, porém *modesta e sensível à es-*
1004 *pecificação*, o que é afirmação mais fraca do que a de versões anteriores sobre as pontuações de
1005 juiz único ($\beta = -0.077$, $p = 0.007$).

1006 E-values. Um E-value pergunta quão forte precisaria ser um confundidor não medido para
1007 explicar inteiramente um achado; quanto maior o número, mais difícil descartar o achado. A
1008 lacuna de camada carrega um E-value de 1.70 na estimativa pontual e de 1.31 no limite do
1009 intervalo mais próximo do nulo. O segundo número é o operante (VanderWeele and Ding, 2017):
1010 um confundidor de nível país associado tanto à camada quanto à acurácia com $RR \approx 1.31$
1011 bastaria para tornar a lacuna compatível com nenhum efeito. Essa é uma barra baixa, e pertence
1012 à avaliação do leitor.

1013 Não relatamos E-value para o gradiente de IDH, embora versões anteriores o fizessem (5.4).
1014 O gradiente não atinge significância ($p = 0.073$), de modo que seu intervalo já inclui o nulo e o
1015 E-value nesse limite é 1.00 — nenhum confundidor é necessário. Relatar apenas o E-value da
1016 estimativa pontual sugeriria uma robustez que a estimativa não tem. A conversão também se
1017 ajusta mal a uma exposição contínua e medida no nível do país, que a formulação em razão de
1018 risco pressupõe inexistente.

1019 4.13 Síntese

1020 A Tabela 9 mapeia cada hipótese ao seu achado, ao mecanismo candidato e a um estatuto
1021 explícito de evidência, para que nenhuma afirmação seja lida como mais forte do que os dados
1022 sustentam.

Tabela 9: Hipóteses, achados, mecanismos candidatos e estatuto de evidência.

Hipótese	Achado	Mecanismo candidato	Estatuto de evidência
H2 (idioma)	-4.8 pp; hindi -11.1	tamanho do corpus da língua	Sustentada; mecanismo descritivo ($n = 3$)
H3 (modelo regional)	$\delta = -0.47$	escala > ajuste regional	Sustentada
H1 (lacuna de camada)	+5.1 pp composto; RC 0.23 em T1	camada (desenvolvimento)	Sustentada; concentrada na recuperação de fato do país
H1 (gradiente)	$\rho = 0.36$, $p = 0.073$	desenvolvimento (IDH)	Exploratória; não significativa
H4 (mecanismo geográfico)	dentro do país $\beta = +0.026$, $p = 2 \times 10^{-8}$	cobertura do país	Sustentada dentro do país; não causal
H4 (pré-especificada)	tamanho da Wikipédia nulo	tamanho do corpus da língua	Não sustentada
H5 (aberto/fechado)	+13.3 pp fechado	tipo de acesso / escala	Descritiva
H6 (per-sona)	DiD +0.6 pp	—	Não sustentada

1023 Corrigir o gabarito reordena o que este estudo pode afirmar. Sustentado, com tamanhos de
1024 efeito: uma *penalidade de idioma nativo* de -4.8 pp (Wilcoxon $p = 3 \times 10^{-15}$, $n = 839$ células),

significativa nos três idiomas e maior para o hindi (-11.1 pp); um *piso de recuperação* nas tarefas que exigem devolver um valor vinculante (T1+T2 contra as demais, $\delta = -0.47$, concentrado em T1, com 0.367); o modelo regional como o *pior* dos catorze ($\delta = -0.47$); e uma *lacuna de camada* Norte/Sul de $+5.1$ pp (IC bootstrap de 95% $[+1.6, +8.5]$, exclui o zero), modesta e sensível à especificação no composto — a reestimação bayesiana a coloca longe do zero ($P(\beta < 0) = 0.993$) enquanto o modelo misto frequentista a deixa marginal ($p = 0.069$), e seu E-value no limite do intervalo é de apenas 1.31 —, mas *inequívoca onde importa*: ao devolver o padrão nacional vinculante, a chance do Sul Global é 0.23 da chance do Norte ($[0.19, 0.28]$), e a lacuna escala com o quanto a resposta depende de um fato específico do país, desaparecendo na única tarefa sem valor de registro a acertar. Exploratório ou não sustentado: o *gradiente* de desenvolvimento não atinge significância ($\rho = 0.36$, $p = 0.073$; Mann-Kendall $p = 0.072$; $\rho = 0.08$ no $n = 15$ pré-especificado), de modo que a diferença de camada está demonstrada mas sua forma não; e a persona *não* estreita a lacuna ($p = 0.27$). Identificado onde o desenho tem resolução: entre países nenhum canal de corpus se separa do desenvolvimento ($\rho = 0.36$, $p = 0.075$; parcial $p = 0.41$), mas dentro dos países — comparando tarefas que dependem de um fato nacional contra tarefas que não dependem, mantendo o país e portanto seu desenvolvimento constantes — a cobertura do país prediz o déficit ($\beta = +0.026$, $p = 2 \times 10^{-8}$), que se fortalece à medida que o contraste fica mais nítido, inverte sob placebo e sobrevive entre os nove países cuja língua oficial é idêntica ($\beta = +0.025$, $p = 6 \times 10^{-4}$).

A implicação prática é clara. O que este estudo demonstra é que os três remédios aos quais uma agência de fato recorreria — perguntar no idioma nacional, declarar o papel oficial, contratar um modelo com ajuste regional — falham todos, e que o primeiro piora materialmente as coisas; e que os modelos são menos confiáveis precisamente na recuperação do valor vinculante em vigor. Isso importa para a gestão ambiental no Sul Global, onde a carga de doença é grande (GBD 2019 Risk Factors Collaborators, 2020; Requia et al., 2024) e onde exatamente a tarefa mais difícil — recuperar o padrão vinculante — é a de que um gestor mais precisa (Joshi et al., 2020; Mohamed et al., 2020).

5 Discussão

Propusemo-nos a medir se os LLMs respondem a perguntas de política de poluição do ar com a mesma confiabilidade para o Sul Global e para o Norte Global, se o enquadramento do prompt muda a resposta, e qual mecanismo impulsiona eventual lacuna. O benchmark — 25 países, 14 modelos, quatro idiomas, cinco tarefas, duas personas, pontuado contra gabarito oficial por código onde a resposta é um valor de registro e por um painel de três fornecedores nos demais casos — devolve um quadro disciplinado e em parte contraintuitivo. Os danos que conseguimos demonstrar são práticos, e não etiológicos: as três mitigações às quais uma agência recorreria falham, a mais intuitiva delas piora materialmente a resposta, e os modelos são menos confiáveis justamente na recuperação do valor vinculante em vigor. Uma diferença de camada Norte/Sul persiste, e identificamos o canal por trás dela apenas onde o desenho tem resolução para tanto.

5.1 Três mitigações intuitivas, todas falhando — e uma que prejudica

A contribuição aplicada é em larga medida negativa.

O idioma local não ajuda e prejudica materialmente. Perguntar no idioma do próprio país reduz a acurácia em 4.8 pp (Wilcoxon $p = 3 \times 10^{-15}$, $n = 839$ células casadas), de forma significativa nos três idiomas, e a penalidade escala com a escassez do corpus daquele idioma: hindi -11.1 pp, espanhol -4.4 , português -3.9 . A Índia, país com maior pontuação entre os 25 em inglês, é a que mais cai em hindi. Este é o mecanismo que a hierarquia de recursos prevê (Joshi et al., 2020; Xue et al., 2021), e aqui a medida tem resolução para vê-lo, porque a unidade é o idioma e não o país.

Tratamos essa afirmação de forma adversarial, e não confirmatória, e ela se sustentou. Não depende de nenhum país, modelo, tarefa, condição de persona ou instrumento de pontuação em particular, nem da qualidade da tradução: um censo de retrotradução de todos os 90 prompts nativos não encontrou nenhum que alterasse o país ou a quantidade solicitada, e a penalidade é a mesma entre as versões verificadas como fiéis. Mais importante, ela se sustenta em um desfecho que não envolve juiz algum: prompts em idioma nativo devolvem um valor verificável contra o registro em apenas 48.7% das vezes, contra 66.4% em inglês (-17.7 pp em pares, teste de sinais $p = 5 \times 10^{-6}$), com a mesma ordenação entre idiomas. O dano não é que um juiz pontue prosa não inglesa com mais severidade; é que o modelo se torna acentuadamente menos propenso a produzir um número conferível.

A persona de gestor local não estreita a lacuna (DiD $+0.6$ pp, permutação $p = 0.27$), coerente com a evidência de que personas de especialista não melhoram de forma confiável a acurácia factual (Zheng et al., 2024; Basil et al., 2025). Uma checagem de manipulação confirma que metade das respostas assume explicitamente o enquadramento de papel, de modo que o nulo não decorre de falha da manipulação.

O modelo regional — o Cabra-Mistral 7B em português brasileiro — é o *pior* desempenho entre os catorze ($\delta = -0.47$), de modo que recorrer a um modelo pequeno com ajuste local troca a escala e o treinamento de fronteira, que são o que de fato sustenta a acurácia no domínio.

Profissionais implantam as três como soluções; nenhuma funciona, e a que um gestor tem mais chance de tentar primeiro é a que causa dano ativo. A mensagem honesta para as agências ambientais do Sul Global é que nenhum contorno barato no nível do prompt ou do modelo substitui verificar o valor vinculante na fonte oficial.

5.2 O piso de recuperação recai sobre os valores que vinculam

A acurácia despenca nas tarefas que exigem devolver um valor específico em vigor: 0.417 para recuperação normativa e de dado local, contra 0.623 para síntese e recomendação ($\delta = -0.47$), e o piso é mais profundo no próprio padrão nacional (T1, 0.367). O risco é concentrado. Um gestor que redige prosa sobre política de qualidade do ar é comparativamente bem servido; um gestor que recupera o limite regulatório do qual depende uma decisão está na pior célula do desenho, e pior ainda se perguntar em um idioma de menos recursos.

Uma checagem interna sustenta que esse piso não é artefato de como pontuamos. Corrigir o gabarito elevou a T2 — a tarefa que vinha sendo pontuada contra uma chave de preenchimento — de 0.368 para 0.460, enquanto deixou a T1 — que sempre teve gabarito oficial — em exatamente

0.367. A correção moveu a tarefa cuja chave era defeituosa e não tocou naquela cuja chave era sólida.

5.3 Uma diferença de camada que podemos mostrar, e um gradiente que não

A H1 foi pré-especificada em duas partes, e a pontuação corrigida as separa: a lacuna de camada se sustenta e o gradiente monotônico não.

A lacuna é de +5.1 pp, com IC bootstrap de [+1.6, +8.5] que exclui o zero, estável à remoção de qualquer país e a toda ponderação do composto, ampliando-se para +8.8 pp apenas no subcomponente factual. É, ainda assim, modesta e sensível a como a pergunta é feita. Um modelo hierárquico bayesiano coloca o efeito longe do zero (-0.047 , HDI de 94% $[-0.085, -0.006]$, $P(\beta < 0) = 0.993$), enquanto um modelo misto frequentista com interceptos aleatórios cruzados o deixa marginal ($\beta = -0.060$, $p = 0.069$), porque cobra do termo de erro a grande heterogeneidade entre países. As três abordagens concordam em magnitude e sinal e discordam quanto à significância, e o E-value no limite do intervalo mais próximo do nulo é de apenas 1.31, de modo que um confundidor de nível país com força modesta bastaria para explicar a lacuna.

Essa modéstia, contudo, é artefato do composto. Estimada tarefa a tarefa sobre o desfecho binário de devolver o valor de registro, a lacuna escala com o quanto a resposta depende de um fato específico daquele país: razão de chances de 0.23 $([0.19, 0.28])$ no padrão nacional vinculante, 0.34 nos instrumentos nacionais de política, 0.51 no dado medido local, 0.67 em uma estimativa internacional de saúde, e nenhuma lacuna na recomendação aberta, a única tarefa sem valor de registro a acertar. A desvantagem não é fraca, e sim *concentrada*, e promediar cinco tarefas em um composto a dilui com tarefas em que ela não existe. Na pergunta que um gestor de fato traz a esses sistemas — qual é o padrão em vigor aqui — um país do Sul Global é servido a aproximadamente um quarto das chances de um país do Norte. Consideramos esta a formulação mais fiel do achado geográfico do que a lacuna do composto, e é a leitura que levamos às implicações.

O gradiente, em contraste, falha em toda leitura: $\rho = 0.37$ com o IDH em $n = 25$ não atinge significância ($p = 0.073$), a tendência de Mann-Kendall concorda ($p = 0.072$), nenhuma estimativa *leave-one-out* se aproxima do limiar pré-especificado de 0.55, e no $n = 15$ registrado ele está essencialmente ausente ($\rho = 0.14$). Esse nulo é informativo, e não meramente vazio: o desenho tem 77% de poder em $\rho = 0.55$ e efeito mínimo detectável de $\rho = 0.56$, de modo que um gradiente da magnitude com a qual nos comprometemos está excluído. Um gradiente fraco não está, já que o poder cai para 48% em $\rho = 0.40$.

Dois outros resultados delimitam o que o contraste de camada significa. Um teste de permutação que reetiqueta a camada entre países — livre de suposição distribucional, e usando o país como unidade — dá $p = 0.020$, que tomamos como resolvendo a discordância entre o bootstrap e o modelo misto em favor de a lacuna ser real. Mas a lacuna se sustenta sob a partição Norte/Sul da UNCTAD e *não* sob partições traçadas apenas por IDH (+2.4 a +2.9 pp, todas não significativas). Isso é coerente com um gradiente de IDH nulo — uma divisão por uma variável que não prediz acurácia não deveria produzir lacuna — e sugere que a variável operante é a posição no sistema mundial, e não a riqueza nacional, que é o que a UNCTAD codifica e o que o enquadramento da colonialidade prevê. Sinalizamos que essa leitura é post hoc, e que um leitor cético pode ver, em vez disso, uma partição entre várias atingindo significância. De todo modo,

a afirmação que defendemos é sobre a distinção Norte/Sul tal como convencionalmente traçada, não sobre desenvolvimento em geral.

Relatamos essa assimetria de forma direta: uma diferença entre grupos que conseguimos demonstrar, e uma forma ao longo da faixa de desenvolvimento que não conseguimos. A ordenação dos países mostra por quê. A Índia lidera os 25 apesar de ser Sul Global; África do Sul e Indonésia superam boa parte do Norte Global; Canadá e França ficam abaixo. A desvantagem é uma diferença de camada sobreposta a substancial idiossincrasia por país, e é precisamente essa idiossincrasia que uma correlação de postos sobre 25 países não tem resolução para atravessar.

5.4 O mecanismo, onde o desenho tem resolução

Nosso teste de mecanismo pré-especificado falha, e a razão acabou sendo um defeito no instrumento, não ausência de sinal. O proxy pré-especificado atribui o tamanho da edição da Wikipédia no idioma oficial dominante de um país; nove dos nossos 25 países — Austrália, Canadá, Índia, Quênia, Nigéria, Filipinas, Reino Unido, Estados Unidos e África do Sul — recebem por isso o valor da Wikipédia *inglesa*. A variável não mede quanto texto existe no idioma de um país. Ela mede se o país tem o inglês como língua oficial, o que é um fato sobre história colonial. Relatamos isso porque afeta qualquer estudo que tenha usado ou venha a usar o mesmo proxy.

Entre países, nenhum canal de corpus pode ser estabelecido. A cobertura do país se correlaciona com a acurácia em $\rho = 0.36$ ($p = 0.075$) e se atenua ainda mais após ajuste por desenvolvimento ($p = 0.41$), porque com 25 países cobertura e desenvolvimento são colineares e a correlação parcial esgota a informação disponível.

A resolução vem de mudar a unidade de variação, não de acrescentar países. Cada país responde a tarefas que diferem em quanto a resposta depende de um fato sobre *aquele* país, e o desenvolvimento de um país é constante entre suas próprias tarefas. Estimar a interação entre cobertura e dependência da tarefa no nível da resposta, com efeito fixo de país, dá $\beta = +0.026$ ($p = 2 \times 10^{-8}$): maior cobertura prediz menor déficit de especificidade. A associação se fortalece à medida que o contraste fica mais puro (contraste mais puro $\beta = +0.042$), inverte-se exatamente sob uma reetiquetagem placebo, e sobrevive ao ajuste pelo canal linguístico.

A checagem decisiva restringe aos nove países que compartilham o inglês como língua oficial. Ali o canal linguístico não é apenas controlado, mas idêntico por construção, e a cobertura do país continua predizendo o déficit ($\beta = +0.025$, $p = 6 \times 10^{-4}$), na mesma magnitude da amostra completa. O que esse coeficiente mede não pode ser idioma.

Enunciamos a afirmação resultante na força que o desenho sustenta. A representação do país é o canal operante para uma lacuna medida em inglês, identificada em um contraste que remove por construção o confundimento no nível do país. Isso não é identificação causal: o desenho elimina o confundimento no nível do país, não no nível de tarefa por país, e se as tarefas dependentes do país fossem mais difíceis de um modo que por acaso acompanhasse a cobertura por razão não relacionada, o teste não distinguiria. O que podemos dizer é que a explicação faz uma predição diferencial, que a predição se confirma, que ela se fortalece à medida que o contraste fica mais nítido, e que sobrevive à única condição em que o idioma é mantido exatamente fixo.

A explicação por corpus também aparece na H2, em que a unidade é o idioma e não o país: a penalidade por idioma cai monotonicamente com o volume de tokens do mC4 (Xue et al., 2021)

e com o tamanho do OSCAR (Abadji et al., 2022), embora com três idiomas isso permaneça descritivo.

5.5 A lição metodológica: a chave importa mais que a amostra

Versões anteriores deste estudo extraíram conclusão diferente das mesmas respostas, e vale enunciar a razão, porque ela generaliza para além deste artigo.

A pontuação original comparava respostas de modelo, em duas das cinco tarefas, contra gabarito de preenchimento, e delegava a um modelo de linguagem a aritmética de decidir se um número devolvido caía dentro de uma faixa autorizada. Reconstruir essas chaves a partir de registros oficiais (WHO Ambient Air Quality Database v6.1, WHO GHO AIR_41, UNEP Global Assessment of Air Pollution Legislation) e mover a comparação para código mudou as conclusões substantivas: o gradiente de desenvolvimento caiu de $\rho = 0.51$ ($p = 0.004$) para $\rho = 0.37$ ($p = 0.073$), enquanto a penalidade do idioma nativo mais que dobrou, de -2.1 pp para -4.8 pp, e transformou o espanhol de nulo em dano significativo. O conjunto de dados não mudou. Só o instrumento de medida mudou.

O instinto do campo, quando um efeito de viés geográfico se mostra frágil, é acrescentar países. Nossa experiência é que o gabarito merece o escrutínio primeiro. Uma chave defeituosa não apenas acrescenta ruído; ela acrescenta ruído *estruturado*, porque os defeitos se concentram onde o dado oficial é mais difícil de obter, que é exatamente onde a hipótese mora. Também constatamos que um prompt de pontuação ambíguo pode se disfarçar de discordância genuína entre juízes: a concordância nos itens afetados era de $r = -0.04$ sob nossa redação e de $r = +1.00$ depois que a faixa admissível passou a ser pré-computada e ao juiz se perguntou apenas se o valor caía dentro dela. Aritmética pertence ao código; ao juiz deve-se perguntar apenas o que exige julgamento.

5.6 Por que o domínio importa

O que está em jogo não são abstrações de benchmarking. O material particulado fino está entre os principais fatores de risco ambiental para mortalidade prematura, e a carga recai desproporcionalmente sobre o Sul Global. A Organização Mundial da Saúde atribui 88.548 mortes no Brasil em 2021 à poluição do ar ambiente (intervalo de incerteza 69.477 to 108.431), lideradas por doença isquêmica do coração, acidente vascular cerebral e infecções respiratórias agudas das vias inferiores (World Health Organization, 2026); a exposição de curto prazo segue produzindo mortalidade mensurável em cidades brasileiras (Requia et al., 2024). Quando um gestor delega uma consulta normativa ou uma recomendação de episódio a um LLM, uma resposta imprecisa pode se propagar para uma nota técnica regulatória ou uma resposta emergencial.

Não afirmamos que o modelo é menos confiável exatamente onde as consequências são maiores, porque não a medimos: a carga de doença não está entre nossas covariáveis de país, e nenhum teste deste estudo relaciona acurácia a mortalidade. A única observação de nível país que temos aponta na direção contrária, já que a Índia carrega uma das maiores cargas de mortalidade por $PM_{2.5}$ do mundo e é também o país de maior pontuação em nossa amostra. Se a confiabilidade está desalinhada da necessidade é uma pergunta bem posta, e de resposta direta ao acrescentar uma covariável de mortalidade atribuível padronizada por idade, mas não é uma pergunta que este

desenho responde. Lemos o padrão que *de fato* medimos dentro do arcabouço da colonialidade do saber (Mohamed et al., 2020): LLMs são sumários comprimidos de corpora produzidos sob acesso digital e editorial desigual, e a penalidade do idioma é um elo mensurável entre assimetria de corpus e assimetria de conhecimento — o único dos três elos que nos propusemos a testar em que a medida tem resolução para enxergá-lo.

5.7 O que este desenho não alcança, e o que cada limite abre

Cada limite abaixo é enunciado como fronteira deste desenho, e cada um nomeia o estudo que o removeria. Listamo-los na ordem em que os faríamos.

A base é defensável: gabarito ancorado em fontes oficiais primárias para todos os 25 países, adjudicação por código sempre que a resposta é um valor de registro conferível, e um painel de três fornecedores no restante, cuja confiabilidade é relatada sobre os mesmos 3.190 itens que produzem os efeitos ($ICC(2, 3) = 0.79$).

De pontuado por painel a ancorado em padrão-ouro. Nenhum especialista humano repontuou respostas neste estudo, e dizemos isso de forma direta. Três propriedades do desenho delimitam o que essa ausência pode custar. Sempre que a resposta correta é um número em registro oficial, o veredito é computado por código e nenhum juiz é envolvido. Onde há necessidade de julgamento, o escore é a média de três juízes de fornecedores diferentes, e não de um só, elevando a confiabilidade de $ICC(2, 1) = 0.56$ para $ICC(2, 3) = 0.79$. E todo efeito relatado é um contraste entre grupos, no qual a severidade sistemática de um juiz se cancela; restringir à acurácia factual objetiva *fortalece* tanto a lacuna de camada quanto a penalidade de idioma, em vez de enfraquecê-las, que é o oposto do que um juiz permissivo produziria. O efeito principal de idioma também se sustenta em um desfecho que nenhum juiz toca. O passo natural seguinte é, ainda assim, uma validação cega por especialista humano sobre amostra estratificada, que converteria um resultado ancorado em fonte oficial em um ancorado em padrão-ouro; uma análise de poder situa isso em cerca de 150 respostas pontuadas por três avaliadores, e nosso pipeline liberado exporta a amostra estratificada diretamente.

De um sinal dentro do país a um desenho causal. O canal é identificado onde o desenho tem resolução, mas não causalmente: entre países nenhum proxy se separa do desenvolvimento, e dentro dos países removemos o confundimento de nível país sem remover o confundimento de tarefa por país. Um desenho que varie a cobertura do país mantendo o desenvolvimento fixo, ou um estudo longitudinal que acompanhe a acurácia à medida que a pegada enciclopédica de um país cresce, fecharia essa lacuna remanescente.

De um gradiente nulo a um teste com poder adequado. A diferença de camada está estabelecida enquanto o gradiente não, em $n = 25$ e com a pontuação corrigida. Uma replicação pré-registrada com n substancialmente maior — que nosso conjunto de dados aberto torna barata — resolveria se o gradiente é genuinamente ausente ou ainda insuficientemente potente.

De três idiomas nativos à matriz multilíngue completa. O resultado mais forte do estudo repousa sobre três idiomas nativos, de modo que seu *mecanismo* é relatado descritivamente ainda que o efeito não seja. A objeção de qualidade de tradução, que de outro modo incidiria diretamente sobre o achado principal, está agora resolvida empiricamente em vez de apenas reconhecida: um censo de retrotradução de todos os 90 prompts nativos, auditado por dois

modelos contra os originais em inglês, não encontrou nenhum prompt que mudasse o país nem nenhum que mudasse a quantidade solicitada, e a penalidade é inalterada entre as traduções verificadas como fiéis (−4.5 pp), com a fidelidade não predizendo seu tamanho (permutação $p = 0.42$). O que permanece aberto é amplitude, não validade: três idiomas não estabelecem o mecanismo de tamanho de corpus, e escalar para mais idiomas — com tradutores humanos, que nossa arquitetura de prompt já acomoda — é a extensão de maior valor que este estudo aponta.

De um domínio a um programa entre domínios. Todos os efeitos vêm de um único domínio aplicado de alto risco (política de poluição do ar) e de uma única família de corpus (Wikimedia); confinamos deliberadamente a linguagem mecanicista a este domínio. O mesmo conjunto de tarefas e o método de registro de gabarito se transferem diretamente a outros domínios regulados e ancorados em fonte (qualidade da água, segurança de alimentos, política de vacinação).

A pilha servida como unidade de análise. Avaliamos modelos *como servidos* por meio de pilhas de acesso fixas, que é o que um gestor público de fato consulta; uma lacuna residual poderia, em princípio, refletir a pilha e não os pesos. Um desenho controlado de quase isolamento (pesos abertos idênticos em pilhas distintas) separaria os dois — um desdobramento limpo que nossa proveniência por chamada já viabiliza.

Uma lacuna de camada real, porém desconfortável. Recomputadas sobre a pontuação corrigida, as corroborações baseadas em modelo são mais fracas que as versões de juiz único relatadas em rascunhos anteriores: o modelo misto cai de $p = 0.007$ para $p = 0.069$, o posterior bayesiano de $P(\beta < 0) = 1.00$ para 0.993, e o E-value no limite do intervalo é 1.31. Relatamos a lacuna como sustentada porque o teste de permutação livre de distribuição rejeita o nulo ($p = 0.020$), o intervalo bootstrap exclui o zero e o posterior bayesiano é decisivo quanto ao sinal, enquanto o modelo misto é marginal ($p = 0.069$) e não contrário. O leitor pode pesar esses resultados uns contra os outros. O que resolveria a questão não é outro estimador sobre estes 25 países, e sim mais países, e o pipeline liberado torna essa replicação barata.

5.8 O que este estudo contribui

Primeiro, é — até onde sabemos — o primeiro benchmark de viés geográfico de LLM em um *domínio aplicado regulado e de alto risco* com gabarito oficial verificável, movendo a pergunta para além de conhecimento numérico geral, avaliações subjetivas e conhecimento cultural cotidiano, na direção das tarefas de recuperação e síntese que um gestor ambiental de fato delega. Segundo, entrega um resultado aplicado decisivo e contraintuitivo: as três correções às quais os profissionais recorrem primeiro — persona de gestor local, idioma local e modelo com ajuste regional — *falham todas juntas*, o idioma local prejudica ativamente em 4.8 pp, e o modelo regional é o único pior desempenho entre catorze. Este é um benchmark cuja contribuição mais útil é dizer ao campo o que não funciona, com os tamanhos de efeito para sustentá-lo. Terceiro, demonstra que, nesta literatura, a chave de gabarito, e não o tamanho da amostra, é a restrição que aperta: as mesmas respostas produzem um gradiente de desenvolvimento significativo sob chaves de preenchimento e um gradiente nulo sob chaves oficiais, enquanto a penalidade de idioma mais que dobra. Quarto, separa o que um desenho de 25 países consegue demonstrar (uma diferença de camada, uma penalidade de idioma, um piso de recuperação e um canal de corpus identificado dentro dos países) do que ele não alcança (a forma do gradiente ao longo do desenvolvimento, e a identificação

causal desse canal), e relata o segundo conjunto como em aberto, e não como sustentado. Quinto, cada número relatado é recomputável a partir do dado bruto por um pipeline de um comando com gate de auditoria de método embutido, estabelecendo um patamar de reprodutibilidade — gabarito de fonte oficial, adjudicação por código onde a resposta é um número, e auditabilidade de ponta a ponta — que a literatura de viés geográfico em larga medida não teve.

5.9 Implicações

Para as agências ambientais do Sul Global, a orientação operacional é concreta: tratar saídas de LLM sobre padrões vinculantes e dados medidos como rascunhos a conferir no diário oficial; não presumir que uma consulta em idioma local melhora a acurácia, porque com base nesta evidência ela a degrada; não esperar que um modelo pequeno com ajuste regional ou um enquadramento de papel fechem a lacuna. Para desenvolvedores de modelos, a penalidade de idioma é a alavanca tratável, e ela é maior exatamente onde o idioma é menos representado. Para a comunidade de medição, um resultado de viés geográfico pode depender da qualidade da chave de gabarito, de modo que a chave merece auditoria antes de a amostra ser ampliada.

6 Conclusão

Modelos de linguagem de grande porte estão se tornando infraestrutura de trabalho para a política de poluição do ar, um domínio em que uma resposta imprecisa sobre um padrão vinculante, uma concentração medida ou uma resposta operacional carrega consequências diretas de saúde pública no Sul Global, onde a carga de mortalidade por $PM_{2.5}$ é mais pesada (GBD 2019 Risk Factors Collaborators, 2020; Requia et al., 2024). Medimos o viés geográfico e modulado por persona nesse domínio com um benchmark de 25 países, 14 modelos e quatro idiomas, pontuado contra gabarito ancorado em fontes oficiais primárias para todos os países — por código onde a resposta é um valor de registro, e pela média de um painel de juízes de três fornecedores no restante.

As mitigações disponíveis a uma agência não funcionam, e a mais intuitiva sai pela culatra. Perguntar no idioma do próprio país *reduz* a acurácia em 4.8 pontos percentuais (Wilcoxon $p = 3 \times 10^{-15}$, $n = 839$ células casadas), de forma significativa nos três idiomas testados e mais acentuada onde o idioma é menos representado nos corpora de treinamento (hindi -11.1 pp). Uma persona de gestor local não estreita a lacuna ($p = 0.27$), e o modelo regional em português brasileiro é o mais fraco dos catorze sistemas ($\delta = -0.47$). Ao lado disso, a acurácia despenca na recuperação de um valor vinculante: 0.37 no padrão nacional contra 0.62 para síntese e recomendação ($\delta = -0.47$), que é justamente a tarefa que um gestor menos pode se dar ao luxo de ver errada.

Uma lacuna de camada Norte/Sul persiste ($+5.1$ pp, IC bootstrap de 95% $[+1.6, +8.5]$, exclui o zero), ainda que de forma modesta e com alguma sensibilidade à especificação: um modelo hierárquico bayesiano a coloca longe do zero ($P(\beta < 0) = 0.993$), enquanto um modelo misto frequentista a deixa marginal ($p = 0.069$). Medida tarefa a tarefa, no entanto, ela é inequívoca e altamente estruturada: ao devolver o padrão nacional vinculante, a chance de resposta correta do Sul Global é 0.23 da chance do Norte ($[0.19, 0.28]$), e a lacuna encolhe monotonicamente à medida

que a resposta depende menos de um fato específico do país, desaparecendo na única tarefa sem valor de registro a acertar. A desvantagem é concentrada, e não fraca, e um teste de permutação livre de suposição distribucional, com o país como unidade, o confirma ($p = 0.020$). Trata-se, contudo, de uma lacuna ao longo da linha Norte/Sul tal como convencionalmente traçada: partições dos mesmos países feitas apenas por IDH não a reproduzem. O gradiente monotônico de desenvolvimento não atinge significância ($\rho = 0.37$ com o IDH, $p = 0.073$; $\rho = 0.14$ no $n = 15$ pré-especificado), de modo que relatamos uma diferença entre grupos que conseguimos demonstrar e uma forma ao longo da faixa de desenvolvimento que não conseguimos.

Sobre o mecanismo, a resposta depende de onde se olha. Entre países, nenhum canal de corpus é identificável, porque cobertura e desenvolvimento são colineares ao longo de 25 observações. Dentro dos países, é: comparando tarefas cuja resposta depende de um fato nacional contra tarefas cuja resposta não depende — um contraste no qual o desenvolvimento é constante por construção — a cobertura do país prediz o déficit ($\beta = +0.026$, $p = 2 \times 10^{-8}$), e continua predizendo entre os nove países que compartilham o inglês como língua oficial, onde o canal linguístico é idêntico por definição ($\beta = +0.025$, $p = 6 \times 10^{-4}$). Identificamos a representação do país como o canal operante sem reivindicar identificação causal.

Para as agências ambientais do Sul Global, a mensagem é concreta e cautelara. Saídas de LLM sobre padrões vinculantes e dados medidos devem ser tratadas como rascunhos a conferir no diário oficial, e nenhum dos contornos baratos no nível do prompt ou do modelo substitui essa verificação — muito menos mudar para o idioma local, que, com base nesta evidência, piora a resposta. Lemos o padrão dentro do arcabouço da colonialidade do saber (Mohamed et al., 2020): os idiomas menos atendidos nos corpora de treinamento (Joshi et al., 2020) são falados onde a poluição do ar mata mais gente, e este estudo transforma esse elo de uma preocupação plausível em um efeito medido.

Relatamos também uma cautela metodológica. Duas das cinco tarefas eram originalmente pontuadas contra chaves de preenchimento, e pedia-se ao juiz que fizesse a aritmética da comparação de faixa. Reconstruir as chaves a partir de registros oficiais e mover essa comparação para código, sobre as mesmas respostas, derrubou o gradiente de desenvolvimento de $\rho = 0.51$ para $\rho = 0.37$ e mais que dobrou a penalidade do idioma nativo. O instinto nesta literatura, quando um efeito se mostra frágil, é acrescentar países; nossa experiência é que a chave de gabarito merece a auditoria primeiro, porque uma chave defeituosa acrescenta ruído estruturado que se concentra onde o dado oficial é mais difícil de obter.

Protocolo, prompts, registros de gabarito de fonte oficial, código de análise e dados de resposta anonimizados são liberados abertamente, com um pipeline de reprodução de um comando e um gate de auditoria de método que recomputa cada número relatado a partir do dado bruto. Para além de seus achados, o estudo oferece um modelo reutilizável para auditorias críveis de equidade aplicada de LLMs — gabarito de fonte oficial, adjudicação por código onde a resposta é um número conferível, e reprodutibilidade de ponta a ponta — nos domínios de alto risco do setor público onde esses sistemas já estão sendo implantados.

Disponibilidade de dados e código

O protocolo completo, os prompts, o código de análise, os registros de gabarito e as respostas anonimizadas dos modelos serão liberados na publicação em github.com/Roverlucas/artigo-vies-analise-regional, sob licenças MIT (código) e CC-BY-4.0 (dados, prompts, documentação). A liberação inclui os registros por resposta a partir dos quais cada efeito relatado é calculado, de modo que todo número deste artigo pode ser recomputado do dado bruto em vez de aceito por confiança. O pipeline de análise roda de ponta a ponta com `python code/run_all.py`.

Protocolo do estudo

Hipóteses, marco amostral, definição de desfecho, limiares de decisão e correção de multiplicidade foram fixados em um plano de análise sob controle de versão antes do início da coleta confirmatória. Esse plano não foi depositado em registro público, de modo que o leitor não pode verificar sua data de forma independente do histórico do repositório, e *não* reivindicamos pré-registro. O escopo entregue também se afastou substancialmente do desenho planejado, o que o próprio plano estabelecia como condição para o estatuto confirmatório.

Relatamos o estudo, portanto, em duas camadas. A primeira declara o que foi especificado de antemão e o que aconteceu com cada item. A segunda relata o que os dados sugeriram e o plano não antecipou, rotulado como exploratório do começo ao fim, com intervalos e sem linguagem confirmatória. Os desvios em relação ao plano estão tabulados no material suplementar.

Agradecimentos

Esta pesquisa não recebeu financiamento específico de agências dos setores público, comercial ou sem fins lucrativos. Os custos de inferência foram pagos pelos autores; nenhum fornecedor concedeu créditos, descontos ou apoio em espécie para este estudo.

Contribuições dos autores

Segundo a taxonomia CRediT:

- **Lucas Rover (UTFPR):** Conceituação, Metodologia, Software, Curadoria de Dados, Análise Formal, Investigação, Visualização, Redação – Rascunho Original, Administração do Projeto.
- **Vitor de Melo Dominski (Faculdade Descomplica):** Curadoria de Dados, Software, Análise Formal.
- **Prof. Anibal Tavares de Azevedo (Unicamp):** Redação – Rascunho Original, Redação – Revisão e Edição.
- **Dr. Eduardo Tadeu Bacalhau (UFPR):** Validação, Supervisão, Redação – Revisão e Edição.
- **Dra. Yara de Souza Tadano (UTFPR):** Validação, Supervisão, Redação – Revisão e Edição.

Declaração sobre IA generativa na redação

É preciso separar dois usos distintos, porque apenas um deles é objeto desta declaração.

Como objeto e instrumento do estudo. Modelos de linguagem são o objeto desta pesquisa e também servem como um de seus instrumentos de medida: GPT-5-mini, Gemini 2.5 Pro, Claude Sonnet 4.6 e DeepSeek-V3 pontuaram respostas contra o registro de gabarito, e o Claude Sonnet 4.6 produziu as versões dos prompts em idioma nativo. Esses usos fazem parte do método, estão descritos na Seção 3, e são a razão de o estudo também relatar confiabilidade entre juízes e uma auditoria de retrotradução dos prompts traduzidos. Onde a resposta correta é um valor de registro oficial, o veredito é computado por código, não por modelo.

Na preparação do manuscrito. Durante a preparação deste trabalho, os autores usaram modelos de linguagem para auxiliar na redação e edição do texto e na implementação do código de análise. Após usar essas ferramentas, os autores revisaram e editaram o conteúdo conforme necessário e assumem responsabilidade integral pelo conteúdo da publicação. Nenhum modelo de linguagem consta como autor, e nenhum modelo contribuiu com a interpretação dos achados ou com as decisões sobre o que a evidência sustenta.

Declaração de interesses

Os autores declaram não haver conflitos de interesse.

Referências

- Abadji, J., Ortiz Suárez, P., Romary, L., and Sagot, B. (2022). Towards a cleaner document-oriented multilingual crawled corpus. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC)*, pages 4344–4355.
- Abril-Pla, O., Andreani, V., Carroll, C., Dong, L., Fonnesbeck, C. J., Kochurov, M., Kumar, R., Lao, J., Luhmann, C. C., Martin, O. A., et al. (2023). PyMC: A modern and comprehensive probabilistic programming framework in Python. *PeerJ Computer Science*, 9:e1516.
- Almeida, T., Nogueira, R., and Pedrini, H. (2025a). Building high-quality datasets for Portuguese LLMs: From Common Crawl snapshots to industrial-grade corpora. *Journal of the Brazilian Computer Society*, 31(1):1247–1263.
- Almeida, T. S., Bonás, G. K., and Santos, J. G. A. (2025b). BRoverbs: Measuring how much LLMs understand Portuguese proverbs. *Journal of the Brazilian Computer Society*, 31:1078–1088.
- Almeida, T. S., Bonás, G. K., Santos, J. G. A., Abonizio, H., and Nogueira, R. (2025c). TiEBe: Tracking language model recall of notable worldwide events through time. *arXiv preprint arXiv:2501.07482*.
- Anthropic (2026). Giving Claude a role with a system prompt. Claude Platform Documentation, Prompt Engineering. Vendor documentation recommending that a role be set in the system prompt. Accessed 2026-08-24.

- 1457 Aoki, N., Tatsumi, T., Naruse, G., and Maeda, K. (2024). Explainable AI for government: Does
1458 the type of explanation matter to the accuracy, fairness, and trustworthiness of an algorithmic
1459 decision as perceived by those who are affected? *Government Information Quarterly*,
1460 41(4):101965.
- 1461 Basil, S., Shapiro, I., Shapiro, D., Mollick, E. R., Mollick, L., and Meincke, L. (2025). Prompting
1462 science report 4 — playing pretend: Expert personas don’t improve factual accuracy. SSRN
1463 Working Paper. SSRN id 5879722.
- 1464 Bender, E. M., Gebru, T., McMillan-Major, A., and Shmitchell, S. (2021). On the dangers
1465 of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM
1466 Conference on Fairness, Accountability, and Transparency*, pages 610–623.
- 1467 Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and
1468 powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*,
1469 57(1):289–300.
- 1470 Choroszewicz, M. (2026). Positioning public sector practitioners as ‘moral crumple zones’: Me-
1471 chanisms in the early use of generative AI work support tools. *Government Information
1472 Quarterly*, 43(2):102128.
- 1473 Cordella, A. and Gualdi, F. (2024). Regulating generative AI: The limits of technology-neutral
1474 regulatory frameworks. insights from Italy’s intervention on ChatGPT. *Government Informa-
1475 tion Quarterly*, 41(4):101982.
- 1476 Couldry, N. and Mejias, U. A. (2019). *The costs of connection: How data is colonizing human
1477 life and appropriating it for capitalism*. Stanford University Press.
- 1478 D’Ignazio, C. and Klein, L. F. (2020). *Data feminism*. MIT Press.
- 1479 GBD 2019 Risk Factors Collaborators (2020). Global burden of 87 risk factors in 204 countries
1480 and territories, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019.
1481 *The Lancet*, 396(10258):1223–1249.
- 1482 Igoikina, A. A. and Meshcheryakov, G. (2020). semopy: A python package for structural equation
1483 modeling. *Structural Equation Modeling*, 27(6):952–963.
- 1484 Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate
1485 of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual
1486 Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for
1487 Computational Linguistics.
- 1488 Kerche, F., Zook, M., and Graham, M. (2026). The silicon gaze: A typology of biases and
1489 inequality in LLMs through the lens of place. *Platforms & Society*.
- 1490 Kim, E. (2026). Generative AI in public administration: A quasi-experimental analysis of bure-
1491 aucratic productivity. *Government Information Quarterly*, 43(1):102108.

1492 Kozlakidis, Z., Wootton, T., and Mayrhofer, M. T. (2026). Through the looking glass: ethical
1493 considerations regarding LLM-induced hallucinations to medical questions. *Frontiers in Digital*
1494 *Health*, 8:1736616.

1495 Le Coz, P., Liu, J. A., Bhattacharjya, D., Curto, G., and Stinckwich, S. (2025). What would an
1496 LLM do? evaluating large language models for policymaking to alleviate homelessness. *arXiv*
1497 *preprint arXiv:2509.03827*.

1498 Manvi, R., Khanna, S., Burke, M., Lobell, D., and Ermon, S. (2024). Large language models
1499 are geographically biased. In *Proceedings of the 41st International Conference on Machine*
1500 *Learning (ICML)*. arXiv:2402.02680.

1501 Mirza, S., Coelho, B., Cui, Y., Pöpper, C., and McCoy, D. (2024). Global-liar: Factuality of
1502 LLMs over time and geographic regions. *arXiv preprint arXiv:2401.17839*.

1503 Moayeri, M., Tabassi, E., and Feizi, S. (2024). Worldbench: Quantifying geographic disparities
1504 in LLM factual recall. In *Proceedings of the 2024 ACM Conference on Fairness, Accountability,*
1505 *and Transparency*, pages 1211–1228, Rio de Janeiro, Brazil.

1506 Mohamed, S., Png, M.-T., and Isaac, W. (2020). Decolonial AI: Decolonial theory as sociotech-
1507 nical foresight in artificial intelligence. *Philosophy & Technology*, 33(4):659–684.

1508 Myung, J. et al. (2024). BLENd: A benchmark for LLMs on everyday knowledge in diverse
1509 cultures and languages. *Advances in Neural Information Processing Systems*, 37:78104–78146.

1510 Nosek, B. A., Ebersole, C. R., DeHaven, A. C., and Mellor, D. T. (2018). The preregistration
1511 revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606.

1512 OECD (2024). Governing with artificial intelligence: The state of play and way forward in core
1513 government functions. Technical report, OECD Publishing, Paris.

1514 OpenAI (2026). Prompt engineering: Identity and message formatting. OpenAI Platform Docu-
1515 mentation. Vendor documentation recommending an “Identity” block describing the assistant’s
1516 purpose and role. Accessed 2026-08-24.

1517 Opuszek, M. and Böhm, P. (2026). New york, new york – unraveling bias in large language
1518 models: Investigating differences between standard and reasoning-based language models. In
1519 *AI Revolution: Research, Ethics and Society*, pages 92–106. Springer.

1520 Patton, M. Q. (2015). *Qualitative research and evaluation methods*. SAGE Publications, 4th
1521 edition.

1522 Quijano, A. (2000). Coloniality of power, eurocentrism, and Latin America. *Nepantla: Views*
1523 *from South*, 1(3):533–580.

1524 Requia, W. J., Vicedo-Cabrera, A. M., Amini, H., and Schwartz, J. D. (2024). Short-term air
1525 pollution exposure and mortality in Brazil: Investigating the susceptible population groups.
1526 *Environmental Pollution*, 340:122797.

1527 Robinson, N. (2026). Open to open-source AI? navigating AI model choice in public sector
1528 agencies. *Government Information Quarterly*, 43(2):102133.

1529 Rover, L., Bacalhau, E. T., and Tadano, Y. (2026). Geographic bias in LLMs: Benchmark
1530 dataset and code. To be deposited on publication.

1531 Simplicio, A., Vinagre, G., Ramos, M. M., Tavares, D., Ferreira, R., et al. (2026). AMALIA
1532 technical report: A fully open source large language model for European Portuguese.

1533 UNCTAD (2024). UNCTAD statistical classifications — june 2024 update. Technical report,
1534 UN Trade and Development.

1535 VanderWeele, T. J. and Ding, P. (2017). Sensitivity analysis in observational research: introdu-
1536 cing the E-value. *Annals of Internal Medicine*, 167(4):268–274.

1537 Vieira, I., Calvo, I., Paulo, I., Furtado, J., Ferreira, R., et al. (2026). ALBA: A European
1538 Portuguese benchmark for evaluating language and linguistic dimensions in generative LLMs.
1539 *arXiv preprint arXiv:2603.26516*.

1540 White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., Elnashar, A., Spencer-Smith,
1541 J., and Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with
1542 ChatGPT. *arXiv preprint arXiv:2302.11382*.

1543 World Bank Group (2025). World Bank Country and Lending Groups — FY26 Classification.
1544 Technical report, The World Bank.

1545 World Health Organization (2021). WHO global air quality guidelines: Particulate matter
1546 (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Techni-
1547 cal report, World Health Organization, Geneva.

1548 World Health Organization (2026). Ambient air pollution attributable deaths (indicator
1549 AIR_41). Global Health Observatory. Reference year 2021, both sexes. Accessed 2026-08-
1550 19.

1551 Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., and Raffel,
1552 C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings*
1553 *of the 2021 Conference of the North American Chapter of the Association for Computational*
1554 *Linguistics: Human Language Technologies (NAACL-HLT)*, pages 483–498.

1555 Zheng, M., Pei, J., Logeswaran, L., Lee, M., and Jurgens, D. (2024). When “a helpful assistant” is
1556 not really helpful: Personas in system prompts do not improve performances of large language
1557 models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages
1558 15126–15154.