

Material Suplementar

Viés Geográfico e Linguístico em LLMs para Política de Poluição do Ar:

Um benchmark de 25 países, 14 modelos, 4 idiomas e 5 tarefas

Reprodutibilidade. Toda tabela orientada por dados a seguir (Tabelas [S1–S7](#)) é regenerada a partir dos artefatos confirmatórios brutos por `code/analysis/make_supplement_tables.py`; nenhum valor é digitado à mão. O juiz primário para todos os compostos reportados é `gpt-5-mini-2025-08-07`. O corpus confirmatório analisado é composto por 9,251 respostas pontuadas pelo juiz (7,580 com prompt em inglês; 1,671 em idioma nativo) sobre 25 países e 14 deployment-stacks. Todos os insumos, o código de pontuação, o registro de gabarito e as respostas anonimizadas serão liberados na publicação sob CC-BY-4.0 (dados/prompts) e MIT (código).

Sumário

S1 Pré-registro, desenho e seleção de países	1
S2 Roster de deployment-stacks e configuração de serving	2
S3 Cobertura	4
S4 Covariáveis dos países	6
S5 Registro de gabarito (T1)	7
S6 Resultado composto e rubrica de pontuação	9
S7 Confiabilidade do painel de juízes	10
S8 Métodos estatísticos e saídas completas dos testes confirmatórios	11
S9 Construção de prompts, template de persona e exemplos verbatim	12

S1 Pré-registro, desenho e seleção de países

As hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão, as correções de comparações múltiplas e o quadro amostral de países foram especificados antes da coleta confirmatória de dados. O desenho pré-registrado cobre **15 países**; a amostra foi subsequentemente estendida, *post registration*, para **25 países** a fim de ganhar poder para o gradiente de desenvolvimento (H1) e para os testes de mecanismo de corpus (H4) e multiplicar os pares de idioma

intra-país (H2). Ao longo do manuscrito e deste suplemento, todo efeito calculado na amostra de 25 países é reportado ao lado de seu valor pré-registrado de 15 países, e nenhuma conclusão pré-registrada é revista com base apenas na extensão (Seção S8).

Os países foram selecionados por amostragem teórica triangulada em três classificações independentes: a classificação UNCTAD Norte/Sul Global (operacionalizando o enquadramento da colonialidade do conhecimento), a taxonomia de seis classes de recurso linguístico de Joshi et al. (2020) [1] e os grupos de renda do Banco Mundial. Os 15 pré-registrados (Conjunto “P” na Tabela S4) abrangem quatro regiões do mundo, cinco classes de Joshi e quatro grupos de renda; os 10 países de extensão (Conjunto “E”) compreendem sete referências adicionais do Norte Global (Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália, Portugal) escolhidas para adensar a extremidade de alto desenvolvimento do gradiente, e três países adicionais do Sul Global com par de idioma nativo (Colômbia, Chile, Angola). A justificativa completa do desenho está em docs/supplement/s1_design_rationale.md.

S2 Roster de deployment-stacks e configuração de serving

Unidade de análise. Avaliamos cada modelo *tal como servido* por meio de uma stack de acesso fixa — a tupla de pesos do modelo, fornecedor, infraestrutura de serving e camada de API/endpoint — em vez de pesos idealizados isoladamente, porque um gestor público interage com a stack servida e qualquer lacuna medida é uma propriedade dessa stack. A Tabela S1 lista as 14 stacks com suas strings exatas de API/tag e os locais de execução.

Tabela S1. Roster de deployment-stacks. Cada modelo é avaliado *tal como servido* por meio de uma stack de acesso fixa; a string de API/tag e o local de execução fazem parte do que cada rótulo denota. As contagens de parâmetros são reportadas pelo fornecedor (densas, ou totais para MoE; contagens de fronteira fechada não divulgadas). *N* e média referem-se à cobertura confirmatória realizada de prompts em inglês.

Modelo	Fornecedor	Camada	String de API/tag	Local	<i>N</i>	Média
DeepSeek-V3	DeepSeek	A	deepseek-chat	DeepSeek API	500	0.625
Command R+	Cohere	A	command-r-plus-08-2024	Cohere (trial)	500	0.509
Llama 3.3 70B	Meta	A	llama-3.3-70b-versatile	Groq (free)	474	0.506
GPT-OSS 120B	OpenAI	A	openai/gpt-oss-120b	Groq (free)	298	0.485
Llama 4 Scout	Meta	A	meta-llama/llama-4-scout-17b-16e-instruct	Groq (free)	500	0.473
Qwen3 32B	Alibaba	B	qwen/qwen3-32b	Groq (free)	498	0.546
Phi-4 14B	Microsoft	B	phi4	Ollama (local)	500	0.485
Qwen3 14B	Alibaba	B	qwen3:14b	Ollama (local)	500	0.474
Llama 3.1 8B	Meta	C	llama-3.1-8b-instant	Groq (free)	777	0.424
Cabra-Mistral 7B	botbot-ai	C	cabra-mistral-7b	Ollama (local)	496	0.320
GPT-5-mini	OpenAI	D	gpt-5-mini	OpenAI API	777	0.626
Gemini 2.5 Flash	Google	D	gemini-2.5-flash	Google AI (free)	490	0.604

Modelo	Fornecedor	Camada	String de API/tag	Local	N	Média
Claude 4.5	Haiku Anthropic	D	claude-haiku-4-5	Anthropic API	490	0.597
GPT-5	OpenAI	E	gpt-5	OpenAI API	780	0.647

Determinismo e tratamento de seed. Todas as stacks foram consultadas a temperatura 0,3 com a configuração de máximo determinismo que cada provedor documenta, e não com uma superfície idêntica de parâmetros, porque as superfícies diferem. O suporte a seed é heterogêneo: stacks servidas localmente (Ollama) honram uma seed fixa; a OpenAI expõe uma seed advisory; a Messages API da Anthropic não expõe parâmetro de seed; e, para os demais endpoints hospedados, a seed é advisory ou não é exposta. Para cada chamada registramos a seed solicitada e um campo `seed_status` (`sent`, `logged-only` ou `not-supported`) nos metadados de execução liberados, de modo que o determinismo de fato alcançado seja auditável em vez de presumido. Duas replicações estocásticas por célula (prompt, modelo, persona) estimam a variabilidade intra-célula.

Janela de aquisição. O comportamento do modelo servido pode derivar à medida que fornecedores atualizam a infraestrutura, de modo que as acurácias reportadas são estimativas point-in-time relativas à janela de coleta. A tag fixada, a string de versão e o timestamp de aquisição são registrados para cada chamada. A coleta confirmatória ocorreu de **2026-04-26 a 2026-06-12** (UTC), abrangendo o piloto, a coleta pré-registrada de 15 países e a extensão post-registration para 25 países. A Tabela S2 dá o timestamp da primeira e da última chamada sem erro por provedor, junto com a documentação oficial de API consultada; os timestamps completos por chamada são liberados com o conjunto de dados.

Tabela S2. Janela de aquisição por fornecedor e documentação oficial de API. As acurácias reportadas são estimativas point-in-time relativas a esta janela; “primeira”/“última” são os timestamps (UTC) da primeira e da última chamada sem erro registrados nos logs de execução. A janela abrange o piloto, a coleta pré-registrada de 15 países e a extensão post-registration.

Fornecedor (local)	Primeira (UTC)	Última (UTC)	Documentação de API
Anthropic API	2026-04-27	2026-06-12	https://docs.anthropic.com/en/api/messages
Cohere (trial)	2026-04-26	2026-06-11	https://docs.cohere.com/reference/chat
DeepSeek API	2026-04-26	2026-06-11	https://api-docs.deepseek.com
Google AI (free)	2026-04-27	2026-06-11	https://ai.google.dev/api
Groq (free)	2026-04-26	2026-06-11	https://console.groq.com/docs/api-reference

Fornecedor (local)	Primeira (UTC)	Última (UTC)	Documentação de API
Ollama (local)	2026-04-27	2026-06-12	https://github.com/ollama/ollama/blob/main/docs/api.md
OpenAI API	2026-04-27	2026-06-12	https://platform.openai.com/docs/api-reference/chat
Todos os fornecedores	2026-04-26	2026-06-12	—

S3 Cobertura

A cobertura por célula não é uniforme ao longo do roster: endpoints gratuitos e com limite de taxa retornaram menos respostas admissíveis do que as APIs medidas, e um candidato (Gemini 2.5 Flash em lotes nativos iniciais) e um sexto juiz (Command R+) atingiram cotas dos provedores. Reportamos a cobertura realizada em vez de descartar silenciosamente células subcobertas. A Tabela S3 dá a matriz modelo $\times$ tarefa para prompts em inglês (os totais por coluna igualam as contagens por tarefa do texto principal); a Tabela S4 dá as contagens por país em inglês, nativo e total com camada e conjunto de pré-registro; a Tabela S5 lista os pares de idioma nativo usados em H2. A matriz de cobertura completa modelo $\times$ país $\times$ tarefa, com o motivo de cota ou exclusão de cada déficit, está incluída no release.

Tabela S3. Matriz de cobertura: respostas confirmatórias realizadas (prompts em inglês) por modelo $\times$ tarefa (T1 padrão, T2 dado local, T3 síntese em saúde, T4 instrumentos, T5 recomendação). Nenhuma célula é descartada silenciosamente; déficits são por cota (Métodos).

Modelo	T1	T2	T3	T4	T5	Total
GPT-5	156	156	156	156	156	780
GPT-5-mini	156	156	156	153	156	777
Llama 3.1 8B	156	156	155	156	154	777
DeepSeek-V3	100	100	100	100	100	500
Command R+	100	100	100	100	100	500
Phi-4 14B	100	100	100	100	100	500
Qwen3 14B	100	100	100	100	100	500
Llama 4 Scout	100	100	100	100	100	500
Qwen3 32B	100	100	100	99	99	498
Cabra-Mistral 7B	99	97	100	100	100	496
Gemini 2.5 Flash	98	98	98	98	98	490
Claude Haiku 4.5	98	98	98	98	98	490
Llama 3.3 70B	98	97	96	92	91	474

Modelo	T1	T2	T3	T4	T5	Total
GPT-OSS 120B	68	72	60	42	56	298
Total	1529	1530	1519	1494	1508	7580

Tabela S4. Cobertura por país: camada (GN/GS), status de pré-registro (P = pré-registrado, 15 países; E = extensão post-registration), e respostas confirmatórias realizadas (inglês, idioma nativo, total).

País	Camada	Conjunto	Inglês	Nativo	Total
Colombia	GS	E	260	251	511
Chile	GS	E	260	241	501
Portugal	GN	E	261	240	501
Angola	GS	E	260	240	500
Argentina	GS	P	355	139	494
India	GS	P	352	138	490
Mexico	GS	P	329	140	469
Peru	GS	P	316	141	457
Brazil	GS	P	260	141	401
Germany	GN	P	356	0	356
Indonesia	GS	P	356	0	356
Bangladesh	GS	P	355	0	355
Egypt	GS	P	355	0	355
Kenya	GS	P	348	0	348
Japan	GN	P	347	0	347
Nigeria	GS	P	317	0	317
Philippines	GS	P	316	0	316
United States	GN	P	312	0	312
South Africa	GS	P	302	0	302
United Kingdom	GN	E	265	0	265
Canada	GN	E	260	0	260
Australia	GN	E	260	0	260
France	GN	E	260	0	260
Italy	GN	E	260	0	260
South Korea	GN	E	258	0	258
Total (25)			7580	1671	9251

Tabela S5. Respostas confirmatórias em idioma nativo por idioma e país (contraste intra-país inglês/nativo, H2).

Idioma nativo (Joshi)	País	<i>N</i> (nativo)
Portuguese (4)	Portugal	240

Idioma nativo (Joshi)	País	N (nativo)
Spanish (5)	Angola	240
	Brazil	141
	Colombia	251
	Chile	241
	Peru	141
	Mexico	140
	Argentina	139
Hindi (4)	India	138

S4 Covariáveis dos países

A Tabela S6 reporta as covariáveis de desenvolvimento e de representação no corpus usadas na análise de mecanismo (H4). As medidas de **corpus do idioma** (classe Joshi; tamanhos mC4/OSCAR reportados no texto principal) indexam quanto texto existe *no* idioma de um país e são o canal candidato para a penalidade de idioma nativo (H2). As medidas de **cobertura de país** (comprimento em bytes do artigo na Wikipédia em inglês, sitelinks do Wikidata, statements do Wikidata) indexam quão amplamente o corpus enciclopédico é *sobre* um país, independentemente do idioma, e são o canal candidato para a lacuna geográfica (H1/H4). Como a lacuna geográfica é medida *em inglês*, uma lacuna Norte/Sul residual não pode ser um efeito de corpus do idioma, razão pela qual H4 isola a cobertura de país para H1 e o tamanho do corpus do idioma para H2. Todas as entidades do Wikidata são identificadas por um QID resolvível e foram recuperadas dentro da janela de coleta.

Tabela S6. Covariáveis dos países. IDH: UNDP HDR 2023–24 (dados de 2022). Joshi: classe de recurso linguístico do idioma oficial dominante [1]. Medidas de corpus do Wikimedia/Wikidata (QID da entidade resolvível): comprimento em bytes do artigo em inglês, sitelinks do Wikidata (edições de idioma) e statements do Wikidata.

País	Camada	IDH	Joshi	Bytes wiki-EN	Sitelinks	Stmts WD
Germany	GN	0.950	5	207,810	403	1402
Australia	GN	0.946	5	233,095	395	1674
United Kingdom	GN	0.940	5	368,888	391	1085
Canada	GN	0.935	5	281,016	393	1346
South Korea	GN	0.929	4	275,291	350	746
United States	GN	0.927	5	383,914	424	1710
Japan	GN	0.920	5	205,844	414	995
France	GN	0.910	5	279,498	413	1196
Italy	GN	0.906	4	305,234	405	1039
Portugal	GN	0.874	4	324,038	369	751
Chile	GS	0.860	5	232,108	379	689
Argentina	GS	0.849	5	267,662	369	881

País	Camada	IDH	Joshi	Bytes wiki-EN	Sitelinks	Stmts WD
Mexico	GS	0.781	5	263,757	398	1286
Peru	GS	0.762	5	239,544	332	867
Brazil	GS	0.760	4	301,844	384	1151
Colombia	GS	0.758	5	303,401	363	774
Egypt	GS	0.728	5	284,547	387	757
South Africa	GS	0.717	5	270,861	365	750
Indonesia	GS	0.713	3	226,349	362	1005
Philippines	GS	0.710	5	493,981	331	963
Bangladesh	GS	0.670	3	275,786	343	814
India	GS	0.644	5	310,681	399	1679
Kenya	GS	0.601	5	216,189	334	699
Angola	GS	0.591	4	180,098	322	676
Nigeria	GS	0.548	5	266,041	349	1194

S5 Registro de gabarito (T1)

A validade do gradiente geográfico (H1) requer que o gabarito seja igualmente disponível e igualmente verificável entre os países. Para T1 (o padrão anual vinculante de PM_{2.5}) ancoramos cada país a uma fonte oficial primária por auditoria documental: o texto-fonte foi recuperado, o valor foi lido verbatim, e a entrada registra o valor, o status, a fonte-de-registro, uma URL resolvível e o método de recuperação (Tabela S7). Três países *não têm* padrão nacional de PM_{2.5}, confirmado pelo texto oficial (a NESREA da Nigéria regula apenas PM₁₀; a Argentina não tem valor federal vinculante; a Angola não tem legislação nacional de qualidade do ar); nesses casos, um modelo fiel deve recusar-se a indicar um limiar inexistente em vez de fabricá-lo. Essa proveniência é mais reproduzível do que a asserção de especialistas: qualquer leitor pode reverificar cada valor a partir da fonte oficial citada. Nenhuma referência no registro é não-verificada, e nenhum valor foi transposto de fontes secundárias sem confirmação contra o texto primário.

Tabela S7. Registro de gabarito ancorado em fontes oficiais primárias; VERIFIED_NO_S = texto oficial; VERIFIED_NO_S = texto oficial; PARTIALLY_VERIFIED = fonte incompleta e trechos verbatim esta

País	Valor
Angola	NO national air-quality legislation / standard
Argentina	NO single binding federal PM2.5 standard (Ley 20.284/1973 framework; PM2.5 limits set

País	Valor
Australia	8 ug/m3 (annual; 7 target 2025)
Bangladesh	15 ug/m3 (annual) per Gazette S.R.O. 220-Law/2005; a 2022 revision exists but the revision is not in force
Brazil	17 ug/m3 (annual, PI-2)
Canada	8.8 ug/m3 (annual, CAAQS 2020)
Chile	20 ug/m3 (annual)
Colombia	25 ug/m3 (annual, in force since 2018; 15 from 2030; 24h=37)
Egypt	PM2.5 limit set under Law 4/1994 (amended 9/2009, 105/2015) Executive Regulations (order of the Council of Ministers)
France	25 ug/m3 (annual, in force; 10 from 2030)
Germany	25 ug/m3 (annual, in force 2026; 10 from 2030)
India	40 ug/m3 (annual)
Indonesia	15 ug/m3 (annual)
Italy	25 ug/m3 (annual, in force; 10 from 2030)
Japan	15 ug/m3 (annual)
Kenya	35 ug/m3 (annual; 24h 75)
Mexico	10 ug/m3 (annual)

País	Valor
Nigeria	NO national PM2.5 standard (PM10 annual=60 ug/m3, 24h=150)
Peru	25 ug/m3 (annual)
Philippines	25 ug/m3 (annual, 1-year guideline)
Portugal	25 ug/m3 (annual, in force; 10 from 2030)
South Africa	20 ug/m3 (annual)
South Korea	15 ug/m3 (annual)
United Kingdom	10 ug/m3 (annual, target by 2040)
United States	9.0 ug/m3 (annual, primary NAAQS, 2024)

S6 Resultado composto e rubrica de pontuação

Cada resposta foi pontuada pelo juiz primário contra a entrada do registro de gabarito (T1, T2, T4) ou a rubrica validada (T3, T5), produzindo cinco subcomponentes, cada um normalizado a $[0, 1]$:

1. **Acurácia factual** contra o valor do registro (binária para T1; crédito parcial para T2–T4).
2. **Compleitude contextual** pontuada contra uma rubrica pré-validada (T3, T4).
3. **Qualidade de citação**, verificada por checagem de DOI/fonte oficial.
4. **Ausência de alucinação**, codificada de forma binária (0 alucinada, 1 fiel).
5. **Validade aplicada**, a pontuação de rubrica para a recomendação operacional (T5).

O composto primário usa pesos iguais. Duas ponderações de sensibilidade pré-especificadas são reportadas — um conjunto derivado por PCA estimado no piloto estendido do Brasil, e um conjunto especificado pelos autores (factual 0,30, contextual 0,25, citação 0,15, alucinação 0,15,

aplicada 0,15) — e uma conclusão é tratada como robusta apenas se valer sob as três. O composto é calculado por célula (país, modelo, persona) para suportar o teste de diferença-em-diferenças de H6. Cada registro pontuado guarda também a justificativa textual do juiz; por exemplo, o juiz `gpt-5-mini` pontuou uma resposta do Llama 4 Scout sobre o padrão T1 do Brasil em 0,15 com a justificativa de que ela “gives wrong regulation (491/2018 vs correct 506/2024) and wrong current value. . . included a specific but incorrect citation and fabricated timing”, ilustrando como os subcomponentes de acurácia factual e de alucinação discriminam falha substantiva.

S7 Confiabilidade do painel de juízes

Para tratar a sobreposição juiz–alvo (o juiz primário, `gpt-5-mini`, está ele próprio entre os modelos avaliados), uma amostra de confiabilidade fixa e estratificada de **131 respostas** (estratificada por país $\times$ tarefa $\times$ persona, seed fixa) foi re-pontuada de forma independente por um painel diverso em fornecedores. A amostra foi congelada *antes* do julgamento — caso contrário, o amostrador de concordância re-sorteia da base de respostas viva, o que dessincronizou as amostras por juiz quando a base cresceu de 15 para 25 países — e fixada aos itens comuns dos juízes por `code/analysis/judge_fixed_keys.py`.

Tabela S8. Confiabilidade inter-juízes na amostra fixa de 131 itens. A quantidade operativa é a confiabilidade da *média* do painel, $ICC(2, k)$; pela relação de Spearman–Brown, ela é alta mesmo quando os juízes individuais concordam apenas moderadamente. Fonte: `judge_panel_reliability.json`.

Quantidade	Valor
Juízes (k)	4 (OpenAI, Anthropic, Google, DeepSeek)
Itens comuns	131
α de Krippendorff (intervalar)	0.667
$ICC(2, 1)$ de juiz único	0.672
$ICC(2, 4)$ da média do painel	0.891
Pearson pareado: GPT-5-mini Claude Sonnet	0.859
GPT-5-mini DeepSeek-V3	0.834
Claude Sonnet DeepSeek-V3	0.821
GPT-5-mini Gemini 2.5 Pro	0.626
Claude Sonnet Gemini 2.5 Pro	0.630
DeepSeek-V3 Gemini 2.5 Pro	0.610

A concordância é mais forte entre GPT-5-mini, Claude e DeepSeek (Pearson 0,82–0,86) e mais baixa para o Gemini, sistematicamente mais leniente (0,61–0,63); como todo efeito reportado é um contraste entre grupos (lacuna de camada, penalidade de idioma, piso de tarefa), o offset de leniência de um juiz cancela e não ameaça esses contrastes. Um quinto juiz (Llama 3.3 70B, Meta) corroborou nos itens que cobriu ($ICC(2, 5) = 0,861$ com cinco juízes), mas, por ser um juiz 70B mais ruidoso, *baixou* o α do painel para 0,538 — confirmando empiricamente que quatro juízes fortes são preferíveis a cinco com um mais fraco. Um sexto candidato (Command R+, Cohere) foi excluído quando sua cota de trial se esgotou no meio da execução; como checagem fora-de-amostra, o Command R+ nos 315 itens que cobriu concordou com o juiz primário em Pearson 0,647 / $ICC(2, 1) = 0,602$. O estudo usa o composto único do `gpt-5-mini` para todos os efeitos, validado por este painel, em vez de uma pontuação média entre juízes; a ausência de uma camada independente de padrão-ouro humano é declarada como limitação no texto principal.

S8 Métodos estatísticos e saídas completas dos testes confirmatórios

Os três testes confirmatórios primários formam uma única família (F1) corrigida em conjunto pelo procedimento step-down de Bonferroni–Holm ($\alpha = 0,05$). Os testes confirmatórios secundários são reportados sem ajuste dentro da família; os testes declarados exploratórios usam FDR de Benjamini–Hochberg a $q = 0,10$. As correlações de postos usam Spearman ρ ; a robustez de tendência monotônica usa o teste de Mann–Kendall; o efeito de persona usa um teste de permutação em nível de país (5,000 permutações). Todas as saídas a seguir são regeneradas por `code/analysis/formal_tests.py`, `robust_tests.py` e `h4_corpus_mechanism.py`.

Tabela S9. Família primária (Bonferroni–Holm): valores pré-registrados de 15 países ao lado da extensão post-registration de 25 países. H1-por-IDH é o único teste primário que rejeita sua hipótese nula a $n = 25$; permanece abaixo do limiar de tamanho de efeito pré-registrado $\rho \geq 0,55$ em ambas as amostras.

Teste	15 países (pré-registrado)	25 países (extensão)
H1 Spearman $\rho(\text{acc, IDH})$	+0.143 (unilateral $p = 0.306$), ns	+0.512 ($p = 0.004$), rejeita sob B–H
H1 Mann–Kendall (por IDH)	$S = 9$, $Z = +0.40$, $p = 0.692$	$S = 102$, $Z = +2.36$, $p = 0.018$
H1 Spearman $\rho(\text{acc, Joshi})$	+0.028, ns	−0.061, ns (desenvolvimento, não linguístico)
H1 vs limiar $\rho \geq 0.55$	não atingido	não atingido (significativo, abaixo do tamanho de efeito)
H4 ρ parcial (acc, Wiki IDH)	+0.218 ($p = 0.45$), ns	+0.036 ($p = 0.87$), ns
H6 DiD persona (GS–GN)	+0.97 pp, perm $p = 0.142$, ns	+0.39 pp, perm $p = 0.257$, ns

Tabela S10. Mecanismo de corpus H4, multi-medida (25 países). A amplitude de cobertura de país (sitelinks do Wikidata) prediz a acurácia no nível de ordem zero e sobrevive à correção de multiplicidade entre os três proxies de cobertura, mas atenua-se até a não-significância após ajuste para desenvolvimento (IDH); reportamos, portanto, como sugestivo/exploratório, não como mecanismo estabelecido. O proxy pré-registrado de edição de idioma é nulo.

Medida	Família	$\rho(\text{acc, log medida})$	parcial IDH
Bytes Wikipédia-inglês	país	+0.198 ($p = 0.34$)	+0.181
Sitelinks Wikidata	país	+0.539 ($p = 0.005$)	+0.317 ($p = 0.13$)
Statements Wikidata	país	+0.313 ($p = 0.13$)	+0.144
Contagem de edições Wikipédia	idioma	+0.082, ns	+0.036, ns

Tabela S11. Achados secundários robustos (25 países), com verificações de leave-one-country-out (LOCO) e de restrição de amplitude.

Achado	Estatística
Lacuna de camada (GN–GS)	+6.2 pp, IC 95% [+3.7, +8.6] (15 países: +6.7 [+2.8, +10.2])
Lacuna de camada, faixa LOCO	[+5.8, +7.1] pp, estável
Gradiente IDH H1, faixa LOCO	$\rho \in [+0.48 \text{ (sem NGA), } +0.66 \text{ (sem IND)}]$
H1 com amplitude restrita (dentro do IDH dos 15)	$\rho = 0.512$ ($p = 0.009$): densidade, não amplitude
Piso de tarefa (T1+T2 vs T3–T5)	0.367 vs 0.638, Mann–Whitney, δ de Cliff = −0.64
H3 Cabra–Mistral vs restante	0.320 vs 0.543, δ de Cliff = −0.51
H2 nativo vs inglês (todos)	$\Delta = -2.1$ pp, Wilcoxon $p = 1.96 \times 10^{-3}$ ($n = 762$)
Espanhol / Português / Hindi	−1.0 ($p = 0.15$) / −2.3 ($p = 0.033$) / −7.8 ($p = 0.013$)
H2 em nível de país (unidade independente, $n = 9$)	9/9 negativos, média −2.4 pp, Wilcoxon $p = 0.008$
H5 aberto vs fechado–acessível	vantagem fechada de +14.1 pp (descritivo)

S9 Construção de prompts, template de persona e exemplos verbatim

Os prompts foram autorados em inglês para o domínio de política de poluição do ar com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrar no conjunto de estímulos confirmatório; um subconjunto-piloto atingiu um limiar inter-avaliadores de α de Krippendorff $\geq 0,70$ antes da escala. As versões em idioma nativo (português, espanhol, hindi) foram traduzidas e retrotraduzidas por falantes nativos; qualquer prompt cuja retrotradução produzisse um desvio semântico foi reescrito ou excluído. Toda afirmação factual em uma entrada de gabarito precisava resolver para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido (o Protocolo de Verificação de Citações do projeto aplicado já na geração do gabarito, não apenas na fase de manuscrito).

Manipulação de persona. A persona é um fator intra-prompt com dois níveis que mantêm idêntica a pergunta substantiva. O nível **neutral** apresenta um pedido simples de informação; o nível **public_manager_env** prepõe um enquadramento fixo de papel. O contraste é mostrado verbatim para o Brasil, T1:

Neutro. “What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

Gestor ambiental público. “*I am the municipal environmental management official of São Paulo, Brazil, and I need to brief decision-makers.* What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

O gabarito correspondente no registro é (em tradução): “Os padrões nacionais de PM_{2.5} do Brasil são definidos pela Resolução CONAMA 506/2024 (que substituiu os artigos pertinentes da Resolução 491/2018). A etapa em vigor em 2026 é a Meta Intermediária PI-2; a Meta Final adota a diretriz anual da OMS 2021 de 5 $\mu\text{g}/\text{m}^3$ ” (fonte: Resolução CONAMA 506/2024). Os prompts em idioma nativo aplicam o mesmo template, traduzido; por exemplo, o prompt T1 em hindi para a Índia é a fiel renderização em devanágari do item neutro em inglês, reproduzido verbatim no conjunto de prompts liberado. O conjunto completo de prompts (370 itens confirmatórios: 25 países $\times$ 5 tarefas $\times$ persona, mais os pares de idioma nativo) é liberado como **prompts_confirmatory.jsonl** com o gabarito, a fonte e a rubrica por item.

Referências

- [1] Pratik Joshi, Sebastin Santy, Amar Budhiraja, Kalika Bali, and Monojit Choudhury. The state and fate of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.acl-main.560.