

Material Suplementar

Viés Geográfico e Linguístico em LLMs para Política de Poluição do Ar:

Um benchmark de 25 países, 14 modelos, 4 idiomas e 5 tarefas

Reprodutibilidade. Toda tabela orientada por dados a seguir (Tabelas [S1–S7](#)) é regenerada a partir dos artefatos confirmatórios brutos por `code/analysis/make_supplement_tables.py`; nenhum valor é digitado à mão. O juiz primário para todos os compostos reportados é `gpt-5-mini-2025-08-07`. O corpus confirmatório analisado é composto por 8.300 células pontuadas (6.629 com prompt em inglês; 1.671 em idioma nativo; 9.251 pontuações no total, das quais 951 células receberam mais de um score em re-execuções e foram colapsadas pela média) sobre 25 países e 14 deployment-stacks. Todos os insumos, o código de pontuação, o registro de gabarito e as respostas anonimizadas serão liberados na publicação sob CC-BY-4.0 (dados/prompts) e MIT (código).

Sumário

S1 Pré-especificação, desenho e seleção de países	2
S2 Roster de deployment-stacks e configuração de serving	2
S3 Cobertura	4
S4 Covariáveis dos países	6
S5 Registro de gabarito (T1)	7
S6 Resultado composto e rubrica de pontuação	9
S7 Confiabilidade do painel de juízes	10
S8 Métodos estatísticos e saídas completas dos testes confirmatórios	10
S9 Análises adicionais de robustez e corroboração	11
S9.1 Acurácia composta por país	12
S9.2 Lacuna de camada sob partições alternativas de país	12
S9.3 Modos representativos de falha, literais	12
S10 Desvios em relação ao plano de análise pré-especificado	13
S11 Construção de prompts, template de persona e exemplos verbatim	15

S1 Pré-especificação, desenho e seleção de países

As hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão, as correções de comparações múltiplas e o quadro amostral de países foram especificados antes da coleta confirmatória de dados. O desenho pré-especificado cobre 15 países; a amostra foi subsequentemente estendida, *post registration*, para 25 países a fim de ganhar poder para o gradiente de desenvolvimento (H1) e para os testes de mecanismo de corpus (H4) e multiplicar os pares de idioma intra-país (H2). Ao longo do manuscrito e deste suplemento, todo efeito calculado na amostra de 25 países é reportado ao lado de seu valor pré-especificado de 15 países, e nenhuma conclusão pré-especificada é revista com base apenas na extensão (Seção S8).

Os países foram selecionados por amostragem teórica triangulada em três classificações independentes: a classificação UNCTAD Norte/Sul Global (operacionalizando o enquadramento da colonialidade do conhecimento), a taxonomia de seis classes de recurso linguístico de Joshi et al. (2020) (Joshi et al., 2020) e os grupos de renda do Banco Mundial. Os 15 pré-especificados (Conjunto “P” na Tabela S4) abrangem quatro regiões do mundo, cinco classes de Joshi e quatro grupos de renda; os 10 países de extensão (Conjunto “E”) compreendem sete referências adicionais do Norte Global (Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália, Portugal) escolhidas para adensar a extremidade de alto desenvolvimento do gradiente, e três países adicionais do Sul Global com par de idioma nativo (Colômbia, Chile, Angola). A justificativa completa do desenho está em docs/supplement/s1_design_rationale.md.

S2 Roster de deployment-stacks e configuração de serving

Unidade de análise. Avaliamos cada modelo *tal como servido* por meio de uma stack de acesso fixa — a tupla de pesos do modelo, fornecedor, infraestrutura de serving e camada de API/endpoint — em vez de pesos idealizados isoladamente, porque um gestor público interage com a stack servida e qualquer lacuna medida é uma propriedade dessa stack. A Tabela S1 lista as 14 stacks com suas strings exatas de API/tag e os locais de execução.

Tabela S1. Roster de deployment-stacks. Cada modelo é avaliado *tal como servido* por meio de uma stack de acesso fixa; a string de API/tag e o local de execução fazem parte do que cada rótulo denota. As contagens de parâmetros são reportadas pelo fornecedor (densas, ou totais para MoE; contagens de fronteira fechada não divulgadas). *N* e média referem-se à cobertura confirmatória realizada de prompts em inglês.

Modelo	Fornecedor	Camada	String de API/tag	Local	<i>N</i>	Média
DeepSeek-V3	DeepSeek	A	deepseek-chat	DeepSeek API	500	0.625
Command R+	Cohere	A	command-r-plus-08-2024	Cohere (trial)	500	0.509
Llama 3.3 70B	Meta	A	llama-3.3-70b-versatile	Groq (free)	474	0.506
GPT-OSS 120B	OpenAI	A	openai/gpt-oss-120b	Groq (free)	298	0.485
Llama 4 Scout	Meta	A	meta-llama/llama-4-scout-17b-16e-instruct	Groq (free)	500	0.473
Qwen3 32B	Alibaba	B	qwen/qwen3-32b	Groq (free)	498	0.546
Phi-4 14B	Microsoft	B	phi4	Ollama (local)	500	0.485

Modelo	Fornecedor	Camada	String de API/tag	Local	N	Média
Qwen3 14B	Alibaba	B	qwen3:14b	Ollama (local)	500	0.474
Llama 3.1 8B	Meta	C	llama-3.1-8b-instant	Groq (free)	777	0.424
Cabra-Mistral 7B	botbot-ai	C	cabra-mistral-7b	Ollama (local)	496	0.320
GPT-5-mini	OpenAI	D	gpt-5-mini	OpenAI API	777	0.626
Gemini 2.5 Flash	Google	D	gemini-2.5-flash	Google AI (free)	490	0.604
Claude Haiku 4.5	Anthropic	D	claude-haiku-4-5	Anthropic API	490	0.597
GPT-5	OpenAI	E	gpt-5	OpenAI API	780	0.647

Determinismo e tratamento de seed. Todas as stacks foram consultadas a temperatura 0,3 com a configuração de máximo determinismo que cada provedor documenta, e não com uma superfície idêntica de parâmetros, porque as superfícies diferem. O suporte a seed é heterogêneo: stacks servidas localmente (Ollama) honram uma seed fixa; a OpenAI expõe uma seed advisory; a Messages API da Anthropic não expõe parâmetro de seed; e, para os demais endpoints hospedados, a seed é advisory ou não é exposta. Para cada chamada registramos a seed solicitada e um campo `seed_status` (`sent`, `logged-only` ou `not-supported`) nos metadados de execução liberados, de modo que o determinismo de fato alcançado seja auditável em vez de presumido. Duas replicações estocásticas por célula (prompt, modelo, persona) estimam a variabilidade intra-célula.

Janela de aquisição. O comportamento do modelo servido pode derivar à medida que fornecedores atualizam a infraestrutura, de modo que as acurácias reportadas são estimativas point-in-time relativas à janela de coleta. A tag fixada, a string de versão e o timestamp de aquisição são registrados para cada chamada. A coleta confirmatória ocorreu de 2026-04-26 a 2026-06-12 (UTC), abrangendo o piloto, a coleta pré-especificada de 15 países e a extensão post-registration para 25 países. A Tabela S2 dá o timestamp da primeira e da última chamada sem erro por provedor, junto com a documentação oficial de API consultada; os timestamps completos por chamada são liberados com o conjunto de dados.

Tabela S2. Janela de aquisição por fornecedor e documentação oficial de API. As acurácias reportadas são estimativas point-in-time relativas a esta janela; “primeira”/“última” são os timestamps (UTC) da primeira e da última chamada sem erro registrados nos logs de execução. A janela abrange o piloto, a coleta pré-registrada de 15 países e a extensão post-registration.

Fornecedor (local)	Primeira (UTC)	Última (UTC)	Documentação de API
Anthropic API	2026-04-27	2026-06-12	https://docs.anthropic.com/en/api/messages
Cohere (trial)	2026-04-26	2026-06-11	https://docs.cohere.com/reference/chat

Fornecedor (local)	Primeira (UTC)	Última (UTC)	Documentação de API
DeepSeek API	2026-04-26	2026-06-11	https://api-docs.deepseek.com
Google AI (free)	2026-04-27	2026-06-11	https://ai.google.dev/api
Groq (free)	2026-04-26	2026-06-11	https://console.groq.com/docs/api-reference
Ollama (local)	2026-04-27	2026-06-12	https://github.com/ollama/ollama/blob/main/docs/api.md
OpenAI API	2026-04-27	2026-06-12	https://platform.openai.com/docs/api-reference/chat
Todos os fornecedores	2026-04-26	2026-06-12	—

S3 Cobertura

A cobertura por célula não é uniforme ao longo do roster: endpoints gratuitos e com limite de taxa retornaram menos respostas admissíveis do que as APIs medidas, e um candidato (Gemini 2.5 Flash em lotes nativos iniciais) e um sexto juiz (Command R+) atingiram cotas dos provedores. Reportamos a cobertura realizada em vez de descartar silenciosamente células subcobertas. A Tabela S3 dá a matriz modelo $\times$ tarefa para prompts em inglês (os totais por coluna igualam as contagens por tarefa do texto principal); a Tabela S4 dá as contagens por país em inglês, nativo e total com camada e conjunto de pré-especificação; a Tabela S5 lista os pares de idioma nativo usados em H2. A matriz de cobertura completa modelo $\times$ país $\times$ tarefa, com o motivo de cota ou exclusão de cada déficit, está incluída no release.

Tabela S3. Matriz de cobertura: respostas confirmatórias realizadas (prompts em inglês) por modelo $\times$ tarefa (T1 padrão, T2 dado local, T3 síntese em saúde, T4 instrumentos, T5 recomendação). Nenhuma célula é descartada silenciosamente; déficits são por cota (Métodos).

Modelo	T1	T2	T3	T4	T5	Total
GPT-5	156	156	156	156	156	780
GPT-5-mini	156	156	156	153	156	777
Llama 3.1 8B	156	156	155	156	154	777
DeepSeek-V3	100	100	100	100	100	500
Command R+	100	100	100	100	100	500
Phi-4 14B	100	100	100	100	100	500
Qwen3 14B	100	100	100	100	100	500
Llama 4 Scout	100	100	100	100	100	500
Qwen3 32B	100	100	100	99	99	498

Modelo	T1	T2	T3	T4	T5	Total
Cabra-Mistral 7B	99	97	100	100	100	496
Gemini 2.5 Flash	98	98	98	98	98	490
Claude Haiku 4.5	98	98	98	98	98	490
Llama 3.3 70B	98	97	96	92	91	474
GPT-OSS 120B	68	72	60	42	56	298
Total	1529	1530	1519	1494	1508	7580

Tabela S4. Cobertura por país: camada (GN/GS), status de pré-registro (P = pré-registrado, 15 países; E = extensão post-registration), e respostas confirmatórias realizadas (inglês, idioma nativo, total).

País	Camada	Conjunto	Inglês	Nativo	Total
Colombia	GS	E	260	251	511
Chile	GS	E	260	241	501
Portugal	GN	E	261	240	501
Angola	GS	E	260	240	500
Argentina	GS	P	355	139	494
India	GS	P	352	138	490
Mexico	GS	P	329	140	469
Peru	GS	P	316	141	457
Brazil	GS	P	260	141	401
Germany	GN	P	356	0	356
Indonesia	GS	P	356	0	356
Bangladesh	GS	P	355	0	355
Egypt	GS	P	355	0	355
Kenya	GS	P	348	0	348
Japan	GN	P	347	0	347
Nigeria	GS	P	317	0	317
Philippines	GS	P	316	0	316
United States	GN	P	312	0	312
South Africa	GS	P	302	0	302
United Kingdom	GN	E	265	0	265
Canada	GN	E	260	0	260
Australia	GN	E	260	0	260
France	GN	E	260	0	260
Italy	GN	E	260	0	260
South Korea	GN	E	258	0	258
Total (25)			7580	1671	9251

Tabela S5. Respostas confirmatórias em idioma nativo por idioma e país (contraste intra-país inglês/nativo, H2).

Idioma nativo (Joshi)	País	<i>N</i> (nativo)
Portuguese (4)	Portugal	240
	Angola	240
	Brazil	141
Spanish (5)	Colombia	251
	Chile	241
	Peru	141
	Mexico	140
	Argentina	139
Hindi (4)	India	138

S4 Covariáveis dos países

A Tabela S6 reporta as covariáveis de desenvolvimento e de representação no corpus usadas na análise de mecanismo (H4). As medidas de corpus do idioma (classe Joshi; tamanhos mC4/OSCAR reportados no texto principal) indexam quanto texto existe *no* idioma de um país e são o canal candidato para a penalidade de idioma nativo (H2). As medidas de cobertura de país (comprimento em bytes do artigo na Wikipédia em inglês, sitelinks do Wikidata, statements do Wikidata) indexam quão amplamente o corpus enciclopédico é *sobre* um país, independentemente do idioma, e são o canal candidato para a lacuna geográfica (H1/H4). Como a lacuna geográfica é medida *em inglês*, uma lacuna Norte/Sul residual não pode ser um efeito de corpus do idioma, razão pela qual H4 isola a cobertura de país para H1 e o tamanho do corpus do idioma para H2. Todas as entidades do Wikidata são identificadas por um QID resolvível e foram recuperadas dentro da janela de coleta.

Tabela S6. Covariáveis dos países. IDH: UNDP HDR 2023–24 (dados de 2022). Joshi: classe de recurso linguístico do idioma oficial dominante (Joshi et al., 2020). Medidas de corpus do Wikimedia/Wikidata (QID da entidade resolvível): comprimento em bytes do artigo em inglês, sitelinks do Wikidata (edições de idioma) e statements do Wikidata.

País	Camada	IDH	Joshi	Bytes wiki-EN	Sitelinks	Stmts WD
Germany	GN	0.950	5	207,810	403	1402
Australia	GN	0.946	5	233,095	395	1674
United Kingdom	GN	0.940	5	368,888	391	1085
Canada	GN	0.935	5	281,016	393	1346
South Korea	GN	0.929	4	275,291	350	746
United States	GN	0.927	5	383,914	424	1710
Japan	GN	0.920	5	205,844	414	995
France	GN	0.910	5	279,498	413	1196
Italy	GN	0.906	4	305,234	405	1039

País	Valor
Argentina	NO single binding federal PM2.5 standard (Ley 20.284/1973 framework; PM2.5 limits set
Australia	
	8 ug/m3 (annual; 7 target 2025)
Bangladesh	15 ug/m3 (annual) per Gazette S.R.O. 220-Law/2005; a 2022 revision exists but the revision
Brazil	17 ug/m3 (annual, PI-2)
Canada	8.8 ug/m3 (annual, CAAQS 2020)
Chile	20 ug/m3 (annual)
Colombia	25 ug/m3 (annual, in force since 2018; 15 from 2030; 24h=37)
Egypt	PM2.5 limit set under Law 4/1994 (amended 9/2009, 105/2015) Executive Regulations (o
France	25 ug/m3 (annual, in force; 10 from 2030)
Germany	25 ug/m3 (annual, in force 2026; 10 from 2030)
India	40 ug/m3 (annual)
Indonesia	15 ug/m3 (annual)
Italy	25 ug/m3 (annual, in force; 10 from 2030)
Japan	15 ug/m3 (annual)
Kenya	35 ug/m3 (annual; 24h 75)
Mexico	10 ug/m3 (annual)

País	Valor
Nigeria	NO national PM2.5 standard (PM10 annual=60 ug/m3, 24h=150)
Peru	25 ug/m3 (annual)
Philippines	25 ug/m3 (annual, 1-year guideline)
Portugal	25 ug/m3 (annual, in force; 10 from 2030)
South Africa	20 ug/m3 (annual)
South Korea	15 ug/m3 (annual)
United Kingdom	10 ug/m3 (annual, target by 2040)
United States	9.0 ug/m3 (annual, primary NAAQS, 2024)

S6 Resultado composto e rubrica de pontuação

Cada resposta foi pontuada pelo juiz primário contra a entrada do registro de gabarito (T1, T2, T4) ou a rubrica validada (T3, T5), produzindo cinco subcomponentes, cada um normalizado a $[0, 1]$:

1. Acurácia factual contra o valor do registro (binária para T1; crédito parcial para T2–T4).
2. Completude contextual pontuada contra uma rubrica pré-validada (T3, T4).
3. Qualidade de citação, verificada por checagem de DOI/fonte oficial.
4. Calibração, o alinhamento entre a confiança declarada e a correção.
5. Ausência de alucinação, codificada de forma binária (0 alucinado, 1 fiel).

O composto primário usa pesos iguais. Duas ponderações de sensibilidade pré-especificadas são reportadas — um conjunto derivado por PCA estimado no piloto estendido do Brasil, e um conjunto especificado pelos autores (factual 0,30, contextual 0,25, citação 0,15, alucinação 0,15,

aplicada 0,15) — e uma conclusão é tratada como robusta apenas se valer sob as três. O composto é calculado por célula (país, modelo, persona) para suportar o teste de diferença-em-diferenças de H6. Cada registro pontuado guarda também a justificativa textual do juiz; por exemplo, o juiz `gpt-5-mini` pontuou uma resposta do Llama 4 Scout sobre o padrão T1 do Brasil em 0,15 com a justificativa de que ela “gives wrong regulation (491/2018 vs correct 506/2024) and wrong current value. . . included a specific but incorrect citation and fabricated timing”, ilustrando como os subcomponentes de acurácia factual e de alucinação discriminam falha substantiva.

S7 Confiabilidade do painel de juízes

A confiabilidade é computada sobre cada item que o painel pontuou — os mesmos itens de que os efeitos relatados são computados —, e não sobre um subconjunto estratificado de calibração. Todas as 3.190 respostas que exigiram juiz foram pontuadas independentemente pelos três membros do painel, escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infle a concordância aparente. O painel substitui o desenho de juiz único do protocolo original, no qual o juiz primário (`gpt-5-mini`) estava ele próprio entre os modelos avaliados.

Tabela S8. Confiabilidade entre juízes sobre os 3.190 itens pontuados pelo painel. A quantidade operativa é a confiabilidade da *média* do painel, ICC(2,3); pela relação de Spearman–Brown ela é alta mesmo quando juízes isolados concordam apenas moderadamente. Fonte: `panel_reliability_full.json`.

Quantidade	Valor
Juízes (k)	3 (Google, Anthropic, DeepSeek)
Itens pontuados por todos os juízes	3.190
α de Krippendorff (intervalar)	0.527
ICC(2,1) de juiz único	0.558
ICC(2,3) da média do painel	0.791
Pearson par a par: Claude Sonnet DeepSeek-V3	0.801
Gemini 2.5 Pro Claude Sonnet	0.663
Gemini 2.5 Pro DeepSeek-V3	0.654
Composto médio por juiz: Gemini 2.5 Pro	0.617
Claude Sonnet 4.6	0.451
DeepSeek-V3	0.379

A concordância par a par é mais forte entre Claude e DeepSeek e menor para o Gemini, sistematicamente mais brando. Como todo efeito relatado é um contraste entre grupos (lacuna de camada, penalidade de idioma, piso de tarefa), o deslocamento de brandura de um juiz se cancela e não ameaça esses contrastes — que é precisamente a razão de a análise usar a *média* do painel em vez de qualquer juiz isolado, cuja confiabilidade sozinha seria ICC(2,1) = 0.56.

S8 Métodos estatísticos e saídas completas dos testes confirmatórios

Os três testes confirmatórios primários formam uma única família (F1) corrigida em conjunto pelo procedimento step-down de Bonferroni–Holm ($\alpha = 0,05$). Os testes confirmatórios secundários são reportados sem ajuste dentro da família; os testes declarados exploratórios usam FDR

de Benjamini–Hochberg a $q = 0,10$. As correlações de postos usam Spearman ρ ; a robustez de tendência monotônica usa o teste de Mann–Kendall; o efeito de persona usa um teste de permutação em nível de país (5,000 permutações). Todas as saídas a seguir são regeneradas por `code/analysis/formal_tests.py`, `robust_tests.py` e `h4_corpus_mechanism.py`.

Tabela S9. Família primária (Bonferroni–Holm): valores pré-especificados de 15 países ao lado da extensão post-registration de 25 países. H1-por-IDH é o único teste primário que rejeita sua hipótese nula a $n = 25$; permanece abaixo do limiar de tamanho de efeito pré-especificado $\rho \geq 0,55$ em ambas as amostras.

Teste	15 países (pré-especificado)	25 países (extensão)
H1 Spearman $\rho(\text{acc, IDH})$	+0.104 ($p = 0.71$), ns	+0.409 ($p = 0.043$)
H1 Mann–Kendall (por IDH)	$S = 7$, $Z = +0.30$, $p = 0.77$, ns	$p = 0.043$, ns
H1 Spearman $\rho(\text{acc, Joshi})$	+0.205 ($p = 0.46$), ns	−0.061, ns (desenvolvimento, não linguístico)
H1 vs limiar $\rho \geq 0.55$	não atingido	não atingido (significativo, abaixo do tamanho de efeito)
H4 ρ parcial (acc, cobertura IDH)	+0.365 ($p = 0.20$), ns	+0.194 ($p = 0.36$), ns
H6 DiD persona (SG–NG)	não recomputada em $n = 15$	+0.83 pp, perm $p = 0.292$, ns

Tabela S10. Mecanismo de corpus H4, multi-medida (25 países). A amplitude de cobertura de país (sitelinks do Wikidata) prediz a acurácia no nível de ordem zero e sobrevive à correção de multiplicidade entre os três proxies de cobertura, mas atenua-se até a não-significância após ajuste para desenvolvimento (IDH); reportamos, portanto, como sugestivo/exploratório, não como mecanismo estabelecido. O proxy pré-especificado de edição de idioma é nulo.

Medida	Família	$\rho(\text{acc, log medida})$	parcial IDH
Bytes Wikipédia-inglês	país	+0.153 ($p = 0.47$)	+0.132 ($p = 0.54$)
Sitelinks Wikidata	país	+0.399 ($p = 0.048$)	+0.194 ($p = 0.36$)
Statements Wikidata	país	+0.296 ($p = 0.15$)	+0.180 ($p = 0.40$)
Contagem de edições Wikipédia	idioma	+0.142, ns	ns

Tabela S11. Achados secundários robustos (25 países), com verificações de leave-one-country-out (LOCO) e de restrição de amplitude.

Achado	Estatística
Lacuna de camada (NG–SG)	+5.4 pp, IC 95% [+1.6, +8.5]; permutação $p = 0.020$
Lacuna de camada, faixa LOCO	[+4.9, +6.4] pp, estável
Gradiente IDH H1, faixa LOCO	$\rho \in [+0.48 \text{ (sem NGA)}, +0.66 \text{ (sem IND)}]$
H1 <i>leave-one-country-out</i>	$\rho \in [+0.31, +0.49]$: nunca atinge o limiar pré-especificado de 0.55
Piso de tarefa (T1+T2 vs T3–T5)	0.367 vs 0.638, Mann–Whitney, δ de Cliff = −0.64
H3 Cabra-Mistral vs restante	0.347 vs 0.549, δ de Cliff = −0.47
H2 nativo vs inglês (todos)	$\Delta = -4.8$ pp, Wilcoxon $p = 3 \times 10^{-15}$ ($n = 839$)
Espanhol / Português / Hindi	−1.0 ($p = 0.15$) / −2.3 ($p = 0.033$) / −7.8 ($p = 0.013$)
H2 em nível de país (unidade independente, $n = 9$)	9/9 negativos, média −2.4 pp, Wilcoxon $p = 0.008$
H5 aberto vs fechado-acessível	vantagem fechada de +12.6 pp (descritivo)

S9 Análises adicionais de robustez e corroboração

Sensibilidade da ponderação do composto. Recomputamos cada efeito principal sob a ponderação dos autores, sob pesos iguais e sob ponderação derivada por ACP. Os dois efeitos sustentados se

mantêm nas três; o gradiente falha nas três. Sob pesos iguais a lacuna de camada é de +4.56 pp e o gradiente $\rho = +0.369$; sob ACP, +4.84 pp e $\rho = +0.375$.

Poder sobre o nulo do gradiente. Simulando amostras de 25 países em correlações conhecidas, o desenho tem 77% de poder para detectar $\rho = 0.55$ e efeito mínimo detectável de $\rho = 0.56$ a 80% de poder. O nulo exclui, portanto, um gradiente da magnitude pré-especificada, mas não um gradiente fraco (poder de 48% em $\rho = 0.40$).

Dependência da taxonomia de camada. A lacuna é significativa sob a partição Norte/Sul da UNCTAD (permutação $p = 0.020$) e não sob nenhuma partição dos mesmos 25 países traçada apenas por IDH (mediana +2.39 pp, $p = 0.269$; IDH < 0.800 +2.92 pp, $p = 0.182$; IDH < 0.700 +1.53 pp, $p = 0.575$). Relatamos isso em vez de descansar sobre a partição favorável.

Política de desempate entre respostas armazenadas. De 8.300 células pontuadas, 951 (11.5%) têm mais de um escore, provenientes de reexecuções em datas diferentes. A política adotada é a *média*: determinística, independente da ordem de leitura, e usa toda a informação coletada. As quatro políticas plausíveis (primeira, última, média, aleatória com semente) movem os efeitos em no máximo 0.06 pp, de modo que a escolha não é consequente.

S9.1 Acurácia composta por país

Tabela S12. Acurácia composta por país, amostra de 25 países (tier: GN = Global North, GS = Global South). Ordered by mean.

País	Camada	Média	País	Camada	Média
Índia	SG	0.652	França	NG	0.536
Japão	NG	0.611	Bangladesh	SG	0.534
Austrália	NG	0.604	Colômbia	SG	0.530
Estados Unidos	NG	0.592	Chile	SG	0.513
Coreia do Sul	NG	0.590	Canadá	NG	0.510
Indonésia	SG	0.584	México	SG	0.507
África do Sul	SG	0.579	Quênia	SG	0.506
Itália	NG	0.577	Angola	SG	0.485
Reino Unido	NG	0.573	Nigéria	SG	0.461
Portugal	NG	0.563	Brasil	SG	0.459
Filipinas	SG	0.546	Egito	SG	0.455
Alemanha	NG	0.544	Argentina	SG	0.445
Peru	SG	0.538			

S9.2 Lacuna de camada sob partições alternativas de país

A divisão Norte/Sul Global segue a classificação da UNCTAD. Uma lacuna visível apenas sob uma taxonomia seria artefato dela, de modo que a reestimamos sob três partições baseadas em desenvolvimento dos mesmos 25 países (Tabela S13). A lacuna é significativa sob a UNCTAD e não significativa sob toda partição traçada pelo IDH, o que é coerente com o gradiente de IDH nulo relatado no texto principal.

S9.3 Modos representativos de falha, literais

Modelo misto e reestimação bayesiana. Um modelo linear misto gaussiano (MixedLM do `statsmodels`, REML) com interceptos aleatórios cruzados de país e modelo dá um efeito do Sul Global de

Tabela S13. Lacuna de camada sob partições alternativas dos mesmos 25 países. Teste de permutação com o país como unidade, 10.000 reetiquetagens.

Partição	Lacuna (pp)	NG/SG	<i>p</i>
UNCTAD Norte/Sul (usada no artigo)	+5.06	10/15	0.020
IDH abaixo da mediana da amostra (0.781)	+2.39	13/12	0.269
IDH < 0.800 (corte “muito alto” do PNUD)	+2.92	12/13	0.182
IDH < 0.700	+1.53	20/5	0.575

Tabela S14. Quadro 1 — Modos representativos de falha (literais, levemente truncados).

Modo de falha	Exemplo
Fabricar um padrão inexistente	Angola has no national norm. Gemini 2.5 Flash asserted an annual standard of “25 $\mu\text{g}/\text{m}^3$ ” em uma replicação e “15 $\mu\text{g}/\text{m}^3$ ” em outra. O GPT-5 afirmou “15 $\mu\text{g}/\text{m}^3$ ” para a Nigéria, que regula apenas PM ₁₀ (NESREA). Uma resposta fiel se recusaria a declarar um valor que não existe.
Errar o valor vinculante (piso de T1)	O padrão anual oficial do Brasil é 17 $\mu\text{g}/\text{m}^3$ (CONAMA 506/2024). A resposta modal foi 15 $\mu\text{g}/\text{m}^3$ (42 respostas), com 10, 20 e 25 também comuns; o valor oficial quase nunca foi devolvido.
Degradação em idioma nativo (H2)	O padrão anual da Índia é 40 $\mu\text{g}/\text{m}^3$. GPT-OSS 120B devolveu o valor correto em inglês e resposta <i>vazia</i> à mesma pergunta em hindi.

$\beta = -0.066$ (EP = 0.036, $p = 0.069$), marginal em vez de convencionalmente significativo porque cobra do termo de erro a grande heterogeneidade entre países. Uma reestimação hierárquica bayesiana com prioris fracamente informativas (pymc; interceptos cruzados de país e modelo, random_seed=42) concorda em magnitude e é decisiva quanto ao sinal: média posterior -0.052 , HDI de 94% $[-0.092, -0.016]$, $P(\beta < 0) = 0.994$ ($\hat{R} = 1.001$).

E-values. A lacuna de camada carrega um E-value de 1.70 na estimativa pontual e 1.31 no limite do intervalo mais próximo do nulo (aproximação de VanderWeele & Ding 2017 a partir do efeito padronizado); o segundo é o número operativo, e é um limiar baixo. Nenhum E-value é relatado para o gradiente de desenvolvimento: seu intervalo já inclui o nulo, de modo que o E-value nesse limite é 1.00 e nenhum confundidor é necessário.

Mediação exploratória (H_4). Um modelo de caminhos padronizado no nível do país (semopy, $n = 25$): IDH $\rightarrow$ sitelinks $a = +0.67$; sitelinks $\rightarrow$ acurácia $b = +0.27$; direto $c' = +0.31$; indireto $ab = +0.18$ com IC bootstrap de 95% $[-0.27, +0.59]$ (inclui o zero). A cobertura do país é, portanto, um mediador sugestivo mas não estabelecido, coerente com o enquadramento do texto principal.

Checação da manipulação de persona. Em 4.349 respostas na condição de persona, 50.2% reconhecem explicitamente o enquadramento de papel de gestor público, de modo que o nulo de persona (H6) não é artefato de o enquadramento ser universalmente ignorado.

S10 Desvios em relação ao plano de análise pré-especificado

O plano de análise exigia que os afastamentos fossem registrados e classificados, e fixava um teto para eles: o estatuto confirmatório só se mantém se os desvios afetarem no máximo 15% das células planejadas. O escopo entregue é de 27.5% da contagem planejada de respostas, de modo que o teto é excedido por larga margem, e o estudo é relatado como exploratório do começo ao

fim.

Os desvios principais, com o efeito de cada um sobre a interpretação:

- Contagem de respostas. Planejadas 33.600; entregues 8.300 (27.5%). Aciona o próprio teto de 15% do plano.
- Registro público. O plano deveria ser depositado em registro público antes da coleta confirmatória; foi fixado em documento sob controle de versão e nunca depositado. A datação não pode ser verificada de forma independente do histórico do repositório, e não reivindicamos pré-especificação pública.
- Piloto de rubrica. Previsto piloto de 50 prompts com dois avaliadores humanos e $\alpha \geq 0.70$ antes de escalar. Não foi executado. A confiabilidade é evidenciada a posteriori, em $\alpha = 0.527$, abaixo do limiar que o plano fixara.
- Instrumento de pontuação. O plano previa juiz único. T2 e T3 passam a ser adjudicadas por código contra registros oficiais onde o valor devolvido é extraível (62.5% e 83.6% das células); o resíduo e toda a T4 são repontuados pela média de um painel de três fornecedores. Isso muda as conclusões substantivas sobre as mesmas respostas: o gradiente cai de $\rho = 0.51$ ($p = 0.004$) para $\rho = 0.37$ ($p = 0.043$) e a penalidade de idioma nativo cresce de -2.1 pp para -4.8 pp.
- Ordenação dos achados. O plano tratava H1 como hipótese primária. H2 passa a ser relatada como achado principal e o gradiente de H1 como exploratório. Reordenação post hoc, motivada pela pontuação corrigida e não por reexame dos dados em busca de narrativa melhor; ambas as hipóteses eram pré-especificadas e ambas são relatadas.
- Tradução para idioma nativo. Previstos tradutores humanos nativos com retrotradução independente e adjudicação bilíngue. Usou-se tradução por LLM, auditada a posteriori por censo de retrotradução dos 90 prompts nativos. O artefato contra o qual o plano se protegia está medido e ausente: 90/90 preservam o país e a quantidade solicitada.
- Cobertura de modelos. A cobertura não é uniforme; dois modelos estão ausentes de vários países após limitação de taxa e esgotamento de crédito. As médias por país são computadas sobre conjuntos de modelos distintos.

Uma propriedade adicional do corpus de respostas, que não é desvio do plano mas consequência de como a coleta foi repetida, pertence a esta seção porque afeta a reprodutibilidade. De 9.760 chaves únicas (modelo, prompt, replicação), 2.147 (22.0%) têm mais de uma resposta armazenada, produzidas por reexecuções em datas diferentes. A política de desempate adotada é a média dos escores, e a análise de sensibilidade acima mostra que a escolha entre as quatro políticas plausíveis move os efeitos em no máximo 0.06 pp.

S11 Construção de prompts, template de persona e exemplos verbatim

Os prompts foram autorados em inglês para o domínio de política de poluição do ar com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrar no conjunto de estímulos confirmatório; um subconjunto-piloto atingiu um limiar inter-avaliadores de α de Krippendorff $\geq 0,70$ antes da escala. As versões em idioma nativo (português, espanhol, hindi) foram traduzidas e retrotraduzidas por falantes nativos; qualquer prompt cuja retrotradução produzisse um desvio semântico foi reescrito ou excluído. Toda afirmação factual em uma entrada de gabarito precisava resolver para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido (o Protocolo de Verificação de Citações do projeto aplicado já na geração do gabarito, não apenas na fase de manuscrito).

Manipulação de persona. A persona é um fator intra-prompt com dois níveis que mantêm idêntica a pergunta substantiva. O nível **neutral** apresenta um pedido simples de informação; o nível **public_manager_env** prepende um enquadramento fixo de papel. O contraste é mostrado verbatim para o Brasil, T1:

Neutro. “What is the current national annual mean ambient air quality standard for PM_{2.5} in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

Gestor ambiental público. “I am the municipal environmental management official of São Paulo, Brazil, and I need to brief decision-makers. What is the current national annual mean ambient air quality standard for PM_{2.5} in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

O gabarito correspondente no registro é (em tradução): “Os padrões nacionais de PM_{2.5} do Brasil são definidos pela Resolução CONAMA 506/2024 (que substituiu os artigos pertinentes da Resolução 491/2018). A etapa em vigor em 2026 é a Meta Intermediária PI-2; a Meta Final adota a diretriz anual da OMS 2021 de 5 $\mu\text{g}/\text{m}^3$ ” (fonte: Resolução CONAMA 506/2024). Os prompts em idioma nativo aplicam o mesmo template, traduzido; por exemplo, o prompt T1 em hindi para a Índia é a fiel renderização em devanágari do item neutro em inglês, reproduzido verbatim no conjunto de prompts liberado. O conjunto completo de prompts (370 itens confirmatórios: 25 países $\times$ 5 tarefas $\times$ persona, mais os pares de idioma nativo) é liberado como `prompts_confirmatory.jsonl` com o gabarito, a fonte e a rubrica por item.

Referências

Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for Computational Linguistics.