

Material Suplementar

De qual regulação o modelo sabe? Confiabilidade da informação regulatória recuperada por LLMs para a gestão ambiental pública em 25 países

Reprodutibilidade. Toda tabela orientada por dados a seguir (Tabelas S1–S7) é regenerada a partir dos artefatos confirmatórios brutos por `code/analysis/make_supplement_tables.py`; nenhum valor é digitado à mão. Nesta versão de leitura em português as tabelas geradas são as mesmas da versão em inglês (com legendas em inglês), para que exista uma única fonte dos números. A pontuação é decidida por código onde o registro tem valor (T1; a parte resolvível de T2 e T3), pela média de um painel de três fornecedores (Gemini 2.5 Pro, Claude Sonnet 4.6, DeepSeek-V3) no resíduo de T2 e T3 e em toda a T4, e pelo juiz da coleta em T5 (`gpt-5-mini-2025-08-07` para os quinze países pré-especificados, `claude-haiku-4-5-20251001` para os dez da extensão). O corpus confirmatório analisado é composto por 8.244 células pontuadas (6.573 com prompt em inglês; 1.671 em idioma nativo; 951 células receberam mais de um escore em reexecuções e foram colapsadas pela média; as 56 células egípcias de T1, sem chave no registro, foram removidas) sobre 25 países e 14 deployment-stacks. Todos os insumos, o código de pontuação, o registro de gabarito e as respostas anonimizadas serão liberados na publicação sob CC-BY-4.0 (dados/prompts) e MIT (código).

Sumário

S1 Pré-especificação, desenho e seleção de países	2
S2 Roster de deployment-stacks e configuração de serving	2
S3 Cobertura	4
S4 Covariáveis dos países	6
S5 Registro de gabarito (T1)	7
S6 Resultado composto e rubrica de pontuação	9
S7 Confiabilidade do painel de juízes	10
S8 Métodos estatísticos e saídas completas dos testes confirmatórios	11
S9 Análises adicionais de robustez e corroboração	11
S9.1 Acurácia composta por país	13

S9.2 Lacuna de camada sob partições alternativas de país	13
S9.3 Modos representativos de falha, literais	13
S10 Desvios em relação ao plano de análise pré-especificado	14
S11 Construção de prompts, template de persona e exemplos verbatim	15

S1 Pré-especificação, desenho e seleção de países

As hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão, as correções de comparações múltiplas e o quadro amostral de países foram especificados antes da coleta confirmatória de dados. O desenho pré-especificado cobre 15 países; a amostra foi subsequentemente estendida, *post registration*, para 25 países a fim de ganhar poder para o gradiente de desenvolvimento (H1) e para os testes de mecanismo de corpus (H4) e multiplicar os pares de idioma intra-país (H2). Ao longo do manuscrito e deste suplemento, todo efeito calculado na amostra de 25 países é reportado ao lado de seu valor pré-especificado de 15 países, e nenhuma conclusão pré-especificada é revista com base apenas na extensão (Seção S8).

Os países foram selecionados por amostragem teórica triangulada em três classificações independentes: a distinção Norte/Sul Global, tomada da classificação de economias desenvolvidas/em desenvolvimento da UNCTAD (operacionalizando o enquadramento da colonialidade do conhecimento), a taxonomia de seis classes de recurso linguístico de Joshi et al. (2020) (Joshi et al., 2020) e os grupos de renda do Banco Mundial. Os 15 pré-especificados (Conjunto “P” na Tabela S4) abrangem quatro regiões do mundo, cinco classes de Joshi e quatro grupos de renda; os 10 países de extensão (Conjunto “E”) compreendem sete referências adicionais do Norte Global (Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália, Portugal) escolhidas para adensar a extremidade de alto desenvolvimento do gradiente, e três países adicionais do Sul Global com par de idioma nativo (Colômbia, Chile, Angola). A UNCTAD declara que as economias desenvolvidas “compreendem, em linhas gerais, a América do Norte e a Europa, Israel, Japão, República da Coreia, Austrália e Nova Zelândia”, sendo as demais em desenvolvimento; os 25 países caem todos no lado que essa regra lhes atribui, Coreia do Sul inclusive. A justificativa completa do desenho está em docs/supplement/s1_design_rationale.md.

S2 Roster de deployment-stacks e configuração de serving

Unidade de análise. Avaliamos cada modelo *tal como servido* por meio de uma stack de acesso fixa — a tupla de pesos do modelo, fornecedor, infraestrutura de serving e camada de API/endpoint — em vez de pesos idealizados isoladamente, porque um gestor público interage com a stack servida e qualquer lacuna medida é uma propriedade dessa stack. A Tabela S1 lista as 14 stacks com suas strings exatas de API/tag e os locais de execução.

Tabela S1. Deployment-stack roster. Each model is evaluated *as served* through a fixed access stack; the API/tag string and execution venue are part of what each label denotes. Parameter counts are vendor-reported (dense or total for MoE; closed-frontier counts undisclosed). N and mean are realized English-prompt confirmatory coverage.

Model	Vendor	Tier	API / tag string	Venue	N	Mean
DeepSeek-V3	DeepSeek	A	deepseek-chat	DeepSeek API	496	0.687
Command R+	Cohere	A	command-r-plus-08-2024	Cohere (trial)	496	0.530
Llama 3.3 70B	Meta	A	llama-3.3-70b-versatile	Groq (free)	391	0.511
Llama 4 Scout	Meta	A	meta-llama/ llama-4-scout-17b-16e-instruct	Groq (free)	496	0.498
GPT-OSS 120B	OpenAI	A	openai/gpt-oss-120b	Groq (free)	257	0.484
Qwen3 32B	Alibaba	B	qwen/qwen3-32b	Groq (free)	494	0.562
Qwen3 14B	Alibaba	B	qwen3:14b	Ollama (local)	496	0.485
Phi-4 14B	Microsoft	B	phi4	Ollama (local)	496	0.477
Llama 3.1 8B	Meta	C	llama-3.1-8b-instant	Groq (free)	496	0.438
Cabra-Mistral 7B	botbot-ai	C	cabra-mistral-7b	Ollama (local)	492	0.351
Gemini Flash	2.5 Google	D	gemini-2.5-flash	Google AI (free)	486	0.634
GPT-5-mini	OpenAI	D	gpt-5-mini	OpenAI API	495	0.626
Claude 4.5	Haiku Anthropic	D	claude-haiku-4-5	Anthropic API	486	0.591
GPT-5	OpenAI	E	gpt-5	OpenAI API	496	0.674

Determinismo e tratamento de seed. Todas as stacks foram consultadas a temperatura 0,3 com a configuração de máximo determinismo que cada provedor documenta, e não com uma superfície idêntica de parâmetros, porque as superfícies diferem. O suporte a seed é heterogêneo: stacks servidas localmente (Ollama) honram uma seed fixa; a OpenAI expõe uma seed advisory; a Messages API da Anthropic não expõe parâmetro de seed; e, para os demais endpoints hospedados, a seed é advisory ou não é exposta. Para cada chamada registramos a seed solicitada e um campo `seed_status` (`sent`, `logged-only` ou `not-supported`) nos metadados de execução liberados, de modo que o determinismo de fato alcançado seja auditável em vez de presumido. Duas replicações estocásticas por célula (prompt, modelo, persona) estimam a variabilidade intra-célula.

Janela de aquisição. O comportamento do modelo servido pode derivar à medida que fornecedores atualizam a infraestrutura, de modo que as acurácias reportadas são estimativas point-in-time relativas à janela de coleta. A tag fixada, a string de versão e o timestamp de aquisição são registrados para cada chamada. A coleta confirmatória ocorreu de 2026-04-26 a 2026-06-12 (UTC), abrangendo o piloto, a coleta pré-especificada de 15 países e a extensão post-registration para 25 países. A Tabela S2 dá o timestamp da primeira e da última chamada sem erro por

provedor, junto com a documentação oficial de API consultada; os timestamps completos por chamada são liberados com o conjunto de dados.

Tabela S2. Per-provider acquisition window and official API documentation. Reported accuracies are point-in-time estimates relative to this window; first/last are the earliest and latest non-error call timestamps (UTC) recorded in the run logs. The window spans the pilot, the pre-specified 15-country collection, and the extension.

Provider (venue)	First (UTC)	Last (UTC)	API documentation
Anthropic API	2026-04-27	2026-06-12	https://docs.anthropic.com/en/api/messages
Cohere (trial)	2026-04-26	2026-06-11	https://docs.cohere.com/reference/chat
DeepSeek API	2026-04-26	2026-06-11	https://api-docs.deepseek.com
Google AI (free)	2026-04-27	2026-06-11	https://ai.google.dev/api
Groq (free)	2026-04-26	2026-06-11	https://console.groq.com/docs/api-reference
Ollama (local)	2026-04-27	2026-06-12	https://github.com/ollama/ollama/blob/main/docs/api.md
OpenAI API	2026-04-27	2026-06-12	https://platform.openai.com/docs/api-reference/chat
All providers	2026-04-26	2026-06-12	—

S3 Cobertura

A cobertura por célula não é uniforme ao longo do roster: endpoints gratuitos e com limite de taxa retornaram menos respostas admissíveis do que as APIs medidas, e um candidato (Gemini 2.5 Flash em lotes nativos iniciais) e um sexto juiz (Command R+) atingiram cotas dos provedores. Reportamos a cobertura realizada em vez de descartar silenciosamente células subcobertas. A Tabela S3 dá a matriz modelo $\times$ tarefa para prompts em inglês (os totais por coluna igualam as contagens por tarefa do texto principal); a Tabela S4 dá as contagens por país em inglês, nativo e total com camada e conjunto de pré-especificação; a Tabela S5 lista os pares de idioma nativo usados em H2. A matriz de cobertura completa modelo $\times$ país $\times$ tarefa, com o motivo de cota ou exclusão de cada déficit, está incluída no release.

Tabela S3. Coverage matrix: realized English-prompt confirmatory responses per model $\times$ task (T1 standard, T2 local datum, T3 health synthesis, T4 instruments, T5 recommendation). No cell is silently dropped; shortfalls are quota-driven (Methods).

Model	T1	T2	T3	T4	T5	Total
GPT-5	96	100	100	100	100	496
DeepSeek-V3	96	100	100	100	100	496
Command R+	96	100	100	100	100	496
Phi-4 14B	96	100	100	100	100	496
Qwen3 14B	96	100	100	100	100	496
Llama 4 Scout	96	100	100	100	100	496
Llama 3.1 8B	96	100	100	100	100	496
GPT-5-mini	96	100	100	99	100	495
Qwen3 32B	96	100	100	99	99	494
Cabra-Mistral 7B	95	97	100	100	100	492
Gemini 2.5 Flash	94	98	98	98	98	486
Claude Haiku 4.5	94	98	98	98	98	486
Llama 3.3 70B	78	81	80	76	76	391
GPT-OSS 120B	54	61	53	40	49	257
Total	1279	1335	1329	1310	1320	6573

Tabela S4. Coverage by country: tier (GN/GS), sample set (P = pre-specified 15; E = extension), and realized confirmatory responses (English, native-language, total).

Country	Tier	Set	English	Native	Total
Colombia	GS	E	260	251	511
Chile	GS	E	260	241	501
Portugal	GN	E	261	240	501
Angola	GS	E	260	240	500
Argentina	GS	P	280	139	419
India	GS	P	279	138	417
Mexico	GS	P	269	140	409
Brazil	GS	P	260	141	401
Peru	GS	P	256	141	397
Germany	GN	P	279	0	279
Indonesia	GS	P	279	0	279
Japan	GN	P	279	0	279
Kenya	GS	P	279	0	279
Bangladesh	GS	P	278	0	278
United Kingdom	GN	E	265	0	265

Country	Tier	Set	English	Native	Total
Canada	GN	E	260	0	260
Australia	GN	E	260	0	260
France	GN	E	260	0	260
Italy	GN	E	260	0	260
South Korea	GN	E	258	0	258
Nigeria	GS	P	257	0	257
Philippines	GS	P	256	0	256
United States	GN	P	252	0	252
South Africa	GS	P	242	0	242
Egypt	GS	P	224	0	224
Total (25)			6573	1671	8244

Tabela S5. Native-language confirmatory responses by language and country (H2 within-country English/native contrast).

Native language (Joshi)	Country	<i>N</i> (native)
Portuguese (4)	Portugal	240
	Angola	240
	Brazil	141
Spanish (5)	Colombia	251
	Chile	241
	Peru	141
	Mexico	140
	Argentina	139
Hindi (4)	India	138

S4 Covariáveis dos países

A Tabela S6 reporta as covariáveis de desenvolvimento e de representação no corpus usadas na análise de mecanismo (H4). As medidas de corpus do idioma (classe Joshi; tamanhos mC4/OSCAR reportados no texto principal) indexam quanto texto existe *no* idioma de um país e são o canal candidato para a penalidade de idioma nativo (H2). As medidas de cobertura de país (comprimento em bytes do artigo na Wikipédia em inglês, sitelinks do Wikidata, statements do Wikidata) indexam quão amplamente o corpus enciclopédico é *sobre* um país, independentemente do idioma, e são o canal candidato para a lacuna geográfica (H1/H4). Como a lacuna geográfica é medida *em inglês*, uma lacuna Norte/Sul residual não pode ser um efeito de corpus do idioma, razão pela qual H4 isola a cobertura de país para H1 e o tamanho do corpus do idioma para H2. Todas as entidades do Wikidata são identificadas por um QID resolvível e foram recuperadas dentro da janela de coleta.

Tabela S6. Country covariates. HDI: UNDP HDR 2023–24 (2022 data). Joshi: linguistic-resource class of the dominant official language (Joshi et al., 2020). Corpus measures from Wikimedia/Wikidata (entity QID resolvable): English-article byte length, Wikidata sitelinks (language editions), and Wikidata statements.

Country	Tier	HDI	Joshi	EN-wiki bytes	Sitelinks	WD stmts
Germany	GN	0.950	5	207,810	403	1402
Australia	GN	0.946	5	233,095	395	1674
United Kingdom	GN	0.940	5	368,888	391	1085
Canada	GN	0.935	5	281,016	393	1346
South Korea	GN	0.929	4	275,291	350	746
United States	GN	0.927	5	383,914	424	1710
Japan	GN	0.920	5	205,844	414	995
France	GN	0.910	5	279,498	413	1196
Italy	GN	0.906	4	305,234	405	1039
Portugal	GN	0.874	4	324,038	369	751
Chile	GS	0.860	5	232,108	379	689
Argentina	GS	0.849	5	267,662	369	881
Mexico	GS	0.781	5	263,757	398	1286
Peru	GS	0.762	5	239,544	332	867
Brazil	GS	0.760	4	301,844	384	1151
Colombia	GS	0.758	5	303,401	363	774
Egypt	GS	0.728	5	284,547	387	757
South Africa	GS	0.717	5	270,861	365	750
Indonesia	GS	0.713	3	226,349	362	1005
Philippines	GS	0.710	5	493,981	331	963
Bangladesh	GS	0.670	3	275,786	343	814
India	GS	0.644	5	310,681	399	1679
Kenya	GS	0.601	5	216,189	334	699
Angola	GS	0.591	4	180,098	322	676
Nigeria	GS	0.548	5	266,041	349	1194

S5 Registro de gabarito (T1)

A validade do gradiente geográfico (H1) requer que o gabarito seja igualmente disponível e igualmente verificável entre os países. Para T1 (o padrão anual vinculante de PM_{2.5}) ancoramos cada país a uma fonte oficial primária por auditoria documental: o texto-fonte foi recuperado, o valor foi lido verbatim, e a entrada registra o valor, o status, a fonte-de-registro, uma URL resolvível e o método de recuperação (Tabela S7). Três países *não têm* padrão nacional de PM_{2.5}, confirmado pelo texto oficial (a NESREA da Nigéria regula apenas PM₁₀; a Argentina não tem valor federal vinculante; a Angola não tem legislação nacional de qualidade do ar); nesses casos, um modelo fiel deve recusar-se a indicar um limiar inexistente em vez de fabricá-lo. Essa proveniência é mais reproduzível do que a asserção de especialistas: qualquer leitor pode

reverificar cada valor a partir da fonte oficial citada. Nenhuma referência no registro é não-verificada, e nenhum valor foi transposto de fontes secundárias sem confirmação contra o texto primário.

Tabela S7. Ground-truth registry for T1 (binding annual PM_{2.5} standard), all 25 countries, anchored to official primary sources by documentary audit. All entries are of source type *official primary* unless noted. Status *verified* = value read from the official text; *no standard* = official confirmation that no national standard exists; *partial* = the value could not be confirmed in an accessible official source (Bangladesh: a 2022 revision is known; Egypt: no value extracted, excluded from T1). Full URLs and verbatim excerpts are in the released registry JSONL.

Country	Value	Status	Official source
Angola	NO national air-quality legislation / standard	no standard	No national ambient air quality regulation (World Bank/WHO note)
Argentina	NO single binding federal PM _{2.5} standard (Ley 20.284/1973 framework; PM _{2.5} limits set subnationally)	no standard	Ley 20.284/1973
Australia	8 µg/m ³ (annual; 7 target 2025)	verified	National Environment Protection (Ambient Air Quality) Measure
Bangladesh	35 µg/m ³ (annual; 24-h 65) per Air Pollution (Control) Rules 2022, S.R.O. 255-Law/2022; superseded 15 (S.R.O. 220-Law/2005)	verified	Air Pollution (Control) Rules 2022 (S.R.O. 255-Law/2022), Schedule of ambient standards; confirmed in DoE, Ambient Air Quality in Bangladesh (2024), Table 3
Brazil	17 µg/m ³ (annual, PI-2)	verified	CONAMA 506/2024 Annex I, DOU 09/07/2024 Ed.130 p.133
Canada	8.8 µg/m ³ (annual, CAAQS 2020)	verified	Canadian Ambient Air Quality Standards (CCME)
Chile	20 µg/m ³ (annual)	verified	D.S. 12/2011 MMA Chile
Colombia	25 µg/m ³ (annual, in force since 2018; 15 from 2030; 24h=37)	verified	Resolucion 2254/2017 MinAmbiente Tabla 1 & 2 (verbatim official scan)
Egypt	PM _{2.5} limit set under Law 4/1994 (amended 9/2009, 105/2015) Executive Regulations (official text in Arabic; value not extracted from an accessible official source)	partial	Environmental Law 4/1994 (EEAA)
France	25 µg/m ³ (annual, in force; 10 from 2030)	verified	EU Ambient Air Quality Directive 2008/50/EC; (EU) 2024/2881
Germany	25 µg/m ³ (annual, in force 2026; 10 from 2030)	verified	EU Ambient Air Quality Directive 2008/50/EC; revised (EU) 2024/2881
India	40 µg/m ³ (annual)	verified	CPCB National Ambient Air Quality Standards (2009)

Country	Value	Status	Official source
Indonesia	15 $\mu\text{g}/\text{m}^3$ (annual)	verified	PP No. 22/2021 Lampiran VII (Indonesia)
Italy	25 $\mu\text{g}/\text{m}^3$ (annual, in force; 10 from 2030)	verified	EU Ambient Air Quality Directive 2008/50/EC; (EU) 2024/2881
Japan	15 $\mu\text{g}/\text{m}^3$ (annual)	verified	Ministry of the Environment Japan, Environmental Quality Standards (2009)
Kenya	35 $\mu\text{g}/\text{m}^3$ (annual; 24h 75)	verified	First Schedule, EMCA (Air Quality) Regulations 2014 (Kenya Gazette Vol. CXVI No.46)
Mexico	10 $\mu\text{g}/\text{m}^3$ (annual)	verified	NOM-025-SSA1-2021, Diario Oficial de la Federacion 27/10/2021
Nigeria	NO national $\text{PM}_{2.5}$ standard (PM_{10} annual=60 $\mu\text{g}/\text{m}^3$, 24h=150)	no standard	NESREA National Environmental (Air Quality Control) Regulations, Schedule XIII (Ambient Air Quality Standards)
Peru	25 $\mu\text{g}/\text{m}^3$ (annual)	verified	D.S. 003-2017-MINAM (Peru)
Philippines	25 $\mu\text{g}/\text{m}^3$ (annual, 1-year guideline)	verified	DENR DAO (RA 8749 Clean Air Act); 25 $\mu\text{g}/\text{Nm}^3$ annual / 50 $\mu\text{g}/\text{Nm}^3$ 24h
Portugal	25 $\mu\text{g}/\text{m}^3$ (annual, in force; 10 from 2030)	verified	EU Ambient Air Quality Directive 2008/50/EC; (EU) 2024/2881
South Africa	20 $\mu\text{g}/\text{m}^3$ (annual)	verified	SA NAAQS under NEMAQA (Act 39/2004), 2012
South Korea	15 $\mu\text{g}/\text{m}^3$ (annual)	verified	Ministry of Environment, Korea
United Kingdom	20 $\mu\text{g}/\text{m}^3$ (annual, limit value in force since 1 Jan 2020; England target 10 by 2040)	verified	Air Quality Standards Regulations 2010, Sch. 2 (Stage 2 limit value); DEFRA National air quality objectives table, 2023-04-03
United States	9.0 $\mu\text{g}/\text{m}^3$ (annual, primary NAAQS, 2024)	verified	EPA Final Reconsideration of PM NAAQS, Federal Register 2024-02637

S6 Resultado composto e rubrica de pontuação

Cada resposta foi pontuada pelo juiz primário contra a entrada do registro de gabarito (T1, T2, T4) ou a rubrica validada (T3, T5), produzindo cinco subcomponentes, cada um normalizado a [0, 1]:

1. Acurácia factual contra o valor do registro (binária para T1; crédito parcial para T2–T4).
2. Completude contextual pontuada contra uma rubrica pré-validada (T3, T4).
3. Qualidade de citação, verificada por checagem de DOI/fonte oficial.
4. Calibração, o alinhamento entre a confiança declarada e a correção.

5. Ausência de alucinação, codificada de forma binária (0 alucinado, 1 fiel).

O composto primário usa pesos iguais. Duas ponderações de sensibilidade pré-especificadas são reportadas — um conjunto derivado por PCA estimado no piloto estendido do Brasil, e um conjunto especificado pelos autores (factual 0,30, contextual 0,25, citação 0,15, alucinação 0,15, aplicada 0,15) — e uma conclusão é tratada como robusta apenas se valer sob as três. O composto é calculado por célula (país, modelo, persona) para suportar o teste de diferença-em-diferenças de H6. Cada registro pontuado guarda também a justificativa textual do juiz; por exemplo, o juiz `gpt-5-mini` pontuou uma resposta do Llama 4 Scout sobre o padrão T1 do Brasil em 0,15 com a justificativa de que ela “gives wrong regulation (491/2018 vs correct 506/2024) and wrong current value. . . included a specific but incorrect citation and fabricated timing”, ilustrando como os subcomponentes de acurácia factual e de alucinação discriminam falha substantiva.

S7 Confiabilidade do painel de juízes

A confiabilidade é computada sobre cada item que o painel pontuou — os mesmos itens de que os efeitos relatados são computados —, e não sobre um subconjunto estratificado de calibração. Todas as 3.190 respostas que exigiram juiz foram pontuadas independentemente pelos três membros do painel, escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infle a concordância aparente. O painel substitui o desenho de juiz único do protocolo original, no qual o juiz da coleta (`gpt-5-mini` para os quinze países pré-especificados, `claude-haiku-4-5` para os dez da extensão) estava ele próprio entre os modelos avaliados e, como a extensão contém sete dos dez países do Norte Global, estava confundido com o tier.

Tabela S8. Confiabilidade entre juízes sobre os 3.190 itens pontuados pelo painel. A quantidade operativa é a confiabilidade da *média* do painel, ICC(2,3); pela relação de Spearman–Brown ela é alta mesmo quando juízes isolados concordam apenas moderadamente. Fonte: `panel_reliability_full.json`.

Quantidade	Valor
Juízes (k)	3 (Google, Anthropic, DeepSeek)
Itens pontuados por todos os juízes	3.190
α de Krippendorff (intervalar)	0.527
ICC(2,1) de juiz único	0.558
ICC(2,3) da média do painel	0.791
Pearson par a par: Claude Sonnet DeepSeek-V3	0.801
Gemini 2.5 Pro Claude Sonnet	0.663
Gemini 2.5 Pro DeepSeek-V3	0.654
Composto médio por juiz: Gemini 2.5 Pro	0.617
Claude Sonnet 4.6	0.451
DeepSeek-V3	0.379

A concordância par a par é mais forte entre Claude e DeepSeek e menor para o Gemini, sistematicamente mais brando. Como todo efeito relatado é um contraste entre grupos (lacuna de camada, penalidade de idioma, piso de tarefa), o deslocamento de brandura de um juiz se cancela e não ameaça esses contrastes — que é precisamente a razão de a análise usar a *média* do painel em vez de qualquer juiz isolado, cuja confiabilidade sozinha seria ICC(2,1) = 0.56.

S8 Métodos estatísticos e saídas completas dos testes confirmatórios

Os três testes confirmatórios primários formam uma única família (F1) corrigida em conjunto pelo procedimento step-down de Bonferroni–Holm ($\alpha = 0,05$). Os testes confirmatórios secundários são reportados sem ajuste dentro da família; os testes declarados exploratórios usam FDR de Benjamini–Hochberg a $q = 0,10$. As correlações de postos usam Spearman ρ ; a robustez de tendência monotônica usa o teste de Mann–Kendall; o efeito de persona usa um teste de permutação em nível de país (5,000 permutações). Todas as saídas a seguir são regeneradas por `code/analysis/formal_tests.py`, `robust_tests.py` e `h4_corpus_mechanism.py`.

Tabela S9. Família primária (Bonferroni–Holm): valores pré-especificados de 15 países ao lado da extensão post-registration de 25 países. H1-por-IDH é o único teste primário que rejeita sua hipótese nula a $n = 25$; permanece abaixo do limiar de tamanho de efeito pré-especificado $\rho \geq 0,55$ em ambas as amostras.

Teste	15 países (pré-especificado)	25 países (extensão)
H1 Spearman $\rho(\text{acc, IDH})$	+0.079 ($p = 0.78$), ns	+0.361 ($p = 0.076$), ns
H1 Mann–Kendall (por IDH)	$S = 3$, $Z = +0.10$, $p = 0.92$, ns	$p = 0.065$, ns
H1 Spearman $\rho(\text{acc, Joshi})$	+0.131 ($p = 0.64$), ns	−0.061, ns (desenvolvimento, não linguística)
H1 vs limiar $\rho \geq 0.55$	não atingido	não atingido
H4 ρ parcial (acc, cobertura IDH)	+0.381 ($p = 0.18$), ns	+0.190 ($p = 0.37$), ns
H6 DiD persona (SG–NG)	não recomputada em $n = 15$	+0.48 pp, perm $p = 0.287$, ns
Lacuna de camada (NG–SG), composto	+6.1 pp, $p = 0.12$ (3 NG)	+5.0 pp, $p = 0.019$

Tabela S10. Mecanismo de corpus H4, multi-medida (25 países). A amplitude de cobertura de país (sitelinks do Wikidata) prediz a acurácia no nível de ordem zero e sobrevive à correção de multiplicidade entre os três proxies de cobertura, mas atenua-se até a não-significância após ajuste para desenvolvimento (IDH); reportamos, portanto, como sugestivo/exploratório, não como mecanismo estabelecido. O proxy pré-especificado de edição de idioma é nulo.

Medida	Família	$\rho(\text{acc, log medida})$	parcial IDH
Bytes Wikipédia-inglês	país	+0.146 ($p = 0.49$)	+0.125 ($p = 0.56$)
Sitelinks Wikidata	país	+0.369 ($p = 0.070$)	+0.190 ($p = 0.37$)
Statements Wikidata	país	+0.248 ($p = 0.23$)	+0.125 ($p = 0.56$)
Contagem de edições Wikipédia	idioma	+0.048, ns	ns

S9 Análises adicionais de robustez e corroboração

Sensibilidade da ponderação do composto. Recomputamos cada efeito principal sob a ponderação dos autores, sob pesos iguais e sob ponderação derivada por ACP. Os dois efeitos sustentados se mantêm nas três, e o gradiente fica abaixo do 0.55 pré-especificado nas três. Sob a ponderação primária a lacuna de camada é de +5.05 pp e o gradiente $\rho = +0.361$; sob pesos iguais, +4.22 pp e $\rho = +0.355$; sob ACP, +4.72 pp e $\rho = +0.380$. Um modelo misto gaussiano com interceptos aleatórios cruzados dá $\beta = -0.063$ ($p = 0.086$) para o Sul Global; a reestimação bayesiana dá média posterior −0.049, HDI de 94% [−0.088, −0.006], $P(\beta < 0) = 0.987$; o E-value é 1.71 no ponto e 1.31 no limite do intervalo mais próximo do nulo.

Tabela S11. Achados secundários robustos (25 países), com verificações de leave-one-country-out (LOCO) e de restrição de amplitude.

Achado	Estatística
Lacuna de camada (NG–SG)	+5.0 pp, IC 95% [+1.6, +8.4]; permutação $p = 0.019$
Lacuna de camada, faixa LOCO	[+4.4, +6.0] pp, estável
Lacuna de camada, só onda de extensão	+5.9 pp [+2.3, +9.6] (7 NG vs 3 SG), perm $p = 0.062$
Lacuna de camada, só desfechos de código (T1; T2, T3 resolvidas)	NG 0.61 vs SG 0.46, +14.7 pp [+5.6, +23.9], perm $p = 0.012$; RC agregada 0.53 [0.48, 0.58] (T1 0.32, T2 0.51, T3 0.65)
H1 <i>leave-one-country-out</i>	$\rho \in [+0.3, +0.5]$: nunca atinge o limiar pré-especificado de 0.55
Piso de tarefa (T1+T2 vs T3–T5)	0.434 vs 0.612, δ de Cliff = -0.41
H3 Cabra-Mistral vs restante	0.351 vs 0.557, δ de Cliff = -0.48
H3 pré-especificada (Cabra vs Llama 3.1 8B, prompts em português)	Brasil 0.258 vs 0.313, $\delta = -0.26$ ($n = 20$ cada); BRA+PRT+AGO 0.304 vs 0.362, $\delta = -0.17$ ($n = 60$ cada)
H2 nativo vs inglês (todos)	$\Delta = -5.0$ pp, Wilcoxon $p = 5 \times 10^{-16}$ ($n = 839$); modelo misto com intercepto aleatório por país -5.0 pp ($p = 6 \times 10^{-7}$), por modelo -4.8 pp ($p = 2 \times 10^{-9}$); país como unidade 8/9 negativos, $t = -4.6$, $p = 0.002$; modelo como unidade 12/14, Wilcoxon $p = 0.058$
Espanhol / Português / Hindi por instrumento de pontuação	$-4.5 / -4.2 / -11.4$ pp, todos significativos código -3.8 ($n = 333$), painel -8.6 ($n = 314$), juiz da coleta -1.1 pp ns ($n = 192$, T5)
só veredito de código, por idioma	português -9.1 ($n = 132$, $p = 0.019$), espanhol -2.1 ($n = 165$, ns), todos -5.0 pp ($n = 318$, $p = 0.048$)
H5 aberto vs fechado-acessível	vantagem fechada de $+12.8$ pp (descritivo)

Poder sobre o nulo do gradiente. Simulando amostras de 25 países em correlações conhecidas, o desenho tem 77% de poder para detectar $\rho = 0.55$ e efeito mínimo detectável de $\rho = 0.56$ a 80% de poder. O nulo exclui, portanto, um gradiente da magnitude pré-especificada, mas não um gradiente fraco (poder de 48% em $\rho = 0.40$).

Dependência da taxonomia de camada. A lacuna é significativa sob a partição desenvolvidas/em desenvolvimento da UNCTAD (permutação $p = 0.019$) e não sob nenhuma partição dos mesmos 25 países traçada apenas por IDH (mediana $+2.14$ pp, $p = 0.329$; IDH < 0.800 $+2.78$ pp, $p = 0.206$; IDH < 0.700 $+1.94$ pp, $p = 0.482$). Relatamos isso em vez de descansar sobre a partição favorável.

Duplicatas, em dois níveis. No nível da resposta, 21,9% das chaves (modelo, prompt, réplica) têm mais de uma resposta armazenada; a que entra na análise é a primeira na ordem dos arquivos de execução, que é a que o juiz da coleta pontuou, e os vereditos de código de T1, T2 e T3 são computados sobre essa mesma resposta. Pontuar todas as respostas e tirar a média dos vereditos muda o veredito de código em 3.1% das células e a média em 0.0002. No nível do escore, 951 células (11.5%) têm mais de um escore de juiz, provenientes de reexecuções em datas diferentes, colapsadas pela *média*: determinística, independente da ordem de leitura, e usa toda a informação coletada. As quatro políticas plausíveis (primeira, última, média, aleatória com semente) movem os efeitos em no máximo 0.06 pp.

Tabela S12. Acurácia composta por país, amostra de 25 países (tier: GN = Global North, GS = Global South). Ordered by mean.

País	Camada	Média	País	Camada	Média
Índia	SG	0.651	França	NG	0.534
Austrália	NG	0.617	Peru	SG	0.529
Japão	NG	0.612	Colômbia	SG	0.526
Coreia do Sul	NG	0.598	Chile	SG	0.520
Indonésia	SG	0.592	Egito	SG	0.509
Estados Unidos	NG	0.587	Canadá	NG	0.509
Itália	NG	0.586	Quênia	SG	0.505
África do Sul	SG	0.575	México	SG	0.501
Portugal	NG	0.562	Angola	SG	0.475
Alemanha	NG	0.557	Nigéria	SG	0.461
Reino Unido	NG	0.554	Brasil	SG	0.458
Filipinas	SG	0.542	Argentina	SG	0.433
Bangladesh	SG	0.542			

S9.1 Acurácia composta por país

S9.2 Lacuna de camada sob partições alternativas de país

A divisão Norte/Sul Global segue a classificação da UNCTAD. Uma lacuna visível apenas sob uma taxonomia seria artefato dela, de modo que a reestimamos sob três partições baseadas em desenvolvimento dos mesmos 25 países (Tabela S13). A lacuna é significativa sob a UNCTAD e não significativa sob toda partição traçada pelo IDH, o que é coerente com o gradiente de IDH nulo relatado no texto principal.

Tabela S13. Lacuna de camada sob partições alternativas dos mesmos 25 países. Teste de permutação com o país como unidade, 10.000 reetiquetagens.

Partição	Lacuna (pp)	NG/SG	<i>p</i>
UNCTAD desenvolvidas/em desenvolvimento (usada no artigo)	+5.05	10/15	0.019
IDH abaixo da mediana da amostra (0.781)	+2.14	13/12	0.329
IDH < 0.800 (corte “muito alto” do PNUD)	+2.78	12/13	0.206
IDH < 0.700	+1.94	20/5	0.482

S9.3 Modos representativos de falha, literais

Tabela S14. Quadro 1 — Modos representativos de falha (literais, levemente truncados).

Modo de falha	Exemplo
Fabricar um padrão inexistente	Angola has no national norm. Gemini 2.5 Flash asserted an annual standard of “25 $\mu\text{g}/\text{m}^3$ ” em uma replicação e “15 $\mu\text{g}/\text{m}^3$ ” em outra. O GPT-5 afirmou “15 $\mu\text{g}/\text{m}^3$ ” para a Nigéria, que regula apenas PM_{10} (NESREA). Uma resposta fiel se recusaria a declarar um valor que não existe.
Errar o valor vinculante (piso de T1)	O padrão anual oficial do Brasil é 17 $\mu\text{g}/\text{m}^3$ (CONAMA 506/2024). A resposta modal foi 15 $\mu\text{g}/\text{m}^3$ (42 respostas), com 10, 20 e 25 também comuns; o valor oficial quase nunca foi devolvido.
Degradação em idioma nativo (H2)	O padrão anual da Índia é 40 $\mu\text{g}/\text{m}^3$. GPT-OSS 120B devolveu o valor correto em inglês e resposta <i>vazia</i> à mesma pergunta em hindi.

Modelo misto e reestimação bayesiana. Um modelo linear misto gaussiano (MixedLM do `statsmodels`, REML) com interceptos aleatórios cruzados de país e modelo dá um efeito do Sul Global de $\beta = -0.063$ (EP = 0.036, $p = 0.086$), marginal em vez de convencionalmente significativo porque cobra do termo de erro a grande heterogeneidade entre países. Uma reestimação hierárquica bayesiana com prioris fracamente informativas (`pymc`; interceptos cruzados de país e modelo, `random_seed=42`) concorda em magnitude e é decisiva quanto ao sinal: média posterior -0.049 , HDI de 94% $[-0.088, -0.006]$, $P(\beta < 0) = 0.987$ ($\hat{R} = 1.001$).

E-values. A lacuna de camada carrega um E-value de 1.71 na estimativa pontual e 1.31 no limite do intervalo mais próximo do nulo (aproximação de VanderWeele & Ding 2017 a partir do efeito padronizado); o segundo é o número operativo, e é um limiar baixo. Nenhum E-value é relatado para o gradiente de desenvolvimento: seu intervalo já inclui o nulo, de modo que o E-value nesse limite é 1.00 e nenhum confundidor é necessário.

Mediação exploratória (H_4). Um modelo de caminhos padronizado no nível do país (`semopy`, $n = 25$): IDH $\rightarrow$ sitelinks $a = +0.67$; sitelinks $\rightarrow$ acurácia $b = +0.27$; direto $c' = +0.31$; indireto $ab = +0.18$ com IC bootstrap de 95% $[-0.27, +0.59]$ (inclui o zero). A cobertura do país é, portanto, um mediador sugestivo mas não estabelecido, coerente com o enquadramento do texto principal.

Checagem da manipulação de persona. Em 4.349 respostas na condição de persona, 50.2% reconhecem explicitamente o enquadramento de papel de gestor público, de modo que o nulo de persona (H_6) não é artefato de o enquadramento ser universalmente ignorado.

S10 Desvios em relação ao plano de análise pré-especificado

O plano de análise exigia que os afastamentos fossem registrados e classificados, e fixava um teto para eles: o estatuto confirmatório só se mantém se os desvios afetarem no máximo 15% das células planejadas. O escopo entregue é de 27.5% da contagem planejada de respostas, de modo que o teto é excedido por larga margem, e o estudo é relatado como exploratório do começo ao fim.

Os desvios principais, com o efeito de cada um sobre a interpretação:

- Contagem de respostas. Planejadas 33.600; entregues 8.300 (27.5%), das quais 8.244 entram na análise após remover as células egípcias de T1 sem chave. Aciona o próprio teto de 15% do plano.
- Registro público. O plano deveria ser depositado em registro público antes da coleta confirmatória; foi fixado em documento sob controle de versão e nunca depositado. A datação não pode ser verificada de forma independente do histórico do repositório, e não reivindicamos pré-especificação pública.
- Piloto de rubrica. Previsto piloto de 50 prompts com dois avaliadores humanos e $\alpha \geq 0.70$ antes de escalar. Não foi executado. A confiabilidade é evidenciada a posteriori, em $\alpha = 0.527$, abaixo do limiar que o plano fixara.
- Instrumento de pontuação. O plano previa juiz único. O juiz da coleta não foi único: GPT-5-mini pontuou os quinze países pré-especificados e Claude Haiku 4.5 os dez da extensão,

que contêm sete dos dez países do Norte Global, de modo que juiz e tier estavam confundidos nas pontuações julgadas. T1, T2 e T3 passam a ser adjudicadas por código contra registros oficiais onde o valor devolvido é extraível (99.8%, 56.3% e 71.8% das células); o resíduo e toda a T4 são repontuados pela média do painel de três fornecedores; T5 mantém as pontuações dos juizes da coleta. Isso muda as conclusões substantivas sobre as mesmas respostas: o gradiente cai de $\rho = 0.51$ ($p = 0.004$) para $\rho = 0.36$ ($p = 0.076$); a penalidade de idioma nativo cresce de -2.1 pp para -5.0 pp e se torna significativa nos três idiomas; a razão de chances de T1 passa de 0.22 sob os juizes para 0.32 sob o código.

- Chave de T1. A chave do Reino Unido foi corrigida em 21/09/2026 de 10 (meta inglesa para 2040) para $20 \mu\text{g}/\text{m}^3$ (valor-limite em vigor desde 2020); o Egito não tem valor recuperável e fica fora de T1; Bangladesh foi corrigido do diário oficial de 2005 (15) para as Rules de 2022 (35) após revisão externa; as escadas oficiais (Brasil, UE, Reino Unido, EUA, Canadá, Austrália, Colômbia, Bangladesh) são armazenadas ao lado do valor em vigor; as versões do registro carregam um prefixo SHA-256 (`t1_registry` b0e5d9e132aab684, `t2_registry` 703dcd8122f88448, `t3_registry` 902de1bc6af893de, `t4_reference_set` 77bca4679aedc93a). A comparação entre tiers em T1 é reportada com e sem os três países sem padrão (0.32 e 0.39) e sob a chave tolerante à escada (0.14).
- Ordenação dos achados. O plano tratava H1 como hipótese primária. H2 passa a ser relatada como achado principal e o gradiente de H1 como exploratório. Reordenação post hoc, motivada pela pontuação corrigida e não por reexame dos dados em busca de narrativa melhor; ambas as hipóteses eram pré-especificadas e ambas são relatadas.
- Tradução para idioma nativo. Previstos tradutores humanos nativos com retrotradução independente e adjudicação bilíngue. Usou-se tradução por LLM, auditada a posteriori por censo de retrotradução dos 90 prompts nativos. O artefato contra o qual o plano se protegia está medido e ausente: 90/90 preservam o país e a quantidade solicitada.
- Cobertura de modelos. A cobertura não é uniforme; dois modelos estão ausentes de vários países após limitação de taxa e esgotamento de crédito. As médias por país são computadas sobre conjuntos de modelos distintos.

Uma propriedade adicional do corpus de respostas, que não é desvio do plano mas consequência de como a coleta foi repetida, pertence a esta seção porque afeta a reprodutibilidade. De 9.760 chaves únicas (modelo, prompt, replicação), 2.147 (22.0%) têm mais de uma resposta armazenada, produzidas por reexecuções em datas diferentes. A política de desempate adotada é a média dos escores, e a análise de sensibilidade acima mostra que a escolha entre as quatro políticas plausíveis move os efeitos em no máximo 0.06 pp.

S11 Construção de prompts, template de persona e exemplos verbatim

Os prompts foram autorados em inglês para o domínio de política de poluição do ar com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrar no

conjunto de estímulos confirmatório; um subconjunto-piloto atingiu um limiar inter-avaliadores de α de Krippendorff $\geq 0,70$ antes da escala. As versões em idioma nativo (português, espanhol, hindi) foram traduzidas e retrotraduzidas por falantes nativos; qualquer prompt cuja retrotradução produzisse um desvio semântico foi reescrito ou excluído. Toda afirmação factual em uma entrada de gabarito precisava resolver para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido (o Protocolo de Verificação de Citações do projeto aplicado já na geração do gabarito, não apenas na fase de manuscrito).

Manipulação de persona. A persona é um fator intra-prompt com dois níveis que mantêm idêntica a pergunta substantiva. O nível **neutral** apresenta um pedido simples de informação; o nível **public_manager_env** prepena um enquadramento fixo de papel. O contraste é mostrado verbatim para o Brasil, T1:

Neutro. “What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

Gestor ambiental público. “I am the municipal environmental management official of São Paulo, Brazil, and I need to brief decision-makers. What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

O gabarito correspondente no registro é (em tradução): “Os padrões nacionais de PM_{2.5} do Brasil são definidos pela Resolução CONAMA 506/2024 (que substituiu os artigos pertinentes da Resolução 491/2018). A etapa em vigor em 2026 é a Meta Intermediária PI-2; a Meta Final adota a diretriz anual da OMS 2021 de 5 $\mu\text{g}/\text{m}^3$ ” (fonte: Resolução CONAMA 506/2024). Os prompts em idioma nativo aplicam o mesmo template, traduzido; por exemplo, o prompt T1 em hindi para a Índia é a fiel renderização em devanágari do item neutro em inglês, reproduzido verbatim no conjunto de prompts liberado. O conjunto completo de prompts (370 itens confirmatórios: 25 países $\times$ 5 tarefas $\times$ persona, mais os pares de idioma nativo) é liberado como `prompts_confirmatory.jsonl` com o gabarito, a fonte e a rubrica por item.

Referências

Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for Computational Linguistics.