

# Material Suplementar

De qual regulação o modelo sabe? Confiabilidade da informação regulatória recuperada por LLMs para a gestão ambiental pública em 25 países

*Reprodutibilidade.* Toda tabela orientada por dados a seguir (Tabelas S1–S7) é regenerada a partir dos artefatos confirmatórios brutos por `code/analysis/make_supplement_tables.py`; nenhum valor é digitado à mão. A pontuação é decidida por código onde o registro tem valor (T1; a parte resolvível de T2 e T3), pela média de um painel de três fornecedores (Gemini 2.5 Pro, Claude Sonnet 4.6, DeepSeek-V3) no resíduo de T2 e T3 e em toda a T4, e pelo juiz da coleta em T5 (gpt-5-mini-2025-08-07 para os quinze países pré-especificados, claude-haiku-4-5-20251001 para os dez da extensão). O corpus confirmatório analisado é composto por 8.244 células pontuadas (6.573 com prompt em inglês; 1.671 em idioma nativo; 951 células receberam mais de um escore em reexecuções e foram colapsadas pela média; as 56 células egípcias de T1, sem chave no registro, foram removidas) sobre 25 países e 14 deployment-stacks. Todos os insumos, o código de pontuação, o registro de gabarito e as respostas anonimizadas serão liberados na publicação sob CC-BY-4.0 (dados/prompts) e MIT (código).

## Sumário

|                                                                             |           |
|-----------------------------------------------------------------------------|-----------|
| <b>S1 Pré-especificação, desenho e seleção de países</b>                    | <b>2</b>  |
| <b>S2 Roster de deployment-stacks e configuração de serving</b>             | <b>2</b>  |
| <b>S3 Cobertura</b>                                                         | <b>4</b>  |
| <b>S4 Covariáveis dos países</b>                                            | <b>6</b>  |
| <b>S5 Registro de gabarito (T1)</b>                                         | <b>7</b>  |
| <b>S6 Resultado composto e rubrica de pontuação</b>                         | <b>10</b> |
| <b>S7 Confiabilidade do painel de juízes</b>                                | <b>10</b> |
| <b>S8 Métodos estatísticos e saídas completas dos testes confirmatórios</b> | <b>11</b> |
| <b>S9 Análises adicionais de robustez e corroboração</b>                    | <b>11</b> |
| S9.1 Acurácia composta por país . . . . .                                   | 13        |
| S9.2 Lacuna de camada sob partições alternativas de país . . . . .          | 13        |
| S9.3 Modos representativos de falha, literais . . . . .                     | 13        |

|           |                                                                       |           |
|-----------|-----------------------------------------------------------------------|-----------|
| <b>S1</b> | <b>Desvios em relação ao plano de análise pré-especificado</b>        | <b>14</b> |
| <b>S1</b> | <b>Construção de prompts, template de persona e exemplos verbatim</b> | <b>16</b> |

## S1 Pré-especificação, desenho e seleção de países

As hipóteses, os modelos primários, o protocolo de persona, os critérios de exclusão, as correções de comparações múltiplas e o quadro amostral de países foram especificados antes da coleta confirmatória de dados. O desenho pré-especificado cobre 15 países; a amostra foi subsequentemente estendida, *post registration*, para 25 países a fim de ganhar poder para o gradiente de desenvolvimento (H1) e para os testes de mecanismo de corpus (H4) e multiplicar os pares de idioma intra-país (H2). Ao longo do manuscrito e deste suplemento, todo efeito calculado na amostra de 25 países é reportado ao lado de seu valor pré-especificado de 15 países, e nenhuma conclusão pré-especificada é revista com base apenas na extensão (Seção S8).

Os países foram selecionados por amostragem teórica triangulada em três classificações independentes: a distinção Norte/Sul Global, tomada da classificação de economias desenvolvidas/em desenvolvimento da UNCTAD (operacionalizando o enquadramento da colonialidade do conhecimento), a taxonomia de seis classes de recurso linguístico de Joshi et al. (2020) (Joshi et al., 2020) e os grupos de renda do Banco Mundial. Os 15 pré-especificados (Conjunto “P” na Tabela S4) abrangem quatro regiões do mundo, cinco classes de Joshi e quatro grupos de renda; os 10 países de extensão (Conjunto “E”) compreendem sete referências adicionais do Norte Global (Reino Unido, Canadá, Austrália, Coreia do Sul, França, Itália, Portugal) escolhidas para adensar a extremidade de alto desenvolvimento do gradiente, e três países adicionais do Sul Global com par de idioma nativo (Colômbia, Chile, Angola). A UNCTAD declara que as economias desenvolvidas “compreendem, em linhas gerais, a América do Norte e a Europa, Israel, Japão, República da Coreia, Austrália e Nova Zelândia”, sendo as demais em desenvolvimento; os 25 países caem todos no lado que essa regra lhes atribui, Coreia do Sul inclusive. A justificativa completa do desenho está em docs/supplement/s1\_design\_rationale.md.

## S2 Roster de deployment-stacks e configuração de serving

**Unidade de análise.** Avaliamos cada modelo *tal como servido* por meio de uma stack de acesso fixa — a tupla de pesos do modelo, fornecedor, infraestrutura de serving e camada de API/endpoint — em vez de pesos idealizados isoladamente, porque um gestor público interage com a stack servida e qualquer lacuna medida é uma propriedade dessa stack. A Tabela S1 lista as 14 stacks com suas strings exatas de API/tag e os locais de execução.

**Tabela S1.** Roster de deployment-stacks. Cada modelo é avaliado *tal como servido* por meio de uma stack de acesso fixa; a string de API/tag e o local de execução fazem parte do que cada rótulo denota. As contagens de parâmetros são reportadas pelo fornecedor (densas, ou totais para MoE; contagens de fronteira fechada não divulgadas).  $N$  e média referem-se à cobertura confirmatória realizada de prompts em inglês.

| Modelo           | Fornecedor | Camada | String de API/tag                         | Local            | $N$ | Média |
|------------------|------------|--------|-------------------------------------------|------------------|-----|-------|
| DeepSeek-V3      | DeepSeek   | A      | deepseek-chat                             | DeepSeek API     | 500 | 0.625 |
| Command R+       | Cohere     | A      | command-r-plus-08-2024                    | Cohere (trial)   | 500 | 0.509 |
| Llama 3.3 70B    | Meta       | A      | llama-3.3-70b-versatile                   | Groq (free)      | 474 | 0.506 |
| GPT-OSS 120B     | OpenAI     | A      | openai/gpt-oss-120b                       | Groq (free)      | 298 | 0.485 |
| Llama 4 Scout    | Meta       | A      | meta-llama/llama-4-scout-17b-16e-instruct | Groq (free)      | 500 | 0.473 |
| Qwen3 32B        | Alibaba    | B      | qwen/qwen3-32b                            | Groq (free)      | 498 | 0.546 |
| Phi-4 14B        | Microsoft  | B      | phi4                                      | Ollama (local)   | 500 | 0.485 |
| Qwen3 14B        | Alibaba    | B      | qwen3:14b                                 | Ollama (local)   | 500 | 0.474 |
| Llama 3.1 8B     | Meta       | C      | llama-3.1-8b-instant                      | Groq (free)      | 777 | 0.424 |
| Cabra-Mistral 7B | botbot-ai  | C      | cabra-mistral-7b                          | Ollama (local)   | 496 | 0.320 |
| GPT-5-mini       | OpenAI     | D      | gpt-5-mini                                | OpenAI API       | 777 | 0.626 |
| Gemini 2.5 Flash | Google     | D      | gemini-2.5-flash                          | Google AI (free) | 490 | 0.604 |
| Claude 4.5 Haiku | Anthropic  | D      | claude-haiku-4-5                          | Anthropic API    | 490 | 0.597 |
| GPT-5            | OpenAI     | E      | gpt-5                                     | OpenAI API       | 780 | 0.647 |

**Determinismo e tratamento de seed.** Todas as stacks foram consultadas a temperatura 0,3 com a configuração de máximo determinismo que cada provedor documenta, e não com uma superfície idêntica de parâmetros, porque as superfícies diferem. O suporte a seed é heterogêneo: stacks servidas localmente (Ollama) honram uma seed fixa; a OpenAI expõe uma seed advisory; a Messages API da Anthropic não expõe parâmetro de seed; e, para os demais endpoints hospedados, a seed é advisory ou não é exposta. Para cada chamada registramos a seed solicitada e um campo `seed_status` (`sent`, `logged-only` ou `not-supported`) nos metadados de execução liberados, de modo que o determinismo de fato alcançado seja auditável em vez de presumido. Duas replicações estocásticas por célula (prompt, modelo, persona) estimam a variabilidade intra-célula.

**Janela de aquisição.** O comportamento do modelo servido pode derivar à medida que fornecedores atualizam a infraestrutura, de modo que as acurácias reportadas são estimativas point-in-time relativas à janela de coleta. A tag fixada, a string de versão e o timestamp de aquisição são registrados para cada chamada. A coleta confirmatória ocorreu de 2026-04-26 a 2026-06-12 (UTC), abrangendo o piloto, a coleta pré-especificada de 15 países e a extensão post-registration para 25 países. A Tabela S2 dá o timestamp da primeira e da última chamada sem erro por

provedor, junto com a documentação oficial de API consultada; os timestamps completos por chamada são liberados com o conjunto de dados.

**Tabela S2.** Janela de aquisição por fornecedor e documentação oficial de API. As acurácias reportadas são estimativas point-in-time relativas a esta janela; “primeira”/“última” são os timestamps (UTC) da primeira e da última chamada sem erro registrados nos logs de execução. A janela abrange o piloto, a coleta pré-registrada de 15 países e a extensão post-registration.

| Fornecedor (local)           | Primeira<br>(UTC) | Última<br>(UTC) | Documentação de API                                                                                                         |
|------------------------------|-------------------|-----------------|-----------------------------------------------------------------------------------------------------------------------------|
| Anthropic API                | 2026-04-27        | 2026-06-12      | <a href="https://docs.anthropic.com/en/api/messages">https://docs.anthropic.com/en/api/messages</a>                         |
| Cohere (trial)               | 2026-04-26        | 2026-06-11      | <a href="https://docs.cohere.com/reference/chat">https://docs.cohere.com/reference/chat</a>                                 |
| DeepSeek API                 | 2026-04-26        | 2026-06-11      | <a href="https://api-docs.deepseek.com">https://api-docs.deepseek.com</a>                                                   |
| Google AI (free)             | 2026-04-27        | 2026-06-11      | <a href="https://ai.google.dev/api">https://ai.google.dev/api</a>                                                           |
| Groq (free)                  | 2026-04-26        | 2026-06-11      | <a href="https://console.groq.com/docs/api-reference">https://console.groq.com/docs/api-reference</a>                       |
| Ollama (local)               | 2026-04-27        | 2026-06-12      | <a href="https://github.com/ollama/ollama/blob/main/docs/api.md">https://github.com/ollama/ollama/blob/main/docs/api.md</a> |
| OpenAI API                   | 2026-04-27        | 2026-06-12      | <a href="https://platform.openai.com/docs/api-reference/chat">https://platform.openai.com/docs/api-reference/chat</a>       |
| <b>Todos os fornecedores</b> | 2026-04-26        | 2026-06-12      | —                                                                                                                           |

### S3 Cobertura

A cobertura por célula não é uniforme ao longo do roster: endpoints gratuitos e com limite de taxa retornaram menos respostas admissíveis do que as APIs medidas, e um candidato (Gemini 2.5 Flash em lotes nativos iniciais) e um sexto juiz (Command R+) atingiram cotas dos provedores. Reportamos a cobertura realizada em vez de descartar silenciosamente células subcobertas. A Tabela S3 dá a matriz modelo  $\times$  tarefa para prompts em inglês (os totais por coluna igualam as contagens por tarefa do texto principal); a Tabela S4 dá as contagens por país em inglês, nativo e total com camada e conjunto de pré-especificação; a Tabela S5 lista os pares de idioma nativo usados em H2. A matriz de cobertura completa modelo  $\times$  país  $\times$  tarefa, com o motivo de cota ou exclusão de cada déficit, está incluída no release.

**Tabela S3.** Matriz de cobertura: respostas confirmatórias realizadas (prompts em inglês) por modelo × tarefa (T1 padrão, T2 dado local, T3 síntese em saúde, T4 instrumentos, T5 recomendação). Nenhuma célula é descartada silenciosamente; déficits são por cota (Métodos).

| Modelo           | T1   | T2   | T3   | T4   | T5   | Total |
|------------------|------|------|------|------|------|-------|
| GPT-5            | 156  | 156  | 156  | 156  | 156  | 780   |
| GPT-5-mini       | 156  | 156  | 156  | 153  | 156  | 777   |
| Llama 3.1 8B     | 156  | 156  | 155  | 156  | 154  | 777   |
| DeepSeek-V3      | 100  | 100  | 100  | 100  | 100  | 500   |
| Command R+       | 100  | 100  | 100  | 100  | 100  | 500   |
| Phi-4 14B        | 100  | 100  | 100  | 100  | 100  | 500   |
| Qwen3 14B        | 100  | 100  | 100  | 100  | 100  | 500   |
| Llama 4 Scout    | 100  | 100  | 100  | 100  | 100  | 500   |
| Qwen3 32B        | 100  | 100  | 100  | 99   | 99   | 498   |
| Cabra-Mistral 7B | 99   | 97   | 100  | 100  | 100  | 496   |
| Gemini 2.5 Flash | 98   | 98   | 98   | 98   | 98   | 490   |
| Claude Haiku 4.5 | 98   | 98   | 98   | 98   | 98   | 490   |
| Llama 3.3 70B    | 98   | 97   | 96   | 92   | 91   | 474   |
| GPT-OSS 120B     | 68   | 72   | 60   | 42   | 56   | 298   |
| <b>Total</b>     | 1529 | 1530 | 1519 | 1494 | 1508 | 7580  |

**Tabela S4.** Cobertura por país: camada (GN/GS), status de pré-registro (P = pré-registrado, 15 países; E = extensão post-registration), e respostas confirmatórias realizadas (inglês, idioma nativo, total).

| País       | Camada | Conjunto | Inglês | Nativo | Total |
|------------|--------|----------|--------|--------|-------|
| Colombia   | GS     | E        | 260    | 251    | 511   |
| Chile      | GS     | E        | 260    | 241    | 501   |
| Portugal   | GN     | E        | 261    | 240    | 501   |
| Angola     | GS     | E        | 260    | 240    | 500   |
| Argentina  | GS     | P        | 355    | 139    | 494   |
| India      | GS     | P        | 352    | 138    | 490   |
| Mexico     | GS     | P        | 329    | 140    | 469   |
| Peru       | GS     | P        | 316    | 141    | 457   |
| Brazil     | GS     | P        | 260    | 141    | 401   |
| Germany    | GN     | P        | 356    | 0      | 356   |
| Indonesia  | GS     | P        | 356    | 0      | 356   |
| Bangladesh | GS     | P        | 355    | 0      | 355   |
| Egypt      | GS     | P        | 355    | 0      | 355   |
| Kenya      | GS     | P        | 348    | 0      | 348   |
| Japan      | GN     | P        | 347    | 0      | 347   |

| País              | Camada | Conjunto | Inglês | Nativo | Total |
|-------------------|--------|----------|--------|--------|-------|
| Nigeria           | GS     | P        | 317    | 0      | 317   |
| Philippines       | GS     | P        | 316    | 0      | 316   |
| United States     | GN     | P        | 312    | 0      | 312   |
| South Africa      | GS     | P        | 302    | 0      | 302   |
| United Kingdom    | GN     | E        | 265    | 0      | 265   |
| Canada            | GN     | E        | 260    | 0      | 260   |
| Australia         | GN     | E        | 260    | 0      | 260   |
| France            | GN     | E        | 260    | 0      | 260   |
| Italy             | GN     | E        | 260    | 0      | 260   |
| South Korea       | GN     | E        | 258    | 0      | 258   |
| <b>Total (25)</b> |        |          | 7580   | 1671   | 9251  |

**Tabela S5.** Respostas confirmatórias em idioma nativo por idioma e país (contraste intra-país inglês/nativo, H2).

| Idioma nativo (Joshi) | País      | <i>N</i> (nativo) |
|-----------------------|-----------|-------------------|
| Portuguese (4)        | Portugal  | 240               |
|                       | Angola    | 240               |
|                       | Brazil    | 141               |
| Spanish (5)           | Colombia  | 251               |
|                       | Chile     | 241               |
|                       | Peru      | 141               |
|                       | Mexico    | 140               |
|                       | Argentina | 139               |
| Hindi (4)             | India     | 138               |

## S4 Covariáveis dos países

A Tabela S6 reporta as covariáveis de desenvolvimento e de representação no corpus usadas na análise de mecanismo (H4). As medidas de corpus do idioma (classe Joshi; tamanhos mC4/OSCAR reportados no texto principal) indexam quanto texto existe *no* idioma de um país e são o canal candidato para a penalidade de idioma nativo (H2). As medidas de cobertura de país (comprimento em bytes do artigo na Wikipédia em inglês, sitelinks do Wikidata, statements do Wikidata) indexam quão amplamente o corpus enciclopédico é *sobre* um país, independentemente do idioma, e são o canal candidato para a lacuna geográfica (H1/H4). Como a lacuna geográfica é medida *em inglês*, uma lacuna Norte/Sul residual não pode ser um efeito de corpus do idioma, razão pela qual H4 isola a cobertura de país para H1 e o tamanho do corpus do idioma para H2. Todas as entidades do Wikidata são identificadas por um QID resolvível e foram recuperadas dentro da janela de coleta.

**Tabela S6.** Covariáveis dos países. IDH: UNDP HDR 2023–24 (dados de 2022). Joshi: classe de recurso linguístico do idioma oficial dominante (Joshi et al., 2020). Medidas de corpus do Wikimedia/Wikidata (QID da entidade resolvível): comprimento em bytes do artigo em inglês, sitelinks do Wikidata (edições de idioma) e statements do Wikidata.

| País           | Camada | IDH   | Joshi | Bytes wiki-EN | Sitelinks | Stmts WD |
|----------------|--------|-------|-------|---------------|-----------|----------|
| Germany        | GN     | 0.950 | 5     | 207,810       | 403       | 1402     |
| Australia      | GN     | 0.946 | 5     | 233,095       | 395       | 1674     |
| United Kingdom | GN     | 0.940 | 5     | 368,888       | 391       | 1085     |
| Canada         | GN     | 0.935 | 5     | 281,016       | 393       | 1346     |
| South Korea    | GN     | 0.929 | 4     | 275,291       | 350       | 746      |
| United States  | GN     | 0.927 | 5     | 383,914       | 424       | 1710     |
| Japan          | GN     | 0.920 | 5     | 205,844       | 414       | 995      |
| France         | GN     | 0.910 | 5     | 279,498       | 413       | 1196     |
| Italy          | GN     | 0.906 | 4     | 305,234       | 405       | 1039     |
| Portugal       | GN     | 0.874 | 4     | 324,038       | 369       | 751      |
| Chile          | GS     | 0.860 | 5     | 232,108       | 379       | 689      |
| Argentina      | GS     | 0.849 | 5     | 267,662       | 369       | 881      |
| Mexico         | GS     | 0.781 | 5     | 263,757       | 398       | 1286     |
| Peru           | GS     | 0.762 | 5     | 239,544       | 332       | 867      |
| Brazil         | GS     | 0.760 | 4     | 301,844       | 384       | 1151     |
| Colombia       | GS     | 0.758 | 5     | 303,401       | 363       | 774      |
| Egypt          | GS     | 0.728 | 5     | 284,547       | 387       | 757      |
| South Africa   | GS     | 0.717 | 5     | 270,861       | 365       | 750      |
| Indonesia      | GS     | 0.713 | 3     | 226,349       | 362       | 1005     |
| Philippines    | GS     | 0.710 | 5     | 493,981       | 331       | 963      |
| Bangladesh     | GS     | 0.670 | 3     | 275,786       | 343       | 814      |
| India          | GS     | 0.644 | 5     | 310,681       | 399       | 1679     |
| Kenya          | GS     | 0.601 | 5     | 216,189       | 334       | 699      |
| Angola         | GS     | 0.591 | 4     | 180,098       | 322       | 676      |
| Nigeria        | GS     | 0.548 | 5     | 266,041       | 349       | 1194     |

## S5 Registro de gabarito (T1)

A validade do gradiente geográfico (H1) requer que o gabarito seja igualmente disponível e igualmente verificável entre os países. Para T1 (o padrão anual vinculante de  $PM_{2.5}$ ) ancoramos cada país a uma fonte oficial primária por auditoria documental: o texto-fonte foi recuperado, o valor foi lido verbatim, e a entrada registra o valor, o status, a fonte-de-registro, uma URL resolvível e o método de recuperação (Tabela S7). Três países *não têm* padrão nacional de  $PM_{2.5}$ , confirmado pelo texto oficial (a NESREA da Nigéria regula apenas  $PM_{10}$ ; a Argentina não tem valor federal vinculante; a Angola não tem legislação nacional de qualidade do ar); nesses casos, um modelo fiel deve recusar-se a indicar um limiar inexistente em vez de fabricá-lo. Essa proveniência é mais reproduzível do que a asserção de especialistas: qualquer leitor pode

reverificar cada valor a partir da fonte oficial citada. Nenhuma referência no registro é não-verificada, e nenhum valor foi transposto de fontes secundárias sem confirmação contra o texto primário.

**Tabela S7.** Registro de gabaritos de respostas corretas ancorado em fontes oficiais primárias. VERIFIED\_NO\_SOURCE = texto oficial; VERIFIED\_NO\_SOURCE + PARTIALLY\_VERIFIED = fontes completas e trechos verbatim extraídos de fontes secundárias.

| País       | Valor                                                                                      |
|------------|--------------------------------------------------------------------------------------------|
| Angola     | NO national air-quality legislation / standard                                             |
| Argentina  | NO single binding federal PM2.5 standard (Ley 20.284/1973 framework; PM2.5 limits set      |
| Australia  | 8 ug/m3 (annual; 7 target 2025)                                                            |
| Bangladesh | 15 ug/m3 (annual) per Gazette S.R.O. 220-Law/2005; a 2022 revision exists but the revision |
| Brazil     | 17 ug/m3 (annual, PI-2)                                                                    |
| Canada     | 8.8 ug/m3 (annual, CAAQS 2020)                                                             |
| Chile      | 20 ug/m3 (annual)                                                                          |
| Colombia   | 25 ug/m3 (annual, in force since 2018; 15 from 2030; 24h=37)                               |
| Egypt      | PM2.5 limit set under Law 4/1994 (amended 9/2009, 105/2015) Executive Regulations (o       |
| France     | 25 ug/m3 (annual, in force; 10 from 2030)                                                  |
| Germany    | 25 ug/m3 (annual, in force 2026; 10 from 2030)                                             |
| India      | 40 ug/m3 (annual)                                                                          |
| Indonesia  | 15 ug/m3 (annual)                                                                          |

| País           | Valor                                                      |
|----------------|------------------------------------------------------------|
| Italy          | 25 ug/m3 (annual, in force; 10 from 2030)                  |
| Japan          | 15 ug/m3 (annual)                                          |
| Kenya          | 35 ug/m3 (annual; 24h 75)                                  |
| Mexico         | 10 ug/m3 (annual)                                          |
| Nigeria        | NO national PM2.5 standard (PM10 annual=60 ug/m3, 24h=150) |
| Peru           | 25 ug/m3 (annual)                                          |
| Philippines    | 25 ug/m3 (annual, 1-year guideline)                        |
| Portugal       | 25 ug/m3 (annual, in force; 10 from 2030)                  |
| South Africa   | 20 ug/m3 (annual)                                          |
| South Korea    | 15 ug/m3 (annual)                                          |
| United Kingdom | 10 ug/m3 (annual, target by 2040)                          |
| United States  | 9.0 ug/m3 (annual, primary NAAQS, 2024)                    |

## S6 Resultado composto e rubrica de pontuação

Cada resposta foi pontuada pelo juiz primário contra a entrada do registro de gabarito (T1, T2, T4) ou a rubrica validada (T3, T5), produzindo cinco subcomponentes, cada um normalizado a  $[0, 1]$ :

1. Acurácia factual contra o valor do registro (binária para T1; crédito parcial para T2–T4).
2. Completude contextual pontuada contra uma rubrica pré-validada (T3, T4).
3. Qualidade de citação, verificada por checagem de DOI/fonte oficial.
4. Calibração, o alinhamento entre a confiança declarada e a correção.
5. Ausência de alucinação, codificada de forma binária (0 alucinado, 1 fiel).

O composto primário usa pesos iguais. Duas ponderações de sensibilidade pré-especificadas são reportadas — um conjunto derivado por PCA estimado no piloto estendido do Brasil, e um conjunto especificado pelos autores (factual 0,30, contextual 0,25, citação 0,15, alucinação 0,15, aplicada 0,15) — e uma conclusão é tratada como robusta apenas se valer sob as três. O composto é calculado por célula (país, modelo, persona) para suportar o teste de diferença-em-diferenças de H6. Cada registro pontuado guarda também a justificativa textual do juiz; por exemplo, o juiz `gpt-5-mini` pontuou uma resposta do Llama 4 Scout sobre o padrão T1 do Brasil em 0,15 com a justificativa de que ela “gives wrong regulation (491/2018 vs correct 506/2024) and wrong current value. . . included a specific but incorrect citation and fabricated timing”, ilustrando como os subcomponentes de acurácia factual e de alucinação discriminam falha substantiva.

## S7 Confiabilidade do painel de juízes

A confiabilidade é computada sobre cada item que o painel pontuou — os mesmos itens de que os efeitos relatados são computados —, e não sobre um subconjunto estratificado de calibração. Todas as 3.190 respostas que exigiram juiz foram pontuadas independentemente pelos três membros do painel, escolhidos por diversidade de fornecedor para que a correlação intrafornecedor não infle a concordância aparente. O painel substitui o desenho de juiz único do protocolo original, no qual o juiz da coleta (`gpt-5-mini` para os quinze países pré-especificados, `claude-haiku-4-5` para os dez da extensão) estava ele próprio entre os modelos avaliados e, como a extensão contém sete dos dez países do Norte Global, estava confundido com o tier.

A concordância par a par é mais forte entre Claude e DeepSeek e menor para o Gemini, sistematicamente mais brando. Como todo efeito relatado é um contraste entre grupos (lacuna de camada, penalidade de idioma, piso de tarefa), o deslocamento de brandura de um juiz se cancela e não ameaça esses contrastes — que é precisamente a razão de a análise usar a *média* do painel em vez de qualquer juiz isolado, cuja confiabilidade sozinha seria  $ICC(2, 1) = 0.56$ .

**Tabela S8.** Confiabilidade entre juízes sobre os 3.190 itens pontuados pelo painel. A quantidade operativa é a confiabilidade da *média* do painel, ICC(2, 3); pela relação de Spearman–Brown ela é alta mesmo quando juízes isolados concordam apenas moderadamente. Fonte: `panel_reliability_full.json`.

| Quantidade                                     | Valor                           |
|------------------------------------------------|---------------------------------|
| Juízes ( $k$ )                                 | 3 (Google, Anthropic, DeepSeek) |
| Itens pontuados por todos os juízes            | 3.190                           |
| $\alpha$ de Krippendorff (intervalar)          | 0.527                           |
| ICC(2, 1) de juiz único                        | 0.558                           |
| ICC(2, 3) da média do painel                   | 0.791                           |
| Pearson par a par: Claude Sonnet   DeepSeek-V3 | 0.801                           |
| Gemini 2.5 Pro   Claude Sonnet                 | 0.663                           |
| Gemini 2.5 Pro   DeepSeek-V3                   | 0.654                           |
| Composto médio por juiz: Gemini 2.5 Pro        | 0.617                           |
| Claude Sonnet 4.6                              | 0.451                           |
| DeepSeek-V3                                    | 0.379                           |

## S8 Métodos estatísticos e saídas completas dos testes confirmatórios

Os três testes confirmatórios primários formam uma única família (F1) corrigida em conjunto pelo procedimento step-down de Bonferroni–Holm ( $\alpha = 0,05$ ). Os testes confirmatórios secundários são reportados sem ajuste dentro da família; os testes declarados exploratórios usam FDR de Benjamini–Hochberg a  $q = 0,10$ . As correlações de postos usam Spearman  $\rho$ ; a robustez de tendência monotônica usa o teste de Mann–Kendall; o efeito de persona usa um teste de permutação em nível de país (5,000 permutações). Todas as saídas a seguir são regeneradas por `code/analysis/formal_tests.py`, `robust_tests.py` e `h4_corpus_mechanism.py`.

**Tabela S9.** Família primária (Bonferroni–Holm): valores pré-especificados de 15 países ao lado da extensão post-registration de 25 países. H1-por-IDH é o único teste primário que rejeita sua hipótese nula a  $n = 25$ ; permanece abaixo do limiar de tamanho de efeito pré-especificado  $\rho \geq 0,55$  em ambas as amostras.

| Teste                                        | 15 países (pré-especificado)            | 25 países (extensão)                          |
|----------------------------------------------|-----------------------------------------|-----------------------------------------------|
| H1 Spearman $\rho(\text{acc}, \text{IDH})$   | +0.079 ( $p = 0.78$ ), ns               | +0.361 ( $p = 0.076$ ), ns                    |
| H1 Mann–Kendall (por IDH)                    | $S = 3$ , $Z = +0.10$ , $p = 0.92$ , ns | $p = 0.065$ , ns                              |
| H1 Spearman $\rho(\text{acc}, \text{Joshi})$ | +0.131 ( $p = 0.64$ ), ns               | −0.061, ns (desenvolvimento, não linguística) |
| H1 vs limiar $\rho \geq 0.55$                | não atingido                            | não atingido                                  |
| H4 $\rho$ parcial (acc, cobertura   IDH)     | +0.381 ( $p = 0.18$ ), ns               | +0.190 ( $p = 0.37$ ), ns                     |
| H6 DiD persona (SG–NG)                       | não recomputada em $n = 15$             | +0.47 pp, perm $p = 0.293$ , ns               |
| Lacuna de camada (NG–SG), composto           | +6.0 pp, $p = 0.13$ (3 NG)              | +5.0 pp, $p = 0.019$                          |

## S9 Análises adicionais de robustez e corroboração

*Sensibilidade da ponderação do composto.* Recomputamos cada efeito principal sob a ponderação dos autores, sob pesos iguais e sob ponderação derivada por ACP. Os dois efeitos sustentados se mantêm nas três, e o gradiente fica abaixo do 0.55 pré-especificado nas três. Sob a ponderação primária a lacuna de camada é de +5.05 pp e o gradiente  $\rho = +0.361$ ; sob pesos iguais, +4.22 pp

**Tabela S10.** Mecanismo de corpus H4, multi-medida (25 países). A amplitude de cobertura de país (sitelinks do Wikidata) prediz a acurácia no nível de ordem zero e sobrevive à correção de multiplicidade entre os três proxies de cobertura, mas atenua-se até a não-significância após ajuste para desenvolvimento (IDH); reportamos, portanto, como sugestivo/exploratório, não como mecanismo estabelecido. O proxy pré-especificado de edição de idioma é nulo.

| Medida                        | Família | $\rho(\text{acc, log medida})$ | parcial   IDH         |
|-------------------------------|---------|--------------------------------|-----------------------|
| Bytes Wikipédia-inglês        | país    | +0.153 ( $p = 0.47$ )          | +0.132 ( $p = 0.54$ ) |
| Sitelinks Wikidata            | país    | +0.399 ( $p = 0.048$ )         | +0.194 ( $p = 0.36$ ) |
| Statements Wikidata           | país    | +0.296 ( $p = 0.15$ )          | +0.180 ( $p = 0.40$ ) |
| Contagem de edições Wikipédia | idioma  | +0.142, ns                     | ns                    |

**Tabela S11.** Achados secundários robustos (25 países), com verificações de leave-one-country-out (LOCO) e de restrição de amplitude.

| Achado                                                            | Estatística                                                                                                                                                                                                                                                                                                           |
|-------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Lacuna de camada (NG–SG)                                          | +5.0 pp, IC 95% [+1.6, +8.4]; permutação $p = 0.019$                                                                                                                                                                                                                                                                  |
| Lacuna de camada, faixa LOCO                                      | [+4.4, +6.0] pp, estável                                                                                                                                                                                                                                                                                              |
| Lacuna de camada, só onda de extensão                             | +5.9 pp [+2.4, +9.6] (7 NG vs 3 SG), perm $p = 0.064$                                                                                                                                                                                                                                                                 |
| Lacuna de camada, só desfechos de código (T1; T2, T3 resolvidas)  | NG 0.61 vs SG 0.46, +14.7 pp [+5.6, +23.9], perm $p = 0.012$ ; RC agregada 0.53 [0.48, 0.58] (T1 0.32, T2 0.51, T3 0.65)                                                                                                                                                                                              |
| H1 <i>leave-one-country-out</i>                                   | $\rho \in [+0.30, +0.48]$ : nunca atinge o limiar pré-especificado de 0.55                                                                                                                                                                                                                                            |
| Piso de tarefa (T1+T2 vs T3–T5)                                   | 0.434 vs 0.612, $\delta$ de Cliff = $-0.41$                                                                                                                                                                                                                                                                           |
| H3 Cabra-Mistral vs restante                                      | 0.351 vs 0.557, $\delta$ de Cliff = $-0.48$                                                                                                                                                                                                                                                                           |
| H3 pré-especificada (Cabra vs Llama 3.1 8B, prompts em português) | Brasil 0.258 vs 0.313, $\delta = -0.26$ ( $n = 20$ cada); BRA+PRT+AGO 0.304 vs 0.362, $\delta = -0.17$ ( $n = 60$ cada)                                                                                                                                                                                               |
| H2 nativo vs inglês (todos)                                       | $\Delta = -5.0$ pp, Wilcoxon $p = 5 \times 10^{-16}$ ( $n = 839$ ); modelo misto com intercepto aleatório por país $-5.0$ pp ( $p = 6 \times 10^{-7}$ ), por modelo $-4.8$ pp ( $p = 3 \times 10^{-9}$ ); país como unidade 8/9 negativos, $t = -4.6$ , $p = 0.002$ ; modelo como unidade 12/14, Wilcoxon $p = 0.058$ |
| Espanhol / Português / Hindi por instrumento de pontuação         | $-4.5 / -4.2 / -11.4$ pp, todos significativos                                                                                                                                                                                                                                                                        |
| só veredito de código, por idioma                                 | código $-3.8$ ( $n = 333$ ), painel $-8.6$ ( $n = 314$ ), juiz da coleta $-1.1$ pp ns ( $n = 192$ , T5)                                                                                                                                                                                                               |
| H5 aberto vs fechado-acessível                                    | português $-9.1$ ( $n = 132$ , $p = 0.019$ ), espanhol $-2.1$ ( $n = 165$ , ns), todos $-5.0$ pp ( $n = 318$ , $p = 0.048$ )                                                                                                                                                                                          |
|                                                                   | vantagem fechada de +12.8 pp (descritivo)                                                                                                                                                                                                                                                                             |

e  $\rho = +0.355$ ; sob ACP, +4.72 pp e  $\rho = +0.380$ . Um modelo misto gaussiano com interceptos aleatórios cruzados dá  $\beta = -0.063$  ( $p = 0.086$ ) para o Sul Global; a reestimação bayesiana dá média posterior  $-0.049$ , HDI de 94%  $[-0.088, -0.006]$ ,  $P(\beta < 0) = 0.987$ ; o E-value é 1.71 no ponto e 1.31 no limite do intervalo mais próximo do nulo.

*Poder sobre o nulo do gradiente.* Simulando amostras de 25 países em correlações conhecidas, o desenho tem 77% de poder para detectar  $\rho = 0.55$  e efeito mínimo detectável de  $\rho = 0.56$  a 80% de poder. O nulo exclui, portanto, um gradiente da magnitude pré-especificada, mas não um gradiente fraco (poder de 48% em  $\rho = 0.40$ ).

*Dependência da taxonomia de camada.* A lacuna é significativa sob a partição desenvolvidas/em desenvolvimento da UNCTAD (permutação  $p = 0.019$ ) e não sob nenhuma partição dos mesmos 25 países traçada apenas por IDH (mediana +2.14 pp,  $p = 0.329$ ; IDH  $< 0.800$  +2.78 pp,  $p = 0.206$ ; IDH  $< 0.700$  +1.94 pp,  $p = 0.482$ ). Relatamos isso em vez de descansar sobre a partição favorável.

*Duplicatas, em dois níveis.* No nível da resposta, 21,9% das chaves (modelo, prompt, réplica)

têm mais de uma resposta armazenada; a que entra na análise é a primeira na ordem dos arquivos de execução, que é a que o juiz da coleta pontuou, e os vereditos de código de T1, T2 e T3 são computados sobre essa mesma resposta. Pontuar todas as respostas e tirar a média dos vereditos muda o veredito de código em 3,1% das células e a média em 0,0001. No nível do escore, 951 células (11.5%) têm mais de um escore de juiz, provenientes de reexecuções em datas diferentes, colapsadas pela *média*: determinística, independente da ordem de leitura, e usa toda a informação coletada. As quatro políticas plausíveis (primeira, última, média, aleatória com semente) movem os efeitos em no máximo 0.06 pp.

### S9.1 Acurácia composta por país

**Tabela S12.** Acurácia composta por país, amostra de 25 países (tier: GN = Global North, GS = Global South). Ordered by mean.

| País           | Camada | Média | País      | Camada | Média |
|----------------|--------|-------|-----------|--------|-------|
| Índia          | SG     | 0.651 | França    | NG     | 0.534 |
| Austrália      | NG     | 0.617 | Peru      | SG     | 0.529 |
| Japão          | NG     | 0.612 | Colômbia  | SG     | 0.526 |
| Coreia do Sul  | NG     | 0.598 | Chile     | SG     | 0.520 |
| Indonésia      | SG     | 0.592 | Egito     | SG     | 0.509 |
| Estados Unidos | NG     | 0.587 | Canadá    | NG     | 0.509 |
| Itália         | NG     | 0.586 | Quênia    | SG     | 0.505 |
| África do Sul  | SG     | 0.575 | México    | SG     | 0.501 |
| Portugal       | NG     | 0.562 | Angola    | SG     | 0.475 |
| Alemanha       | NG     | 0.557 | Nigéria   | SG     | 0.461 |
| Reino Unido    | NG     | 0.554 | Brasil    | SG     | 0.458 |
| Filipinas      | SG     | 0.542 | Argentina | SG     | 0.433 |
| Bangladesh     | SG     | 0.542 |           |        |       |

### S9.2 Lacuna de camada sob partições alternativas de país

A divisão Norte/Sul Global segue a classificação da UNCTAD. Uma lacuna visível apenas sob uma taxonomia seria artefato dela, de modo que a reestimamos sob três partições baseadas em desenvolvimento dos mesmos 25 países (Tabela S13). A lacuna é significativa sob a UNCTAD e não significativa sob toda partição traçada pelo IDH, o que é coerente com o gradiente de IDH nulo relatado no texto principal.

**Tabela S13.** Lacuna de camada sob partições alternativas dos mesmos 25 países. Teste de permutação com o país como unidade, 10.000 reetiquetagens.

| Partição                                                  | Lacuna (pp) | NG/SG | <i>p</i> |
|-----------------------------------------------------------|-------------|-------|----------|
| UNCTAD desenvolvidas/em desenvolvimento (usada no artigo) | +5.06       | 10/15 | 0.020    |
| IDH abaixo da mediana da amostra (0.781)                  | +2.39       | 13/12 | 0.269    |
| IDH < 0.800 (corte “muito alto” do PNUD)                  | +2.92       | 12/13 | 0.182    |
| IDH < 0.700                                               | +1.53       | 20/5  | 0.575    |

### S9.3 Modos representativos de falha, literais

*Modelo misto e reestimação bayesiana.* Um modelo linear misto gaussiano (MixedLM do **statsmodels**, REML) com interceptos aleatórios cruzados de país e modelo dá um efeito do Sul Global de

**Tabela S14.** Quadro 1 — Modos representativos de falha (literais, levemente truncados).

| Modo de falha                         | Exemplo                                                                                                                                                                                                                                                                                                                                                 |
|---------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Fabricar um padrão inexistente        | Angola has no national norm. Gemini 2.5 Flash asserted an annual standard of “25 $\mu\text{g}/\text{m}^3$ ” em uma replicação e “15 $\mu\text{g}/\text{m}^3$ ” em outra. O GPT-5 afirmou “15 $\mu\text{g}/\text{m}^3$ ” para a Nigéria, que regula apenas $\text{PM}_{10}$ (NESREA). Uma resposta fiel se recusaria a declarar um valor que não existe. |
| Errar o valor vinculante (piso de T1) | O padrão anual oficial do Brasil é 17 $\mu\text{g}/\text{m}^3$ (CONAMA 506/2024). A resposta modal foi 15 $\mu\text{g}/\text{m}^3$ (42 respostas), com 10, 20 e 25 também comuns; o valor oficial quase nunca foi devolvido.                                                                                                                            |
| Degradação em idioma nativo (H2)      | O padrão anual da Índia é 40 $\mu\text{g}/\text{m}^3$ . GPT-OSS 120B devolveu o valor correto em inglês e resposta <i>vazia</i> à mesma pergunta em hindi.                                                                                                                                                                                              |

$\beta = -0.063$  (EP = 0.036,  $p = 0.086$ ), marginal em vez de convencionalmente significativo porque cobra do termo de erro a grande heterogeneidade entre países. Uma reestimação hierárquica bayesiana com prioris fracamente informativas (`pymc`; interceptos cruzados de país e modelo, `random_seed=42`) concorda em magnitude e é decisiva quanto ao sinal: média posterior  $-0.049$ , HDI de 94%  $[-0.088, -0.006]$ ,  $P(\beta < 0) = 0.987$  ( $\hat{R} = 1.001$ ).

*E-values.* A lacuna de camada carrega um E-value de 1.71 na estimativa pontual e 1.31 no limite do intervalo mais próximo do nulo (aproximação de VanderWeele & Ding 2017 a partir do efeito padronizado); o segundo é o número operativo, e é um limiar baixo. Nenhum E-value é relatado para o gradiente de desenvolvimento: seu intervalo já inclui o nulo, de modo que o E-value nesse limite é 1.00 e nenhum confundidor é necessário.

*Mediação exploratória (H4).* Um modelo de caminhos padronizado no nível do país (`semopy`,  $n = 25$ ): IDH  $\rightarrow$  sitelinks  $a = +0.67$ ; sitelinks  $\rightarrow$  acurácia  $b = +0.27$ ; direto  $c' = +0.31$ ; indireto  $ab = +0.18$  com IC bootstrap de 95%  $[-0.27, +0.59]$  (inclui o zero). A cobertura do país é, portanto, um mediador sugestivo mas não estabelecido, coerente com o enquadramento do texto principal.

*Checação da manipulação de persona.* Em 4.349 respostas na condição de persona, 50.2% reconhecem explicitamente o enquadramento de papel de gestor público, de modo que o nulo de persona (H6) não é artefato de o enquadramento ser universalmente ignorado.

## S10 Desvios em relação ao plano de análise pré-especificado

O plano de análise exigia que os afastamentos fossem registrados e classificados, e fixava um teto para eles: o estatuto confirmatório só se mantém se os desvios afetarem no máximo 15% das células planejadas. O escopo entregue é de 27.5% da contagem planejada de respostas, de modo que o teto é excedido por larga margem, e o estudo é relatado como exploratório do começo ao fim.

Os desvios principais, com o efeito de cada um sobre a interpretação:

- Contagem de respostas. Planejadas 33.600; entregues 8.300 (27.5%), das quais 8.244 entram na análise após remover as células egípcias de T1 sem chave. Aciona o próprio teto de 15% do plano.

- Registro público. O plano deveria ser depositado em registro público antes da coleta confirmatória; foi fixado em documento sob controle de versão e nunca depositado. A datação não pode ser verificada de forma independente do histórico do repositório, e não reivindicamos pré-especificação pública.
- Piloto de rubrica. Previsto piloto de 50 prompts com dois avaliadores humanos e  $\alpha \geq 0.70$  antes de escalar. Não foi executado. A confiabilidade é evidenciada a posteriori, em  $\alpha = 0.527$ , abaixo do limiar que o plano fixara.
- Instrumento de pontuação. O plano previa juiz único. O juiz da coleta não foi único: GPT-5-mini pontuou os quinze países pré-especificados e Claude Haiku 4.5 os dez da extensão, que contêm sete dos dez países do Norte Global, de modo que juiz e tier estavam confundidos nas pontuações julgadas. T1, T2 e T3 passam a ser adjudicadas por código contra registros oficiais onde o valor devolvido é extraível (99.8%, 56.3% e 71.8% das células); o resíduo e toda a T4 são repontuados pela média do painel de três fornecedores; T5 mantém as pontuações dos juízes da coleta. Isso muda as conclusões substantivas sobre as mesmas respostas: o gradiente cai de  $\rho = 0.51$  ( $p = 0.004$ ) para  $\rho = 0.36$  ( $p = 0.076$ ); a penalidade de idioma nativo cresce de  $-2.1$  pp para  $-5.0$  pp e se torna significativa nos três idiomas; a razão de chances de T1 passa de 0.22 sob os juízes para 0.32 sob o código.
- Chave de T1. A chave do Reino Unido foi corrigida em 21/09/2026 de 10 (meta inglesa para 2040) para  $20 \mu\text{g}/\text{m}^3$  (valor-limite em vigor desde 2020); o Egito não tem valor recuperável e fica fora de T1; Bangladesh foi corrigido do diário oficial de 2005 (15) para as Rules de 2022 (35) após revisão externa; as escadas oficiais (Brasil, UE, Reino Unido, EUA, Canadá, Austrália, Colômbia, Bangladesh) são armazenadas ao lado do valor em vigor; as versões do registro carregam um prefixo SHA-256 (`t1_registry` b0e5d9e132aab684, `t2_registry` 703dcd8122f88448, `t3_registry` 902de1bc6af893de, `t4_reference_set` 77bca4679aedc93a). A comparação entre tiers em T1 é reportada com e sem os três países sem padrão (0.32 e 0.39) e sob a chave tolerante à escada (0.14).
- Ordenação dos achados. O plano tratava H1 como hipótese primária. H2 passa a ser relatada como achado principal e o gradiente de H1 como exploratório. Reordenação post hoc, motivada pela pontuação corrigida e não por reexame dos dados em busca de narrativa melhor; ambas as hipóteses eram pré-especificadas e ambas são relatadas.
- Tradução para idioma nativo. Previstos tradutores humanos nativos com retrotradução independente e adjudicação bilíngue. Usou-se tradução por LLM, auditada a posteriori por censo de retrotradução dos 90 prompts nativos. O artefato contra o qual o plano se protegia está medido e ausente: 90/90 preservam o país e a quantidade solicitada.
- Cobertura de modelos. A cobertura não é uniforme; dois modelos estão ausentes de vários países após limitação de taxa e esgotamento de crédito. As médias por país são computadas sobre conjuntos de modelos distintos.

Uma propriedade adicional do corpus de respostas, que não é desvio do plano mas consequência de como a coleta foi repetida, pertence a esta seção porque afeta a reprodutibilidade.

De 9.760 chaves únicas (modelo, prompt, replicação), 2.147 (22.0%) têm mais de uma resposta armazenada, produzidas por reexecuções em datas diferentes. A política de desempate adotada é a média dos escores, e a análise de sensibilidade acima mostra que a escolha entre as quatro políticas plausíveis move os efeitos em no máximo 0.06 pp.

## S11 Construção de prompts, template de persona e exemplos verbatim

Os prompts foram autorados em inglês para o domínio de política de poluição do ar com supervisão de domínio (PPGSAU/UTFPR) e validados contra o registro de gabarito antes de entrar no conjunto de estímulos confirmatório; um subconjunto-piloto atingiu um limiar inter-avaliadores de  $\alpha$  de Krippendorff  $\geq 0,70$  antes da escala. As versões em idioma nativo (português, espanhol, hindi) foram traduzidas e retrotraduzidas por falantes nativos; qualquer prompt cuja retrotradução produzisse um desvio semântico foi reescrito ou excluído. Toda afirmação factual em uma entrada de gabarito precisava resolver para uma URL de fonte oficial ou um DOI revisado por pares antes de o prompt correspondente ser admitido (o Protocolo de Verificação de Citações do projeto aplicado já na geração do gabarito, não apenas na fase de manuscrito).

**Manipulação de persona.** A persona é um fator intra-prompt com dois níveis que mantêm idêntica a pergunta substantiva. O nível *neutral* apresenta um pedido simples de informação; o nível *public\_manager\_env* prepende um enquadramento fixo de papel. O contraste é mostrado verbatim para o Brasil, T1:

*Neutro.* “What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

*Gestor ambiental público.* “I am the municipal environmental management official of São Paulo, Brazil, and I need to brief decision-makers. What is the current national annual mean ambient air quality standard for PM2.5 in Brazil? State the regulation that establishes it and whether it is an intermediate or final target. Limit to 1–3 sentences.”

O gabarito correspondente no registro é (em tradução): “Os padrões nacionais de PM<sub>2.5</sub> do Brasil são definidos pela Resolução CONAMA 506/2024 (que substituiu os artigos pertinentes da Resolução 491/2018). A etapa em vigor em 2026 é a Meta Intermediária PI-2; a Meta Final adota a diretriz anual da OMS 2021 de 5  $\mu\text{g}/\text{m}^3$ ” (fonte: Resolução CONAMA 506/2024). Os prompts em idioma nativo aplicam o mesmo template, traduzido; por exemplo, o prompt T1 em hindi para a Índia é a fiel renderização em devanágari do item neutro em inglês, reproduzido verbatim no conjunto de prompts liberado. O conjunto completo de prompts (370 itens confirmatórios: 25 países  $\times$  5 tarefas  $\times$  persona, mais os pares de idioma nativo) é liberado como `prompts_confirmatory.jsonl` com o gabarito, a fonte e a rubrica por item.

## Referências

Joshi, P., Santy, S., Budhiraja, A., Bali, K., and Choudhury, M. (2020). The state and fate of linguistic diversity and inclusion in the NLP world. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 6282–6293. Association for Computational Linguistics.